

# Linear model for predictions

川田恵介

## Table of contents

|      |   |    |
|------|---|----|
| 1    | 予測問題  | 2  |
| 1.1  | 問題の定式化 . . . . .                            | 2  |
| 1.2  | 予測精度の推定 . . . . .                           | 2  |
| 1.3  | 予測精度の指標 . . . . .                           | 2  |
| 1.4  | 理想の予測モデル . . . . .                          | 3  |
| 1.5  | 一致推定結果 . . . . .                            | 3  |
| 1.6  | 予測誤差の分解 . . . . .                           | 3  |
| 1.7  | 例 . . . . .                                 | 3  |
| 1.8  | 例 . . . . .                                 | 4  |
| 1.9  | 練習問題 ( <a href="#">リンク</a> ) . . . . .      | 4  |
| 1.10 | 例 . . . . .                                 | 4  |
| 1.11 | まとめ . . . . .                               | 4  |
| 1.12 | まとめ . . . . .                               | 5  |
| 1.13 | 補論: 過剰適合 . . . . .                          | 5  |
| 1.14 | 数値例 . . . . .                               | 5  |
| 2    | Penalized Regression                        | 7  |
| 2.1  | LASSO Algorithm . . . . .                   | 7  |
| 2.2  | Constrained optimization としての書き換え . . . . . | 7  |
| 2.3  | $\lambda$ の役割: OLS . . . . .                | 8  |
| 2.4  | 練習問題 ( <a href="#">リンク</a> ) . . . . .      | 8  |
| 2.5  | $\lambda$ の役割: 平均 . . . . .                 | 8  |
| 2.6  | 数値例 . . . . .                               | 8  |
| 2.7  | $\lambda$ の役割 . . . . .                     | 11 |
| 3    | 交差推定  | 11 |
| 3.1  | 交差推定のアイデア . . . . .                         | 11 |
| 3.2  | シンプルなサンプル分割 . . . . .                       | 12 |
| 3.3  | 交差検証 . . . . .                              | 12 |

|      |                       |    |
|------|-----------------------|----|
| 3.4  | 数値例: 3 分割 . . . . .   | 12 |
| 3.5  | 数値例 . . . . .         | 13 |
| 3.6  | 数値例: Step 1 . . . . . | 14 |
| 3.7  | 数値例: Step 2 . . . . . | 15 |
| 3.8  | 数値例: Step 3 . . . . . | 17 |
| 3.9  | 比較 . . . . .          | 18 |
| 3.10 | 実践: 単位問題 . . . . .    | 18 |
| 3.11 | 実践: 一致推定量 . . . . .   | 19 |
| 3.12 | 実践: 変数の除外 . . . . .   | 19 |
| 3.13 | まとめ . . . . .         | 19 |
|      | Reference . . . . .   | 19 |

## 1 予測問題

### 1.1 問題の定式化

- 課題: データと同じ母集団からランダムサンプリングされる事例について、 $X$  から  $Y$  を予測するモデル  $g_Y(X)$  をデータから構築する

- 予測精度は二乗誤差の**母平均** (平均二乗誤差; MSE) で測定

$$E[(Y - g_Y(X))^2]$$

- 母集団外へ拡張可能? (Rothenhäusler and Bühlmann 2023)

### 1.2 予測精度の推定

- あるモデルの予測精度は母集団上で定義された Estimand

- データから推定する必要がある

- 代表的なアプローチは、**データ分割**

- データを Training/Test データにランダム分割し、Training データに対して Algorithm を提供し、Test データで予測精度を推定する

\* 80:20, 95:5 などの比率が代表的

### 1.3 予測精度の指標

- 例: 推定されたモデル  $\hat{g}_Y(X)$  について、テストデータから、平均二乗誤差  $E[(Y - \hat{g}_Y(X))^2]$  を推定

- 決定係数 ( $R^2$ ) =  $1 - (E[(Y - \hat{g}_Y(X))^2] / \text{var}(Y))$  はより解釈しやすい

\*  $g_Y(X)$  が予測した  $Y$  の変動

- Linear Model については、伝統的な理論的指標である AIC/BIC も候補

#### 1.4 理想の予測モデル

- $E[(Y - g_Y(X))^2]$  を最小化する予測モデルは母平均  $E[Y|X]$ 
  - 母平均を Estimand として推定する問題に帰結
    - \* 事例数が多く、 $X$  の数が少なければ、OLS 推定は有力候補
  - $\iff$  OLS は  $E[Y|X]$  の (研究者が設定する) 線形近似 (Linear approximation) が Estimand

#### 1.5 一致推定結果

- 無限大の事例数で推定されたモデル  $= g_{Y,\infty}(X)$
- 必ずしも Estimand とは一致しない
  - 例: Mis-specification があれば、 $g_{Y,\infty}(X) \neq E[Y|X]$

#### 1.6 予測誤差の分解

•

$$\begin{aligned}
 Y - g_Y(X) &= \underbrace{Y - E[Y|X]}_{\text{母集団における個人差: Irreducible error}} \\
 &+ \underbrace{E[Y|X] - g_{Y,\infty}(X)}_{\text{母平均と一致推定の乖離: Approximation error}} \\
 &+ \underbrace{g_{Y,\infty}(X) - g_Y(X)}_{\text{一致推定と Estimator の乖離: Estimation error}}
 \end{aligned}$$

#### 1.7 例

- $Y \sim \beta_0 + \beta_1 \text{Size}$  を 10 事例で推定

•

$$\begin{aligned}
 \underbrace{Y - g_Y(X)}_{\text{おそらく大きい}} &= \underbrace{Y - E[Y|X]}_{\text{Size 以外の決定要因があり、おそらく大きい}} \\
 &+ \underbrace{E[Y|X] - g_{Y,\infty}(X)}_{\text{"一直線の関係"ではないので、おそらく大きい}} \\
 &+ \underbrace{g_{Y,\infty}(X) - g_Y(X)}_{\text{事例数が少なすぎ、大きい可能性が高い}}
 \end{aligned}$$

## 1.8 例

- 事例数が 100 万に増やし、同じモデルを推定する

•

$$\begin{aligned} Y - g_Y(X) &= \underbrace{Y - E[Y|X]}_{\text{不変!!!}} \\ &\quad + \underbrace{E[Y|X] - g_{Y,\infty}(X)}_{\text{不変!!!}} \\ &\quad + \underbrace{g_{Y,\infty}(X) - g_Y(X)}_{\text{ほとんど0になることが期待できる}} \end{aligned}$$

## 1.9 練習問題 ([リンク](#))

- 10 事例のまま、 $Y \sim \beta_0 + \beta_1 p(\text{Size}, 9)$  を推定した結果、予測性能が大幅に悪化した。何が起こったか?

•

$$\begin{aligned} Y - g_Y(X) &= \underbrace{Y - E[Y|X]}_{\text{Irreducible Error}} \\ &\quad + \underbrace{E[Y|X] - g_{Y,\infty}^*(X)}_{\text{Approximation Error}} + \underbrace{g_{Y,\infty}^*(X) - g_Y(X)}_{\text{Estimation Error}} \end{aligned}$$

## 1.10 例

- 10 事例のまま、 $Y \sim \beta_0 + \beta_1 p(\text{Size}, 9)$  を推定

•

$$\begin{aligned} Y - g_Y(X) &= \underbrace{Y - E[Y|X]}_{\text{不変!!!}} \\ &\quad + \underbrace{E[Y|X] - g_{Y,\infty}(X)}_{\text{減少}} \\ &\quad + \underbrace{g_{Y,\infty}(X) - g_Y(X)}_{\text{非常に大きくなる可能性が高い}} \end{aligned}$$

## 1.11 まとめ

- モデルを複雑にすると、近似誤差は低下する一方で、推定誤差は増加することが多い
  - Bias-variance トレードオフとして知られる
    - \* 直感的には、モデルが複雑であれば、より多くをデータに決めさせるので、推定されたモデルはデータの特徴により強く依存する

### 1.12 まとめ

- 活用できる変数が増えると削減不可能な誤差を減らせる
  - アルゴリズムがうまく扱わないと、予測精度そのものは悪化する
- 事例数の増加は、トレードオフを緩和
  - ただし人間が適切にモデルを複雑化する介入が必要
    - \* 多くの実践で、人間には困難

### 1.13 補論: 過剰適合

- モデルが複雑 ( $\beta$  の数が多い) であれば、推定に用いたデータへの適合度は高くなるが、予測精度は悪化する
  - 過剰適合/過学習
- 直感: OLS は  $\sum(Y - g_Y(X))^2$  を最小にするように  $\beta$  を決定
  - $\beta$  の数が増えれば、最小化に用いるフリーパラメタが増えるので、必ず  $\sum(Y - g_Y(X))^2$  は減少する

### 1.14 数値例

```
library(tidyverse)

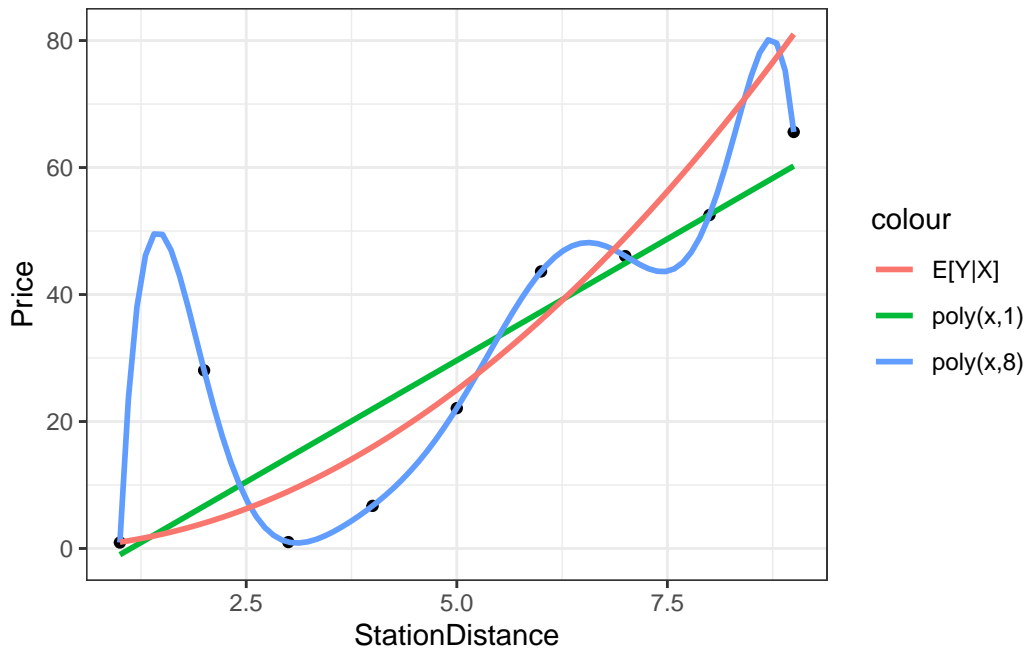
SimData <- function(n,seed) {
  set.seed(seed)
  Temp <- tibble(
    StationDistance = sample(1:9,n),
    PriceTrue = StationDistance^2,
    Price = PriceTrue + rnorm(n,0,10)
  )
  return(Temp)
}

SimData(9,1) |>
  ggplot(
    aes(
```

```

    x = StationDistance,
    y = Price
  )
) +
theme_bw() +
geom_point() +
geom_smooth(
  aes(
    color = "poly(x,1)"
  ),
  method = "lm",
  se = FALSE
) +
geom_smooth(
  aes(
    color = "poly(x,8)"
  ),
  method = "lm",
  se = FALSE,
  formula = y ~ poly(x,8)
) +
geom_smooth(
  aes(
    y = PriceTrue,
    color = "E[Y|X]"
  ),
  method = "lm",
  se = FALSE,
  formula = y ~ poly(x,8)
)

```



## 2 Penalized Regression

- 事例数に応じて、適切にモデルの複雑性を調整することは困難
  - $X$  の数が多いと特に難しい
- データ主導で”自動化”する
  - 代表例は LASSO

### 2.1 LASSO Algorithm

0. 十分に複雑なモデルからスタート
1. 何らかの基準 (後述) に基づいて Hyper (Tuning) parameter  $\lambda$  を設定
2. 以下の最適化問題を解いて、Linear model  $g(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \dots$  を推定

$$\min \sum (y_i - g(x_i))^2 + \lambda(|\beta_1| + |\beta_2| + \dots)$$

### 2.2 Constrained optimization としての書き換え

1. 何らかの基準 (後述) に基づいて Hyper parameter  $A$  を設定

2. 以下の最適化問題を解いて、Linear model  $g(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \dots$  を推定

$$\min \sum (y_i - g(x_i))^2$$

where

$$|\beta_1| + |\beta_2| + \dots \leq A$$

## 2.3 $\lambda$ の役割: OLS

- $\lambda = 0$  と設定すれば、(複雑なモデルを)OLS で推定した推定結果と一致

•

$$\begin{aligned} Y - g_Y(X) &= \underbrace{Y - E[Y|X]}_{\text{不変}} \\ &+ \underbrace{E[Y|X] - g_{Y,\infty}(X)}_{\text{小さい}} + \underbrace{g_{Y,\infty}(X) - g_Y(X)}_{\text{大きい傾向}} \end{aligned}$$

## 2.4 練習問題 ([リンク](#))

- $\lambda$  を極めて大きな値に設定した

1. どのようなモデルになるか?

2. 予測性能が OLS よりも改善した。何が起きたか?

•

$$\begin{aligned} Y - g_Y(X) &= \underbrace{Y - E[Y|X]}_{\text{Irreducible Error}} \\ &+ \underbrace{E[Y|X] - g_{Y,\infty}^*(X)}_{\text{Approximation Error}} + \underbrace{g_{Y,\infty}^*(X) - g_Y(X)}_{\text{Estimation Error}} \end{aligned}$$

## 2.5 $\lambda$ の役割: 平均

- $\lambda = \infty$  と設定すれば、必ず  $\beta_1 = \beta_2 = \dots = 0$  となる  
 -  $\beta_0$  のみ、最小二乗法で推定:  $g(X) = \text{サンプル平均}$

•

$$\begin{aligned} Y - g_Y(X) &= \underbrace{Y - E[Y|X]}_{\text{不変}} \\ &+ \underbrace{E[Y|X] - g_{Y,\infty}(X)}_{\text{大きい}} + \underbrace{g_{Y,\infty}(X) - g_Y(X)}_{\text{小さい傾向}} \end{aligned}$$

## 2.6 数値例



```

library(tidyverse)

SimData <- function(n,seed) {
  set.seed(seed)
  Temp <- tibble(
    StationDistance = sample(1:9,n),
    PriceTrue = StationDistance^2,
    Price = PriceTrue + rnorm(n,0,10)
  )
  return(Temp)
}

Y = SimData(9,1)$Price
X = model.matrix(~ 0 + poly(StationDistance,8), SimData(9,1))

OLS = lm(
  Price ~ poly(StationDistance,8),
  SimData(9,1)
)$fitted

LASSO = gamlr::gamlr(
  x = X,
  y = Y
) |>
predict(X) |>
as.numeric()


SimData(9,1) |>
ggplot(
  aes(
    x = StationDistance,
    y = Price
  )
) +
theme_bw() +
geom_point() +
geom_smooth(
  aes(
    y = OLS,

```

```

    color = "OLS"
  ),
  method = "lm",
  se = FALSE,
  formula = y ~ poly(x,8)
) +
geom_smooth(
  aes(
    y = LASSO,
    color = "LASSO"
  ),
  method = "lm",
  se = FALSE,
  formula = y ~ poly(x,8)
) +
geom_smooth(
  aes(
    y = PriceTrue,
    color = "E[Y|X]"
  ),
  method = "lm",
  se = FALSE,
  formula = y ~ poly(x,2)
)

```



## 2.7 $\lambda$ の役割

- やりたい事: 予測性能を最大化できるように  $\lambda$  を設定し、単純すぎるモデル (Approximation error が大きすぎる) と複雑すぎるモデル (Estimation error が大きすぎる) の間の”ちょうどいい”モデルを構築する
- 設定方法: サンプル分割 (交差推定, [glmnet](#) で実装)、情報基準 ([gamlr](#) で採用)、理論値 ([hdm](#) で採用)
  - 本スライドでは交差推定 (Cross fit/Cross validation) を紹介

## 3 交差推定

- 訓練/中間評価にどの程度事例を割くか、についてトレードオフ
  - 訓練に事例を割きすぎると、評価が正確にできない
- 交差検証により緩和: 全ての事例を中間評価に持ちこる

### 3.1 交差推定のアイデア

- 予測性能の高いモデルを算出しやすい  $\lambda$  を使用したい
  - 母平均  $E[Y|X]$  の良い近似モデルを算出しやすい  $\lambda$  を使用したい
- ある  $\lambda$  が生み出すモデルの平均的な予測性能がわかれば、最善の  $\lambda$  を見つけ出せる

- 全く同じ事例を試作と評価に使うと、複雑なモデルを過大評価してしまう
  - 試作と検証は異なる事例でやりさえすれば良い

### 3.2 シンプルなサンプル分割

- ある  $\lambda$  のもとで推定されるモデルの平均的な性能を評価する
0. データを訓練/中間評価用 (Validation) データに分割
  1. 訓練データを用いて、モデルを”試作”する
  2. 中間評価用データを用いて、予測性能を評価する
- 異なる  $\lambda$  について繰り返し、最も性能の良いものを採用

### 3.3 交差検証

- ある  $\lambda$  のもとで推定されるモデルの平均的な性能を評価する
0. データを細かく分割 (第 1,...,10 サブグループなど)
  1. 第 1 サブグループ以外で推定して、第 1 サブグループで評価
  2. 第 2...サブグループについて、繰り返す
  3. 全評価値の平均を最終評価値とする

### 3.4 数値例: 3 分割

```
library(tidyverse)

SimData <- function(n,seed) {
  set.seed(seed)
  Temp <- tibble(
    StationDistance = sample(1:9,n,replace = TRUE),
    Price = StationDistance + rnorm(n,0,10)
  )
  return(Temp)
}

PopData <- SimData(9,1) |>
```

```

mutate(
  Group = sample(rep(1:3,each = 9/3)) |>
  factor()
)

X = model.matrix(
  ~ 0 + poly(StationDistance,5),
  PopData
)

Y = PopData$Price

FitCV = glmnet::cv.glmnet(
  x = X,
  y = Y
)

PopData

```

```

# A tibble: 9 x 3
  StationDistance Price Group
      <int>     <dbl> <fct>
1         9  6.05    3
2         4  3.94    2
3         7 31.0     3
4         1  8.64    1
5         2 -5.99    3
6         7 -4.48    1
7         2 -0.895   1
8         3  0.00785  2
9         1 -3.12    2

```

### 3.5 数値例

- $f_Y(X) = \beta_0 + \beta_1 X + \dots + \beta_5 X^5$  を
  - OLS で推定
  - LASSO ( $\lambda = 4$ ) で推定

### 3.6 数值例: Step 1

```
Target <- 1

LASSO = glmnet::glmnet(
  x = X[PopData$Group != Target,],
  y = PopData$Price[PopData$Group != Target]
)

PredOLS <- predict(
  LASSO,
  X,
  s = 0.01
) |>
as.numeric()

PredBest <- predict(
  LASSO,
  X,
  s = 4
) |>
as.numeric()

tibble(
  Price = PopData$Price,
  `Prediction with 4` = PredBest,
  `Prediction with 0.01` = PredOLS,
  SubGroup = PopData$Group
) |>
filter(SubGroup == Target)

# A tibble: 3 x 4
  Price `Prediction with 4` `Prediction with 0.01` SubGroup
  <dbl>          <dbl>          <dbl> <fct>
1  8.64          3.92          -2.76 1
2 -4.48         14.8           30.3 1
3 -0.895        0.0725        -5.82 1
```

```
tibble(
  Price = PopData$Price,
  `Prediction with 4` = PredBest,
  `Prediction with 0.01` = PredOLS,
  SubGroup = PopData$Group
) |>
filter(SubGroup != Target)
```

```
# A tibble: 6 x 4
```

|   | Price   | `Prediction with 4` | `Prediction with 0.01` | SubGroup |
|---|---------|---------------------|------------------------|----------|
|   | <dbl>   | <dbl>               | <dbl>                  | <fct>    |
| 1 | 6.05    | 9.03                | 6.22                   | 3        |
| 2 | 3.94    | 3.61                | 4.19                   | 2        |
| 3 | 31.0    | 14.8                | 30.3                   | 3        |
| 4 | -5.99   | 0.0725              | -5.82                  | 3        |
| 5 | 0.00785 | 0.462               | -0.228                 | 2        |
| 6 | -3.12   | 3.92                | -2.76                  | 2        |

- Out-of-data R2: -2.57 with 0.01, -0.04 with 4
- In-data R2: 1 with 0.01, 0.53 with 4

### 3.7 数值例: Step 2

```
Target <- 2

LASSO = glmnet::glmnet(
  x = X[PopData$Group != Target,],
  y = PopData$Price[PopData$Group != Target]
)

PredOLS <- predict(
  LASSO,
  X,
  s = 0.01
) |>
as.numeric()

PredBest <- predict(
  LASSO,
```

```

X,
s = 4
) |>
as.numeric()

tibble(
  Price = PopData$Price,
  `Prediction with 4` = PredBest,
  `Prediction with 0.01` = PredOLS,
  SubGroup = PopData$Group
) |>
filter(SubGroup == Target)

```

# A tibble: 3 x 4

|   | Price   | `Prediction with 4` | `Prediction with 0.01` | SubGroup |
|---|---------|---------------------|------------------------|----------|
|   | <dbl>   | <dbl>               | <dbl>                  | <fct>    |
| 1 | 3.94    | -0.448              | -5.27                  | 2        |
| 2 | 0.00785 | 21.0                | 21.9                   | 2        |
| 3 | -3.12   | 8.18                | 8.67                   | 2        |

```

tibble(
  Price = PopData$Price,
  `Prediction with 4` = PredBest,
  `Prediction with 0.01` = PredOLS,
  SubGroup = PopData$Group
) |>
filter(SubGroup != Target)

```

# A tibble: 6 x 4

|   | Price  | `Prediction with 4` | `Prediction with 0.01` | SubGroup |
|---|--------|---------------------|------------------------|----------|
|   | <dbl>  | <dbl>               | <dbl>                  | <fct>    |
| 1 | 6.05   | 6.81                | 6.06                   | 3        |
| 2 | 31.0   | 7.48                | 13.2                   | 3        |
| 3 | 8.64   | 8.18                | 8.67                   | 1        |
| 4 | -5.99  | 2.22                | -3.39                  | 3        |
| 5 | -4.48  | 7.48                | 13.2                   | 1        |
| 6 | -0.895 | 2.22                | -3.39                  | 1        |

- Out-of-data R2: -0.84 with 0.01, -0.54 with 4
- In-data R2: 0.16 with 0.01, -0.02 with 4



### 3.8 数值例: Step 3

```
Target <- 3

LASSO = glmnet::glmnet(
  x = X[PopData$Group != Target,],
  y = PopData$Price[PopData$Group != Target]
)

PredOLS <- predict(
  LASSO,
  X,
  s = 0.01
) |>
as.numeric()

PredBest <- predict(
  LASSO,
  X,
  s = 4
) |>
as.numeric()

tibble(
  Price = PopData$Price,
  `Prediction with 4` = PredBest,
  `Prediction with 0.01` = PredOLS,
  SubGroup = PopData$Group
) |>
filter(SubGroup == Target)
```

# A tibble: 3 x 4

|   | Price | `Prediction with 4` | `Prediction with 0.01` | SubGroup |
|---|-------|---------------------|------------------------|----------|
|   | <dbl> | <dbl>               | <dbl>                  | <fct>    |
| 1 | 6.05  | 0.683               | -3.50                  | 3        |
| 2 | 31.0  | 0.683               | -4.44                  | 3        |
| 3 | -5.99 | 0.683               | -0.905                 | 3        |

```
tibble(
  Price = PopData$Price,
  `Prediction with 4` = PredBest,
  `Prediction with 0.01` = PredOLS,
  SubGroup = PopData$Group
) |>
filter(SubGroup != Target)
```

# A tibble: 6 x 4

|   | Price   | `Prediction with 4` | `Prediction with 0.01` | SubGroup |
|---|---------|---------------------|------------------------|----------|
|   | <dbl>   | <dbl>               | <dbl>                  | <fct>    |
| 1 | 3.94    | 0.683               | 3.91                   | 2        |
| 2 | 8.64    | 0.683               | 2.76                   | 1        |
| 3 | -4.48   | 0.683               | -4.44                  | 1        |
| 4 | -0.895  | 0.683               | -0.905                 | 1        |
| 5 | 0.00785 | 0.683               | 0.0172                 | 2        |
| 6 | -3.12   | 0.683               | 2.76                   | 2        |

- Out-of-data R2: -2.6 with 0.01, -1.6 with 4
- In-data R2: 0.91 with 0.01, 0.85 with 4

### 3.9 比較

- 全データをモデルの試作と中間評価に使用すると、複雑なモデルを過大評価
- データを分割すると、全データを用いた評価はできない
  - 事例数が少ないと評価制精度が悪い
- 交差推定を行えば、過剰適合を避けながら、全データを評価に使用できる
  - 計算時間などの問題点もある

### 3.10 実践: 単位問題

- LASSO の推定結果は、 $X$  の”単位”に影響を受ける
  - $X = 10 \text{ km}/10,000 \text{ m}$
  - 実戦では、推定前に平均 0/分散 1 に標準化することが多い
  - 標準化された  $X = \frac{X - \text{mean}(X)}{\text{var}(X)}$

- 「 $X$  の一部は  $Y$  と強く相関する一方で、相関が弱い変数も大量に存在する」 (Approximate Sparsity) 状態で LASSO の予測性能は良好な傾向

### 3.11 実践: 一致推定量

- 十分に複雑なモデルを設定できれば、LASSO (+  $\lambda$  のデータ主導の決定)、定式化への依存を減らせる
  - 元々の  $X$  について、交差項と連続変数については二乗項を作成など
  - 事例数に応じて  $\lambda$  が減少すれば、母平均の一致推定量を得られる
    - \* 交差推定など多くの方法で満たされる

### 3.12 実践: 変数の除外

- LASSO で推定した場合、厳密に 0 となる  $\beta$  が出てくる
  - 非常に稀な場合を除いて、OLS では厳密に 0 にならない (非常に小さいはあり得る)
- $\underbrace{\beta_1}_{=0} \times X_1$  であれば、 $X_1$  をモデルから変数をデータ主導で除外している、と解釈できる
  - Double Selection において重要な手法

### 3.13 まとめ

- 良い予測には、適度な複雑性を持つモデルが必要
- OLS は人間がモデルを事前に定式化する必要があるが、非常に困難
- ここまでの内容は CausalML Chap 1/3 参照

## Reference

Rothenhäusler, Dominik, and Peter Bühlmann. 2023. “Distributionally Robust and Generalizable Inference.” *Statistical Science* 38 (4): 527–42.