

Estimation with Partial Linear Model: Asymptotics

川田恵介

Table of contents


| | | |
|------|--|----|
| 1 | 大標本性質: without nuisance | 2 |
| 1.1 | イメージ: 近似に基づく議論 | 3 |
| 1.2 | 例: 平均値の推定 | 3 |
| 1.3 | 例: 平均値の推定 | 3 |
| 1.4 | 大標本性質: ざっくり | 4 |
| 1.5 | 応用上の含意 | 4 |
| 1.6 | 平均値: $N = 2000$ | 5 |
| 1.7 | 平均値: $N = 200$ | 5 |
| 1.8 | 大標本性質 | 6 |
| 1.9 | 収束速度 | 6 |
| 1.10 | 例: $\theta - \theta_0$ | 6 |
| 1.11 | 例: $\sqrt{N}(\theta - \theta_0)$ | 7 |
| 1.12 | 拡張: 合成指標 | 7 |
| 1.13 | 拡張: Implicit function | 7 |
| 1.14 | 例 | 8 |
| 1.15 | 注意点 | 8 |
| 1.16 | 補論: 正規分布への収束 | 8 |
| 2 | 大標本性質: with nuisance function | 8 |
| 2.1 | R-learner | 8 |
| 2.2 | Single-learner | 9 |
| 2.3 | Estimator | 9 |
| 2.4 | 分解 | 9 |
| 2.5 | 分解 | 9 |
| 2.6 | イメージ | 10 |
| 2.7 | イメージ | 10 |
| 2.8 | 仮定 | 10 |
| 2.9 | イメージ: R learner | 11 |
| 2.10 | イメージ: Normalized | 12 |

| | | |
|------|---|----|
| 2.11 | AI のミスの影響への保障: Recap | 12 |
| 2.12 | 仮定: 収束速度 | 12 |
| 2.13 | 補論: 収束速度 | 13 |
| 2.14 | 前提: サンプル分割 | 13 |
| 2.15 | 数値例 | 13 |
| 2.16 | 数値例: Add outlier | 13 |
| 2.17 | 補論: 収束速度 | 14 |
| 2.18 | Single learner | 14 |
| 2.19 | イメージ: Single Model | 15 |
| 3 | Neyman's orthogonal condition | 15 |
| 3.1 | Estimand | 15 |
| 3.2 | Neyman's orthogonal condition | 16 |
| 3.3 | 実装 | 16 |
| 3.4 | 仮定の検討 | 16 |
| | Reference | 17 |

1 大標本性質: without nuisance

- 事例数が無限大に大きい時に成り立つ性質を、事例数が十分に大きことを前提に近似的に用いる
 - サンプルング方法に”強い”仮定 = “ランダムサンプリング”
 - 教科書的な最尤法やベイズ法に比べて、母集団への parametric assumption が少ない

1.1 イメージ: 近似に基づく議論



- 十分大きい N を前提に、近似的に”0”として議論
 - B_N の方が近似精度が良い

1.2 例: 平均値の推定

- Estimand: Y の母平均 $\theta_0 = E[Y] = \int Y f(Y) dY$
 - Estimator: サンプル平均 $\theta = \sum_i Y_i / N$
 - * Moment 法 (“置き換え法”)
- Estimator は、データ上の Y の分布に依存するので、研究者によって異なる
 - 一般に $\theta_0 \neq \theta$
 - 多くの実証研究では、点推定量だけでなく信頼区間 (ないし代替指標 (Imbens 2021)) を報告し、対処する

1.3 例: 平均値の推定

- 平均値の推定

```
readr::read_csv("Public/Data.csv") |>
  estimatr::lm_robust(
    Price ~ 1,
    data = _)
```

| | Estimate | Std. Error | t value | Pr(> t) | CI Lower | CI Upper | DF |
|-------------|----------|------------|----------|----------|----------|----------|-------|
| (Intercept) | 39.00496 | 0.2015849 | 193.4915 | 0 | 38.60984 | 39.40008 | 22138 |

- 何を根拠に、どのような解釈ができるのか?

1.4 大標本性質: ざっくり

- 事例数が無限大になると、Estimator の分布について、以下の性質が成り立つ

- サンプル平均は、母平均 θ_0 に収束する

$$\theta_0 - \theta \rightarrow 0, N \rightarrow \infty$$

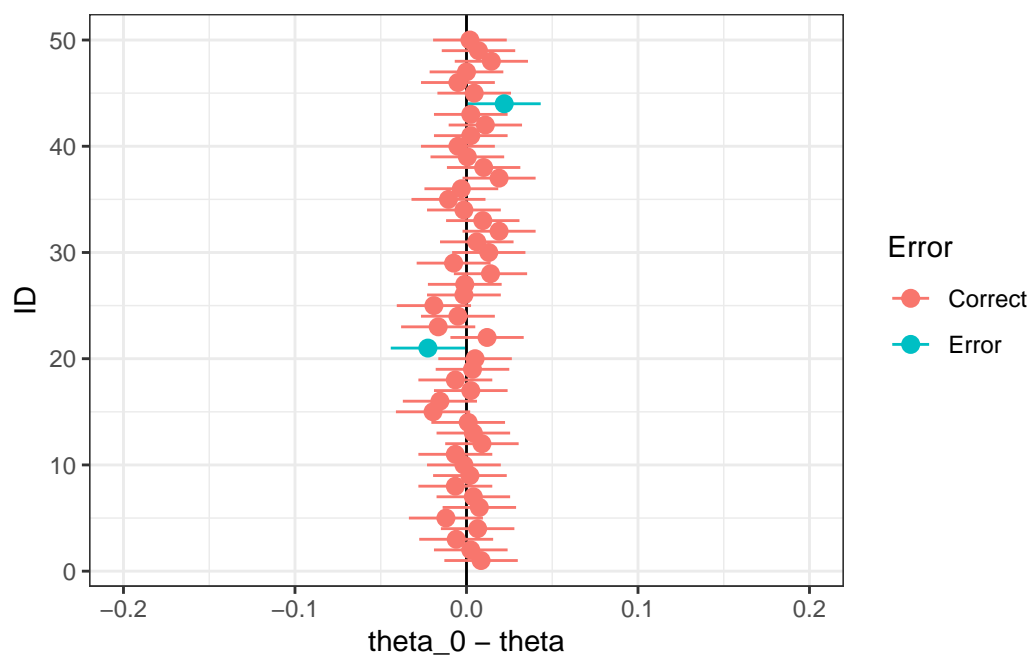
- θ の分布は、正規分布 $N(\theta_0, \sigma^2/N)$ に収束する (中心極限定理)

* $\sigma^2 = Y$ の母分散

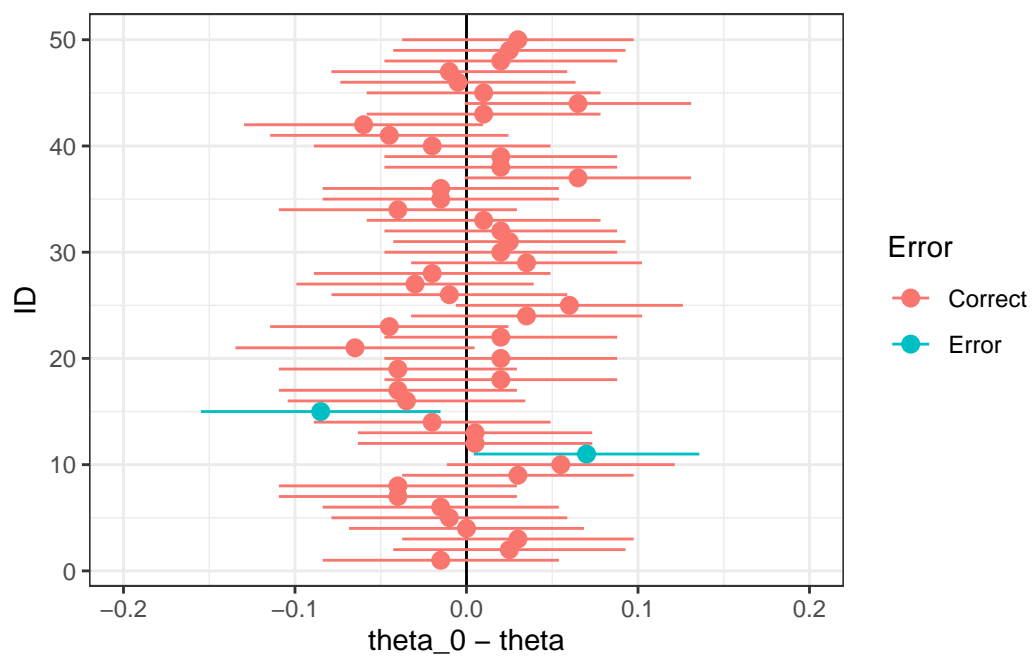
1.5 応用上の含意

- 事例数が十分に大きいと
 - 点推定量は、ほぼほぼ母平均と一致する
 - 信頼区間は、ほぼほぼ 95% の ” 確率 ” で母平均を含む
- ただし、十分に大きい、の水準は違う

1.6 平均值: $N = 2000$



1.7 平均值: $N = 200$



1.8 大標本性質

- $N^{a(<0.5)}(\theta_0 - \theta) \rightarrow 0, N \rightarrow \infty$

- $N^{a(>0.5)}(\theta_0 - \theta) \rightarrow ?, N \rightarrow \infty$

-

$$N^{0.5}(\theta_0 - \theta) \rightarrow \text{Normal}(0, \sigma^2), N \rightarrow \infty$$

– よって $\theta_0 - \theta \sim N(0, \sigma^2/N)$

* σ を推定し、信頼区間を計算できる

1.9 収束速度

- $\{a, b\} \rightarrow 0, N \rightarrow \infty$ である時に、


$$\frac{a}{b} \rightarrow 0, N \rightarrow \infty$$

であれば、“a は b よりも早く (確率) 収束する” と呼ぶ


– N が十分に大きくなれば、 $a < b$ が (高い確率) で成り立つ

- 平均値は、 $N^{-a(<0.5)}$ よりも早く収束する

1.10 例: $\theta - \theta_0$



1.11 例: $\sqrt{N}(\theta - \theta_0)$



1.12 拡張: 合成指標

- Estimand: 複数の変数 $O = \{X_1, \dots, X_L\}$ によって、定義される指標 $m(O)$ の平均値 $\theta_0 = E[m(O)]$
 - サンプル平均値 $\theta = \sum m(O)/N$ で置き換える
 - ただし関数 $m(O)$ は既知であり、全ての研究者が同じ式を用いる必要がある
- 例: 国語 X と算数 Y の合計点の平均値

$$m(O = \{X, Y\}) = X + Y$$

1.13 拡張: Implicit function

- 隠関数の平均値として、Estimand は定義できるのであれば、以上の議論を適用できる
- Estimand: 以下の関数を満たす θ_0

$$E[m(\theta_0, O)] = 0$$
 - 一意に θ は定まり、微分可能性
- Estimator = サンプル平均 $0 = \sum m(\theta, O)$ を満たす θ

1.14 例

- サンプル平均: $m(\theta_0, O) = \theta_0 - Y$
- OLS: $m(O, \theta_0) = X(Y - \theta_0 X)$
 - Estimand = $\min E[(Y - \theta_0 X)^2]$ を達成する θ_0

1.15 注意点

- 以上の議論は同じ関数 m を Estimand の定義と推定に用いているが、分離できることに注意
- 同じ θ を定義する関数は、一般に”無数”に存在する
 - 例: $m = \theta - E[Y]$ と $m = (\theta - E[Y])^2$ は同じ θ
 - 推定上、“便利”な定義を使えば良い

1.16 補論: 正規分布への収束

- Berry-Esseen's Central Limit Theorem
 - (see Chap 1 in CausalML)
- 任意の標準化された X (平均 0, 分散 1) について

$$\sup_{x \in \mathbb{R}} |\Pr[X \leq x] - \Pr[N(0, 1) \leq x]| \leq K E[|X|^3] / \sqrt{N}$$

最大値

- $K =$ 何らかのパラメタ (< 0.5)

2 大標本性質: with nuisance function

2.1 R-learner

- Estimand = 以下を満たす θ_0

$$0 = E[m_R(O, \theta_0)]$$

where

$$O = \{X, D, Y\}$$

$$\mu(X) = \{\mu_D(X), \mu_Y(X)\}$$

$$m_R = (D - \mu_D(X)) \times [Y - \mu_Y(X) - \theta_0(D - \mu_D(X))]$$

2.2 Single-learner

- 一般に複数の m 関数が、同じ estimand の一致推定量を提供する。
- 例えば、

$$m_S = (D - \mu_D(X)) \times [Y - \theta_0(D - \mu_D(X))]$$

- どれを使えばいいのか?
 - 一つの指針は、大標本性質

2.3 Estimator

- データ上で置き換えると、 $\sum m(O_i, g(X), \theta) = 0$ 、ただし $g(X) = \{g_D(X), g_Y(X)\}$ は Auxiliary data を用いて推定された関数
- 一見すると Moment 法がそのまま適用できそうだが、 $g(X)$ に依存していることに注意
 - $\mu(X) \neq g(X)$ (AI のミス)

2.4 分解

- 肝は、 $\sqrt{N}(\theta_0 - \theta)$, $N \rightarrow \infty$ の保証
- 仮想的な Estimator θ^* を考える

$$\sum m(O_i, \mu(X), \theta^*) = 0$$
- AI がミスを犯さないケースの推定値

2.5 分解

- $\sqrt{N}(\theta_0 - \theta) = \underbrace{\sqrt{N}(\theta_0 - \theta^*)}_{\substack{O \text{ に依存} \\ \rightarrow N(0, \sigma^2), N \rightarrow \infty}} + \underbrace{\sqrt{N}(\theta^* - \theta)}_{\substack{AI \text{ のミスに起因} \\ \rightarrow ?, N \rightarrow \infty}}$
 - 一項目に対しては、中心極限定理を適用できる
 - 二項目は、
 - Single learner であれば発散する恐れがある
 - R learner であれば、AI のミスの影響が削減できる
- $* \rightarrow 0, N \rightarrow \infty$

2.6 イメージ

- Auxiliary data

```
# A tibble: 4 x 3
      X      D      Y
<int> <dbl> <dbl>
1    -1  2.27  3.25
2     1  1.41  1.82
3    -1 -0.540 0.325
4     0 -0.929 -1.09
```

- Main data with prediction (by random forest)

```
# A tibble: 4 x 11
      X      D      Y PredictY PredictD TrueY TrueD  ResY  ResD ResTrueY
<int> <dbl> <dbl>   <dbl>   <dbl> <dbl> <dbl>  <dbl> <dbl>  <dbl>
1     1  0.401 -0.562     1.06    0.538     1     1 -1.63 -0.137  -1.56
2    -1  1.29  -0.0376    1.06    0.538     1     1 -1.10  0.757  -1.04
3     0  0.390  0.523     1.06    0.538     0     0 -0.540 -0.148   0.523
4     1 -0.208 -0.314     1.06    0.538     1     1 -1.38 -0.746  -1.31
# i 1 more variable: ResTrueD <dbl>
```

2.7 イメージ

- データは、 $X = U(-1, 1), D = X^2 + N(0, 1), Y = 2D - X^2 + N(0, 1)$
- $\theta_0 = 2$
- $\theta = (Y - g_Y(X)) \sim (D - g_D(X))$
- $\theta^* = (Y - \mu_Y(X)) \sim (D - \mu_D(X))$
 - $\sqrt{4} * (\theta_0 - \theta^*) = 1.5741579$
 - $\sqrt{4} * (\theta^* - \theta) = -0.751546$

2.8 仮定

- $\sqrt{N}(\theta_0 - \theta) = \underbrace{\sqrt{N}(\theta_0 - \theta^*)}_{\rightarrow N(0, \sigma^2), N \rightarrow \infty} + \underbrace{\sqrt{N}(\theta^* - \theta)}_{\rightarrow 0, N, N \rightarrow \infty}$ を保証したい


– 第2項 (AI のミス) の影響は、(信頼区間を計算できる程度に) 事例数が十分に大きければ、無視できる

• R-learner を前提とした場合、主要な十分条件は


– サンプル分割

– g が十分な速度で収束する

2.9 イメージ: R learner



2.10 イメージ: Normalized



2.11 AI のミスの影響への保障: Recap

- AI のミスの影響が $N^{1/4}$ 以上の速度で減少
- 例: $g_D(X = I)$ のミスの影響

$$\left(\sum_{i|X_i=I} Y_i / N_M(I) - g_Y(I) \right) \times \underbrace{e_D(I)}_{\mu_D(I) - g_D(I)}$$

– g_Y, g_D が十分な速度で μ_Y, μ_D に収束

– g_D と $\sum_{i|X_i=I} Y_i / N_M(I)$ が無相関

2.12 仮定: 収束速度

- 十分条件の一つは、

$$\left\{ N^{1/4} \sqrt{E[(\mu_Y(X) - g_Y(X))^2]}, \right. \\ \left. N^{1/4} \sqrt{E[(\mu_D(X) - g_D(X))^2]} \right\} \rightarrow 0, N \rightarrow \infty$$

– $N^{1/4}$ よりも収束速度が速い

2.13 補論: 収束速度

- g を正しいモデルで OLS 推定できれば、

$$N^{a(<0.5)} \sqrt{E[(\mu(X) - g(X))^2]} \rightarrow 0, N \rightarrow \infty$$

– $N^{1/4}$ よりも 確実に収束速度が速い

- 誤定式化を犯している OLS では、そもそも収束しない
- 多くの機械学習は、 $N^{1/2}$ よりも収束速度が遅い
 - R learner は、機械学習 (含む Nonparametric estimation) の収束の遅さを補完

2.14 前提: サンプル分割

- サンプル分割しないと予測モデルと Main data の平均値との間に相関が生じ、収束速度が低下する
 - 相関の影響は (個人的に) わかりにくい
 - * 個人的おすめは、外れ値がデータに紛れ込んだ時の影響を想像する

2.15 数値例

- 同じデータで g を (random forest で) 推定する

A tibble: 8 x 6

| | X | D | Y | PredictY | PredictD | MeanY |
|---|-------|----------|-----------|----------|----------|----------|
| | <int> | <dbl> | <dbl> | <dbl> | <dbl> | <dbl> |
| 1 | -1 | -0.540 | -2.37 | 0.674 | 1.02 | 0.849 |
| 2 | 1 | 0.0714 | -1.16 | -0.135 | 0.480 | -0.00968 |
| 3 | -1 | 0.705 | -0.000952 | 0.674 | 1.02 | 0.849 |
| 4 | 0 | -0.00577 | 0.241 | -0.725 | -0.0520 | -1.14 |
| 5 | -1 | 3.40 | 4.92 | 0.674 | 1.02 | 0.849 |
| 6 | 1 | 1.76 | 2.96 | -0.135 | 0.480 | -0.00968 |
| 7 | 1 | 0.201 | -1.84 | -0.135 | 0.480 | -0.00968 |
| 8 | 0 | -1.15 | -2.52 | -0.725 | -0.0520 | -1.14 |

2.16 数値例: Add outlier

- D (例: 部屋の広さ) が非常に大きな事例が混入
 - Y (例: 取引価格) も同時に大きい

A tibble: 9 x 6

| | X | | D | | Y | PredictY | PredictD | MeanY |
|---|-------|----------|-----------|--|-------|----------|----------|-------|
| | <dbl> | | <dbl> | | <dbl> | <dbl> | <dbl> | <dbl> |
| 1 | -1 | -0.540 | -2.37 | | 5.56 | 3.30 | 0.849 | |
| 2 | 1 | 0.0714 | -1.16 | | 4.53 | 2.75 | -0.00968 | |
| 3 | -1 | 0.705 | -0.000952 | | 5.56 | 3.30 | 0.849 | |
| 4 | 0 | -0.00577 | 0.241 | | 18.4 | 9.31 | 25.9 | |
| 5 | -1 | 3.40 | 4.92 | | 5.56 | 3.30 | 0.849 | |
| 6 | 1 | 1.76 | 2.96 | | 4.53 | 2.75 | -0.00968 | |
| 7 | 1 | 0.201 | -1.84 | | 4.53 | 2.75 | -0.00968 | |
| 8 | 0 | -1.15 | -2.52 | | 18.4 | 9.31 | 25.9 | |
| 9 | 0 | 40 | 80 | | 18.4 | 9.31 | 25.9 | |

- $\sum Y/N - g_Y$ も $g_Y - \mu_Y$ も同時増加

2.17 補論: 収束速度

- g を正しいモデルで OLS 推定できれば、

$$N^{a(<0.5)} \sqrt{E[(\mu(X) - g(X))^2]} \rightarrow 0, N \rightarrow \infty$$


– $N^{1/4}$ よりも 確実に収束速度が速い

- 誤定式化を犯している OLS では、そもそも収束しない
- 多くの機械学習は、 $N^{1/2}$ よりも収束速度が遅い
 - R learner は、機械学習 (含む Nonparametric estimation) の収束の遅さを補完

2.18 Single learner

- $g_D(X)$ が、 $N^{1/2}$ よりも速い速度で収束する必要がある
 - 正しいモデルを OLS 推定する必要がある
 - * 実質”不可能”

2.19 イメージ: Single Model



3 Neyman's orthogonal condition

- R learner への議論は、より一般的な状況に適用可能

3.1 Estimand

- $$E[m(\theta_0, O, \mu)]$$

として、Estimand θ_0 を定義

- m については、
 - θ について一意に定まり、かつ微分可能
 - Neyman の直行条件を満たす
 - サンプル分割、 $N^{-1/4}$ よりも収束速度が速いのであれば、 μ は機械学習の推定結果で置き換えられる
- * 機械学習で推定できる必要はある

3.2 Neyman's orthogonality condition

- AI の微妙なミスに対して、estimator が影響を受けない

- $\partial m / \partial \mu = 0$

- * 関数で微分するとは ???

-

$$\left. \frac{\partial E[m(\theta_0, X, g(t))]}{\partial t} \right|_{t=0} = 0$$

- $g_Z(t) = t g_Z(X) + (1-t) \mu_Z(X), t \in [0, 1]$

- * 母平均を、何らかの関数に少し移動させる

- * ガトー微分

3.3 実装

- Neyman の直行条件を満たす m 関数は、以下の方法で導出できる
 - テイラー近似 (手計算) (Hines et al. 2022 がわかりやすい入門)
 - データから”自動計算”する (Chernozhukov, Newey, and Singh 2022)
 - * 現状、大衆的な実装方法はない

3.4 仮定の検討

- $n^{-1/4}$ よりも速い収束の保証は、現状強い仮定
 - X の数が多い場合に特に怪しい
 - * 現状は、「正しいモデルを仮定」するよりもマシなので、とりあえず目をつぶって応用している印象
 - * Best practice として、Stacking を利用
 - 本質的な代替案としては、高次近似の利用 (Bonvini et al. 2024 とその引用文献) だが、まだ基礎的理論研究が続いている印象

Reference

- Bonvini, Matteo, Edward H Kennedy, Oliver Dukes, and Sivaraman Balakrishnan. 2024. “Doubly-Robust Inference and Optimality in Structure-Agnostic Models with Smoothness.” *arXiv Preprint arXiv:2405.08525*.
- Chernozhukov, Victor, Whitney K Newey, and Rahul Singh. 2022. “Automatic Debiased Machine Learning of Causal and Structural Effects.” *Econometrica* 90 (3): 967–1027.
- Hines, Oliver, Oliver Dukes, Karla Diaz-Ordaz, and Stijn Vansteelandt. 2022. “Demystifying Statistical Learning Based on Efficient Influence Functions.” *The American Statistician* 76 (3): 292–304.
- Imbens, Guido W. 2021. “Statistical Significance, p-Values, and the Reporting of Uncertainty.” *Journal of Economic Perspectives* 35 (3): 157–74.