

# Inference on heterogeneity aware estimand

川田恵介

## Table of contents

1	Weighted average difference	1
1.1	サブサンプル平均	1
1.2	Estimand: Weighted average difference	2
1.3	Estimand: Proportion weight	2
1.4	Moment condition	2
1.5	Argumented inverse propensity score	2
1.6	Algorithm	3
2	Best Linear Projection for CATE	3
2.1	Algorithm	3
2.2	Best Linear projection	3
3	Proportional weight の問題点と対策	3
3.1	Overlap weight	4
3.2	Propensity score weight	4

## 1 Weighted average difference

- ここまで  $E[Y|D=1, X] - E[Y|D=0, X] = \tau$  を仮定
  - ほとんどの応用で  $X$  によって異なることが予想される
  - $\tau(X)$  = Conditional average difference (function)
  - 因果推論では Conditional average treatment effect (CATE) と呼ばれる

### 1.1 サブサンプル平均

- $X = x$  を満たすサブサンプルサイズが十分にあれば、ただのサブサンプル平均差で、応用上問題ない

- CATE を直接推定できる
- ほとんどの応用で、大量の  $X$  を用いるので、サブサンプルサイズは不足する

## 1.2 Estimand: Weighted average difference

- Estimand

$$\theta_0 = \int \tau(X) \times \omega(X) dX$$

- $\omega(X)$  = “研究者” が暗黙のうちに設定する集計用 Weight

## 1.3 Estimand: Proportion weight

- $\omega(X) = f(X)$ 
  - 因果推論では Average Treatment Effect と呼ばれる

$$\theta_0 = \int \tau(X) \times f(X) dX$$

## 1.4 Moment condition

- 複数存在する:  $\theta = E[m(Y, D, X)]$  where  $m(O)$

–

$$= \mu_Y(1, X) - \mu_Y(0, X)$$

–

$$= \frac{DY}{\mu_D(X)} - \frac{(1-D)Y}{1-\mu_D(X)}$$

## 1.5 Argumented inverse propensity score

- おすすめの Moment condition

•

$$m(O) = \mu_Y(1, X) - \mu_Y(0, X) + \underbrace{\frac{D(Y - \mu_Y(1, X))}{\mu_D(X)} - \frac{(1-D)(Y - \mu_Y(0, X))}{1 - \mu_D(X)}}_{Adjustment}$$

- Neyman's orthogonal condition を満たす

## 1.6 Algorithm

1. データ分割 (auxiliary/main data)
2.  $\mu_Y, \mu_D$  を auxiliary data (+ 機械学習) で推定する
3. Moment condition に代入  $m(O, g)$  し、main data を持ちいて平均値を推定、信頼区間とともに推定する

## 2 Best Linear Projection for CATE

- 平均差では、 $X$  との関係性について、何もわからない
  - 信頼区間もしっかり推定しつつ、CATE の持つ特徴を、もう少し理解することを目指す

### 2.1 Algorithm

1. データ分割 (auxiliary/main data)
  - 交差推定も活用可能
2.  $\mu_Y, \mu_D$  を auxiliary data (+ 機械学習) で推定する
3. Moment condition に代入  $m(O, g)$  し、main data を持ちいて  $m \sim Z$  を OLS で推定、信頼区間とともに推定する

### 2.2 Best Linear projection

- 以下の関数を推定する

$$\min E[(\tau(X) - g_\tau(Z))^2]$$

where  $Z \subset X$

- 線形モデルで近似する

$$g_\tau = \beta_0 + \beta_1 Z_1 + \dots + \beta_L Z_L$$

## 3 Proportional weight の問題点と対策

- 完璧な対策はない

### 3.1 Overlap weigh

- Proportional weight 以外にも色々な weight が存在する
- R learner でかつ  $D \in \{0, 1\}$  であれば、

$$\omega(X) = \frac{E[D|X](1 - E[D|X])f(X)}{\int E[D|X](1 - E[D|X])f(X)dX}$$

- Overlap weight と呼ばれる

### 3.2 Propensity score weight weigh

- 

$$\omega(X) = \frac{E[D|X]f(X)}{\int E[D|X]f(X)dX}$$

- 因果推論において、Average Treatment Effect on Treated において暗黙のうちに使用される