

部分線形モデル

Semiparametric 推定への応用

川田恵介

Table of contents

Semiparametric 推定への応用	2
準備: 収束	3
数値例	3
数値例	4
$X = 4$ についての比較	4
収束速度	5
Well Specified Model	5
\sqrt{N} CAN estimator	5
イメージ	5
例	6
例	6
まとめ	7
準備: 大表本理論に基づく推論	7
Well-specified model	7
OLS 推定	7
$N = 10$	8
$N = 200$	8
$N = 5000$	9
分解	9
信頼区間	9
不適切な区間	10
漸近正規性の活用	10
漸近正規性	10
漸近正規性	11
95% 信頼区間	12

サンプルサイズの影響	12
Misspecified model	13
中間まとめ	13
95% 信頼区間	13
典型的教師付き学習の応用	14
典型的教師付き学習の応用	14
Tree	14
Partialling Out	15
Partialling Out with Tree	15
まとめ	15
Partialling Out 推定量の特徴	16
Partialling Out	16
ばらつきの源泉は?	16
ポイント	16
Oracle 推定値	16
分解	17
Estimation Error	17
例題: 母分散の推定	17
書き換え	18
書き換え	18
Reducible \times Reducible	18
例	19
不適切な例: 小規模サンプル	19
Reducible \times Irreducible	20
例	20
不適切な例: 交差推定なし	21
PartiallingOut	21
分解	21
数値例	22
まとめ	22
Reference	22

Semiparametric 推定への応用

- Partial out 推定が持つ統計的性質を理解するために以下を” 復習”
 - 何を目標とするのか? (Well-Specified Model について成り立つ漸近性質)
 - 何について議論しているのか? (収束)

- Partialling out 推定の持つ、教師付き学習の収束の遅さを補う性質を紹介
 - SeminalPaper の一つは、Chernozhukov et al. (2018)


準備: 収束

- 大標本性質: 事例数が大きくなると近似的に成り立つ性質
 - “収束の速度” をざっくり理解
 - 詳しく知りたい人は、大学院レベルの計量分析のテキストなどを参照
- 基本アイディア: “いいレースになる” 単純な数式で記述


数値例

- $E[Y|X]$
 - $X \in [-10, 10]$ の整数
- Well-specified model: $Y \sim factor(X)$
- Prune Tree: 剪定をした決定木
- とともに一致推定量だが、
 - Well-specified model の方が、収束速度は同等以上

数値例



$X = 4$ についての比較



収束速度

- 収束速度の上限をシンプルに記述する
 - シンプルな”式”とのスピード勝負
- 発展: ランダウ記法 $\mathcal{O}(n^\alpha)$ and $o(n^\alpha)$

Well Specified Model

- $\beta = g(X = 4)$ が母集団における値 $\beta^P = E_P[Y|X = 4]$ に収束するかどうか
 - OLS で推定すると $\beta = E[Y_i|X_i = 4] := \sum_i Y_i / N|X_i = 4$
- 一致性を満たすので、 $\lim_{N \rightarrow \infty} (\beta - \beta^P) \rightarrow 0$
- 総和 $N \times \beta := \sum_i Y_i$ は発散する


\sqrt{N} CAN estimator

- $\lim_{N \rightarrow \infty} N^\alpha \times (\beta - \beta^P) = ?$
- 両極端な性質
 - $\lim_{N \rightarrow \infty} N^{\alpha=0} \times (\beta - \beta^P) \rightarrow 0$
 - $\lim_{N \rightarrow \infty} N^{\alpha=1} \times (\beta - \beta^P) \rightarrow \infty$
- 収束も発散もしない、“ちょうどいい” α があるのでは?
 - Yes !!!
 - $\alpha = 1/2$!!!


イメージ

- $N^\alpha(\beta - \beta^P) = \frac{\beta - \beta^P}{1/N^\alpha}$
 - 分子分母ともに 0 に向かって収束する
 - $\alpha = 1/2$ について、分子の収束スピードは分母と同等
- 多くの教師付き学習 (Nonparametric 推定) で得られる予測値 $g(X)$ は、 $E_P[Y|X]$ に収束するが、
 - $\alpha = 1/2$ に収束速度で負ける!!!

例



例



まとめ

- OLS は、 $1/N^{1/2}$ と同等の収束速度
 - ただし、Misspecified であれば、BLP に収束
- 代表的な教師付き学習の推定値は、 $1/N^{1/2}$ に収束速度で負ける
 - “収束が遅い”
- Partialling Out: $1/N^{1/4}$ には勝つ教師付き学習を前提

準備: 大表本理論に基づく推論

- サンラムサンプリング (IID) の仮定が持つ、母集団への含意は？
 - 母集団への詳細な仮定なしで何が言える？


Well-specified model

- “入門教科書” 的な問題設定
- $g(D, X) = \beta_0 + \beta_D D + \beta_1 X_1 + \dots + \beta_L X_L$
- $E_P[Y|D, X] = g(D, X)$ を達成する β^P が存在

OLS 推定


- $Y \sim X$ を Empirical Risk を最小にするように推定
 - 推定値のばらつき (Sampling Uncertainty) の源泉は？
 - Y, X のデータ上の分布の (研究者間での) 違い

N = 10




- 100 名研究者が独立して研究 (事例数 = 10)

N = 200



N = 5000



分解

- β_{∞} : サンプルサイズ無限大の元での推定値, β : 推定値

$$\underbrace{\beta^P}_{\text{真の値}} - \beta = \underbrace{\beta^P - \beta_{\infty}}_{=0 \text{ Consistency}}$$

$$+ \underbrace{\beta_{\infty} - E_P[\beta]}_{=0 : \text{Bias}}$$


$$\underbrace{E_P[\beta] - \beta}_{\neq 0}$$

信頼区間

- 「推定値 = 真の値」を前提に議論を始めると、“100%” 間違ふ
 - 独立した研究者間での合意も不可能
- ハードルを下げる
 - 大多数 (典型的には 95%) の研究者について、真の値を含む区間 (信頼区間) を計算する

- 注意: 信頼区間自体は、独立した研究間で異なる
 - 合意可能なのは、「多くの研究者について、信頼区間は真の値を含む」のみ

不適切な区間



漸近正規性の活用

- 信頼区間を計算するには、推定値の分布 (研究者間の散らばり具合) への仮定が必要
 - 本当の分布は、母分布に依存
- 母分布に直接仮定を置くアプローチ: 教科書的な最尤法、ベイズ
- 近似性質を仮定するアプローチ: サンプル方法への仮定 (ランダムサンプリング) “のみ” に基づいて導出される、漸近性質 (サンプルサイズがある程度大きければ、近似的になりつつ性質) を活用

漸近正規性

- 中心極限定理 + 不偏性から導ける漸近正規性を活用


$$\lim_{N \rightarrow \infty} \sqrt{N} \times (\beta - \beta^P) \sim \mathcal{N}$$

- サンプルサイズが大きければ、正規分布で近似できる

– 真の値よりも、“早め”に収束する


- \sqrt{N} CAN estimator

漸近正規性




- 注意: 真の値からの”距離”だけわかる

95% 信頼区間



サンプルサイズの影響



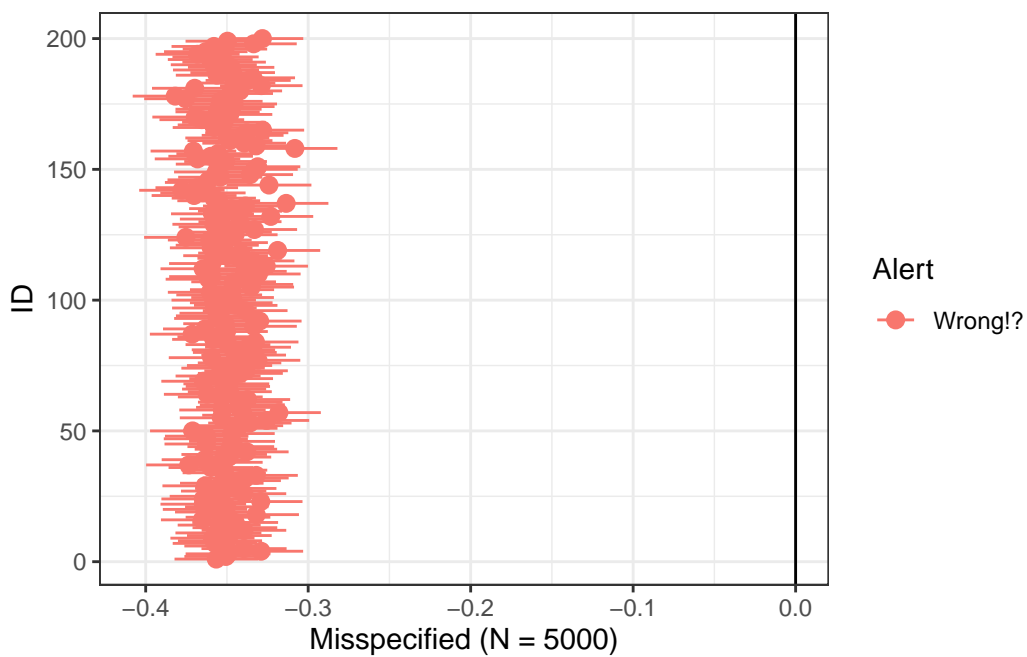
Misspecified model

- $g(D, X) = \beta_0 + \beta_D D + \beta_1 X_1 + \dots + \beta_L X_L$
 - β を推定
- β をどう選んでも、 $E_P[Y|D, X] \neq g(D, X)$ (Approximation Error)
 - OLS で推定すると **BLP** β^{BLP} についての CAN estimator
 - BLP について信頼区間を提供

中間まとめ

$$\begin{aligned}\beta^{BLP} - \beta &= \underbrace{\beta_{BLP}(X) - \beta_{\infty}(X)}_{=0} \\ &+ \underbrace{\beta_{\infty}(X) - E[\beta]}_{=0} \\ &\underbrace{E[\beta] - \beta}_{\sim \mathcal{N}}\end{aligned}$$

95% 信頼区間



典型的教師付き学習の応用



- $\beta^P = E_P[E_P[Y|D=1, X] - E_P[Y|D=0, X]]$ を推定できるか？
- 一致性を持つ予測モデル $g(D, X)$ を推定
 - $\beta = \sum_i [g(D+1, X_i) - g(D, X_i)]$

典型的教師付き学習の応用

$$\begin{aligned} \beta^P - \beta &= \underbrace{\beta^P - \beta_\infty}_{\approx 0} \\ &+ \underbrace{\underbrace{\beta_\infty - E_P[\beta]}_{\neq 0} + \underbrace{E_P[\beta] - \beta}_{\neq 0}}_{?} \end{aligned}$$

- 一般に、母集団の明確な特徴について、CAN estimator にならない
 - 何を推定している？

Tree



Partialling Out


- 目指すは

$$\beta^P - \beta = \underbrace{\beta^P - \beta_\infty}_{\simeq 0}$$

$$+ \underbrace{\beta_\infty - E_P[\beta]}_{\simeq 0}$$

$$\underbrace{E_P[\beta] - \beta}_{\sim \mathcal{N}}$$

Partialling Out with Tree



まとめ

- CAN estimator であれば、近似的な信頼区間を用いて、母集団の性質について議論できる
- OLS は、**BLP** についての信頼区間を形成できるが、一般に周辺化された平均差についてではない
 - 特定の変数間の関係性を捉えるのには向いていない
- 教師付き学習の Naive な応用は、“何を推定しているのかわからない”

Partialling Out 推定量の特徴

- Partialling Out 推定量はどのような大样本性質を持つのか？
 - 緩やかな条件 (機械学習の推定値が $1/n^{1/4}$ よりも早い速度で、条件つき平均値に収束) の下で
 - 単回帰と同じ性質 (\sqrt{N} CAN) !!!!

Partialling Out

- 議論を見やすくするために、データを 2 分割 (Auxiliary/Estimation データ) し、交差推定しない
- 1. Auxiliary データを用いて、 $g_Y(X) \sim E_P[Y|X]$, $g_D(X) \sim E_P[D|X]$ を推定
- 2. Estimation データを用いて、 $Y - g_Y(X) \sim D - g_D(X)$ を OLS 推定し、 β を推定

ばらつきの源泉は？

1. Estimation データにおける Y, D の分布
2. Auxiliary データから推定される予測関数 $g_Y(X), g_D(X)$

ポイント

- 一般に、 $g_Y(X), g_D(X)$ の収束が遅いので、 β の収束速度は $1/n^{1/2}$ に負けるが、、
- $g_Y(X), g_D(X)$ が $1/n^{1/4}$ よりも早ければ、2 番目の源泉は漸近的に無視できる!!!
 - $g_Y(X), g_D(X)$ が”推定されている”という事実を漸近的に無視できる!!!

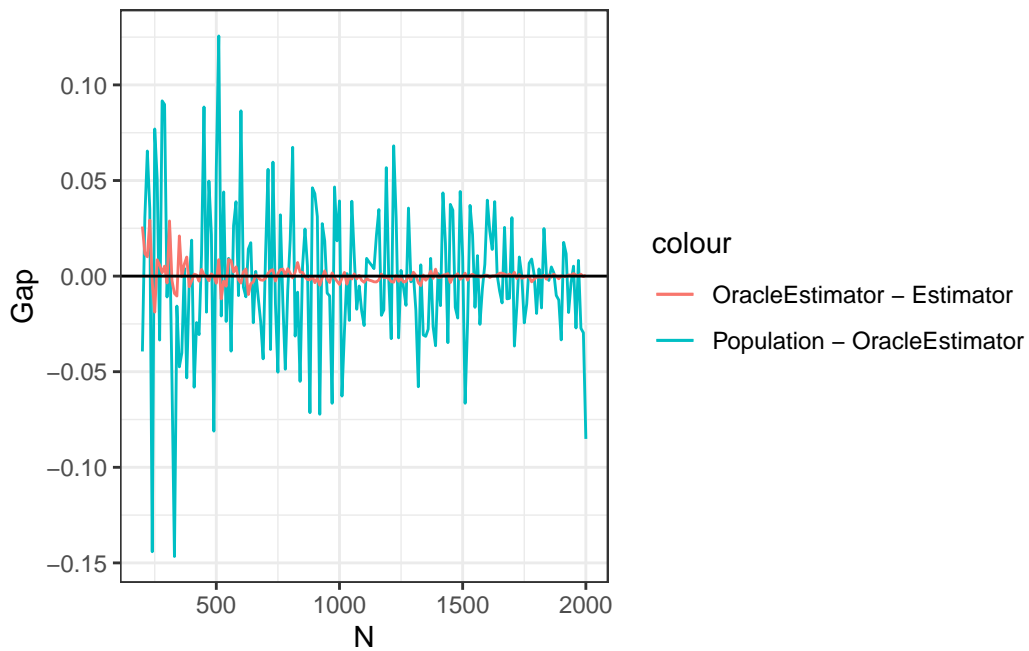
Oracle 推定値

- 理解の助けとして、仮想的な推定値 (Oracle Estimator β^{Oracle}) を導入
- $Y - E_P[Y|X] \sim D - E_P[D|X]$ を OLS した結果得られる係数値
 - E_P は非確率変数なので、既知のルールで変換した変数同士を回帰しているだけ
 - ばらつきの厳選は、Estimation データにおける Y, D の分布のみ
 - \sqrt{N} CAN estimator

分解

$$\begin{aligned}\beta^P - \beta &= \underbrace{\beta^P - \beta^{Oracle}}_{\sim \mathcal{N}} \\ &+ \underbrace{\beta^{Oracle} - \beta}_{\rightarrow 0 !!!}\end{aligned}$$

Estimation Error



例題: 母分散の推定

- 性質を理解しやすくするために、よりシンプルな状況を考える
- Estimand (母分散): $E_P[(Y - E_P[Y])^2]$
- Estimator $E[(Y - g)^2]$
 - g は Auxiliary データから推定

書き換え

$$E[(Y - g)^2] = E[(\underbrace{Y - E_P[Y]}_{IrreducibleError} + \underbrace{E_P[Y] - g}_{ReducibleError})^2]$$

書き換え

$$\begin{aligned} E[(Y - g)^2] &= \underbrace{E[(Y - E_P[Y])^2]}_{Oracle} \\ &+ 2 \times \underbrace{E[(E_P[Y] - g) \times (Y - E_P[Y])]}_{Reducible \times Irreducible} \\ &+ \underbrace{E[(E_P[Y] - g) \times (E_P[Y] - g)]}_{Reducible \times Reducible} \end{aligned}$$

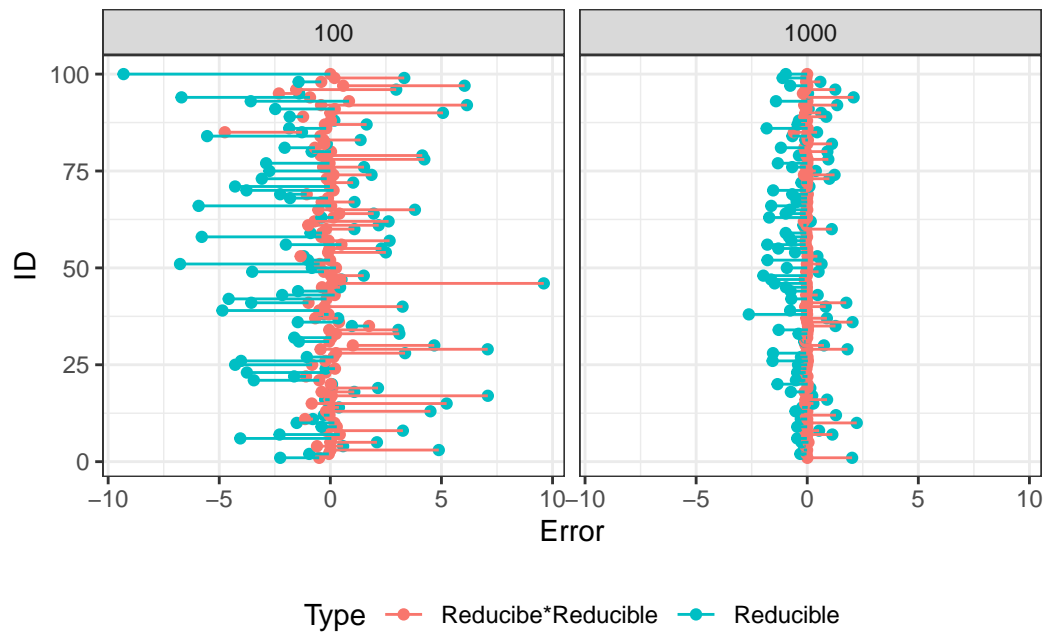
Reducible × Reducible

$$E[(E_P[Y] - g) \times (E_P[Y] - g)]$$


$$= \underbrace{(E_P[Y] - g) \times (E_P[Y] - g)}_{Reducible \times Reducible}$$

- Auxiliary データが研究者によって異なるので、ばらつきをもつ
 - g がバイアスを持つのであれば、掛け算もバイアスを持つ
- ただし掛け算なので、 g の推定精度が十分に高ければ (乖離が”1”より小さければ)、掛け算の方が乖離は小さくなる
 - Reducible 単体よりも、収束速度は早くなる

例



不適切な例: 小規模サンプル




Reducible × Irreducible

$$2 \times E[\underbrace{(E_P[Y] - g) \times (Y - E_P[Y])}_{\text{無相関}}]$$


$$= 2 \times (E_P[Y] - g) \times \underbrace{[E[Y] - E_P[Y]]}_{1/\sqrt{N} \text{で収束}}$$

- 注意: g の推定を別のデータで行っているので、書き換えができる
 - バイアスの除去
 - 収束の改善

例



不適切な例: 交差推定なし



PartiallingOut

- ほぼ同じ議論が適用できる

$$\beta = \frac{E[(D - E[D|X])(Y - E[Y|X])]}{E[(D - E[D|X])^2]}$$

$$= \frac{E[(D - E_P[D|X] + E_P[D|X] - E[D|X])(Y - E_P[Y|X] + E_P[Y|X] - E[Y|X])]}{E[(D - E[D|X])^2]}$$

分解


- Oracle 推定料 + Reducible × Reducible + Reducible × Irreducible
- 大きな違いは、*Reducible* × *Reducible*

$$= E[(E_P[Y|X] - g_Y(X)) \times (E_P[D|X] - g_D(X))]$$

- Yを予測する”AI” と Dを予測する”AI” の間違いの掛け算
 - 十分に精度が高ければ、“AI” 同士の”ダブルチェック”により、間違いを減らせる

- 精度が悪いと、間違いが増加

数値例



まとめ

- Partialling out 推定は、 g_Y, g_D が $n^{-1/4}$ よりも早く収束すれば、漸近正規性
 - サンプルサイズがある程度大きくなれば、バイアスを無視できる (Debiased)
- AI 同士の”掛け算” (Double) にすることで、収束速度を上げている
 - 交差推定も活用
- より一般化可能 (後述)

Reference

Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. 2018. “Double/Debiased Machine Learning for Treatment and Structural Parameters.” *The Econometrics Journal* 21 (1): C1–68.