

平均差の NonParametric 推定

異質性分析

川田恵介

Table of contents

1	平均差の機械学習による推定	2
1.1	条件付き平均差の近似モデル	2
1.2	応用: 個人因果効果の予測	2
1.3	応用: 個人因果効果の予測	2
1.4	分解	3
1.5	分解: BLP	3
1.6	分解: ここからの手法	3
1.7	T Learner (Künzel et al. 2019)	3
1.8	数値例	4
1.9	数値例	4
1.10	数値例	5
1.11	Regulization bias	5
1.12	DR-learner	5
1.13	DR-learner (Kennedy 2020)	6
1.14	R-learner (Nie and Wager 2021)	6
1.15	R-learner (Nie and Wager 2021)	6
1.16	Causal Forest	6
1.17	数値例: Causal Forest VS T-Learner	7
1.18	推定誤差	7
1.19	Example. Britto, Pinotti, and Sampaio (2022)	7
1.20	Example. Britto, Pinotti, and Sampaio (2022)	8
1.21	補論: 予測性能	8
1.22	補論: Stacking	8
2	異質性の発見	8
2.1	Motivating example	8
2.2	Group average treatment effect (Chernozhukov et al. 2018)	9

2.3	Algorithm	9
2.4	Example. Fukai, Ichimura, and Kawata (2021)	9
2.5	Example. SetUp	9
2.6	Nuisance	10
2.7	Example. Prediction	11
2.8	Example. GATE	11
2.9	Example. GATE	12
2.10	Classification analysis	12
2.11	Example. Classification analysis	13
2.12	付論: Treatment effect risk	13
	Reference	14

1 平均差の機械学習による推定

- Chap 13 and 14 in CausalML 参照

1.1 条件付き平均差の近似モデル

- Estimand:

$$\theta_{\tau}(X) = E[Y|D = 1, X] - E[Y|D = 0, X]$$

の近似モデル $g_{\tau}(X)$

- 中心極限定理などにはこだわらず、近似精度 $E[(\tau(X) - g_{\tau}(X))^2]$ の最小化を目標とする

1.2 応用: 個人因果効果の予測

- 潜在結果の枠組み (Imbens 2022) を用いると、個人因果効果を定義できる

– $D = 0$ の世界線における結果 $Y_i(0)$ と $D = 1$ の結果 $Y_i(1)$ の差 $\tau_i = Y_i(1) - Y_i(0)$

* “合理的” 意思決定の基礎情報 (限界効果)

- 異なる世界線は原理的に観察不可能なので、 τ_i を推定することは”不可能”

– 因果推論の根本問題

1.3 応用: 個人因果効果の予測

- 通常の枠組みに収められる

•

$$E[(\tau_i - g_{\tau}(X_i))^2]$$

を最小にする関数 g_τ を推定する

– 理想の予測モデル:

$$g_\tau(X_i) = E_P[\tau_i|X_i]$$

– τ_i が観察できないので、直接的な推定はできない

1.4 分解

$$\begin{aligned} \tau_i - g_\tau(X_i) &= \underbrace{\tau_i - E_P[\tau|X]}_{IrreducibleError} \\ &+ \underbrace{E_P[\tau|X] - g_{\tau,\infty}(X)}_{ApproximationError} + \underbrace{g_{\tau,\infty}(X) - g_\tau(X)}_{EstimationError} \end{aligned}$$

1.5 分解: BLP

- $g_\tau(X) \sim \beta_0 + \dots + \beta_L X_L$ の推定法は、前々回議論

$$\begin{aligned} \tau_i - g_\tau(X_i) &= \underbrace{\tau_i - E_P[\tau|X]}_{IrreducibleError} \\ &+ \underbrace{E_P[\tau|X] - g_{\tau,\infty}(X)}_{ApproximationError \neq 0} + \underbrace{g_{\tau,\infty}(X) - g_\tau(X)}_{EstimationError \sim N(0, \sigma^2)} \end{aligned}$$

- Approximation error が大きい可能性がある

1.6 分解: ここからの手法

$$\begin{aligned} \tau_i - g_\tau(X_i) &= \underbrace{\tau_i - E_P[\tau|X]}_{IrreducibleError} \\ &+ \underbrace{E_P[\tau|X] - g_{\tau,\infty}(X) + g_{\tau,\infty}(X) - g_\tau(X)}_{同時に最小化を目指す} \end{aligned}$$


1.7 T Learner (Künzel et al. 2019)

- Varian (2014)
- 1. $E[Y|1, X] \sim g_Y(1, X), E[Y|0, X] \sim g_Y(0, X)$ を教師付き学習で推定
- 2. $g_\tau(X) = g_Y(1, X) - g_Y(0, X)$

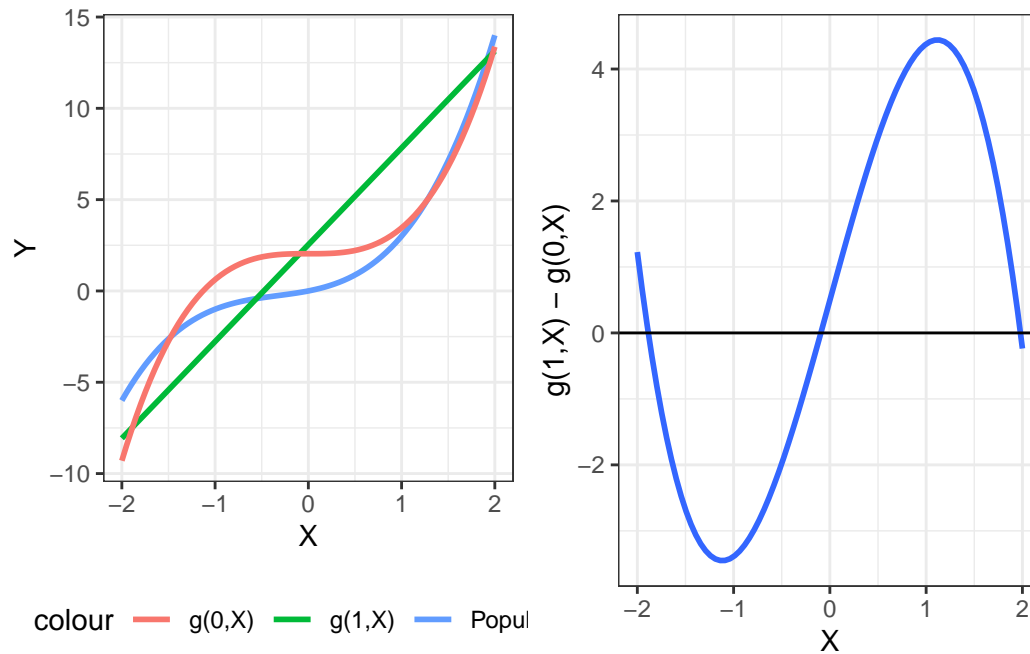
1.8 数値例

- $E[Y|D, X] = X + X^2 + X^3$
 - $D = 1/0$ のサブグループごとに LASSO を用いて、 $Y \sim X + X^2 + X^3$ を推定
 - $\Pr[D == 1] = 0.1$
 - $\Pr[D == 0] = 0.9$

1.9 数値例



1.10 数値例



1.11 Regularization bias

- 教師付き学習は、“適切に単純化する”はずだが、過剰に複雑化させている
 - D の分布が偏っているケースにおいて、非常に深刻
- 問題点: 最適化問題の設定ミス
 - $\min E[(\tau_i - g_\tau)^2]$ ではなく、 $\min E[(Y_i - g_\tau)^2]$ を目指して単純化が行われるため

1.12 DR-learner

- 母集団にモデルを適合できれば、 $E[Y|1, X] - E[Y|0, X]$ を識別できる最適化問題を解く
- AIPW を応用: Psude-outcome を定義

$$\begin{aligned} \phi(X) &= g_Y(1, X) - g_Y(0, X) \\ &+ \frac{D(Y - g_Y(1, X))}{g_D(X)} - \frac{(1 - D)(Y - g_Y(0, X))}{1 - g_D(X)} \end{aligned}$$

- $E[\phi(X)|X] = \tau(X)$ なので、 $\phi(X)$ の近似モデルは平均差の良い近似モデルであることが期待できる

1.13 DR-learner (Kennedy 2020)

1. $g_Y(d, X) \sim E[Y|d, X], g_D(X) \sim E[D|X]$ を交差推定
2. Psude outcome $\phi(X)$ を計算
3. $\phi(X) \sim X$ をなんらかの Algorithm で推定
 - 機械学習も使用可能

1.14 R-learner (Nie and Wager 2021)

- Partialling Out の一般化

$$\min E[(Y - E[Y|X] - \tau(X) \times [D - E[D|X]])^2]$$

- PartialingOut した Y と D について、母集団における誤差を最小化するように $\tau_P(X)$ を定義
 - 最も母集団に適合する $\tau(X)$ 関数を推定

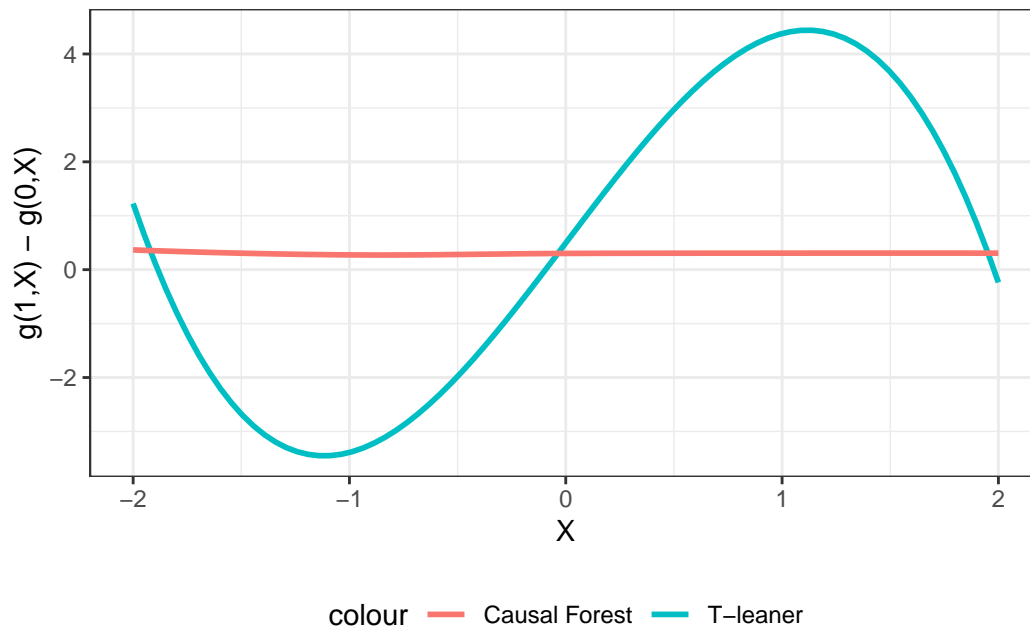
1.15 R-learner (Nie and Wager 2021)

1. $g_Y(X) \sim E[Y|X], g_D(X) \sim E[D|X]$ を交差推定
2. $E_P[(Y - g_Y(X) - \tau(X) \times [D - f_D(X)])^2]$ を近似的に最小化するよう τ を推定
 - 2段階目にも、教師付き学習も活用可能
 - 前回は OLS

1.16 Causal Forest

- R learner の特殊ケース
- 2段階目を RandomForest で実装
- 様々な工夫 (Chap 14.4 in CausalML 参照)

1.17 数値例: Causal Forest VS T-Learner



1.18 推定誤差

- 2段階目も教師付き学習で推定した場合、一般に推定誤差 (母平均との乖離リスク) を推定することは困難
- Causal Forest は例外的に可能
 - ただし X の数は少ない必要がある
 - (川田の経験上)、信頼区間がかなり大きくなる

1.19 Example. Britto, Pinotti, and Sampaio (2022)

- 大規模 (整理) 解雇 = D は、犯罪 = Y を増加するか?
 - 司法データ (裁判日誌) と雇用データ (Employee-Employer matched data) を名寄せ !!! したパネルデータ (Difference-in-Difference)
 - * ブラジルの男性について、平均効果 23%

1.20 Example. Britto, Pinotti, and Sampaio (2022)

- BLP 分析より、若年・短い勤続年数の労働者において大きい
- 98 % の労働者について、“有意” な効果が検出
 - 幅広い犯罪の拡大効果をもつ

1.21 補論: 予測性能

- 色々な提案
 - Rank Average Treatment Effect (Yadlowsky et al. 2021) は grf に実装済み

1.22 補論: Stacking

- $g_{\tau(X)}$ 自体も集計できる
1. サンプルを Prediction/Confirm データに分割
 2. Prediction データのみを用いて、 $g_{\tau,1}(X), \dots, g_{\tau,L}(X)$ を推定する
 3. Confirm データを用いて、psud-outcome $\phi(X)$ を推定し、 $\phi(X) \sim g_{\tau,1}(X) + \dots + g_{\tau,L}(X)$ を OLS 回帰する

2 異質性の発見

- 機械学習により推定された関数について、安定的な統計的推論は難しい
 - Causal forest でも、 X の数が多い、ないし Random Forest が適さない母集団である可能性がある
- “顕著な効果” をもつグループの存在を示すのみであれば、より選択肢が広がる

2.1 Motivating example

X	Tau(X)	Pr[X]
1	10	0.1
2	1	0.8
3	-2	0.1

- 平均効果: $10 \times 0.1 + 1 \times 0.8 - 2 \times 0.1 = 0.7$

- 上位 10 % の平均効果 = 10
- 下位 10 % の平均効果 = -2

2.2 Group average treatment effect (Chernozhukov et al. 2018)

- Estimand: $E[Y|1, X] - E[Y|0, X]$ の予測値 $g_\tau(X)$ を”前提”として、

$$E[\tau(X)|g_\tau(X) \in \{\tau_-, \tau_+\}]$$

- 予測モデルは、因果効果の異質性を探索するための、シグナルとしてのみ用いる
 - 予測モデルについての統計的推論は”不要”

2.3 Algorithm

1. サンプルを Prediction/Confirm データに分割
 2. Prediction データのみを用いて、 $g_\tau(X)$ を推定する
 3. Confirm データを用いて、Nuisance 関数および GATE を推定する
- 交差推定を行う場合は、sequential test が必要 (Wager 2024)

2.4 Example. Fukai, Ichimura, and Kawata (2021)

- 2019/2020 年 = D の就業状態 = Y を比較
 - COVID の”効果”
- 過去の就業状態や年齢など = X について GATE を推定
 - COVID の”効果” は一部の層に集中している

2.5 Example. SetUp

```
set.seed(111)

library(tidyverse)
library(mlr3verse)
library(DoubleML)

Data = read_csv("Public/Data.csv") |>
```

```

filter(TradeYear == 2022)

Group = sample(
  1:2,
  nrow(Data),
  replace = TRUE
)

Y = Data$Price |> log()

D = Data$Reform

Z = Data |>
  model.matrix(
    ~ Size + Distance + Tenure ,
    data = _
  )

Z = Z[,-1]

X = Data |>
  model.matrix(
    ~ poly(Size,2) + poly(Distance,2) + poly(Tenure,2),
    data = _
  )

X = X[,-1]

```

2.6 Nuisance

```

TaskPrediction = double_ml_data_from_matrix(
  y = Y[Group == 1],
  d = D[Group == 1],
  X = X[Group == 1,]
)

TaskConfirm = double_ml_data_from_matrix(
  y = Y[Group == 2],
  d = D[Group == 2],

```

```

X = X[Group == 2,]
)

ModelPrediction = DoubleMLPLR$new(
  TaskPrediction,
  lrn("regr.cv_glmnet", s = "lambda.min"),
  lrn("classif.cv_glmnet", s = "lambda.min"),
  n_folds = 2
)

ModelConfirm = DoubleMLIRM$new(
  TaskConfirm,
  lrn("regr.cv_glmnet", s = "lambda.min"),
  lrn("classif.cv_glmnet", s = "lambda.min"),
  n_folds = 2
)

lgr::get_logger("mlr3")$set_threshold("warn")

ModelPrediction$fit(store_predictions = TRUE)

ModelConfirm$fit(store_predictions = TRUE)

```

2.7 Example. Prediction

```

FitTau = grf::causal_forest(
  X = Z[Group == 1,],
  W = D[Group == 1],
  Y = Y[Group == 1],
  Y.hat = ModelPrediction$predictions$ml_l,
  W.hat = ModelPrediction$predictions$ml_m
) |>
predict(Z)

```

2.8 Example. GATE

```

Cutoff = FitTau$predictions[Group == 2] |> quantile(probs = c(1/3,2/3))

```

Cutoff


33.33333% 66.66667%
0.03954255 0.13648334

```
Score = ModelConfirm$psi_b[,1,1]

estimatr::lm_robust(
  Score ~ 1,
  subset = FitTau$predictions[Group == 2] > Cutoff[2])
```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
(Intercept)	0.2464015	0.01768526	13.93259	4.393406e-42	0.2117169	0.281086	1899

2.9 Example. GATE



2.10 Classification analysis

- Chernozhukov et al. (2018)
- どのようなサブグループについて、効果が大きい/小さいか?
- Estimand: ある背景変数 X_l について

$$E[X_l | g_\tau(X) > Q(q)] - E[X_l | g_\tau(X) \leq Q(q)]$$

—

$$Q(q) =$$

qth quantile of $q_\tau(X)$

2.11 Example. Classification analysis

```
Data |>
  filter(
    Group == 2
  ) |>
  select(
    Size,
    Distance,
    Tenure
  ) |>
  mutate(
    Group = FitTau$predictions[Group == 2] > Cutoff[2]
  ) |>
  gtsummary::tbl_summary(by = Group)
```

Characteristic	FALSE, N = 3,802	TRUE, N = 1,900
Size	35 (20, 60)	50 (30, 60)
Distance	6.0 (4.0, 9.0)	6.0 (4.0, 10.0)
Tenure	12 (7, 17)	36 (28, 43)

2.12 付論: Treatment effect risk

- Kallus (2023) により提案

•

$$E_P[\tau(X)|\tau(X) \leq Q(q)]$$

—

$$Q(q) =$$

qth quantile of $\tau(X)$

- Estimand が完全に母集団上で定義できており、解釈がより明確
- **Neyman の直行条件**を満たすので、 g の推定誤差は漸近分布を計算する際に無視できる

Reference

- Britto, Diogo GC, Paolo Pinotti, and Breno Sampaio. 2022. “The Effect of Job Loss and Unemployment Insurance on Crime in Brazil.” *Econometrica* 90 (4): 1393–423.
- Chernozhukov, Victor, Mert Demirer, Esther Duflo, and Ivan Fernandez-Val. 2018. “Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments, with an Application to Immunization in India.” National Bureau of Economic Research.
- Fukai, Taiyo, Hidehiko Ichimura, and Keisuke Kawata. 2021. “Describing the Impacts of COVID-19 on the Labor Market in Japan Until June 2020.” *The Japanese Economic Review* 72 (3): 439–70.
- Imbens, Guido W. 2022. “Causality in Econometrics: Choice Vs Chance.” *Econometrica* 90 (6): 2541–66.
- Kallus, Nathan. 2023. “Treatment Effect Risk: Bounds and Inference.” *Management Science* 69 (8): 4579–90.
- Kennedy, Edward H. 2020. “Towards Optimal Doubly Robust Estimation of Heterogeneous Causal Effects.” *arXiv Preprint arXiv:2004.14497*.
- Künzel, Sören R, Jasjeet S Sekhon, Peter J Bickel, and Bin Yu. 2019. “Metalearners for Estimating Heterogeneous Treatment Effects Using Machine Learning.” *Proceedings of the National Academy of Sciences* 116 (10): 4156–65.
- Nie, Xinkun, and Stefan Wager. 2021. “Quasi-Oracle Estimation of Heterogeneous Treatment Effects.” *Biometrika* 108 (2): 299–319.
- Varian, Hal R. 2014. “Big Data: New Tricks for Econometrics.” *Journal of Economic Perspectives* 28 (2): 3–28.
- Wager, Stefan. 2024. “Sequential Validation of Treatment Heterogeneity.” *arXiv Preprint arXiv:2405.05534*.
- Yadlowsky, Steve, Scott D. Fleming, Nigam Haresh Shah, Emma Brunskill, and Stefan Wager. 2021. “Evaluating Treatment Prioritization Rules via Rank-Weighted Average Treatment Effects.” In.