

# Estimate Partial Linear Model

機械学習の経済学への応用

川田恵介

## 問題設定

- $E[Y|D, X]$  の**特定**の特徴 (Estimand) を推定
- 母集団において、以下を**仮定**

$$E[Y|D, X] = \underbrace{\beta_D}_{Interest} D + \underbrace{f(X)}_{Unkwnon}$$

- Partial Linear Model (Robinson 1988)
- OLS:  $f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_L X_L$  の一般化
- 定式化に誤りがあっても解釈可能 (後日)

## 推定アルゴリズム: Partialling-out (Robinson 1988)

1.  $E[Y|X], E[D|X]$  を推定  $\rightarrow f_Y(X), f_D(X)$ 
  - 機械学習 + 交差推定 (Chernozhukov et al. 2018)
2.  $Y - f_Y(X)$  を  $D - f_D(X)$  で回帰 (定数項は含めない)
3.  $f_Y(X), f_D(X)$  の推定誤差を**無視**して、信頼区間を RobustStandardError を用いて推定
  - 機械学習を Nuisance function を推定するツールとして使用

## 直感

$$Y = \beta_D D + f(X) + \underbrace{u}_{Y - E[Y|D, X] \text{ (Mean Zero)}}$$

$$E[Y|X] = \beta_D E[D|X] + f(X)$$

- 両辺を引くと

$$Y - E[Y|X] = \beta_D \times (D - E[D|X]) + u$$

## OLS との関係性: FWL 定理

- FWL 定理より、OLS 推定は以下のアルゴリズムで書き下せる
1.  $E[Y|X], E[D|X]$  を推定  $\rightarrow f_Y(X), f_D(X)$
  - 同じ OLS + 非交差推定
  2.  $Y - f_Y(X)$  を  $D - f_D(X)$  で回帰 (定数項は含めない)
  3.  $f_Y(X), f_D(X)$  の推定誤差を無視して、信頼区間を RobustStandardError を用いて推定

## 論点

- なぜ OLS ではダメなのか？
  - 過剰適合 あるいは 誤定式化が生じるため
- なぜ機械学習を応用した他のアルゴリズムではダメなのか？
  - 収束 (漸近) 性質が悪い

## OLS の問題点

KeyConcept: Misspecification

- 推定モデルの定式化 = 推定されうる関数の集合
- Misspecification:  $\beta \in R_L$  をどう選んでも、 $f_Y(X) \neq E[Y|X]$ 
  - $\beta$  を増やせば、Misspecification は避けられるが、、、

## ざっくり性質

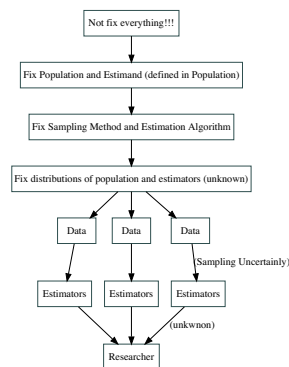
- “正しいモデル”: Misspecification が無い +  $\beta$  の数  $\ll$  サンプルサイズ
  - 真のパラメータへの信頼区間を形成可能
- “間違ったモデル”: Misspecification
  - 線形近似モデルへの信頼区間形成可能  $\neq$  真のパラメータ

- 過剰なパラメータモデル
  - 過剰適合問題
  - 推定不可能、精度の大幅な悪化、信頼区間爆発

## 信頼区間

- 一般に推定値と真の値は、一致し得ない
  - 無限に大きいサンプルサイズが必要
  - 母集団への含意が不明瞭
- 代替的に信頼区間を用いて議論
  - 高い確率で真の値を含んだ区間を得られるため

## 復習: Repeated Sampling Framework



## KeyConcepts

- $\beta_0$  : 母集団におけるパラメータ (Fix but unknown)

- $\beta_N$  : サンプルサイズ  $N$  のデータから計算された推定値 (Random with unknown distribution)

## Key Property


- 大標本
  - Consistency :  $\beta_0 - \beta_{N \rightarrow \infty} \rightarrow 0$ 
    - \* 経済学では主張の根拠にしづらい
  - Asymptotic Normality :  $\lim_{N \rightarrow \infty} \sqrt{N}(\beta_0 - \beta_N) \rightarrow N(0, \sigma^2)$ 
    - \* 信頼区間の近似計算の基盤
- 有限標本
  - Unbiasedness:  $E[\beta_N] = \beta$

## OLS + 正しいモデル


- ランダムサンプルデータであれば、Asymptotic Normality を満たす
  - Consistency, Unbiasedness も
- 独立して研究を行う大量の研究者をイメージ
  - 結論は全員異なる
  - サンプルが大きくなるにつれて、真の値に近い推定値を得る
  - **多くの研究者が真の値を含む信頼区間を得る**

## Numerical Example

### PointEstimation




### ConfidenceInterval




## Wrong OLS

- Estimate  $E[Y|D, X] = \beta_0 + \beta_D D + \beta_1 X$




## OverParametrization

- Estimate  $E[Y|D, X] = \beta_D D + \beta_1 X + \sum_{g \in StepFunction} \beta_g I(x \in g)$



### OverParametrization



### OLS まとめ

- OLS + 少数のパラメタ without miss-specification: 素晴らしいパフォーマンス

- 非現実的？
- OLS + Miss-specification
  - Invalid Confidence Interval, Non-Consistent
- OLS + 大量のパラメータ
  - 過剰適合、標準誤差の爆発、信頼区間が広すぎる|計算できない

## 付録: RCT

- シンプルな線形モデルを用いた因果推論は、“TopJournal”でも散見される
- 重要な例外:  $D$  がランダムに決定
  - $X$  を導入しても漸近性質は悪化しない (Lin 2013)
  - “Top Journal”における因果推論の多くは、RCT | 綺麗な自然実験を用いたものが多い
- 機械学習の応用にも有益

## 付録: Saturated Model

- $f(X)$  = ありうる全ての  $X$  の組み合わせについてのダミー変数を導入し、OLS 推定 (Angrist and Pischke 2009)
  - Saturated Model
- Partial Linear Model の範囲内では誤定式化は起きない
  - より一般的なケースでも、解釈可能
- 過剰適合は大丈夫???

## 機械学習の応用

- 基本戦略「過剰に複雑なモデルを適度に単純化する」を踏襲
- Partialling-out を推奨
  - Nuisance 関数の推定に機械学習を使用

## 非推奨: Machine Learning as Modelling

- $E[Y|D, X]$  を直接推定



- 例: 以下を推定


$$\min \sum_i [Y - \beta_D \times D - \underbrace{\tilde{f}(X)}_{\text{十分に複雑な線形モデル}}]^2 + \lambda \sum_l |\beta_l|$$

- LASSO


### 非推奨: Single MachineLearning

1.  $D \in \{0, 1\}$  を想定
2.  $E[Y|D=0, X]$  を推定  $\rightarrow f_{Y0}(X)$
3.  $Y - f_{Y0}(X)$  を  $D$  で回帰


### LASSO



## Single LASSO



## Double LASSO



## まとめ: 機械学習

- Population Risk (MSE) を最小化するように設計
  - パラメータの推論が主目的ではない
- 非常に緩やかな仮定の元で、一致性が成り立つアルゴリズムは複数存在
- 一般に（有限標本）バイアスが発生
- 収束が遅い、漸近正規性が成り立たなず、信頼区間計算が難しい
  - Bootstrap 法でも同じ

## まとめ: 理想的な OLS

$$\begin{aligned}\beta_{interest} - \beta_N &= \underbrace{\beta_{interest} - \beta_0}_{Identification} \\ &+ \underbrace{\beta_0 - \beta_{N \rightarrow \infty}}_{=0} + \underbrace{\beta_{N \rightarrow \infty} - E[\beta_N]}_{=0} + \underbrace{E[\beta_N] - \beta_N}_{\text{正規分布で近似}}\end{aligned}$$

- 一般に  $\lim_{N \rightarrow \infty} \sqrt{N}(\beta_N - \beta_0) \rightarrow Normal$

## まとめ: 誤定式化

$$\begin{aligned}\beta_{interest} - \beta_N &= \underbrace{\beta_{interest} - \beta_0}_{Identification} \\ &+ \underbrace{\beta_0 - \beta_{N \rightarrow \infty}}_{\neq 0} + \underbrace{\beta_{N \rightarrow \infty} - E[\beta_N]}_{=0} + \underbrace{E[\beta_N] - \beta_N}_{\text{正規分布で近似}}\end{aligned}$$

- 一般に  $\lim_{N \rightarrow \infty} \sqrt{N}(\beta_N - \beta_0) \rightarrow \infty$

## まとめ: 複雑すぎるモデル

$$\begin{aligned}\beta_{interest} - \beta_N &= \underbrace{\beta_{interest} - \beta_0}_{Identification} \\ &+ \underbrace{\beta_0 - \beta_{N \rightarrow \infty}}_{=0} + \underbrace{\beta_{N \rightarrow \infty} - E[\beta_N]}_{=0} + \underbrace{E[\beta_N] - \beta_N}_{\text{爆発の恐れ}}\end{aligned}$$

- 一般に  $\lim_{N \rightarrow \infty} \sqrt{N}(\beta_N - \beta_0) \rightarrow Normal$  だが、、

## まとめ: LASSO

$$\begin{aligned}\beta_{interest} - \beta_N &= \underbrace{\beta_{interest} - \beta_0}_{Identification} \\ &+ \underbrace{\beta_0 - \beta_{N \rightarrow \infty}}_{=0} + \underbrace{\beta_{N \rightarrow \infty} - E[\beta_N]}_{\neq 0} + \underbrace{E[\beta_N] - \beta_N}_{SamplingUncertainly}\end{aligned}$$

- 一般に  $\lim_{N \rightarrow \infty} \sqrt{N}(\beta_N - \beta_0) \rightarrow \infty$

## まとめ: Single MachineLearning

$$\begin{aligned}\beta_{interest} - \beta_N &= \underbrace{\beta_{interest} - \beta_0}_{Identification} \\ &+ \underbrace{\beta_0 - \beta_{N \rightarrow \infty}}_{=0} + \underbrace{\beta_{N \rightarrow \infty} - E[\beta_N]}_{\neq 0} + \underbrace{E[\beta_N] - \beta_N}_{SamplingUncertainly}\end{aligned}$$

- 一般に  $\lim_{N \rightarrow \infty} \sqrt{N}(\beta_N - \beta_0) \rightarrow \infty$

## まとめ: PartiallingOut

$$\begin{aligned}\beta_{interest} - \beta_N &= \underbrace{\beta_{interest} - \beta_0}_{Identification} \\ &+ \underbrace{\beta_0 - \beta_{N \rightarrow \infty}}_{=0} + \underbrace{\beta_{N \rightarrow \infty} - E[\beta_N]}_{\rightarrow 0} + \underbrace{E[\beta_N] - \beta_N}_{\text{正規分布で近似}}\end{aligned}$$

- 一般に  $\lim_{N \rightarrow \infty} \sqrt{N}(\beta_N - \beta_0) \rightarrow Normal$

## Reference

- Angrist, Joshua D, and Jörn-Steffen Pischke. 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton university press.
- Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. 2018. "Double/Debiased Machine Learning for Treatment and Structural Parameters." *The Econometrics Journal* 21 (1): C1C68. <https://doi.org/10.1111/ectj.12097>.
- Lin, Winston. 2013. "Agnostic Notes on Regression Adjustments to Experimental Data: Reexamining Freedman's Critique." *The Annals of Applied Statistics* 7 (1): 295–318.
- Robinson, P. M. 1988. "Root-n-Consistent Semiparametric Regression." *Econometrica* 56 (4): 931954. <https://doi.org/10.2307/1912705>.