

# Linear Model

## 機械学習の経済学への応用

川田恵介

### Non-Penalized Linear Model

- スムーズな予想木と並ぶ人気モデル
  - NonPenalized Empirical Risk Minimization (OLS など): 漸近性質が” ほぼほぼ” 解明されている
  - Penalized Empirical Risk Minimization (LASSO などなど): そのものの  $X$  が多いデータにおいて現実的な選択肢

### Linear Model

- “線形” モデルを事前に設定

$$f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_L X_L$$

- 非線形モデルも設定可能

$$f(X) = \beta_0 + \beta_1 X + \dots + \beta_L X^L$$

### OLS

- Empirical Risk Minimization として、線形モデルを推定


$$\min \sum_i (Y_i - f(X_i))^2$$

- 解釈:: 母集団における Risk(MSE) を最小化する線形近似  $f_P$  の” 優れた” 推定量

$$\min_{\beta_0, \dots, \beta_L} E[(\mu_Y(X) - f_P(X))^2]$$


例: Approximation Error

- $f(X, D) = \beta_0 + \beta_D D + \beta_1 X$



例: Approximation Error

- $f(X, D) = \beta_0 + \beta_D D + \beta_1 X$



## モデルの複雑化


- 複雑なモデルは容易に想定可能
- 2 次モデル

$$f(X, D) = \beta_0 + \beta_D D + \beta_1 X + \beta_2 X^2$$

- “線形モデル” =  $\beta_2 = 0$  という特殊ケース


## 例 Approximation Error

- $f(X, D) = \beta_0 + \beta_D D + \beta_1 X + \beta_2 X^2$



### 例 Approximation Error

- $f(X, D) = \beta_0 + \beta_D D + \beta_1 X + \dots + \beta_{25} X^{25}$




## 復習

- 予測誤差の分解

$$Y - f(X) = \underbrace{Y - \mu_Y(X)}_{\text{IrreducibleError}} + \underbrace{\mu_Y(X) - f_\infty(X)}_{\text{ApproximationError}} + \underbrace{f_\infty(X) - f(X)}_{\text{EstimationError}}$$


## 例 Estimation Error

- $f(X, D) = \beta_0 + \beta_D D + \beta_1 X$



## 例 Estimation Error

- $f(X, D) = \beta_0 + \beta_D D + \beta_1 X + \dots + \beta_{25} X^{25}$



## まとめ

- “適度”な複雑性をもつモデルを”事前”設定できれば、OLS や最尤法、ベイズ推定は極めて実用的
  - 社会科学では (おそらく BioMedical Science でも) 困難
- 複雑すぎると EstimationError、単純すぎると ApproximationError が深刻
  - 古典的な予測モデルは、単純すぎる場合が多いとも (Breiman 2001)

## Penalized Linear Model

- 複雑すぎる線形モデルからスタート
- 複雑性へのペナルティーをつけて推定

## LASSO

- 以下の Penalized Empirical Minimization の解

$$\min \sum_i (Y_i - f(X_i))^2 + \lambda[|\beta_1| + \dots + |\beta_L|]$$

- $\lambda$  は CrossValidation で決定
  - 代替: AIC で決定 (gamlr パッケージ)


## 解釈: 条件付き最適化

- 以下と同値

$$\min \sum_i (Y_i - f(X_i))^2 \text{ s.t. } |\beta_1| + \dots + |\beta_L| \leq A$$

- $A \rightarrow 0 (\lambda \rightarrow \infty)$  ならば,  $f(X) \rightarrow$  サンプル平均
- $A \rightarrow \infty (\lambda \rightarrow 0)$  ならば,  $f(X) \rightarrow$  OLS
- 一般に、サンプル平均と OLS の間

## 例



## 係数値

```
17 x 1 sparse Matrix of class "dgCMatrix"
      s1
(Intercept)  2.7578375
poly(X, 15)1  5.9612713
poly(X, 15)2  7.8721161
poly(X, 15)3  .
```

```

poly(X, 15)4 .
poly(X, 15)5 0.8987052
poly(X, 15)6 .
poly(X, 15)7 .
poly(X, 15)8 .
poly(X, 15)9 .
poly(X, 15)10 .
poly(X, 15)11 .
poly(X, 15)12 .
poly(X, 15)13 .
poly(X, 15)14 .
poly(X, 15)15 .
D          0.1884852

```

## Sparcity

- OLS:  $X$  の数  $>$  サンプルサイズとなると推定不可能
- Penalized Linear model や Tree 系は、可能
  - LASSO や Tree 系は、係数値の一部を厳密に “0” として推定
  - ノイズ的  $X$  が大量に含まれていることが予想される場合、特に重要
- RandomForest などと比べても、 $X$  の数が多い時は LASSO に比較優位
  - 目安: サンプルサイズ/4  $>$   $X$  の数 (Taddy 2019)

## 発展: ElasticNet

- $\alpha, \lambda$  を CrossValidation で決定

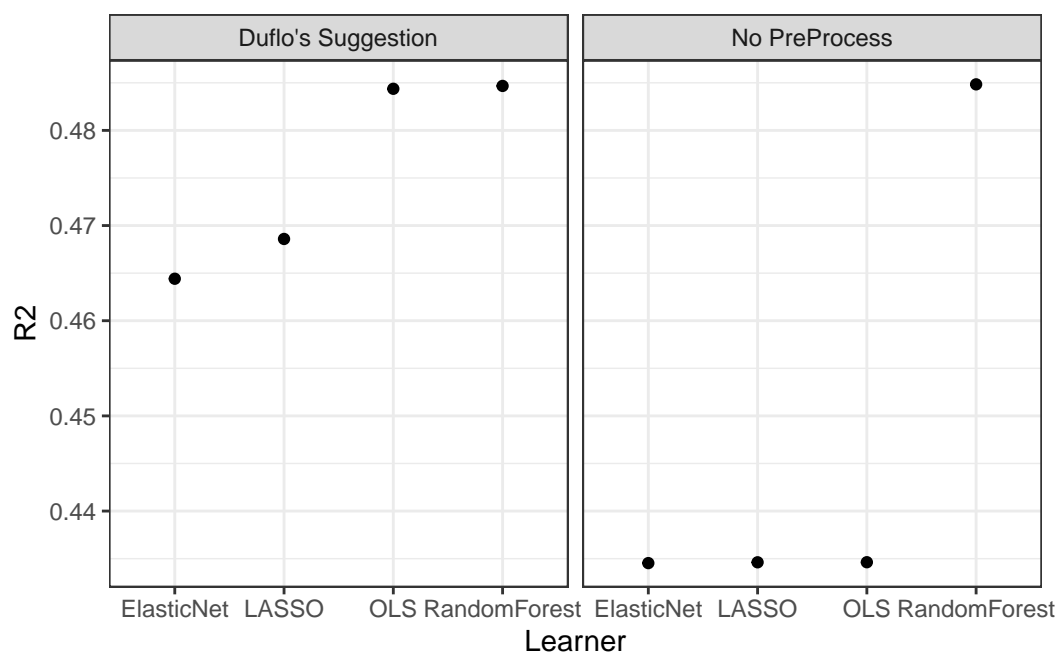
$$\begin{aligned}
 & \min \sum_i (Y_i - f(X_i))^2 \\
 & + \underbrace{\lambda \alpha [|\beta_1| + \dots + |\beta_L|]}_{L1 \text{ペナルティ}-(LASSO)} \\
 & + \underbrace{\lambda (1 - \alpha) [\beta_1^2 + \dots + \beta_L^2]}_{L2 \text{ペナルティ}-(Ridge)}
 \end{aligned}$$



## Practice

- Tree 系とは異なり、完全な Nonparametric モデルの推定ではない
  - 十分に複雑なモデル (OverParametric モデル) からスタートしたい
- [Duflo's suggestion](#)
  - 全ての  $X$  を投入
  - 連続変数については二乗項、Option として交差項
  - 欠損値は欠損ダミーを作成した後に、0 を補完
  - Variation がない変数や完全な多重共線を起こしている変数は除外

## 実例



## まとめ

- 母平均の複雑すぎるパラメトリックモデルからスタートし、ペナルティー項を用いて単純化
- 決めうちの深い予測木 + Pruning と同じ戦略

## Reference

- Breiman, Leo. 2001. "Statistical Modeling: The Two Cultures." *Statistical Science* 16 (3): 199–231.  
<https://doi.org/10.1214/ss/1009213726>.
- Taddy, Matt. 2019. *Business Data Science: Combining Machine Learning and Economics to Optimize, Automate, and Accelerate Business Decisions*. McGraw Hill Professional.