

Neyman's orthogonality condition

川田恵介

1 Double debiased machine learning

1.1 機械学習の応用

- 「社会やその仕組み(構造)」の特徴を把握するために
 - Moment 推定をベースに、補助的に機械学習を活用するアプローチが発展
 - Nuisance 関数を含むモーメント条件 with Neyman's orthogonality + 交差推定 + 機械学習 (Chernozhukov et al., 2018; Victor Chernozhukov, Escanciano, et al., 2022)
- 多くの発展的議論 (Victor Chernozhukov, Newey, et al., 2022; Chernozhukov, Newey and Singh, 2022; Luedtke, 2024; Laan et al., 2025)

1.2 Get Started: Return to education

```
library(tidyverse)

data("CPS1985", package = "AER")

Y <- log(CPS1985$wage)

D <- CPS1985$education

X <- model.matrix(~ age + ethnicity + gender, CPS1985)

X <- X[,-1]
```

1.3 Get Started: Return to education

```
model <- ddml::ddml_plm(
  y = Y,
  D = D,
  X = X,
  learners = list(
    list(fun = ddml::ols),
    list(fun = ddml::mdl_ranger)
  ),
  shortstack = TRUE,
```

```

    silent = TRUE
  )

summary(model)

```

PLM estimation results:

```

, , nnls

              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.00039    0.01951    0.02 9.84e-01
D_r          0.07885    0.00789   10.00 1.58e-23

```

2 Nuisance 関数を含む Moment 法

2.1 Moment 法

- Moment 推定: 母集団上のモーメント条件を用いて推定対象を定義し、データ上で同じ条件を適用し推定する
 - ▶ 本講義の範囲内では、「母集団上で仮想的に行われる計算結果」として推定対象を定義し、「データ上での同じ計算」の結果を推定値とする方法」と考えて概ね OK

2.2 例: Population OLS

- 関心のあるパラメタ β は、Population OLS の計算結果として定義
 - ▶ 以下を母集団で最小化するように決定

$$L = \min E[(Y - \beta X)^2]$$

- ▶ モーメント条件としては、

$$\frac{\partial L}{\partial \beta} = 0 \Leftrightarrow 0 = E[X \times (Y - \beta X)]$$

2.3 例: 推定

- ある data 上で、同じ最小化問題を解く: 以下を最小化
 - ▶ $\mathbb{L}(data) = (Y - \beta X)^2$ の data 上の平均値
 - ▶ モーメント条件は、

$$\frac{\partial \mathbb{L}(data)}{\partial \beta} = 0$$

$$\Leftrightarrow 0 = X \times (Y - \beta X) \text{ の data 上の平均値}$$

2.4 本スライドの推定対象

- 推定対象 $\beta_D(X)$ は partial linear model で定義される

$$E[Y | D, X] = \beta_D(X) \times D + f(X)$$

- 本スライドでは $\beta_D(X) \simeq \beta_D$ の場合を議論
- $D = [0, 1]$ であれば、 $\beta_D = X$ の分布を完全にバランスさせた後の Y の平均値の比較
- 識別の仮定 Conditional independence の元で、 $\beta_D = D$ の効果

2.5 重要ポイント

- 同じ推定対象を算出する、母集団上での計算手順(定式化)は、一般に無数に存在する
 - 推定 (推定対象 \rightarrow 推定値) が容易な定式化を採用すれば良い
- 経済学の類似例: 以下は全く同じ生産計画を導く
 - 投入財について利潤最大化問題を解く
 - 投入財について費用最小化問題を解いた後に、生産量について利潤最大が問題を解く
 - 計算/解釈しやすい方法を採用すれば良い

2.6 Single residual による定義

- β_D は、母集団上で以下の問題を解けば良い

$$E[(Y - f(X) - \beta_D \times D)^2]$$

- $f(X) = E[Y | D = 0, X]$ なので、

$$E \left[\left(\underbrace{Y - E[Y | D = 0, X]}_{=\hat{Y}} - \beta_D \times D \right)^2 \right]$$

- $\hat{Y} \sim D$ を OLS 推定する

2.7 Single residual に基づく推定

- nuisance 関数 ($E[Y | D = 0, X]$) を事前に推定する必要がある
- 1. 予測モデル $g_Y(0, X) \simeq E[Y | D = 0, X]$ を Stacking などを用いて推定
 - 例えば、 $D = 0$ の事例のみを用いて、 Y を X から予測するモデルとして推定
 - あるいは、 X, D から Y を予測するモデルを推定し、 $D = 0$ を代入

2.8 Single residual に基づく推定

- モデルの予測値を代入し、 $\hat{Y} = Y - g_Y(0, X)$ を算出し、 $\hat{Y} \sim D$ を OLS 回帰

2.9 Double residuals による定義

- β_D は以下を回帰しても得られる

$$E \left[\left(\underbrace{Y - E[Y | X]}_{\hat{Y}} - \beta_D \times \left(\underbrace{D - E[D | X]}_{\hat{D}} \right) \right)^2 \right]$$

- ▶ $\hat{Y} \sim \hat{D}$ を OLS 推定
- R-learner/Residuals regression と呼ばれる

2.10 Double residuals による推定

- データ上で以下のように再現できる
1. 予測モデル $g_Y(X) \simeq E[Y | X]/g_D(X) \simeq E[D | X]$ を Stacking などを用いて推定
 2. 推定値を代入し、 $\hat{Y} = Y - g_Y(X)/\hat{D} = D - g_D(X)$ を算出し、 $\hat{Y} \sim \hat{D}$ を OLS 回帰


2.11 Single VS Double

- どちらが扱いやすい定式か?
- nuisance 関数 $g_Y(0, X)/g_Y(X)/g_D(X)$ の推定に、機械学習などのデータ主導の推定を活用したいのであれば、Double residuals が推奨される
 - ▶ β_D の分布を正規分布で近似しやすくなり、信頼区間の近似計算が容易
 - 実際には交差推定も活用する必要がある (次のスライド)
 - ▶ Single residual の場合、推定値の分布は一般にバイアスを持つ

2.12 数値例

- $Z_1, X \sim \text{unif}(0, 1), Z_2 \sim N(Z_1, 0.5)$
- $D \sim N(X, 0.5), Y \in N(X + Z_2, 1)$
- Nuisance はすべて LASSO で推定
 - ▶ スライド内では、500 事例
 - Appendix では、50000 事例

2.13 数値例



3 Oracle estimator を用いた理解

3.1 Single VS Double: 推奨

- Double residuals の定式化は、Neyman's orthogonality を満たすため、nuisance 関数の推定の自由度が高い
 - ▶ 機械学習などの推定誤差の性質が悪い/不透明な方法を用いても、緩やかな条件のもとで、最終的な推定結果 β_D の推定誤差に悪影響を与えにくい
 - 「機械学習の推定誤差が、最終的な推定結果に転嫁されにくい」
 - なぜ？

3.2 議論の方針

- CausalML 以外にも、しっかり理解するための教材は多数存在 (Fisher and Kennedy, 2021; Ichimura and Newey, 2022; Hines et al., 2022; Renson et al., 2025; Ahrens et al., 2025)
- ここでは理論的なベンチマーク (Oracle estimator) の分布性質をまず議論し、実際の推定値がベンチマークを近似できるかどうかを議論する
 - ▶ 正式な漸近性質は次回議論

3.3 復習: 推定誤差の原因

- 推定誤差(推定値の分布): 同じ母集団を対象としたとしても、データの特徴が異なるため生じる誤差
- 2段階推定定において、推定誤差の源泉が2種類ある
 - ▶ Step 1 における、予測モデルの推定結果が異なる
 - ▶ 仮に同じ予測モデルを用いても、Step 2 において、 β_D の推定結果が異なる
 - 以上の総和が、推定誤差


3.4 Step 1 における推定誤差の確認

- 説明のために、推定された $A \in [Y, D]$ の予測モデルを以下のように表現する

$$g_A(X) = \underbrace{E[A | X]}_{\text{最善の予測値}} + \underbrace{e_A(X)}_{\text{推定誤差}}$$

- 様々なアルゴリズムを用いた Stacking 法などで $g_A(X)$ を推定すれば、無限大の事例数のもとで $e_A(X) \simeq 0 \Leftrightarrow g_A(X) = E[A | X]$ が期待できる
 - ▶ 一貫性

3.5 数値例: Nuisance



- 500 事例では、推定誤差がマイナスに偏る (“Finite sample” bias)

3.6 Benchmark

- 論点整理のために、母平均が正確に推定できたケース ($e_A(X) = 0$)を”想像”する

▶ Oracle estimator と呼ばれる

- Step 2 における推定では、


$$Y - E[Y \mid D = 0, X] \sim D$$

ないし

$$Y - E[Y \mid X] \sim D - E[D \mid X]$$

を OLS で推定すれば良い

3.7 数値例: Oracle 対決



- 推定誤差の分布は正規分布で近似できる

3.8 Oracle 推定の近似

- 十分に事例数が大きい場合
- Single residuals の推定誤差は、


$$\underbrace{\text{Step1の誤差}}_{?} + \underbrace{\text{Step2の誤差}}_{\text{正規分布で近似}} \neq \text{Oracle推定}$$

- 緩やかな仮定 (次回議論) のもとで、Double residuals の推定誤差は、

$$\underbrace{Step1の誤差}_{\approx 0} + \underbrace{Step2の誤差}_{\text{正規分布で近似}} \simeq Oracle推定$$

- ▶ Step 1 における推定誤差を、近似的に無視できる

3.9 数値例: VS Oracle 対決



3.10 まとめ

- Double residuals による定義 + 緩やかな仮定 (nuisance 関数についての推定精度 + 交差推定; 次回議論)のもとで、推定値は oracle estimator と近似的に一致
 - ▶ 十分な事例数であれば、step 1 の推定誤差を無視できる
 - step 1 に機械学習を活用し、推定誤差の詳細な性質が不明でも、最終的な推定結果が影響されにくくできる

4 Neyman's orthogonality

4.1 微分の活用

- なぜ Step 1 の誤差の影響が、定式化で異なるのか?
 - ▶ “微分”の応用で、確認できる

4.2 復習: 微分の使い方

- $f(X)$ を微分 $\partial f(X)/\partial X = X$ を少し変化させた場合の $f(X)$ の変化率
 - ▶ $\partial f(X)/\partial X |_{X=0} = 0 \Leftrightarrow X$ の ($X = 0$ からの)局所的な変化について $f(X)$ の値は頑強

– local robust

4.3 推定

- データ上で以下を β_D について最小化

$$L_S(data) = (Y - g_Y(D = 0, X) - \beta_D D)^2 \text{の平均}$$

$$L_D(data) = (Y - g_Y(X) - \beta_D(D - g_D(X)))^2 \text{の平均}$$

- $\partial L_S(data)/\partial \beta_D = \partial L_D(data)/\partial \beta_D = 0$ が、 β_D の推定値の決定式

4.4 推定誤差の影響

- β_D の決定式が、予測モデル g_Y の推定誤差 e_Y について local robust であることを確認したい
- $g_Y(X) = E[Y | X] + e_Y(X)$ と書き換え、 $e_Y(X)$ で交差微分を計算し、 $e_Y(X) = 0$ で評価

4.5 シンプルな例

- 本スライドでは、 X の組み合わせは少数であると想定する
 - $X = [\text{板橋}, \text{文京}]$
 - 板橋/文京区についての予測誤差 $e_Y(\text{板橋})/e_Y(\text{文京})$ をパラメタとして扱えるため、通常の微分が可能
- より一般のケースでは、関数微分を用いる必要がある

4.6 Single rediauls

- $$\partial \left(\frac{\partial L_S(data)}{\partial \beta_D} \right) / \partial e_Y(0, \text{板橋}) \Big|_{e_Y(0, \text{板橋})=0}$$
$$= \frac{\partial (D[Y - E[Y | 0, X] - e_Y(0, X) - \beta_D D]) \text{の平均}}{\partial e_Y(0, \text{板橋})} \Big|_{e_Y(0, \text{板橋})=0}$$
$$= -D \text{の板橋内での平均} \neq 0$$

- step 1 の推定誤差について、 β_D は robust ではない

4.7 Double rediauls

- $$\partial \left(\frac{\partial L_D(data)}{\partial \beta_D} \right) / \partial e_Y(\text{板橋}) \Big|_{e_Y(\text{板橋})=0}$$
$$= -(D - g_D(\text{板橋})) \text{の板橋内での平均}$$
$$= -[D \text{の板橋内での平均値} - g_D(\text{板橋})]$$

4.8 Double residuals

- step 1 で用いる事例数が十分にあれば、 $g_D(\text{板橋}) \simeq \text{母平均}$
- step 2 で用いる事例数が十分にあれば、データ上での平均 \simeq 母平均
- よって、 $\partial\left(\frac{\partial L_D(\text{data})}{\partial \beta_D}\right) / \partial e_Y(\text{板橋}) \big|_{e_Y(\text{板橋})=0} \simeq 0$

4.9 事例数の影響

- Single residuals: 事例数が増えれば、step 1 の推定誤差 $e_A(X)$ を削減できる
 - ▶ 現実的な事例数のもとでは、step 1 の推定誤差の影響は、0 にはならない
- Double residuals: step 1 の推定誤差の削減 + step 1 の推定誤差の”影響”の削減
 - ▶ 現実的な事例数のもとで、ほぼ 0 になることが期待できる
 - 「収束の速度が改善する」(次回議論)

4.10 Neyman's orthogonality

- 推定対象となるパラメタ θ は、nuisance 関数 g_0 を用いて、以下の最適化問題の解として定義する

$$\min L(\theta, g_0)$$

- Neyman's orthogonality: 母集団上で定義されるモーメント条件が以下の条件を満たす

$$\frac{\partial^2 L(\theta, g)}{\partial \beta \partial g} \bigg|_{g=g_0} = 0$$

4.11 別表現

- θ は母集団上でのモーメント条件 $E[m(\theta, g_0)] = 0$ として定義する
- Neyman's orthogonality: 母集団上で定義されるモーメント条件が以下の条件を満たす

- $$E\left[\frac{\partial m(\theta, g)}{\partial g} \bigg|_{g=g_0}\right] = 0$$

4.12 まとめ


- 機械学習を用いて推定した予測モデル $g(X)$ は、一般に母平均からの推定誤差 $E[Y | X] - g(X)$ を減らすようにデザインされる
 - ▶ 推定誤差をうまく削減したとしても、その詳細な性質が black box
 - 一般にバイアスを持ち、正規分布で近似できない

- ⇔ 通常の OLS については、母平均の”近似モデル”についての推定誤差はバイアスのない正規分布で近似できる


4.13 まとめ

- Debiased machine learning のアイデア: 機械学習の推定誤差を”改善”ではなく、最終的な推定値への影響を削減する
 - ▶ Neyman’s orthogonality を満たすように推定対象を定義する
- 経済学における類似例: 景気変動や地震への対応
 - ▶ 一般に景気変動の要因や地震そのものを”消失”させることは困難
 - 悪影響が家計に及ばないような(金融/財政/社会保障/減災)政策を議論

4.14 Appendix: Large sample example



4.15 Appendix: Large sample example



4.16 Reference

Bibliography

Ahrens, A. et al. (2025) “An introduction to double/debiased machine learning,” arXiv preprint arXiv:2504.08324 [Preprint].

Chernozhukov, V. et al. (2018) “Double/debiased machine learning for treatment and structural parameters,” *The Econometrics Journal*, 21(1), pp. C1–C68.

Chernozhukov, Victor, Escanciano, et al. (2022) “Locally robust semiparametric estimation,” *Econometrica*, 90(4), pp. 1501–1535.

Chernozhukov, V., Newey, W. and Singh, R. (2022) “Automatic debiased machine learning of causal and structural effects,” *Econometrica*, 90(3), pp. 967–1027.

Chernozhukov, Victor, Newey, et al. (2022) “Riesznet and forestriesz: Automatic debiased machine learning with neural nets and random forests,” in *International Conference on Machine Learning*, pp. 3901–3914.

Fisher, A. and Kennedy, E.H. (2021) “Visually communicating and teaching intuition for influence functions,” *The American Statistician*, 75(2), pp. 162–172.

Hines, O. et al. (2022) “Demystifying statistical learning based on efficient influence functions,” *The American Statistician*, 76(3), pp. 292–304.

Ichimura, H. and Newey, W.K. (2022) “The influence function of semiparametric estimators,” *Quantitative Economics*, 13(1), pp. 29–61.

Laan, L. van der et al. (2025) “Automatic Debiased Machine Learning for Smooth Functionals of Nonparametric M-Estimands,” arXiv preprint arXiv:2501.11868 [Preprint].

Luedtke, A. (2024) “Simplifying debiased inference via automatic differentiation and probabilistic programming,” arXiv preprint arXiv:2405.08675 [Preprint].

Renson, A. et al. (2025) “Pulling back the curtain: the road from statistical estimand to machine-learning based estimator for epidemiologists (no wizard required),” arXiv preprint arXiv:2502.05363 [Preprint].