

# Heterogeneity analysis

川田恵介

2025-07-08

## 1 $\beta(X)$ の記述

### 1.1 研究目標の実際

- 多くの研究目標:  $\beta(X) = E[Y | D = 1, X] - E[Y | D = 0, X]$  の”特徴把握”を要求
  - ▶ 学歴  $D$  間での所得  $Y$  格差の実態を明らかにする
  - ▶ 東大経済学研究科  $D$  への進学が、30 歳時点での所得  $Y$  に与える効果を明らかにする
- 明らかにしたい具体的な”特徴”を、意識的に定めることが重要

### 1.2 ここまで

- 推定対象として、 $\beta(X)$  の平均 (Partial Linear Model/AIPW) と Nonparametric な推定 (Causal Forest) を学ぶ

### 1.3 比較

- Partial Linear Model/AIPW: Valid な統計的推論が可能だが、 $X$  との関係性について”一切の”情報を持たない
  - ▶  $E[D = 1 | X] \simeq 0$  な事例が存在する場合、Average “treatment effect” on treated が有効 (Section 5)
- Nonparametric な推定: 無限大の事例/計算/認知資源があれば理想的だが、非現実的
  - ▶ 例えば、Valid な統計的推論が難しい
    - 例外的な状況:  $X$  の数が少ない場合、Causal Forest は標準誤差を提供 (CausalML 14 章参照)
- 適切な妥協が有効な場合が多い

## 2 比較研究のフロー: 私案

### 2.1 大前提

- 「 $\beta(X)$  の特徴」が分析対象であるとししっかり認識 (同質性 ( $\beta(X) = \beta$ ) を仮定しているわけではない)

- Overlap していないことが明白な事例は、事前に除外
- 異質性を確認したい変数  $Z$  は、研究目標に照らして、事前に決める

### 2.2 分析フロー

1. Overlap の仮定を確認: 例えば推定された  $f(d | X)$  の分布を確認
2. 最もシンプルな集計値 ( $\beta(X)$  の平均値) である、PLR/AIPW を示す
  - Overlap の仮定に注意: 場合によっては Average “Treatment” Effect on Treated/Control を使用
3. GATE を示し、 $\beta(X)$  の分布を要約する
4. BLP を推定し、 $Z$  に関する要約された特徴を示す

### 2.3 実例

- 研究目標: 改装 (Reform) が、取引価格に与える効果を推定
- 重要な識別の仮定: Reform は、 $X = [Size, Tenure, Distance, RoomNumber, Youseki]$  が同じであれば、Random に決まっている
- 推定目標:  $\tau(X) = E[Y | D = 1, X] - E[Y | D = 0, X]$
- 懸案: ほとんど Reform していない物件の存在が予想される
  - ▶ “ググると”築 10 年以降から、Reform を検討し始めるのが多そうなので、メイン分析では築 10 年以上の物件に限定

### 2.4 Data

```
library(tidyverse)

Data <- read_csv("Public/Data.csv") |>
  filter(TradeYear == 2024) |>
  filter(Tenure >= 10)

Y <- Data$Y
D <- Data$Reform
X <- model.matrix(~ Size + Tenure + Distance + RoomNumber + Youseki, Data)
X <- X[, -1]
```

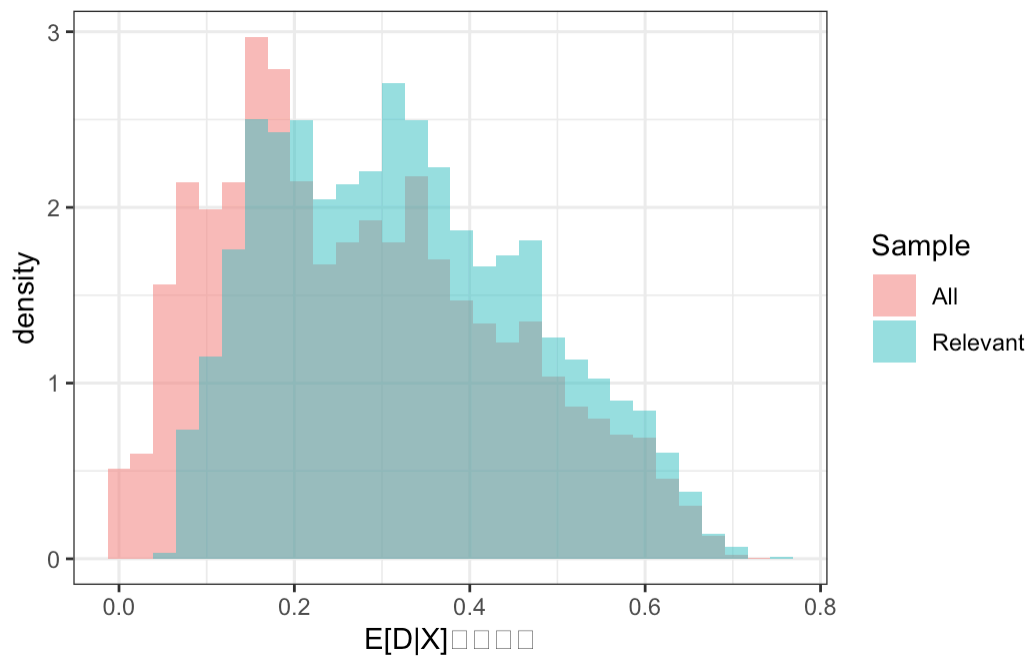
## 2.5 Nuisance<sup>1</sup>

```
library(SuperLearner)

HatY <- SuperLearner(
  Y = Y,
  X = X,
  newX = X,
  SL.library = c("SL.mean", "SL.lm", "SL.ranger"),
  cvControl = list(V = 2)
)

HatD <- SuperLearner(
  Y = D,
  X = X,
  newX = X,
  SL.library = c("SL.mean", "SL.lm", "SL.ranger"),
  family = binomial(),
  cvControl = list(V = 2)
)
```

## 2.6 Check



## 2.7 grf

---

<sup>1</sup>Section 6

```

Tau <- grf::causal_forest(
  Y = Y,
  W = D,
  X = X,
  Y.hat = HatY$SL.predict[, 1],
  W.hat = HatD$SL.predict[, 1]
)

```

## 2.8 Average

```

ATE <- grf::average_treatment_effect(Tau)


ATT <- grf::average_treatment_effect(Tau, target.sample = "treated")

ATC <- grf::average_treatment_effect(Tau, target.sample = "control")

OR <- grf::average_treatment_effect(Tau, target.sample = "overlap")

```

## 2.9 Result



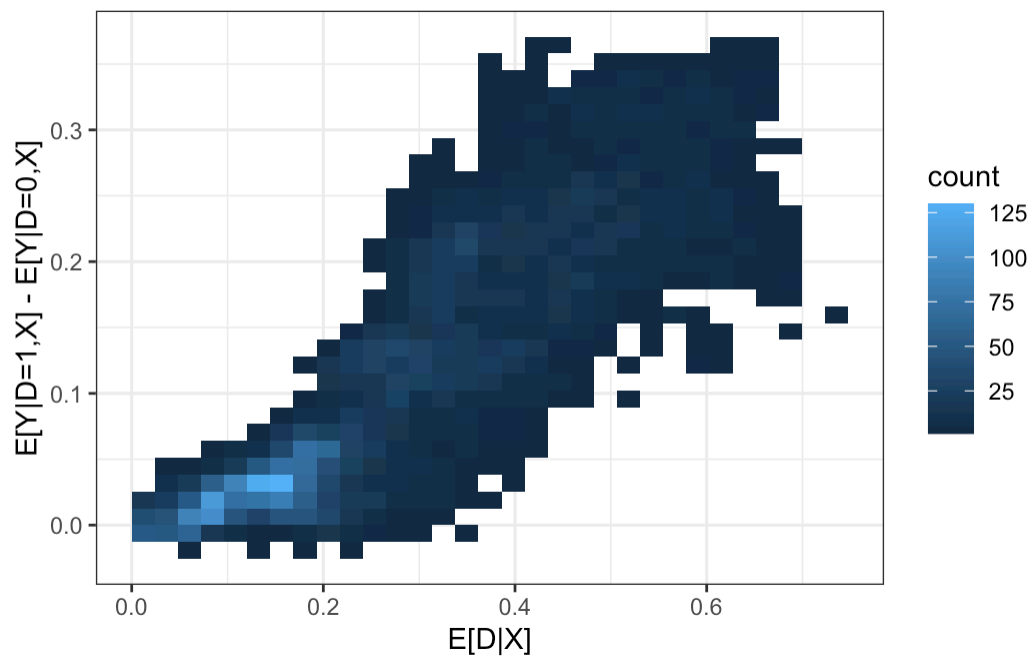
## 2.10 直感

```

tibble(
  Tau = Tau_All$predictions,
  HatD = HatD_All$SL.predict[, 1]
) |>

```

```
ggplot(
  aes(
    x = HatD,
    y = Tau
  )
) +
geom_bin2d() +
theme_bw() +
ylab("E[Y|D=1,X] - E[Y|D=0,X]") +
xlab("E[D|X]")
```



## 3 Best Linear Projection

### 3.1 線型モデルの把握への活用

- 線型モデルの役割は、予測だけではなく、変数間の関係性の”把握”
  - 人間が把握できるモデルは通常、 $\beta$ の数が少なく、現実的な事例数のもとで適切に推定できる
- 完全に Nonparametric な推定は、信頼区間の推定が難しい
  - “仮にできたとしても”、 $X$  の組み合わせ分ある推定値を人間が認知できない
  - “過剰な推定目標”である可能性

### 3.2 Best Linear Projection

- Semenova and Chernozhukov (2021)
- $\beta(X) \simeq \beta_0 + \beta_1 Z_1 + \dots$  で近似
  - ▶  $X$  を全て  $Z$  として使っても、一部を使っても OK
- 注: 把握が目的なので、人間が理解できないほど複雑化できない
  - ▶ 典型的には関心となる変数  $Z$  を人間が指定し、線型モデルを推定する
    - $Z$  を標準化すれば、 $\beta_0$  は”平均差”として解釈できる

### 3.3 推定方法

1. 機械学習などにより、 $E[Y | d, X], E[D | X]$  を推定
2. AIPW のスコア ( $\theta = E[\phi]$ ) を算出

$$\phi = \tau(X)$$

$$+ \frac{D(Y - E[Y | 1, X])}{f(D = 1 | X)} - \frac{(1 - D)(Y - E[Y | 0, X])}{f(D = 0 | X)}$$

3.  $\phi$  を  $Z$  で OLS 推定し、通常の信頼区間を算出

### 3.4 注意点

- 多重共線性による、ミスリードする結果に注意
  - ▶ 相関が強い変数は、一つの変数にまとめる
    - 例: 部屋の広さと部屋の数に相関が強いので、部屋の広さで代表する
- $Z$  について標準化 ( $(Z - Z$  の平均)/ $Z$  の Standard Error) を推奨
  - ▶ 特に  $\beta_0$  が  $\beta(X)$  の代表的な値として解釈できる
    - 標準化しないと  $\beta_0 \simeq \tau(Z = 0)$  であり、解釈困難

### 3.5 BLP

```
Z <- Data |> select(Size, Tenure, Distance)

grf::best_linear_projection(Tau, scale(Z))
```

Best linear projection of the conditional average treatment effect.  
Confidence intervals are cluster- and heteroskedasticity-robust (HC3):

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	0.1384357	0.0071136	19.4606	< 2e-16 ***

```
Size      0.0180019  0.0081167  2.2179  0.02661 *
Tenure    0.0835991  0.0075295 11.1028 < 2e-16 ***
Distance  0.0169091  0.0073172  2.3109  0.02089 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

## 4 Group Average Difference

### 4.1 グループ化

- $X$  の相関が強い場合/非線形性が強い場合、線型モデルは  $\tau(X)$  異質性の特徴をうまく捉えきれない
- $X$  の情報をもとに、事例をグループ化して、平均差の違いを推定する方法が有力
  - ▶  $\tau(X)$  によって、“sort”する (Chernozhukov et al., 2018; Kallus, 2022)

### 4.2 Athey and Wager (2019)


1. Causal Forest などを用いて、 $\tau(X)$  を交差推定<sup>2</sup>
2.  $\tau(X)$  でソートし、事前に指定したルールに基づいて、サブグループ分け (例: median よりも高い/低い)
3. サブグループごとに平均差を AIPW など推定 (因果推論では、Group Average Treatment Effect と呼ばれる)
4. サブグループ間での  $X$  の違いを記述 (Classification Analysis)

### 4.3 Hetero

```
hist(predict(Tau)$predictions)
```

---

<sup>2</sup>Section 7



## 4.4 Group Average Difference

```
grf::average_treatment_effect(
  Tau,
  subset = Tau$predictions >= median(Tau$predictions)
)
```

```
estimate    std.err
0.22638253 0.01089877
```

```
grf::average_treatment_effect(
  Tau,
  subset = Tau$predictions < median(Tau$predictions)
)
```

```
estimate    std.err
0.050488890 0.009131508
```

## 4.5 CLAN

```
Data |>
  mutate(
    Group = if_else(
      Tau$predictions >= median(Tau$predictions),
```



```

    "Hige",
    "Low"
  )
) |>
select(Group, Size:Youseki) |>
gtsummary::tbl_summary(
  by = Group
)

```

Characteristic	Hige N = 2,167 <sup>1</sup>	Low N = 2,167 <sup>1</sup>
Size	55 (40, 65)	30 (20, 60)
Tenure	36 (26, 44)	17 (13, 21)
Distance	7.0 (4.0, 10.0)	6.0 (4.0, 8.0)
RoomNumber		
1	667 (31%)	1,357 (63%)
2	715 (33%)	390 (18%)
3	726 (34%)	401 (19%)
4	57 (2.6%)	19 (0.9%)
5	2 (<0.1%)	0 (0%)
Youseki	300 (200, 400)	400 (300, 500)

<sup>1</sup> Median (Q1, Q3); n (%)

## 5 Appnedix: Propensity score weight

### 5.1 様々な Weight

- $ATE = \int \tau(X) f(X) dX$
- $PLR = \int \tau(X) \frac{f(D=1|X)f(D=0|X)}{\int f(D=1|X)f(D=0|X) dX} f(X) dX$
- $ATT = \int \tau(X) \times f(X | D = 1) dX$   

$$= \int \tau(X) \times \frac{f(D = 1 | X)}{f(D = 1)} \times f(X) dX$$
- $ATC = \int \tau(X) \times f(X | D = 0) dX$   

$$= \int \tau(X) \times \frac{f(D = 0 | X)}{f(D = 0)} \times f(X) dX$$

## 5.2 ATT/ATC の特徴

- 解釈が用意: 平均差  $\tau(X)$  を  $D = 1/D = 0$  における  $X$  の分布を用いて集計
  - ▶  $D$  が  $X$  ないでランダムに決まっていれば、 $D = 1/0$  グループ内での“平均効果”と解釈できる
- Neyman’s orthogonality を満たすように書き換えられる
  - ▶ ATT:  $E[D | X] \simeq 0$  が存在しても推定できる
    - $E[D | X] \simeq 1$  が存在すれば問題

## 6 Appendix: Stacking

### 6.1 Stacking

- nuisance 関数の推定については、stacking を使用を推奨
  - ▶ 使用するアルゴリズムの数が、非常に多い場合、2 重の交差推定が必要
    - Ahrens et al. (2025)

## 7 Appendix: Causal Forest の特徴

### 7.1 Out of sample prediction

- Bagging 系統のアルゴリズムでは、ブートストラップ法を用いて、大量の予測モデルを生成
  - ▶ 特定の事例  $i$  が含まれないデータのみから生成された予測モデルも存在
    - そのようなモデルのみを集計すれば、事例  $i$  について交差推定できる
- 追加的なサンプル分割なしで、交差推定できる

### 7.2 AIPW

- grf パッケージにおける AIPW 推定は、以下の定式化を使用

$$E[\theta - \phi] = 0$$

where  $\phi = \tau(X) +$

$$\frac{D - E[D | X]}{E[D | X](1 - E[D | X])} \\ \times (Y - E[Y | X] - (D - E[D | X]) \times \tau(X))$$

## 7.3 Reference

### Bibliography

Ahrens, A. et al. (2025) “Model averaging and double machine learning,” *Journal of Applied Econometrics* [Preprint].

Athey, S. and Wager, S. (2019) “Estimating treatment effects with causal forests: An application,” *Observational studies*, 5(2), pp. 37–51.

Chernozhukov, V. et al. (2018) Generic machine learning inference on heterogeneous treatment effects in randomized experiments, with an application to immunization in India.

Kallus, N. (2022) “Treatment Effect Risk: Bounds and Inference,” 2022 ACM Conference on Fairness, Accountability, and Transparency (Minor revision in Management Science) [Preprint].

Semenova, V. and Chernozhukov, V. (2021) “Debiased machine learning of conditional average treatment effects and other causal functions,” *The Econometrics Journal*, 24(2), pp. 264–289.