概要

経済学のための機械学習入門

川田恵介

2026-04-05

Table of contents

1 **本講義について** 3

1.1 講義の目標 3

1.2 機械学習の経済学への導入 4

1.3 イメージ: DML 4

1.4 推定目標 6

1.5 講義中の例: 初等教育の効果 6

1.6 DML の背後にある発想 6

1.7 成績評価 6

1.8 次回までの準備 7

1.9 文献 7

2 **予測研究**: Get started 7

2.1 子供数予測 (Botswana 1988) 7

2.2 推定方法: OLS VS 教師付き学習 7

2.3 実例: Set-Up 8

2.4 実例: 子供数予測 8

2.5 実例: 子供数予測 8

2.6 実例: 62 年生まれ/26 歳の予測値 10

2.7 統計的推論 10

2.8 実例: 90 % 予測区間 11
2.9 予測研究まとめ 12

3 **比較研究**: Get started 13
3.1 社会の仕組みや特徴の把握 13
3.2 教育水準と子供数の関係性把握 13
3.3 要約モデル 13
3.4 推定方法: OLS VS 機械学習 13
3.5 実例: 平均価格差 14
3.6 実例: 90 % 信頼 VS 予測区間 14
3.7 比較研究まとめ 15

4 **調整後の比較研究**: Get started 16
4.1 初等教育と年齢や宗教的背景 16
4.2 調整後の比較研究 16
4.3 Nuisance を含む要約モデル 17
4.4 推定: OLS VS 教師付き学習 VS DML 17
4.5 実例: Residuals regression 17
4.6 実例: Residuals regression 18

5 Takeaway 18
5.1 本日の要点 18
5.2 要約モデル VS 予測モデル 19
5.3 要約モデル VS 予測モデル 20
5.4 機械学習の役割 20
5.5 “ブルシットジョブ” の外注 20
5.6 適当なイメージ 21
5.7 不適当なイメージ 22
5.8 他の応用 22

6 **補論: 研究目標** 22
6.1 ３つの検討事項 22
6.2 3 層構造 23
6.3 経済学の特徴 24
6.4 事後解釈 VS 識別 24
6.5 研究目標の分類軸 24
6.6 研究目標の分類: 例 24

7 **補論: 回帰木モデル** 25
7.1 補論: 回帰木モデル 25
7.2 実例. 30 歳以上と初等教育による分類 25
7.3 実例. データ主導 25

8 **補論: 異質性の推定** 26
8.1 Causal Forest 26
8.2 $\beta_D(X)$ の推定結果 27
8.3 BLP (Semenova and Chernozhukov 2021) 27
8.4 GATE (Chernozhukov et al. 2025) 28
8.5 CLAN (Chernozhukov et al. 2025) 29
Reference 29

1 本講義について

1.1 講義の目標

- 「実証経済学への活用」を目標とした**機械学習** 入門
- **DML**[*1]: **推定目標**を、「機械学習 + OLS や平均値」によって推定
  - $\simeq$ **教師付き学習 + セミパラメトリック推定**
  - 利点: 母分布への仮定を弱めながら、**推定目標**に対する**統計的推論 (信頼区間等)** が可能

[*1] Double/Debiased Machine Learning

1.2 機械学習の経済学への導入

- 多くの教科書で導入されている (Stock and Watson 2019; Hansen 2022)
- 特に因果推論への応用は、最新の教科書ではほぼ例外なく紹介されている (講義サイト (tetokawata/TargetML) 参照)
  - 狭義の予測だけでなく、「社会やその仕組みの特徴把握」の推定への応用に強い関心

1.3 イメージ: DML

- **DML**: 予測モデルを、推定目標の推定に活用する方法

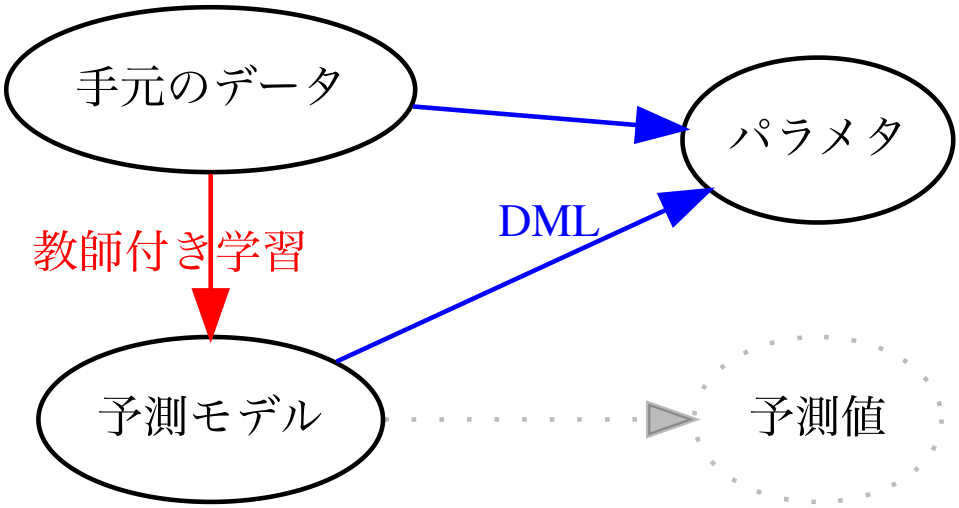
手元のデータ
パラメタ
教師付き学習
DML
予測モデル
予測値

1.4 推定目標

- データから推定したい値やモデル[*2]
- 「**研究目標**に関する**推定結果**を得る」を分解できる
  - **識別** (設定): **研究目標**に対応する**推定目標**とは?
    - 経済/因果/規範理論[*3] を活用
  - **推定方法**: **推定目標**に対応する**推定結果**の算出法は?
    - 狭義の統計学/機械学習 (含む DML) を活用

1.5 講義中の例: 初等教育の効果

- **研究目標**: 1988 年のボツワナにおける子供数への効果
  - **ポイント**: 効果 = データから観察できない**概念**
- 潜在結果モデルで推定目標を設定し、DML で推定する
  - **代替的な識別の枠組み**: do-演算子 (DAG), 経済モデル等
  - **代替的な推定方法**: 最尤法/ベイズ/OLS 等
- **非推奨**: 機械学習/OLS で子供数の決定モデル「っぽい式」をなんとなく推定し、結果を解釈する

1.6 DML の背後にある発想

- "...there are parts of the model **where economic theory is silent**, and where the modern machine learning methods can be extremely effective..." (Imbens and Athey 2021)
- (経済/因果/規範) 理論は、推定目標や推定目標の設定について" 雄弁" であり、理論と背景知識を併用できる人間が得意
- 推定のためのモデル化 (過剰適合の緩和) については" 沈黙" するため、機械学習を活用した、よりデータ主導のアプローチが有効

1.7 成績評価

- レポート + 講義時間中のテスト
- 講義時間中のテスト: UTOL 上でのオンラインテスト
  - 回答することが重要 (正答であれば、若干のボーナス点)
  - 毎回行い、上位 8 回分を成績に反映
- レポート: 期間中 2 回を予定

[*2] Estimand, Parameter of interest, Primitives
[*3] Shapiro (2026) ; Wang, Richardson, and Robins (2025) ; Rose (2023)

1.8 次回までの準備

- 講義資料の事前ダウンロード
  - 講義レポジトリ: tetokawata/TargetML
- 実習環境の整備
  - 講義では R + Rstudio をサポート
  - 課題では、Python を使用しても OK

1.9 文献

- 教師付き学習: James et al. (2021)
  - 注: OLS も重要な手法として紹介される
- + セミパラメトリック推定 (DML): Chernozhukov et al. (2026)
  - 講義内容は主に Chapter 1-4, 8, 9, 14-15 に該当
- 講義レポジトリ: tetokawata/TargetML
  - 講義資料 + 練習用データ + おすすめ参考資料

2 予測研究: Get started

2.1 子供数予測 (Botswana 1988)

- **研究目標**: 子供数 (`children`) を、背景 (生まれ年や宗教的背景、学歴) から予測する
  - 平均二乗誤差で予測性能を測定する場合は、最善の予測モデルは条件付き母平均:

$$\text{推定目標} = E[\underbrace{Y}_{children} \mid \underbrace{X}_{\text{背景}}]$$

- **課題**: 限られた事例数から、複雑なモデルを推定することが難しい (**過剰適合**)

2.2 推定方法: OLS VS 教師付き学習

- **OLS**: **研究者が推定可能な線形モデル**を設定する

$$\underbrace{E[Y \mid X] \simeq \text{予測値}}_{\text{極力近づける}} = \underbrace{\beta_0 + \beta_1 \times \underbrace{X_1}_{yearborn} + \ldots}_{\text{研究者が単純化}}$$

- **教師付き学習**: より複雑なモデルの推定方法を提供
  - "new generation of nonparametric estimators" (Jiafeng Chen の講義資料)

2.3 実例: Set-Up

```
set.seed(111)

library(wooldridge) # Data
library(tidyverse) # Preprocess
library(mlr3verse) # Machine Learning
library(mlr3pipelines) # Stacking
library(ranger) # Random Forest
library(DoubleML) # DML
library(estimatr) # OLS
library(cobalt) # Balance check
library(grf) # Causal Forest

data("fertil2")
```

2.4 実例: 子供数予測

- 予測問題の定義

```
task <- as_task_regr(
  x = select(
    fertil2,
    children,
    yearborn, age, spirit, protest, catholic, educ),
  target = "children"
)
```

2.5 実例: 子供数予測

```
stacking <-ppl(
    "stacking",
    lrns(c("regr.ranger")), # Stacking with Random Forest and "OLS"
    lrn("regr.lm", id = "meta"),
    folds = 2
```

```r
  )

stacking <- as_learner(stacking)

model_Y <- stacking$clone()$train(task)

model_Y$model$meta$model
```

```
Call:
stats::lm(formula = form, data = data)

Coefficients:
                     (Intercept)  regr.ranger.regr.ranger.response
                         2.97448                           0.40168
                             age                          catholic
                         0.05808                           0.04822
                            educ                           protest
                        -0.05814                           0.04277
                          spirit                          yearborn
                         0.08469                          -0.04841
```

2.6 実例: 62 年生まれ/26 歳の予測値

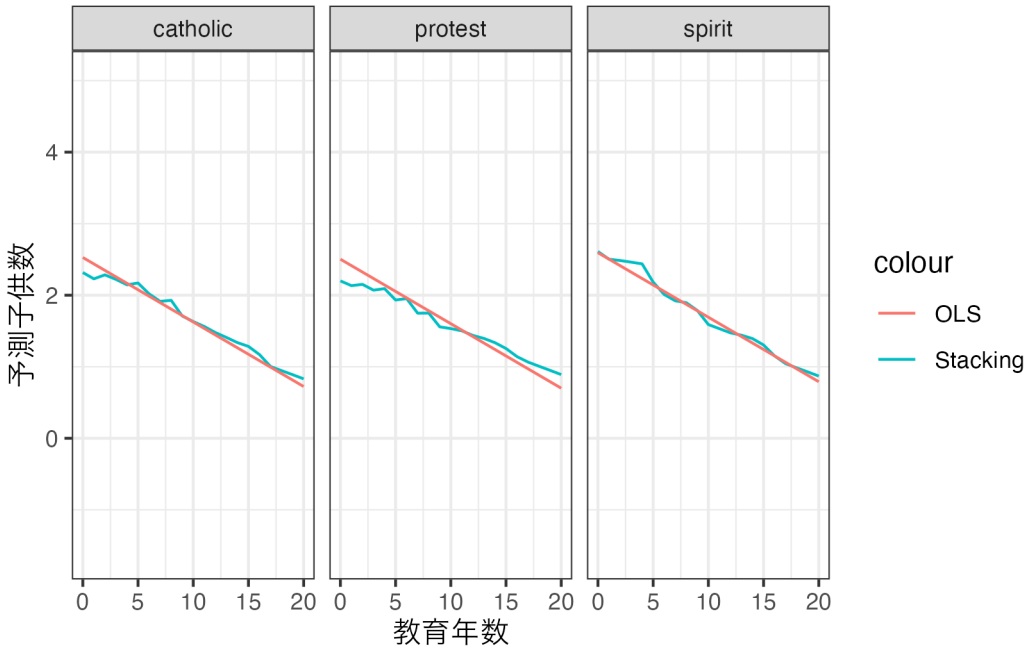

2.7 統計的推論

- 「前提 (仮定) が真であれば、結論は**概ね**真」
  - 「知見の蓄積」や「重要な意思決定への活用」の" 必須" 要件
- **社会的変数** (Social outcome) の予測は難しく、「予測値 = 真の子供数」はほぼ偽[*4]
  - **予測区間**[*5]: 仮定が真であれば、「Y は区間の範囲内」は概ね (90 % など) 真

[*4] Narayanan and Kapoor (2024)
[*5] Dewolf, Baets, and Waegeman (2023)

2.8 実例: 90 % 予測区間

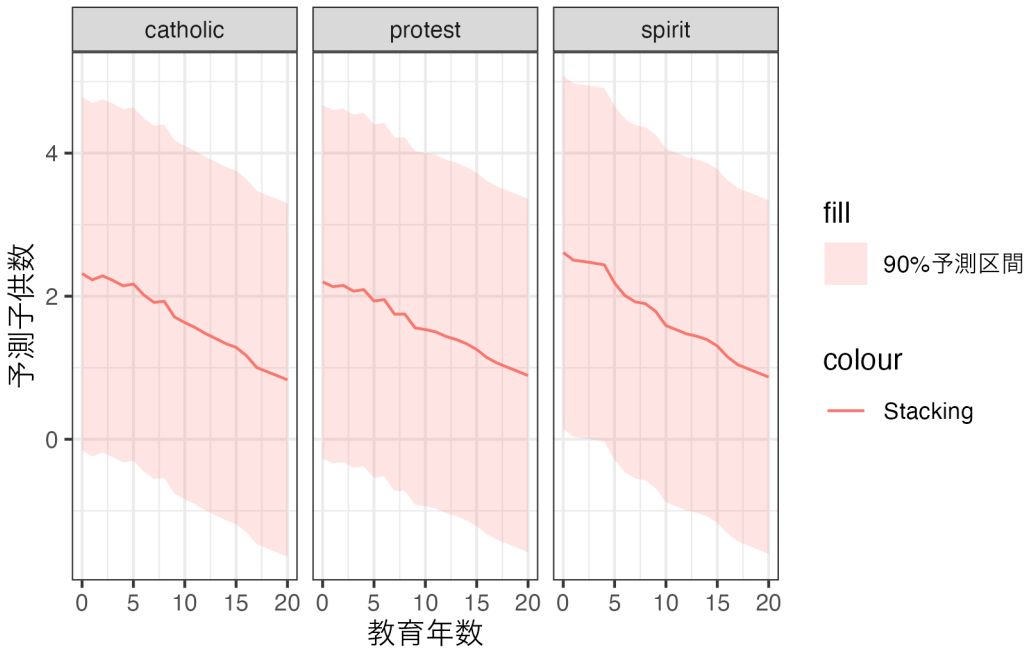
catholic
protest
spirit
予測子供数
4
2
0
0
5
10
15
20
教育年数
fill
90%予測区間
colour
Stacking

2.9 予測研究まとめ

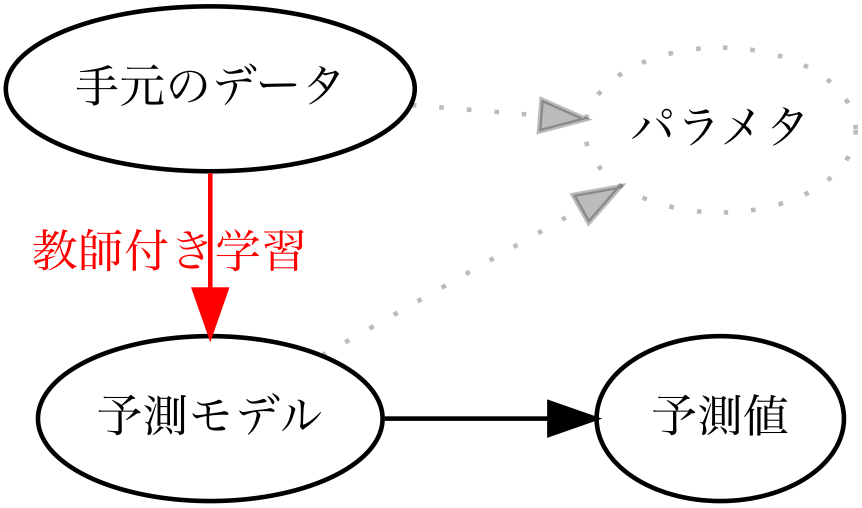

3 比較研究: Get started

3.1 社会の仕組みや特徴の把握

- 「政策や企業戦略案を立案、比較、検討する」ためには
  - 社会の特徴や仕組みを、**人間が**把握する必要がある
- 正確な賃金予測を提供されても、1 億個以上の数字を理解できる人間は存在しない
  - 高性能な予測モデルは、一般に複雑すぎて人間が理解できない
- 「母集団の**人間が理解できる**要約値 (**パラメタ**)」を、推定目標とする方が妥当

3.2 教育水準と子供数の関係性把握

- 初等教育の有無で、子供数はどのくらい異なるのか?
- 推定目標は、子供数の「包括モデル」ではなく、その一部 (初等教育と子供数の関係性)
- 人間が理解可能な推定目標を定義するために、**要約モデル**を活用
  - 予測ではなく、「推定目標となるパラメタの明確化」が役割

3.3 要約モデル

- $D_1 = \texttt{educ} \geq 7$ であれば 1、それ以外は 0
- $D_0 = \texttt{educ} < 7$ であれば 1、それ以外は 0
- 母集団の要約モデル

$$E[Y \mid D_0, D_1] = \underbrace{\beta_0}_{\text{推定目標}} \times D_0 + \underbrace{\beta_D}_{\text{推定目標}} \times D_1$$

3.4 推定方法: OLS VS 機械学習

- **統計的推論**: β_D に関する妥当な推論が目標
  - **信頼区間**: 仮定が真ならば、**推定目標**を" 概ね含む" 区間
- シンプルなモデルであれば、OLS による推定が有力
  - 機械学習の多くの手法は、信頼区間の計算が難しく、優位性もほとんどない

3.5 実例: 平均価格差

```
fertil2$D <- if_else(fertil2$educ >= 7,1,0)

lm_robust(children ~ 0 + factor(D), fertil2)
```

```
           Estimate Std. Error  t value Pr(>|t|) CI Lower CI Upper   DF
factor(D)0 3.251290 0.05610069 57.95454        0 3.141304 3.361276 4359
factor(D)1 1.481222 0.03286571 45.06891        0 1.416788 1.545655 4359
```

- $E[Y \mid D = 0]$: 概ね $3.14 \sim 3.36$
- $E[Y \mid D = 1]$: 概ね $1.42 \sim 1.55$

3.6 実例: 90 % 信頼 VS 予測区間

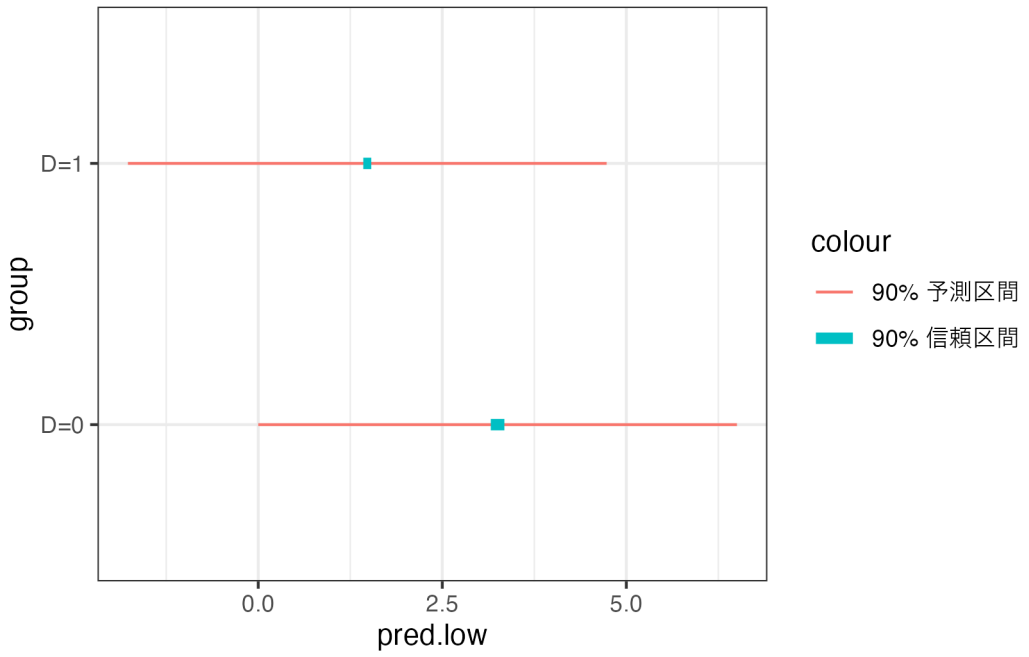

- 平均値を推論したいのであれば、(平均から乖離している事例の値も含むように計算される) 予測区間は" 過剰"

3.7　比較研究まとめ

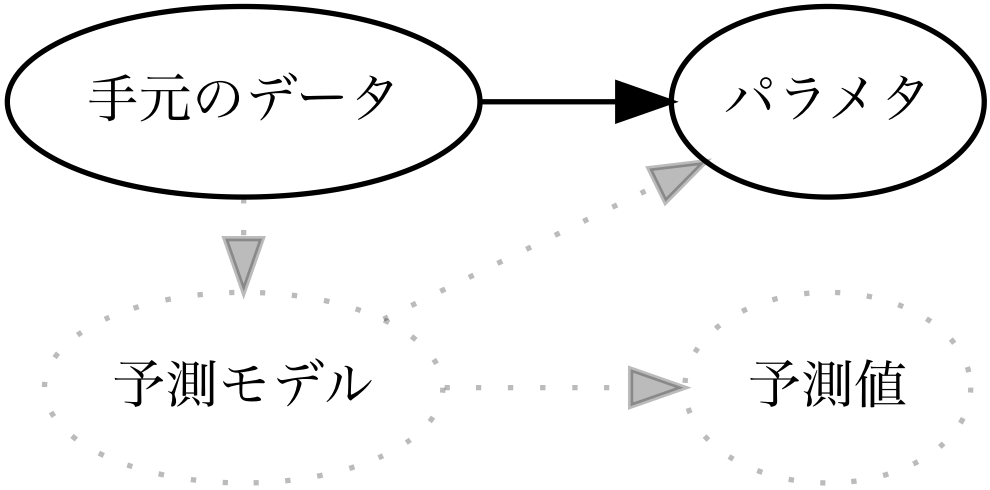

4　調整後の比較研究: Get started

4.1　初等教育と年齢や宗教的背景

```
love.plot(
  D ~ yearborn + age + spirit + protest + catholic, # 背景変数についての平均差
  data = fertil2
)
```

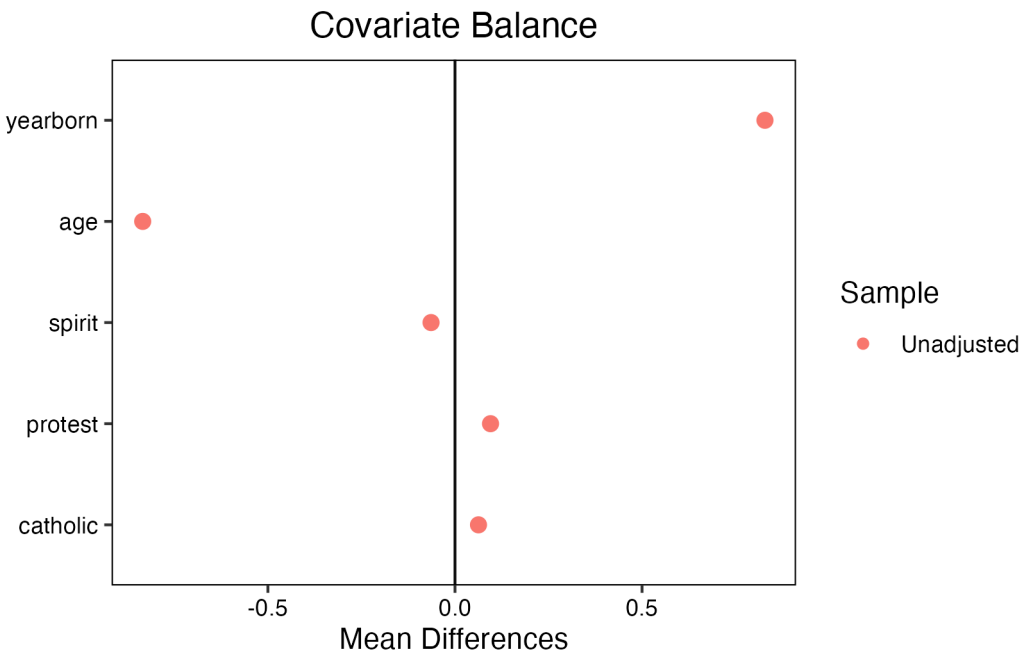

4.2　調整後の比較研究

- 同じような背景を持つ事例内で、初等教育以上かと否かと子供数の関係性を要約

$$E[Y \mid D_1 = 1, \underbrace{x}_{\text{背景}}] - E[Y \mid D_1 = 0, \underbrace{x}_{\text{背景}}] \text{の特徴}$$

- **応用例**: 合計的特殊出生率、物価指数 (Bajari et al. 2025)、因果効果 (Rehill 2025)、格差 (Vafa, Athey, and Blei 2025)、事業者や個人の評価 (Susmann et al. 2025; Hong et al. 2026)

4.3 Nuisance を含む要約モデル

- 要約モデルによって、関心となるパラメタとそれ以外 (Nuisance) を明確に定義できる

$$E[Y \mid D, X] \simeq \underbrace{\beta_D}_{\text{推定目標}} \times D_1 + \underbrace{\beta_1 X_1 + ...}_{Nuisance}$$

- **Nuisance の役割**: 関心ではないが、条件付き母平均を近似するために必要 (≃ コントロール)
  - **課題**: Nuisance の定式化

4.4 推定: OLS VS 教師付き学習 VS DML

- **OLS**: 研究者が Nuisance を単純かつ適切に定式化する必要がある
- **教師付き学習**: 信頼区間の計算が難しい
- **DML**: OLS と教師付き学習を" 併用"
  - 利点: 機械学習が複雑な予測モデルを活用しながら、信頼区間の計算ができる
  - DML の一例: Residuals regression

4.5 実例: Residuals regression

```
X <- select(fertil2,yearborn, age, spirit, protest, catholic) |>
    data.matrix()

task <- double_ml_data_from_data_frame(
  fertil2,
  x_cols = c("yearborn", "age", "spirit", "protest", "catholic"),
  y_col = "children",
  d_cols = "D")

model_beta <- DoubleMLPLR$new(
  task,
  stacking$clone(),
  stacking$clone(),
  n_folds = 2
)

model_beta$fit(store_predictions = TRUE)
```

4.6 実例: Residuals regression

```r
model_beta$summary()
```

```
Estimates and significance testing of the effect of target variables
  Estimate. Std. Error t value Pr(>|t|)
D  -0.57273    0.04759  -12.03   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- 信頼区間

```r
model_beta$confint()
```

```
       2.5 %     97.5 %
D -0.6660074 -0.4794473
```

- 初等教育以上か否かでの平均子供数差は-0.65 ∼ -0.46
  - 調整しない場合は、-1.90 ∼ -1.64

5 Takeaway

5.1 本日の要点

- 要約モデルと予測モデルは何が違うのか?
- 機械学習の役割は?

5.2　要約モデル VS 予測モデル

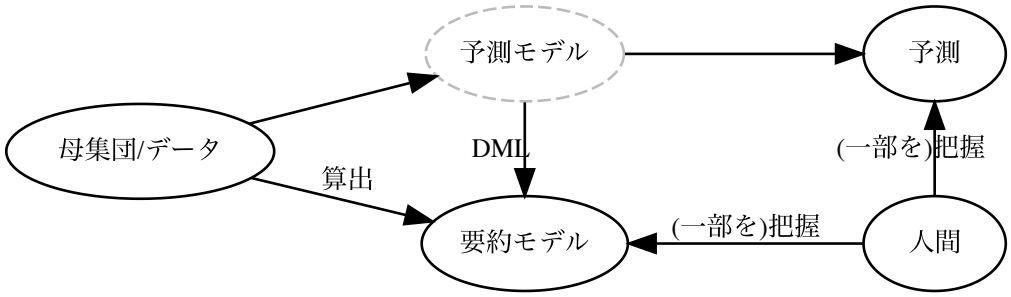

5.3 要約モデル VS 予測モデル

- **予測の活用例**:「背後にある予測モデルが理解できなくても」明日の天気予報は有益
- **記述の活用例**:「個別の留年を予測できなくても」平均的な留年率が高い層の同定は、教育政策、大学運営の基礎情報として有益
  - 「個別の因果効果が予測できなくても」、最低賃金が就業率や賃分分布に与える効果の推定は、労働市場政策の基礎情報として有益

5.4 機械学習の役割

- 一義的には、予測モデルの構築
  - ただし社会的変数の予測は難しい
- 要約モデルの推定への応用も有望
  - 直接的な活用は困難 (統計的性質がブラックボックス化し、適切な統計的推論が難しい)
  - nuisance の処理に活用 (DML)

5.5 "ブルシットジョブ" の外注

- **伝統なアプローチとの共通点**: 推定目標の定義と識別は、背景知識や「理論」を活用できる人間がやる
- **相違点**:「理論」が沈黙する部分 (nuisance に関するモデル定式化) の処理
  - **伝統的アプローチ**: 研究者が" 経験とカン" で定式化
  - **DML**: データにより多くを委ねる
- 研究者は、"人類が比較優位を持つ部分" (推定目標の設定) に集中できる
  - 私見: 時間制約が厳しい実務者による研究において、より比較優位を持つ手法

5.6　適当なイメージ

Figure1: Correct

5.7 不適当なイメージ

Figure2: Wrong

5.8 他の応用

- 母分布の組みわせとして定義する推定目標の推定一般に応用可能 (Ichimura and Newey 2022; Renson et al. 2025)
- 例: 被災者数の推定 (Das, Kennedy, and Jewell 2024)、平均以外による要約 (Kallus, Mao, and Uehara 2024; Kallus 2023; Chetverikov, Liu, and Tsyvinski 2025)
  - 柔軟な推定方法も議論 (Williams, Hines, and Rudolph 2025)
    - Engh and Aronow (2025)：汎用 LLM による予測の活用
- より一般的な議論 (Fernández-Villaverde forthcoming; Liang R & R)

6 補論: 研究目標

6.1 ３つの検討事項

1. **研究目標** (Research question) の設定: **社会**について、「知りたいこと」
2. **推定目標** (Esitmand/parameter of interest) の設定: 研究目標と関連する**母集団**の特徴
3. **推定方法** (Estimators) の設定: 推定目標についての推定結果を、**データ**から算出する方法

6.2　3 層構造

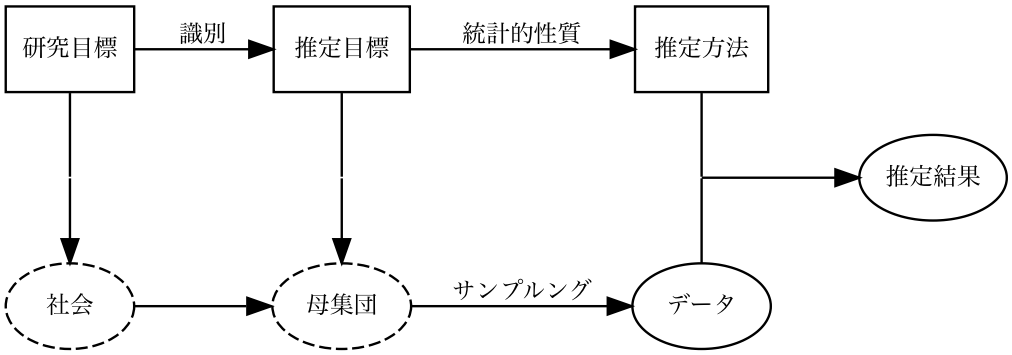

□ : 研究者が介入する、点線: 想像する

6.3 経済学の特徴

- 観察できる変数ではなく、データから直接観察できない**概念** (Concepts) を研究目標とすることが多い
  - 厚生、因果効果、反実仮想、格差等
- 経済/因果/規範理論: 研究目標となる概念を定義し、推定目標を識別する
- 汎用的な統計、機械学習、DML: 推定目標をデータから推定する

6.4 事後解釈 VS 識別

- 研究目標:「データから観察できない/実在しない」概念や仕組みによって、定義されうる
- **識別**: 研究目標 $\Longleftrightarrow$ 推定目標
- **事後解釈**: 推定結果を見てから、研究目標への含意を議論する (研究目標 $\Longleftrightarrow$ 推定結果)
  - 現代的なデータ分析: 識別 (研究目標への含意が明確な研究を計画する) をより重視する傾向

6.5 研究目標の分類軸

- 本講義と関連する研究目標は、以下の軸で分類できる[*6]
  - 要約か予測か: 集団の特徴を人間が把握したいのか、個別の値を予測したいのか?
  - 変数か概念/仕組みか: データから直接観察できる変数か？ 理論的に定義される概念か?
  - 外的妥当性をどこまで重視?: データを抽出した集団の外でも成り立つ知見を知りたい?

6.6 研究目標の分類: 例

	予測	記述
観察可能な変数	子供数の予測	子供数の平均差
観察不可能な概念	個別効果の予測	平均効果

- 外的妥当性を重視 $\simeq$ 自律的な関係性[*7] (法則性) を探求する研究目標

[*6] 要約・観察できる変数・外的妥当性を重視しない研究をまとめて、記述的研究と呼ぶこともある。
[*7] ルーカス批判 (Lucas Jr 1976) ; 自律性 (Aldrich 1989) ; 不変生 (Bühlmann 2020)

7　補論: 回帰木モデル

7.1　補論: 回帰木モデル

- 機械学習の手法の特徴は、**データ主導**
- 例: サブグループ分析
  - 伝統的アプローチ: 研究者がサブグループを設定し、平均値を算出する
  - データ主導のアプローチ: データに極力当てはまるように、サブグループも算出する
    - `rpart::rpart()` : データへの当てはまりを (近似的に) 最大にするようにサブグループを決定

7.2　実例. 30 歳以上と初等教育による分類

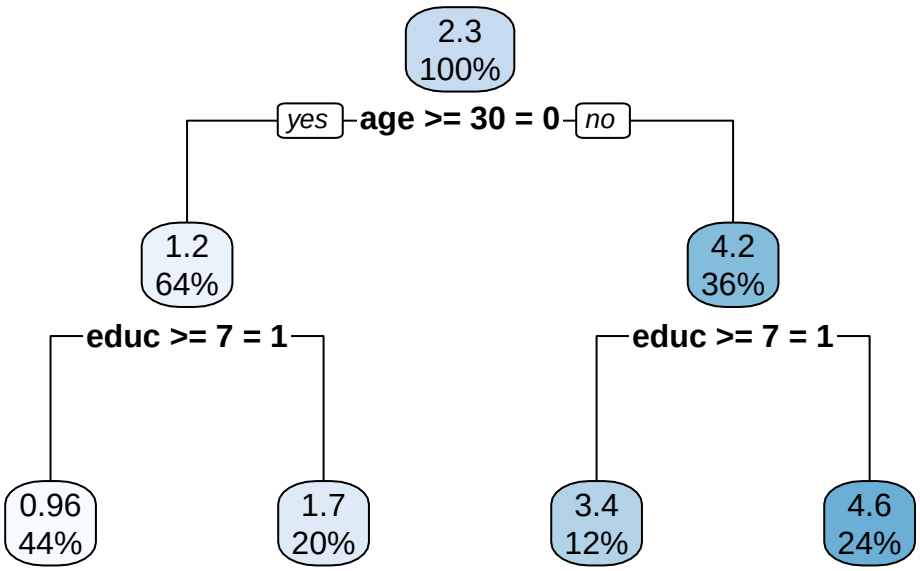

7.3　実例. データ主導

```
rpart::rpart(
  children ~ yearborn + age + spirit + protest + catholic + educ,
  fertil2,
  control = rpart::rpart.control(maxdepth = 2)) |>
```

```
rpart.plot::rpart.plot()
```

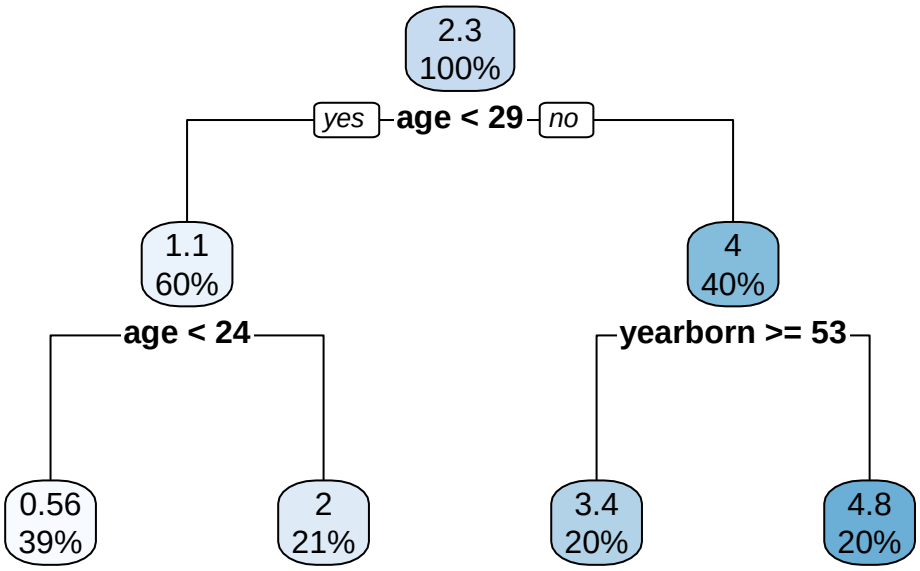

8 補論: 異質性の推定

8.1 Causal Forest[*8]

- 一般化した要約モデルを推定できる

$$E[Y \mid D, X] \simeq \underbrace{\beta_D(X)}_{\text{推定目標}=X\text{の関数}} D + \underbrace{\beta_1 X_1 + ...}_{Nuisance}$$

```
model_cate <- grf::causal_forest(
  Y = fertil2$children,
  W = fertil2$D,
  X = select(
    fertil2,
    yearborn, age, spirit, protest, catholic),
  Y.hat = model_beta$predictions$ml_l,
  W.hat = model_beta$predictions$ml_m)
```

[*8] Wager and Athey (2018) ; Athey, Tibshirani, and Wager (2019)

8.2 $\beta_D(X)$ の推定結果

```
tibble(`E[Y|D=1,X]-E[Y|D=0,X]`= model_cate$predictions[,1]) |>
  ggplot(
    aes(
      x = `E[Y|D=1,X]-E[Y|D=0,X]`
    )
  ) +
  geom_histogram() +
  theme_bw() +
  ylab("事例数")
```

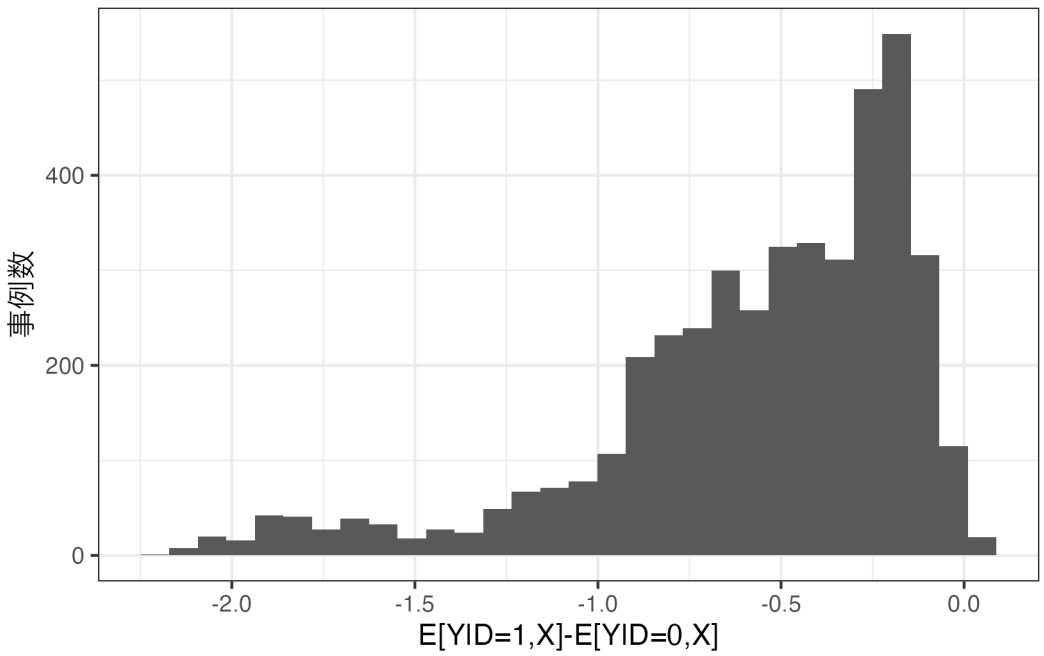

8.3 BLP (Semenova and Chernozhukov 2021)

```
grf::best_linear_projection(
  model_cate,
  model.matrix(
    ~ 0 + scale(yearborn) + spirit + protest + catholic,
    fertil2)
```

```
  )
```

```
Best linear projection of the conditional average treatment effect.
Confidence intervals are cluster- and heteroskedasticity-robust (HC3):

                 Estimate Std. Error t value  Pr(>|t|)
(Intercept)     -0.719187   0.125902 -5.7123 1.189e-08 ***
scale.yearborn.  0.425052   0.088839  4.7845 1.771e-06 ***
spirit           0.302889   0.147013  2.0603   0.03943 *
protest          0.163684   0.191066  0.8567   0.39166
catholic        -0.072992   0.227250 -0.3212   0.74808
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

8.4 GATE (Chernozhukov et al. 2025)

```
fertil2$gate_group <- ntile(model_cate$predictions,3)

grf::average_treatment_effect(
  model_cate,
  subset = fertil2$gate_group == 1)
```

```
  estimate    std.err
-0.9375490  0.1304094
```

```
grf::average_treatment_effect(
  model_cate,
  subset = fertil2$gate_group == 2)
```

```
   estimate     std.err
-0.59503025  0.08111519
```

```
grf::average_treatment_effect(
  model_cate,
  subset = fertil2$gate_group == 3)
```

```
   estimate     std.err
```

Characteristic	**1** N = 1,454[1]	**2** N = 1,454[1]	**3** N = 1,453[1]
yearborn	54 (47, 58)	61 (56, 64)	69 (66, 71)
age	34 (30, 41)	27 (24, 32)	19 (17, 21)
spirit	482 (33%)	650 (45%)	709 (49%)
protest	399 (27%)	305 (21%)	289 (20%)
catholic	180 (12%)	175 (12%)	92 (6.3%)

[1]Median (Q1, Q3); n (%)

```
-0.15173603  0.08586734
```

8.5 CLAN (Chernozhukov et al. 2025)

```
select(fertil2,gate_group,yearborn,age,spirit,protest,catholic) |>
  gtsummary::tbl_summary(
    by = gate_group
  )
```

Reference

Aldrich, John. 1989. "Autonomy." *Oxford Economic Papers* 41 (1): 15–34.

Athey, Susan, Julie Tibshirani, and Stefan Wager. 2019. "Generalized Random Forest." *The Annals of Statistics* 47 (2): 1148–78.

Bajari, Patrick, Zhihao Cen, Victor Chernozhukov, Manoj Manukonda, Suhas Vijaykumar, Jin Wang, Ramon Huerta, et al. 2025. "Hedonic Prices and Quality Adjusted Price Indices Powered by AI." *Journal of Econometrics* 251: 106052.

Bühlmann, Peter. 2020. "Invariance, Causality and Robustness." *Statistical Science* 35 (3): 404–26.

Chernozhukov, Victor, Mert Demirer, Esther Duflo, and Iván Fernández-Val. 2025. "Fisher–Schultz Lecture: Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments, with an Application to Immunization in India." *Econometrica* 93 (4): 1121–64.

Chernozhukov, Victor, Christian Hansen, Nathan Kallus, Martin Spindler, and Vasilis Syrgkanis. 2026. "Applied Causal Inference Powered by ML and AI."

Chetverikov, Denis, Yukun Liu, and Aleh Tsyvinski. 2025. "Weighted-Average Quantile Regression." *Journal of Econometrics* 252: 106115.

Das, Manjari, Edward H Kennedy, and Nicholas P Jewell. 2024. "Doubly Robust Capture-Recapture Methods for Estimating Population Size." *Journal of the American Statistical Association* 119 (546): 1309–21.

Dewolf, Nicolas, Bernard De Baets, and Willem Waegeman. 2023. "Valid Prediction Intervals for Regression Problems." *Artificial Intelligence Review* 56 (1): 577–613.

Engh, Chris, and PM Aronow. 2025. "Using LLMs to Directly Guess Conditional Expectations Can Improve Efficiency in Causal Estimation." *arXiv Preprint arXiv:2510.09684*.

Fernández-Villaverde, Jesús. forthcoming. "Deep Learning for Solving Economic Models." *Journal of Economic Literature*, forthcoming.

Hansen, Bruce E. 2022. *Econometrics*. Princeton, NJ: Princeton University Press.

Hong, Miru, Minho Lee, Geonhee Jo, Hyeokje Jo, Pascal Bauer, and Sang-Ki Ko. 2026. "Modeling Matches as Language: A Generative Transformer Approach for Counterfactual Player Valuation in Football." *arXiv Preprint arXiv:2603.15212*.

Ichimura, Hidehiko, and Whitney K Newey. 2022. "The Influence Function of Semiparametric Estimators." *Quantitative Economics* 13 (1): 29–61.

Imbens, Guido, and Susan Athey. 2021. "Breiman's Two Cultures: A Perspective from Econometrics." *Observational Studies* 7 (1): 127–33.

James, Gareth, Daniela Witten, Trevor Hastie, Robert Tibshirani, et al. 2021. *An Introduction to Statistical Learning*. Vol. 112. Springer.

Kallus, Nathan. 2023. "Treatment Effect Risk: Bounds and Inference." *Management Science* 69 (8): 4579–90.

Kallus, Nathan, Xiaojie Mao, and Masatoshi Uehara. 2024. "Localized Debiased Machine Learning: Efficient Inference on Quantile Treatment Effects and Beyond." *Journal of Machine Learning Research* 25 (16): 1–59.

Liang, Annie. R & R. "Using Machine Learning to Generate, Clarify, and Improve Economic Models." *Journal of Economic Literature*, R & R.

Lucas Jr, Robert E. 1976. "Econometric Policy Evaluation: A Critique." In *Carnegie-Rochester Conference Series on Public Policy*, 1:19–46. North-Holland.

Narayanan, Arvind, and Sayash Kapoor. 2024. *AI Snake Oil: What Artificial Intelligence Can Do, What It Can't, and How to Tell the Difference*. Princeton University Press.

Rehill, Patrick. 2025. "How Do Applied Researchers Use the Causal Forest? A Methodological Review." *International Statistical Review* 93 (2): 288–316.

Renson, Audrey, Lina Montoya, Dana E Goin, Iván Díaz, and Rachael K Ross. 2025. "Pulling Back the Curtain: The Road from Statistical Estimand to Machine-Learning-Based Estimator for Epidemiologists (No Wizard Required)." *American Journal of Epidemiology* 194 (12): 3566–71.

Rose, Evan K. 2023. "A Constructivist Perspective on Empirical Discrimination Research." *Journal of Economic Literature* 61 (3): 906–23.

Semenova, Vira, and Victor Chernozhukov. 2021. "Debiased Machine Learning of Conditional Average Treatment Effects and Other Causal Functions." *The Econometrics Journal* 24 (2): 264–89.

Shapiro, Jesse M. 2026. *Introduction to Quantitative Economics*. MIT Press.

Stock, James H., and Mark W. Watson. 2019. *Introduction to Econometrics*. 4th Global. Harlow, United Kingdom: Pearson Education Limited.

Susmann, Herbert P, Yiting Li, Mara A McAdams-DeMarco, Iván Díaz, and Wenbo Wu. 2025. "Doubly

Robust Nonparametric Efficient Estimation for Healthcare Provider Evaluation." *Journal of the Royal Statistical Society Series A: Statistics in Society*, qnaf145.

Vafa, Keyon, Susan Athey, and David M Blei. 2025. "Estimating Wage Disparities Using Foundation Models." *Proceedings of the National Academy of Sciences* 122 (22): e2427298122.

Wager, Stefan, and Susan Athey. 2018. "Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests." *Journal of the American Statistical Association* 113 (523): 1228–42.

Wang, Linbo, Thomas Richardson, and James Robins. 2025. "Causal Inference: A Tale of Three Frameworks." *arXiv Preprint arXiv:2511.21516*.

Williams, Nicholas T, Oliver J Hines, and Kara E Rudolph. 2025. "Riesz Representers for the Rest of Us." *arXiv Preprint arXiv:2507.19413*.