線形近似モデル

経済学のための機械学習入門

川田恵介

2026-04-11

Table of contents

1 **線形モデル**: Get started 3

1.1 子供の数のモデル . . . 3

1.2 OLS と LASSO による推定 . . . 4

1.3 Simple OLS . . . 4

1.4 OLS . . . 5

1.5 LASSO . . . 5

1.6 結果 . . . 6

1.7 本日の到達目標 . . . 7

2 **OLS によるデータへの当てはめ** 7

2.1 想定するデータ . . . 7

2.2 線形モデル . . . 7

2.3 OLS . . . 8

2.4 OLS の別解釈 . . . 8

2.5 数値例 . . . 8

2.6 例: `children` ∼ `educ` . . . 9

2.7 例: `children` ∼ `educ` . . . 10

2.8 よくある誤解 . . . 10

2.9 例: `children` ∼ `poly(educ,2)` . . . 11

2.10 例: `children` ∼ `poly(educ,6)` . . . 11

3 **推定の基本枠組み** 12

3.1 推定 12

3.2 Sampling Uncertainty 12

3.3 推定目標 12

3.4 母集団 12

3.5 まとめ: 三層構造 13

4 **条件付き母平均の推定** 14

4.1 本講義の鍵となる推定目標 14

4.2 アナログ原理による推定 14

4.3 問題点: 次元の呪い 14

4.4 数値例: N = 5000 15

4.5 数値例: N = 50 15

4.6 まとめ: 平均値による推定 16

5 **線形モデルの活用** 16

5.1 モデル化による対処 16

5.2 OLS の事実上の推定目標 16

5.3 条件付き母平均の推定 16

5.4 整理: OLS 17

6 **Population OLS の推定** 17

6.1 アナログ原理による推定 17

6.2 推定精度 17

6.3 過剰適合 17

6.4 数値例: $Y \sim \beta_0 + \beta_1 X$ 18

6.5 数値例: $Y \sim \beta_0 + \beta_1 X$ 19

6.6 数値例: $Y \sim \beta_0 + \cdots + \beta_6 X^6$ 19

6.7 数値例: $Y \sim \beta_0 + \cdots + \beta_6 X^6$ 20

6.8 まとめ 20

7 LASSO 20
7.1 LASSO 20
7.2 罰則付き回帰の一つ 21
7.3 経済学のアナロジー 21
7.4 LASSO 21
7.5 数値例: $Y \sim \beta_0 + \cdots + \beta_6 X^6$ 22
7.6 数値例: $Y \sim \beta_0 + \cdots + \beta_6 X^6$ 22
7.7 LASSO による変数選択 23
7.8 LASSO VS OLS 23
7.9 予告: LASSO の応用 23
7.10 補論: Ridge 23

8 **補論 (多分に私見)** 23
8.1 母集団/推定目標の実質的役割 23
8.2 イメージ 24
8.3 余談: 関連する?格言集 24
8.4 余談: 関連する?格言集 24
Reference 25

1 線形モデル: Get started

1.1 子供の数のモデル

```
set.seed(111)

data("fertil2", package = "wooldridge")
```

- Simple モデル $= \beta_0 + \beta_1 \times yearborn + \beta_2 \times educ$
- Main モデル $=$

$$\begin{aligned} &\beta_0 + \beta_1 \times yearborn + \beta_2 \times educ \\ &+ \underbrace{\beta_3 \times yearborn^2 + \beta_4 \times educ^2}_{\text{二乗項}} \\ &+ \underbrace{\beta_5 \times yearborn \times educ}_{\text{交差項}} \end{aligned}$$

1.2 OLS と LASSO による推定

```r
simple <- lm(
  children ~ yearborn + educ, # Simple
  fertil2) # OLS

ols <- lm(
  children ~ (yearborn + educ)^2
  + I(yearborn^2) + I(educ^2), # Main
  fertil2) # 交差項 + 二乗項

lasso <- hdm::rlasso(  # LASSO
  children ~ (yearborn + educ)^2
  + I(yearborn^2) + I(educ^2), # Main
  fertil2,
  post = FALSE)
```

1.3 Simple OLS

```r
summary(simple)
```

```
Call:
lm(formula = children ~ yearborn + educ, data = fertil2)

Residuals:
    Min      1Q  Median      3Q     Max 
-6.5461 -0.6668 -0.0647  0.7532  7.1528 

Coefficients:
             Estimate Std. Error t value Pr(>|t|)    
(Intercept) 13.360799   0.157809   84.66   <2e-16 ***
yearborn    -0.174735   0.002703  -64.64   <2e-16 ***
educ        -0.091035   0.005977  -15.23   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.475 on 4358 degrees of freedom
Multiple R-squared:  0.5595,	Adjusted R-squared:  0.5593
F-statistic:  2768 on 2 and 4358 DF,  p-value: < 2.2e-16
```

1.4 OLS

```r
summary(ols)
```

```
Call:
lm(formula = children ~ (yearborn + educ)^2 + I(yearborn^2) + 
    I(educ^2), data = fertil2)

Residuals:
    Min      1Q  Median      3Q     Max 
-5.9086 -0.6806  0.0035  0.7110  7.4452 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)    3.8642513  0.9021586   4.283 1.88e-05 ***
yearborn       0.1802020  0.0321261   5.609 2.16e-08 ***
educ          -0.1963339  0.0460694  -4.262 2.07e-05 ***
I(yearborn^2) -0.0032765  0.0002857 -11.467  < 2e-16 ***
I(educ^2)     -0.0087300  0.0012038  -7.252 4.83e-13 ***
yearborn:educ  0.0035962  0.0007351   4.892 1.04e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.447 on 4355 degrees of freedom
Multiple R-squared:  0.5765,	Adjusted R-squared:  0.576 
F-statistic:  1186 on 5 and 4355 DF,  p-value: < 2.2e-16
```

1.5 LASSO

```r
summary(lasso,all = FALSE)
```

```
Call:
rlasso.formula(formula = children ~ (yearborn + educ)^2 + I(yearborn^2) +
    I(educ^2), data = fertil2, post = FALSE)

Post-Lasso Estimation:  FALSE

Total number of variables: 5
Number of selected variables: 2

Residuals:
     Min       1Q   Median       3Q      Max
-5.97267 -0.70567 -0.06414  0.72063  7.52478

              Estimate
(Intercept)      8.279
I(yearborn^2)   -0.002
I(educ^2)       -0.007

Residual standard error: 1.455
Multiple R-squared:  0.5715
Adjusted R-squared:  0.5713
Joint significance test:
 the sup score statistic for joint significance test is 1.091e+05 with a p-value of     0
```

- 変数選択が生じ、一部の X がモデルから" 除外" (係数が厳密に 0) されている

1.6 結果

- 定義上、「Main モデル + OLS」が決定係数[*1]は最も高い
- 「Main モデル + LASSO」の決定係数は、「Main モデル + OLS」と大差ない
  - 「Simple モデル + OLS」よりも高い

[*1] 係数の数が事例数に比べて少なければ、予測性能の近似指標

1.7 本日の到達目標

1. データ分析の論定整理法に慣れる

- 社会とデータの仮想的な中間層 (母集団) を導入し、データと推定目標 (+ 予測目標) を定義する

2. OLS や LASSO を、「条件付き母平均の最善の線形近似モデル」を**推定目標**とする推定方法であると解釈する[*2]

2 OLS によるデータへの当てはめ

2.1 想定するデータ

```
  children yearborn educ
1        0       64   12
2        3       56   13
3        1       58    5
4        2       45    4
5        2       45   11
6        1       52    7
```

- 行が事例、列が変数、セルが値に対応
  - tidy データ形式

2.2 線形モデル

- 係数 $\beta = [\beta_0, \beta_1]$ について、足し算のモデル:

$$\beta_0 + \beta_1 \times X_1$$

- 注: 本スライドでは、スペースを節約するために単回帰を例とする。
  - 議論の中身は、重回帰 $(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots)$ にも適用できる

[*2] 参考資料: Angrist and Pischke (2009) ; Aronow and Miller (2019) ; Chernozhukov et al. (2026)

2.3 OLS

- 以下を最小にするように β を決定する:

$$
\begin{aligned}
&(\underbrace{Y_1}_{\text{第1事例の}Y} - \beta_0 - \beta_1 \times \underbrace{X_1}_{\text{第1事例の}X})^2 \\
&+(\underbrace{Y_2}_{\text{第2事例の}Y} - \beta_0 - \beta_1 \times \underbrace{X_2}_{\text{第2事例の}X})^2 + ...
\end{aligned}
$$

- 極力 Y の値に当てはまるように推定:「Y のモデル」

2.4 OLS の別解釈

- 以下を最小しても、同じ β が算出される:

$$(\text{第1事例の平均値} - \beta_0 - \beta_1 \times X_1)^2 + ...$$

- ただし第 1 事例の平均値は、X_1 についての条件付き平均値
- 「Y の平均値のモデル」

2.5 数値例

Y	X	Y の平均値
4	1	4
3	2	3
4	3	3
2	3	3

- モデルを「Y の平均値」に OLS で当てはめても、同じ係数が算出される

2.6 例: `children` ∼ `educ`

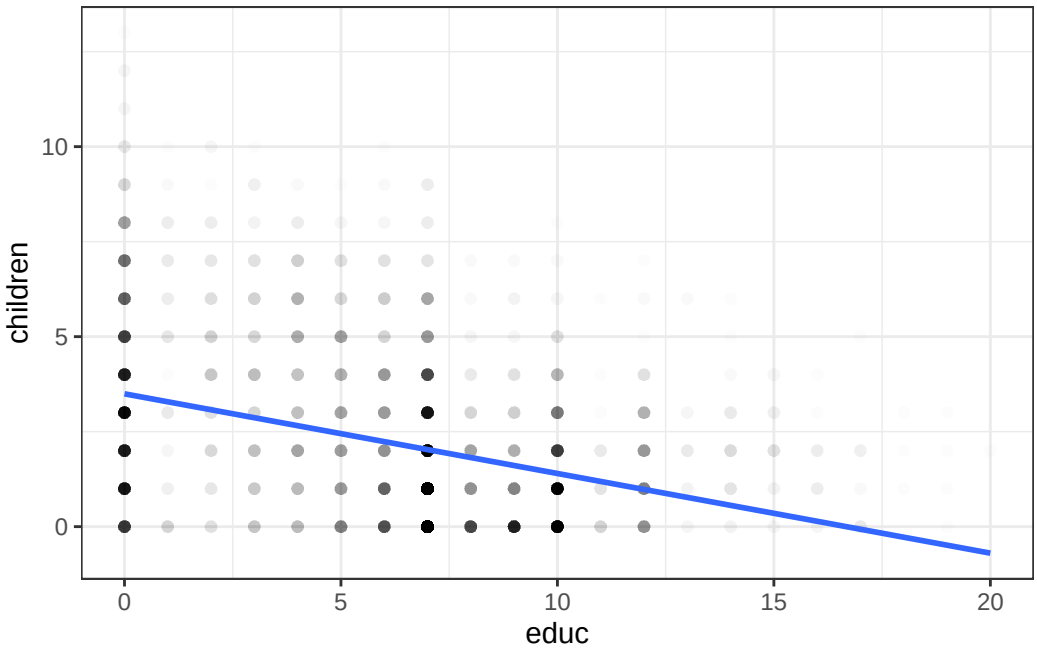

- Y のモデルに見えない?

2.7 例: `children` ∼ `educ`

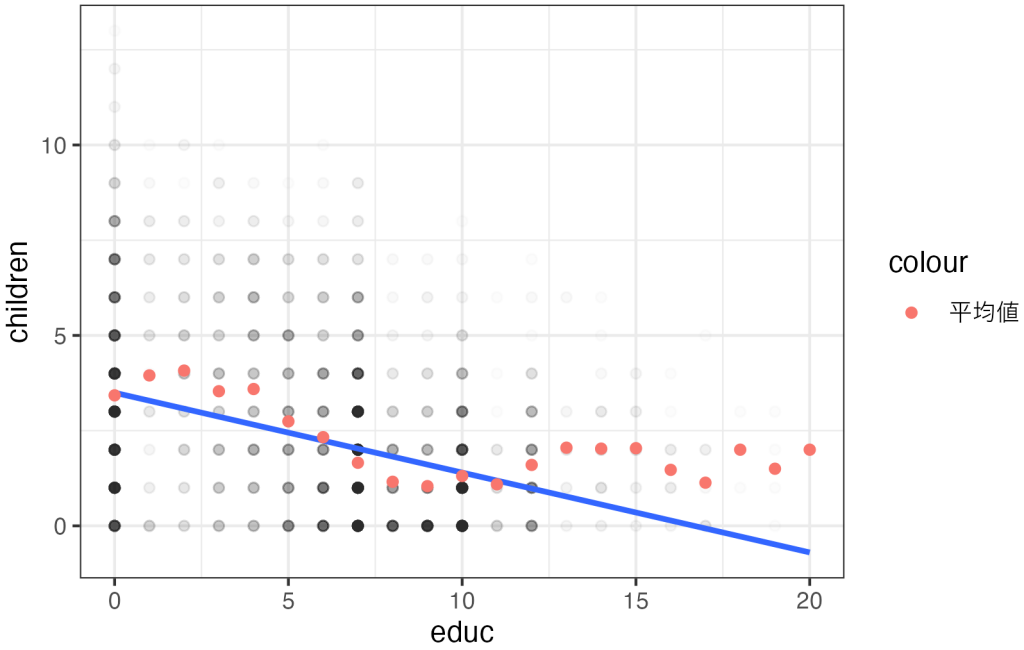

2.8 よくある誤解

- X ではなく、β について足し算であれば OK
- 高次項や交差項も導入できる

$$\beta_0 + \beta_1 \times X + \beta_2 \times X^2 + ...$$

2.9 例: `children` ∼ `poly(educ,2)`

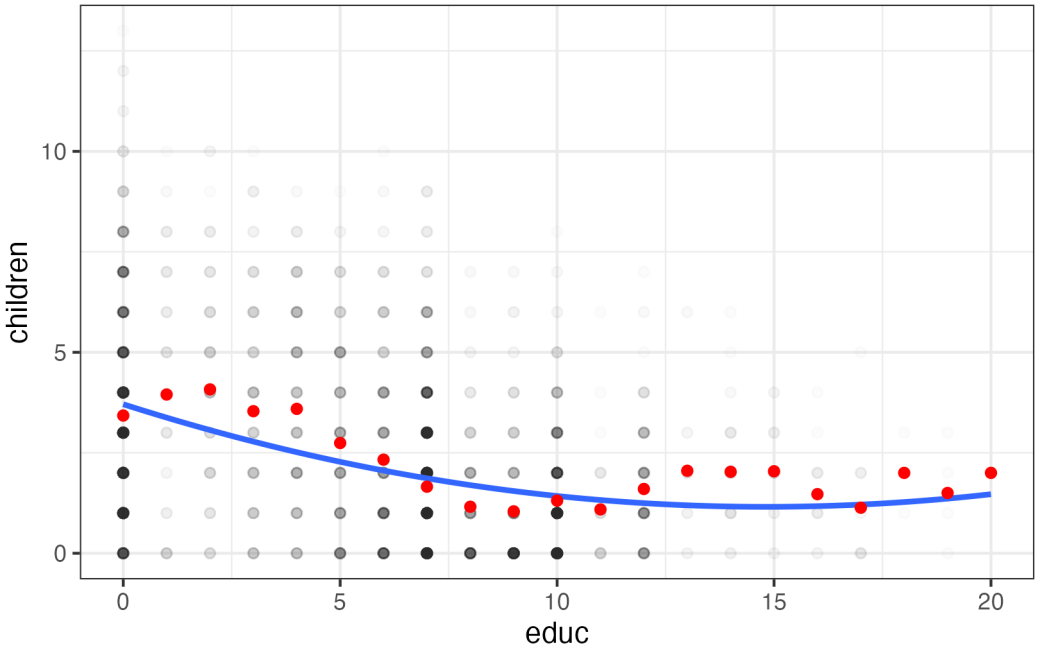

2.10 例: `children` ∼ `poly(educ,6)`

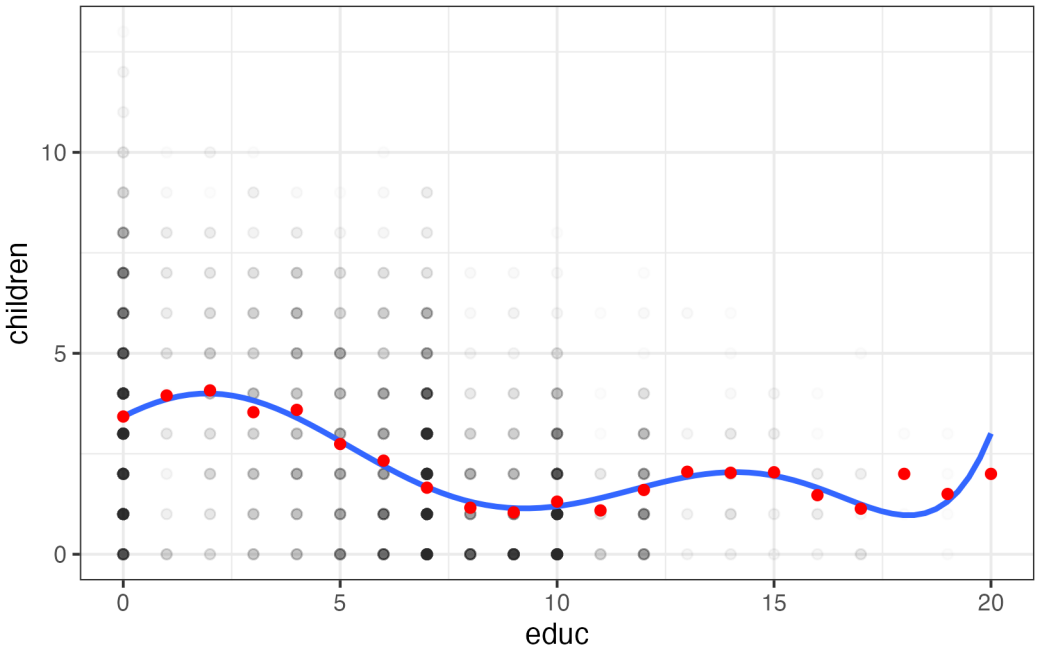

- **十分な高次項と交差項を加えれば、平均値を”なぞる”モデルが算出される**

3 推定の基本枠組み

3.1 推定

- そのままでは意思決定や社会の理解に活用できない膨大な事例集 (データ) から、推定結果 (情報) を抽出する
- 推定結果には、特定の活用目的 (予測、社会の理解等) がある

3.2 Sampling Uncertainty

- 二つの研究チームが、**同じ社会**から、**同じ方法**でデータを収集し、**同じ分析コード**を使用しても、
  - **推定結果は異なり**、結果の厳密な再現ができない
- データに含まれる事例が異なる
  - 厳密には、「データから観察できない性質」が異なる
    - 経済学の関心 (人間、企業、国家等) において顕著
    - 「理科室での実験」との決定的な相違

3.3 推定目標

- 「不確実性への対処」を論じるために、以下を区別する:
  - **推定目標**: データから原理的に導ける**正答**
  - **推定結果**: データからの実際の**回答**
- 「回答は研究者によって異なるが、正答は共通」という問題設定に持ち込む

3.4 母集団

- データと推定目標を定義 (接続) するための「仮舞台」
  - 本講義では、「**データと同じ変数**、**無限大の事例数**、を持つ巨大データ」をイメージして OK
- **データ**: **母集団**から独立・無相関 (I.I.D)[*3]に選ばれた事例から構成
- **推定目標**: **母集団**から (研究者が決めた方法で) 計算できる値
  - 母集団が同じであれば、推定目標は共通

[*3] Random Sampling などで保証

3.5 まとめ: 三層構造

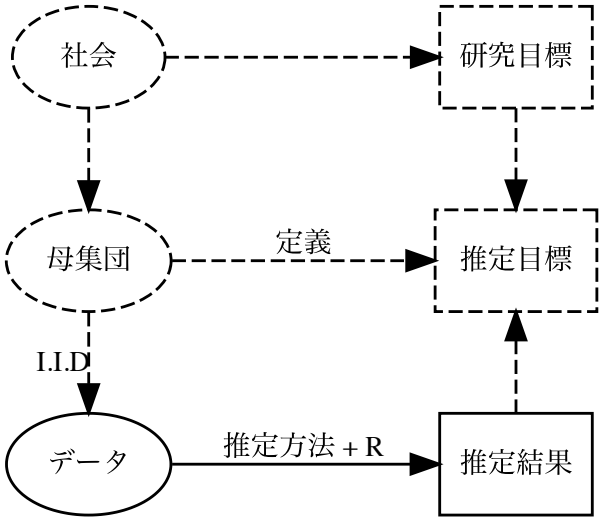

4　条件付き母平均の推定

4.1　本講義の鍵となる推定目標

- Y の X についての (条件付き) 母平均 $E[Y \mid X]$
- 例: 同じ年齢、生まれ年、教育年数の事例の**母集団における**平均子供数

$$E[children \mid \underbrace{age, yearbirth, educ, religion}_{X}]$$

- 一定の条件のもとで、子供数の最善の予測値

4.2　アナログ原理による推定

- シンプルな推定方法: 推定目標の定義式 (母集団上での計算式) をデータに適用
  - X ごとに平均値を計算する
    - 「データ $\simeq$ 母集団」を期待
- **正当化**: 一致性
  - 「ランダムサンプリング」+「$1/$事例数 $\to 0$」であれば、「データ上の平均値 $=$ 母平均」

4.3　問題点: 次元の呪い

- `yearbirth`, `educ` の組み合わせは、原理的に 756 個の条件付き母平均が存在する
  - 推定: 1 事例しかない組み合わせが 96、データ上に事例が存在しない組みわせが 288
    - データに選ばれた事例が偶然持つ特徴を強く反映してしまう
    - 一致性を根拠にできるほどの、十分な事例数が確保できていない

4.4　数値例: N = 5000

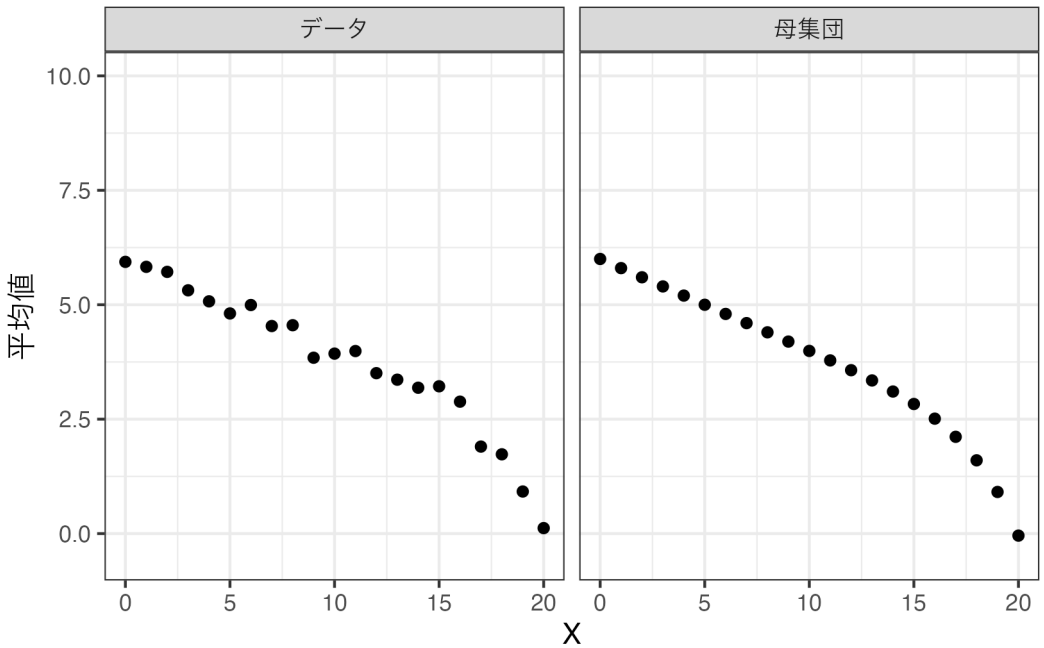

4.5　数値例: N = 50

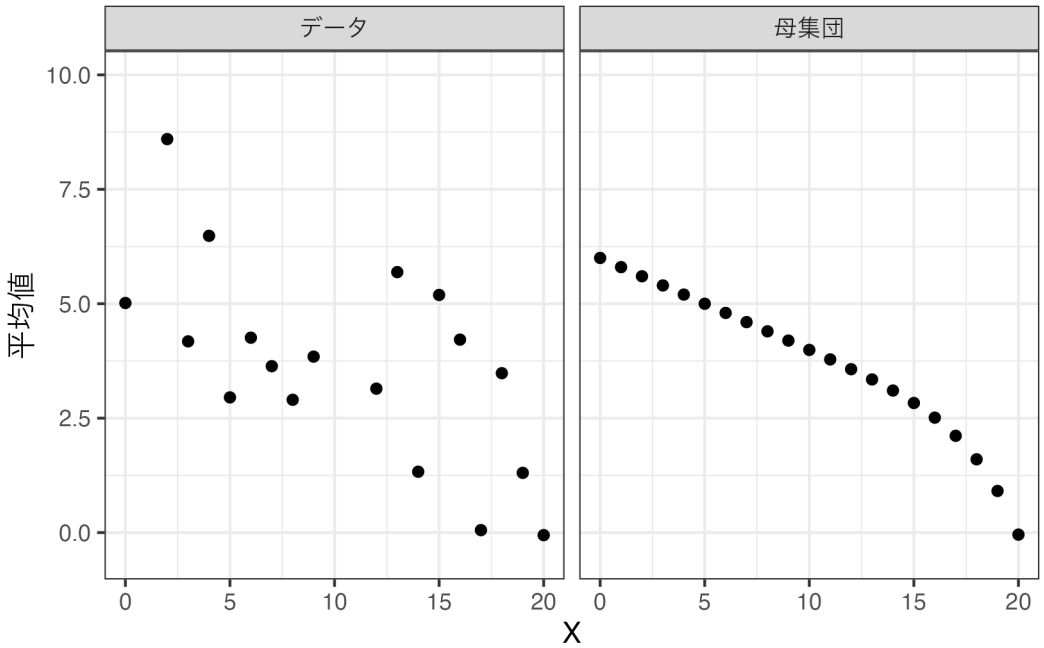

4.6 まとめ: 平均値による推定

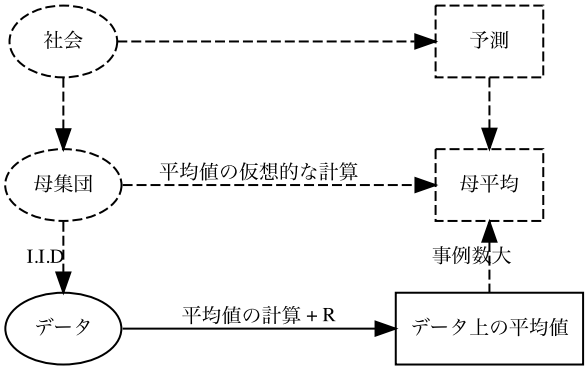

Figure1: “Mean”

5 線形モデルの活用

5.1 モデル化による対処

- 母平均のモデルを想定する
$$E[Y \mid X] \simeq \beta_0 + \beta_1 X_1 + ...$$
- 例: $E[children \mid yearbirth, educ] \simeq$
$$\beta_0 + \beta_1 \times yearbirth + \beta_2 \times educ$$
- 個別の母平均ではなく、(たった 3 つの) β を推定する問題に置き換わる

5.2 OLS の事実上の推定目標

- あるモデル $\beta_0 + \beta_1 X_1 + ...$ を無限大の事例数を持つデータに当てはめた場合、
  - 推定結果 = 同じモデルを**条件付き母平均**に OLS で当てはめた結果 (Population OLS)
    - Best Linear Projection (Prediction)
- 含意: **どのようなモデルを推定したとしても**、そのモデルを前提とした「母平均のモデル」を、推定目標として想定できる

5.3 条件付き母平均の推定

- 「推定目標 = 条件付き母平均」とするには、

– Population OLS $\simeq E[Y \mid X]$ を保証する必要がある
– 高次項や交差項を導入する必要がある

5.4 整理: OLS

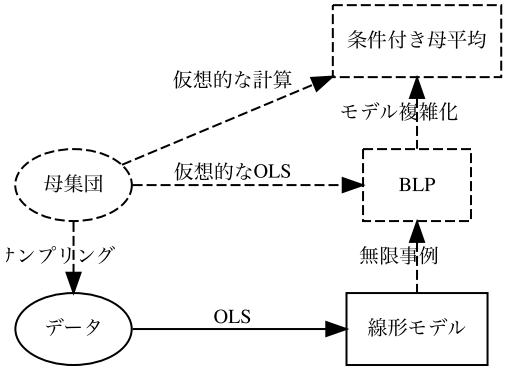

Figure2: “OLS”

6 Population OLS の推定

6.1 アナログ原理による推定

- 推定方法: 推定目標を定義式 (母集団上での計算式) をデータ上で行う
  – データ上での OLS!!!
- **正当化**: 一致性
  –「ランダムサンプリング」+「係数の数/事例数 $\to 0$」であれば、「データ上での OLS = Population OLS」

6.2 推定精度

- 「Population OLS とデータ上での OLS の乖離」は、事例数だけでなく、係数の数/事例数にも依存
- 「係数の数 $\geq$ 事例数」では、OLS では推定不可能
  –「係数の数 $\simeq$ 事例数」では、推定精度が大幅に悪化 (過剰適合)
- Kolesár, Müller, and Roelsgaard (2025)
  –「係数の数 $> 0.2\times$ 事例数」では、**過剰適合** が深刻化

6.3 過剰適合

- 「推定結果と推定目標」を改めて意識

- 推定目標: 母平均
- 少ない事例数のデータで、複雑なモデルを推定すると

$$\text{データ上での}OLS \underbrace{\simeq}_{\text{複雑なモデル}} \text{データ上での平均}$$
$$\underbrace{\neq}_{\text{少ない事例数}} \text{母平均}$$

6.4 数値例: $Y \sim \beta_0 + \beta_1 X$

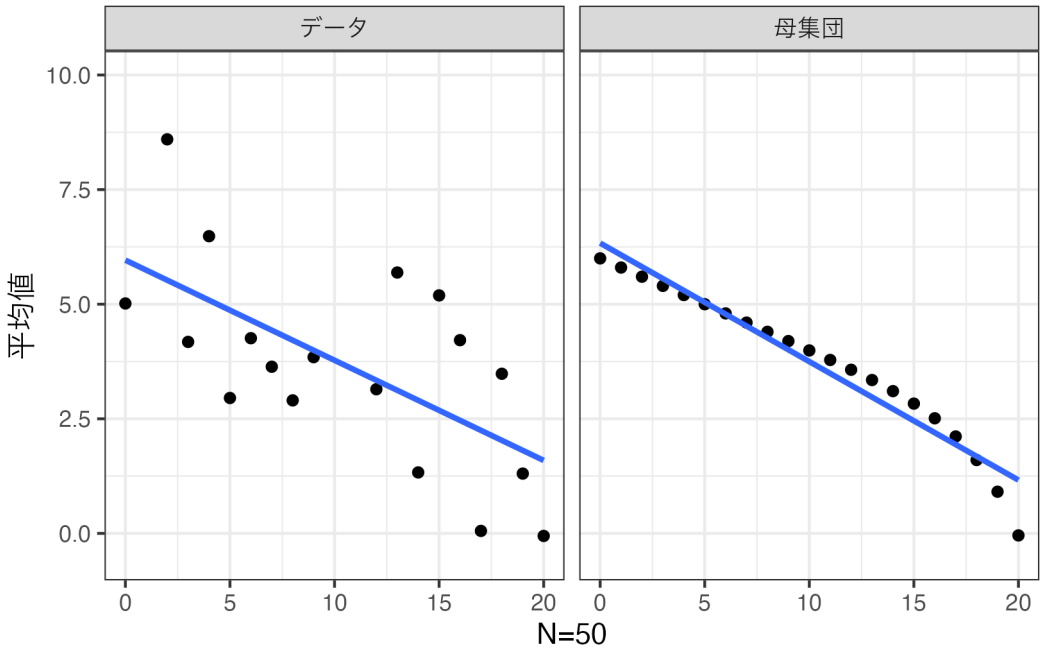

6.5 数値例: $Y \sim \beta_0 + \beta_1 X$

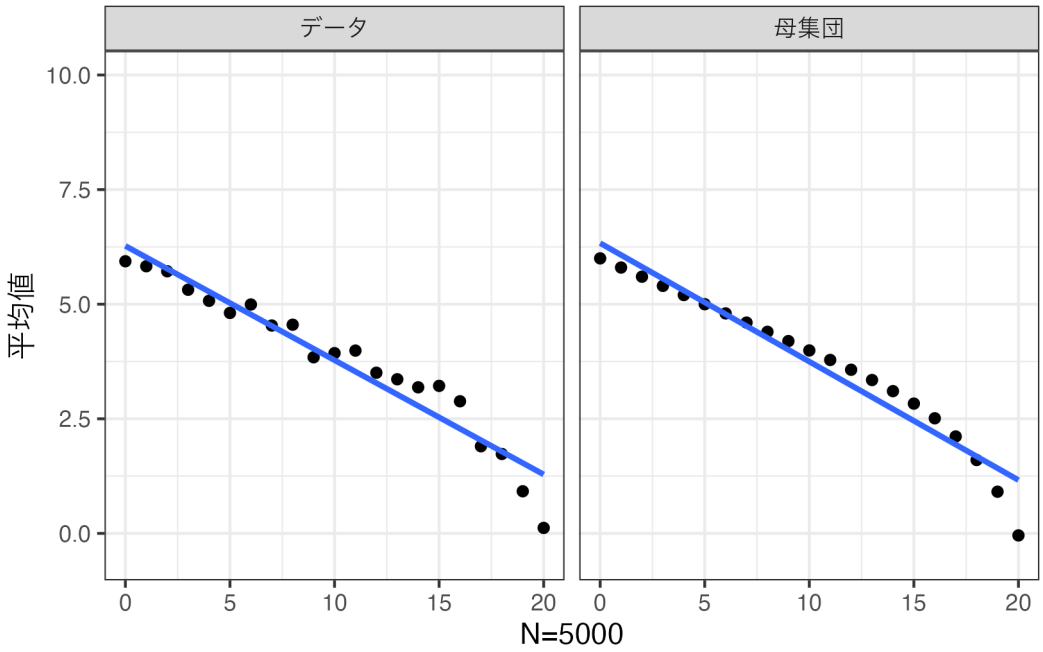

6.6 数値例: $Y \sim \beta_0 + \cdots + \beta_6 X^6$

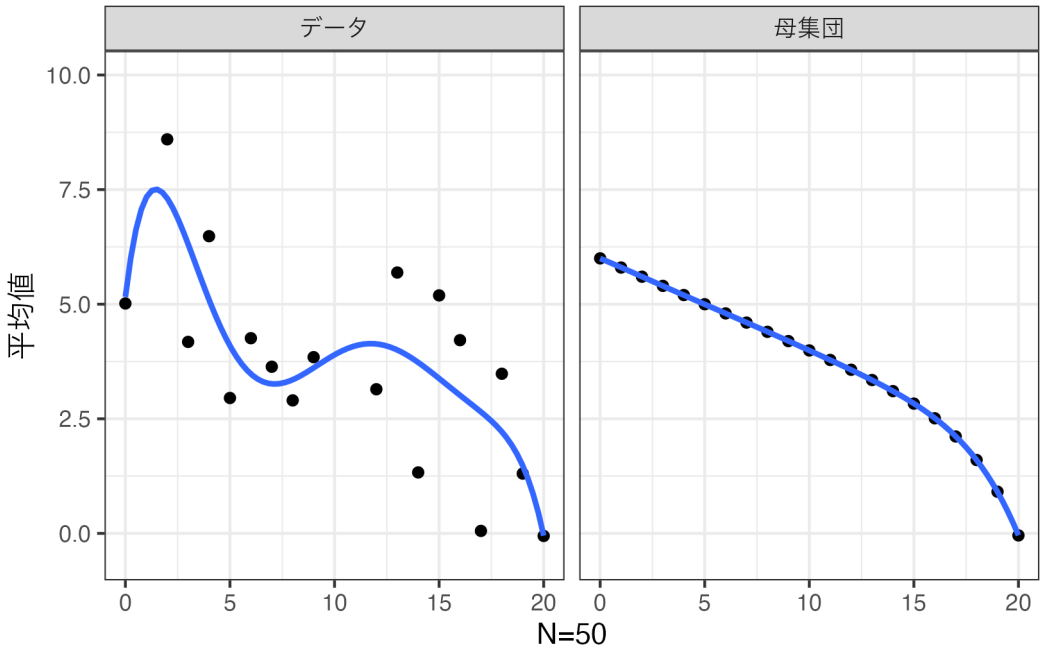

6.7 数値例: $Y \sim \beta_0 + \cdots + \beta_6 X^6$

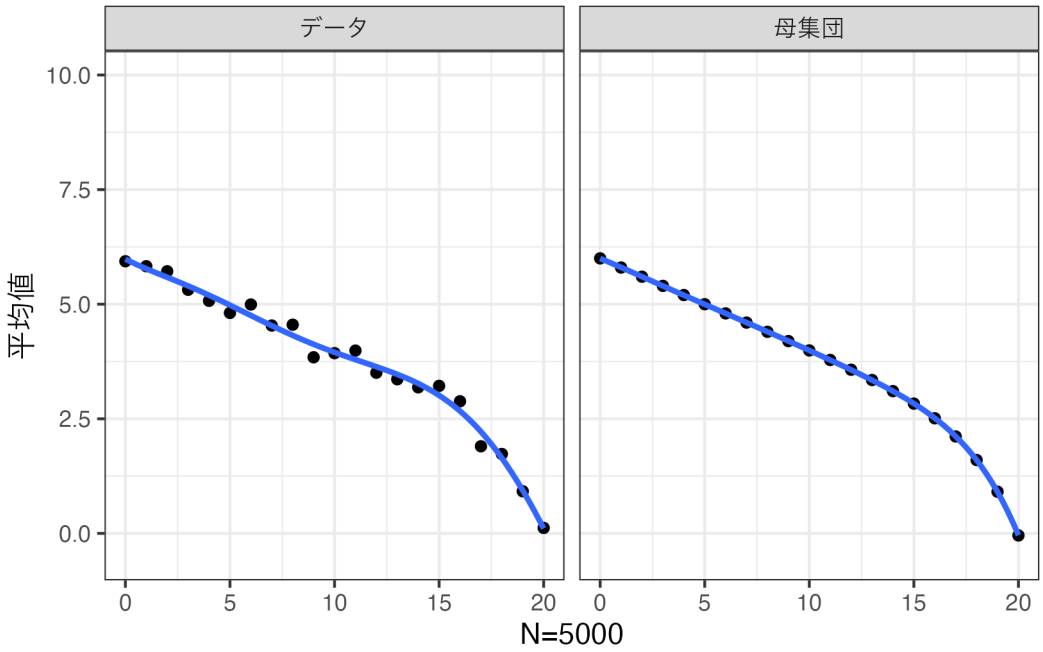

6.8 まとめ

- OLS のよくある紹介: $E[Y \mid X] = \beta_0 + \ldots$ を達成できることを**仮定し**、平均値の推定方法として紹介
- 本スライド: 2 段階の議論
  - 「どんな線形モデル」を推定したとしても、「そのモデルによる母平均の近似 (BLP)」は O 推定目標
  - 推定するモデルに高次項や交差項を十分に加えれば、母平均が推定目標
- 複雑すぎるモデルの推定結果は、推定目標 (BLP) と乖離傾向

7 LASSO

7.1 LASSO

- 母平均を推定するために、複雑なモデルを過剰適合を抑えながら推定したい
- 係数の数 $\simeq$ 事例数なモデルの推定において、比較優位を持つ手法
  - 罰則付き回帰の一つ
- モデルの複雑性を抑える" 罰則" を導入した最適化を行う

7.2 罰則付き回帰の一つ

- 以下を最小化するようにモデルを推定する

$$\underbrace{(\tau \times D + \beta_0 + \cdots + \beta_L X_L - Y)^2 \text{の平均}}_{\text{平均二乗誤差}}$$

$$+ \underbrace{\lambda \times \text{モデルの複雑性の指標}}_{\text{罰則項}}$$

7.3 経済学のアナロジー

- $\lambda =$ 複雑性への" 課税"
- 企業に任せると利益 (データへの当てはまり) のみを追求してしまう
  - 社会厚生を高めるためには、CO2 の排出 (モデルの複雑さ) を抑える必要がある
    - 標準的な政策 = 炭素税などで CO2 の排出量をコントロールする

7.4 LASSO

- 複雑性の指標 $= |\beta_1| + ...$
  - $\lambda = \infty$ であれば、モデル $= Y$ の単純平均
  - $\lambda = 0$ であれば、モデル = OLS の推定結果
- λ の選び方: 多数提案されている[*4]
  - 基本的には、条件付き母平均に近づくように設定される

[*4] Tibshirani (1996) ; Taddy (2017) ; CausalML (Chapter 3)

7.5　数値例: $Y \sim \beta_0 + \cdots + \beta_6 X^6$

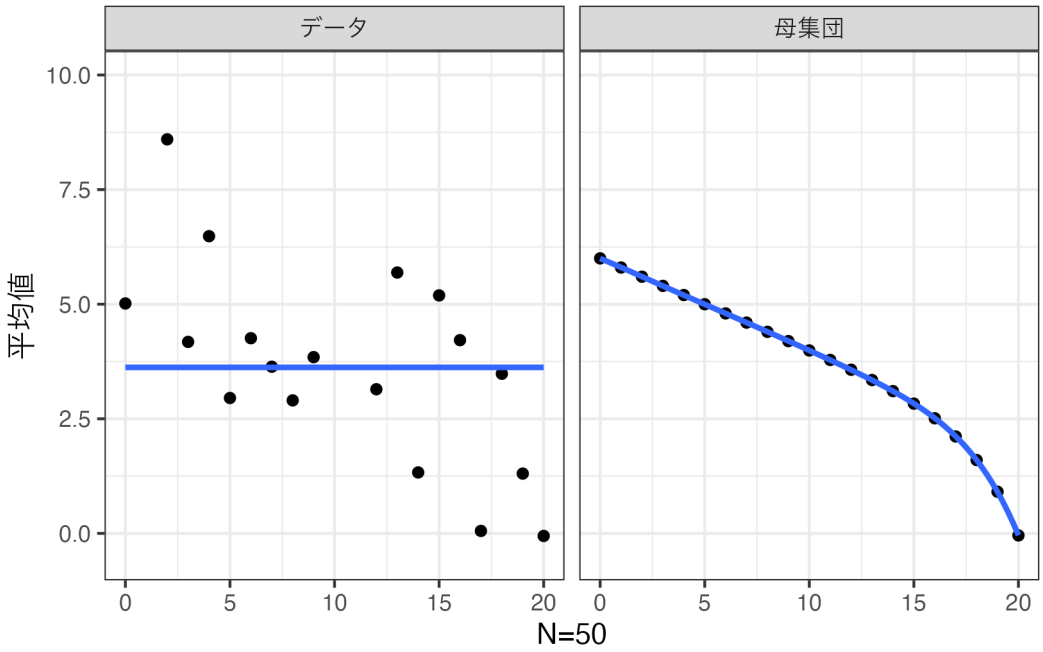

7.6　数値例: $Y \sim \beta_0 + \cdots + \beta_6 X^6$

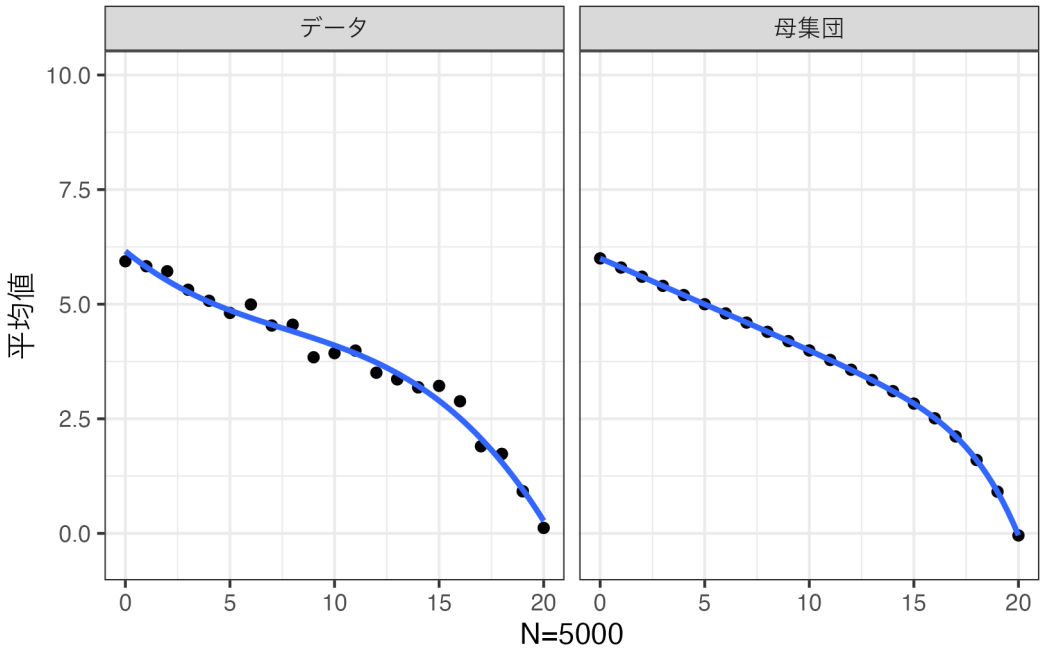

7.7 LASSO による変数選択

- 複雑性を絶対値により測定しているので、係数の推定値が厳密に"0" となりうる
  - 変数が「モデルから除外された」と解釈できる
  - OLS では、一般に生じない推定結果
- 予告: Double selection 法において活用

7.8 LASSO VS OLS

- LASSO は、「X の中で、Y との関連性が強い変数は一部」な母分布に対して有効
  - Sparsity (疎) と呼ばれる
- 経済学における Sparsity の妥当性には、疑義も多い (Abadie and Kasy 2019; Giannone, Lenza, and Primiceri 2021; Fava and Lopes 2021; Kolesár, Müller, and Roelsgaard 2025)
  - 社会においては、全ての変数が関連しており、本質的に Dense (密) な構造を持つのでは?
  - 調査などでは、重要ではない変数は質問しないのでは?

7.9 予告: LASSO の応用

- 予測問題: LASSO だけでなく、OLS も Stacking に含めることを強く推奨
- 比較問題: LASSO によって推定された係数を見て、母集団や社会の特徴を議論することは危険
  - 罰則項のせいで、「深刻なバイアスの発生、信頼区間が計算不可能等」の多くの問題が発生し、ミスリードな結果となる

7.10 補論: Ridge

- 罰則項の定式化が異なる罰則付き回帰
  - 罰則項 $= \lambda \times (\beta_1^2 + \dots)$

8 補論 (多分に私見)

8.1 母集団/推定目標の実質的役割

- 社会は極めて複雑/流動的であり、研究目標も曖昧にしか定義できない
- 推定目標/母集団: 暫定的な仮足場

  - 利点: データから「原理的には論理的に回答可能な正答」を明確に定義できる[*5]
- 注意: 経済学において、「推定目標は不変的な真理」、「母集団は実在している」、と見做せるかどうかは慎重に検討する必要がある

8.2 イメージ

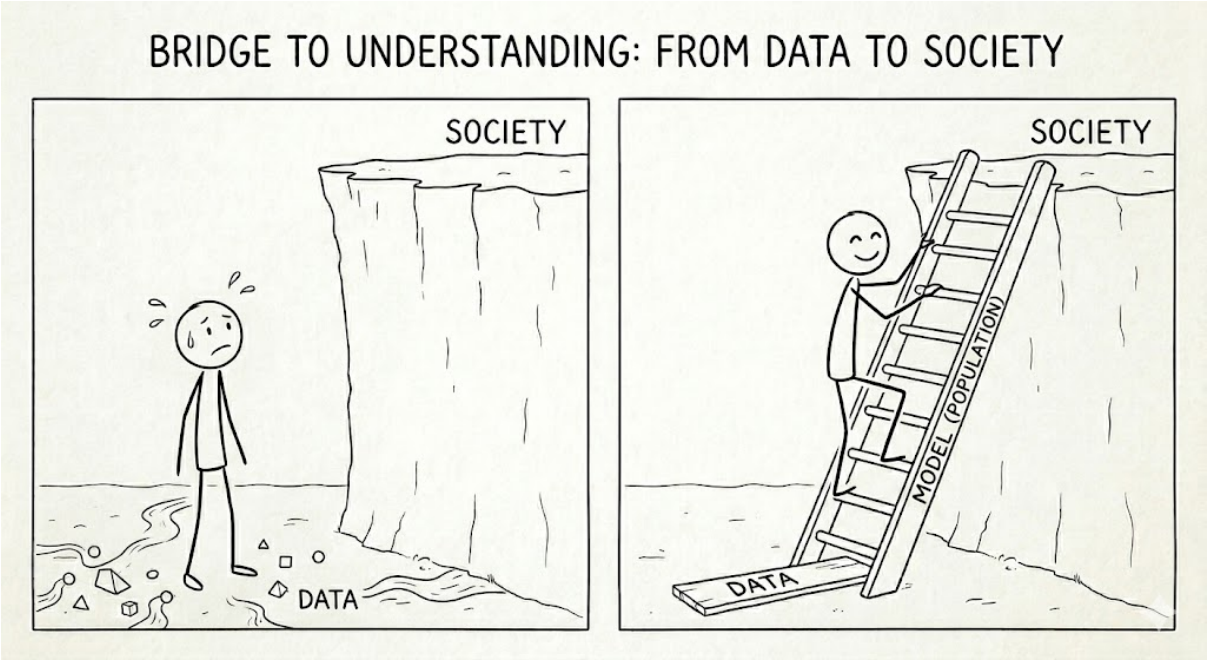

Figure3: “By gemini”

8.3 余談: 関連する?格言集

- 「暫定的な仮足場」の効能と注意点について、幅広い分野で類似した指摘がある
- フォン・ノイマン (数学):「Truth is much too complicated to allow anything but approximations」
- ジョージ・ボックス (統計学):「All models are wrong, but some are useful」

8.4 余談: 関連する?格言集

- ダニ・ロドニック (経済学): 私たちは賢いから数学を使うのではなく、十分に賢くないから使うのである。とはいえ、十分に賢くないと気づく程度には賢い。
- 仏教哲学: 二つの真理 (wiki)

[*5] 経済モデルと似た役割

– 世俗的真理: 厳密に考察しない限り一般的な理にかないかつ容認できる/生滅を有する/現実的効果を有する (シャーンタラクシタ)[*6]
–「指がなければ月をさすわけにはいかぬが、指を月と誤解してはならぬ」(鈴木大拙)

Reference

Abadie, Alberto, and Maximilian Kasy. 2019. "Choosing Among Regularized Estimators in Empirical Economics: The Risk of Machine Learning." *Review of Economics and Statistics* 101 (5): 743–62.

Angrist, Joshua D, and Jörn-Steffen Pischke. 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton university press.

Aronow, Peter M, and Benjamin T Miller. 2019. *Foundations of Agnostic Statistics*. Cambridge University Press.

Chernozhukov, Victor, Christian Hansen, Nathan Kallus, Martin Spindler, and Vasilis Syrgkanis. 2026. *Applied Causal Inference Powered by ML and AI*.

Fava, Bruno, and Hedibert F Lopes. 2021. "The Illusion of the Illusion of Sparsity." *Brazilian Journal of Probability and Statistics* 35 (4): 699–720.

Giannone, Domenico, Michele Lenza, and Giorgio E Primiceri. 2021. "Economic Predictions with Big Data: The Illusion of Sparsity." *Econometrica* 89 (5): 2409–37.

Kolesár, Michal, Ulrich K. Müller, and Sebastian T. Roelsgaard. 2025. "The Fragility of Sparsity." https://arxiv.org/abs/2311.02299.

Taddy, Matt. 2017. "One-Step Estimator Paths for Concave Regularization." *Journal of Computational and Graphical Statistics* 26 (3): 525–36.

Tibshirani, Robert. 1996. "Regression Shrinkage and Selection via the Lasso." *Journal of the Royal Statistical Society Series B: Statistical Methodology* 58 (1): 267–88.

立川武蔵. 2015. **空の思想史 原始仏教から日本近代へ**. 講談社学術文庫.

[*6] 立川武蔵 (2015)