予測

経済学のための機械学習入門

川田恵介

2026-04-27

Table of contents

1 **予測問題** 3

1.1 サンプル分割法: Get started . . . 3

1.2 サンプル分割法: Get started . . . 3

1.3 サンプル分割法: Get started . . . 4

1.4 研究目標 . . . 5

1.5 反面教師: 丸暗記 . . . 5

1.6 実例 . . . 5

2 **予測問題の枠組み** 5

2.1 標準的な予測問題 . . . 5

2.2 整理 . . . 6

2.3 推定問題 . . . 7

3 **予測モデルの評価** 7

3.1 予測誤差の分解 . . . 7

3.2 数値例: $Y \sim \beta_0 + \beta_1 X$ . . . 7

3.3 数値例: モデル複雑化 . . . 8

3.4 数値例: 事例数増加 . . . 8

3.5 数値例: 単純なモデル + 多くの事例 . . . 9

3.6 ポイント . . . 9

3.7 OLS の整理 9
3.8 推奨 10

4 **予測誤差の推定** 10
4.1 サンプル分割法 10
4.2 推定手順 10
4.3 正当化 10
4.4 悪例: 丸暗記 + サンプル非分割 10
4.5 余談: インチキ自己啓発本の書き方 11

5 Prediction interval 11
5.1 推定と推論 11
5.2 妥当な推論 11
5.3 予測区間 12
5.4 計算方法 12
5.5 例 12
5.6 例 13
5.7 区間の性質 13
5.8 練習問題 13
5.9 例 14

6 **補論**: Smoothing matrix **による再解釈** 14
6.1 予測における OLS の役割 14
6.2 線形推定量 14
6.3 例: 丸暗記方法 15
6.4 例: サブグループによる Smooting 15
6.5 線形モデルの別解釈 15
6.6 例: OLS 15
6.7 例: 過剰適合 16
6.8 再解釈 16

7 補論: Distributional robustness 17
7.1 本来の問題構造 17
7.2 本来の問題構造 18
7.3 具体例 18
7.4 補論: 教養的入門書との乖離 18
Reference 18

1 予測問題

1.1 サンプル分割法: Get started

```
set.seed(111)

library(tidyverse)

data("fertil2", package = "wooldridge")

split <- rsample::initial_split(fertil2)

train <- rsample::training(split)

test <- rsample::testing(split)
```

1.2 サンプル分割法: Get started

```
model_simple <- lm(
  children ~ educ,
  train)

model_main <- hdm::rlasso(
  children ~ (educ + age + yearborn)^2 +
    I(educ^2) + I(age^2) + I(yearborn^2),
  train,
  post = FALSE)
```

```r
summary(model_main,all = FALSE)
```

```

Call:
rlasso.formula(formula = children ~ (educ + age + yearborn)^2 +
    I(educ^2) + I(age^2) + I(yearborn^2), data = train, post = FALSE)

Post-Lasso Estimation:  FALSE

Total number of variables: 9
Number of selected variables: 4

Residuals:
     Min       1Q   Median       3Q      Max
-5.48550 -0.73887 -0.01362  0.72759  7.77837

              Estimate
(Intercept)      2.724
I(educ^2)       -0.007
I(yearborn^2)   -0.001
educ:age         0.000
age:yearborn     0.002

Residual standard error: 1.457
Multiple R-squared:  0.5707
Adjusted R-squared:  0.5702
Joint significance test:
 the sup score statistic for joint significance test is 9.422e+04 with a p-value of     0
```

1.3 サンプル分割法: Get started

```r
test$pred_simple <- predict(model_simple,test)

test$pred_main <- predict(model_main,test)

mean((test$children - test$pred_main)^2)/
  mean((test$children - test$pred_simple)^2)
```

```
[1] 0.4911998
```

1.4 研究目標

- X のみ観察できる事例 (予測目標) について、Y の値を予測する
  - Einav et al. (2018)：医療レセプトの情報 X から、余命 Y を予測する
    - 「終末期医療論争」の基礎研究 (結果: 余命予測は困難)
- **研究目標**: X から Y の値を計算する" 数式" (予測モデル) とその評価

1.5 反面教師: 丸暗記

- **Learning by memorization** ("丸暗記法")
- 予測対象と全く同じ X を持つ事例をデータから探し、その Y (またはその平均値) を予測値とする
  - 機械の動作のような個体差が少ない/ルール運用のような個体差が" 存在するべきではない" 状況以外では、実用的な方法ではない

1.6 実例

- 「教育年数 1 年、48 歳、1940 年生まれ、カトリック」の子供数は?
  - `fertil2` において、同じ X を持つ **1 事例**が存在し、その子供数は 10 → 予測子供数は 10
  - 次元の呪いによる少数事例問題:「自分に最も近い"1 事例" がどのような特徴を持つか?」、に予測が致命的に左右されがち

2 予測問題の枠組み

2.1 標準的な予測問題

- **予測目標**: データと同じ母集団からランダム抽出される
- **予測性能**: 母集団における平均二乗予測誤差

$$E[(Y - \text{予測値})^2]$$

- **推定目標**: 母集団から計算できる" 理想的な" 予測モデル
  - **事実上の推定目標**: 母平均 $E[Y \mid X]$

2.2　整理

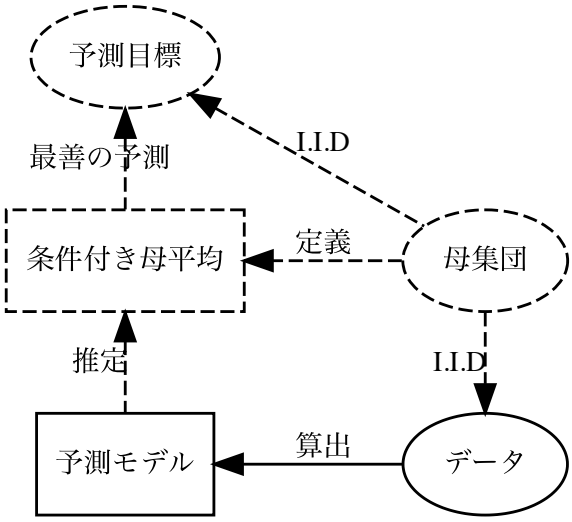

2.3 推定問題

- $E[Y \mid X]$ の推定：前回の内容 (ある程度複雑なモデルを OLS/LASSO で推定) を活用できる
  - 丸暗記法の問題点: データ上の平均値で推定しており、次元の呪いによる過剰適合が深刻になりやすい

3 予測モデルの評価

3.1 予測誤差の分解

- 予測誤差は、以下のように定義、分解できる

$$
\begin{aligned}
\underbrace{Y - \text{予測値}}_{\text{予測誤差}} &= \underbrace{Y - \text{母平均}}_{\text{削減不可能な誤差}} \\
&+ \underbrace{\text{母平均} - Population\ OLS}_{\text{定式化による誤差}} \\
&+ \underbrace{Population\ OLS - \text{予測値}}_{\text{推定誤差}}
\end{aligned}
$$

3.2 数値例: $Y \sim \beta_0 + \beta_1 X$

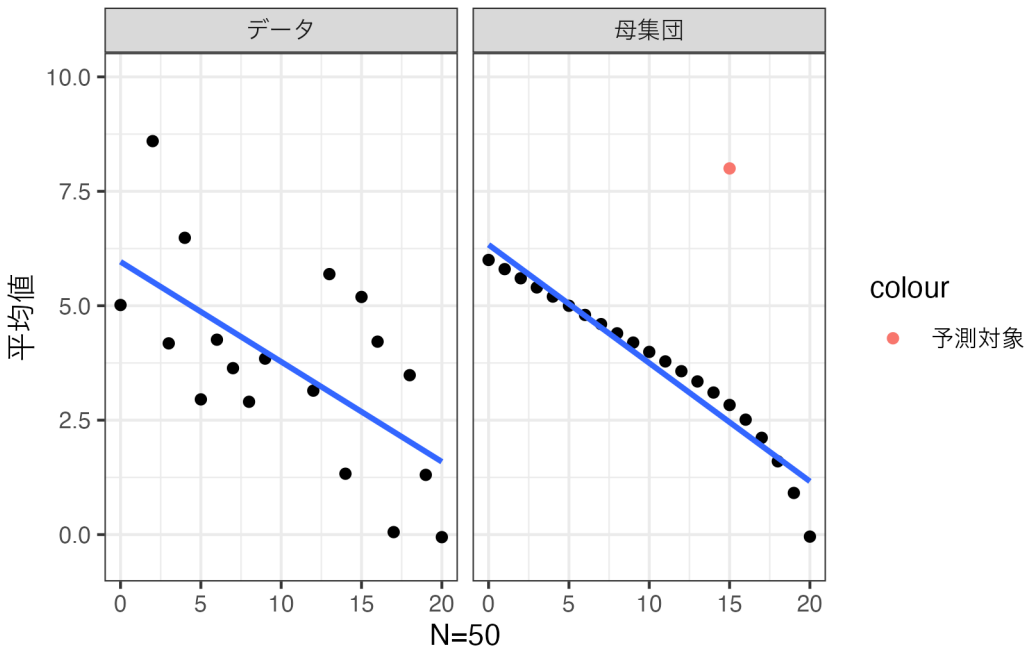

3.3　数値例: モデル複雑化

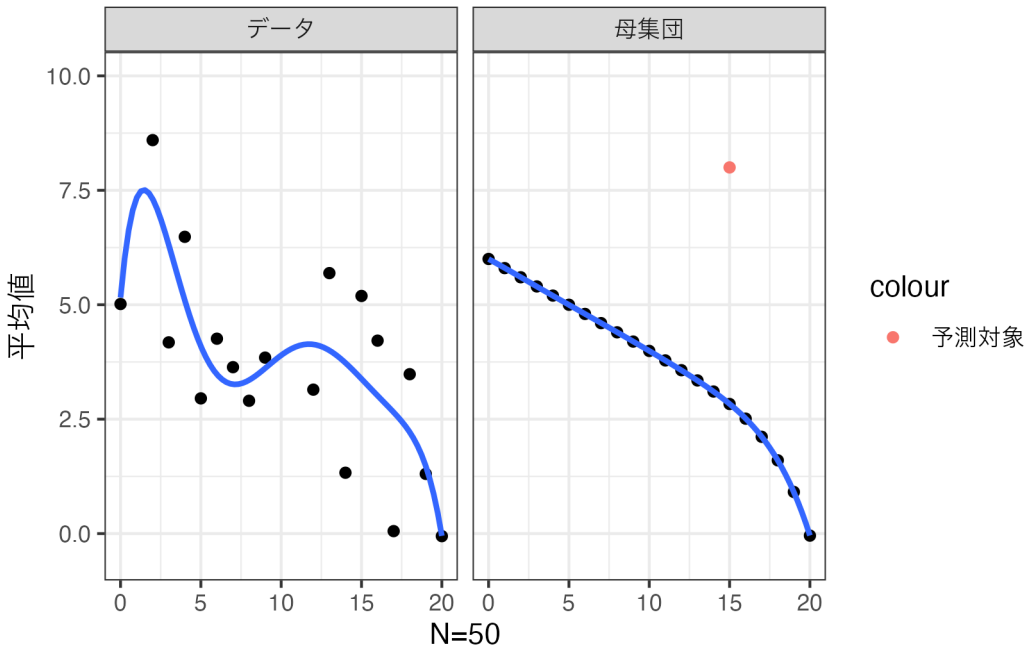

3.4　数値例: 事例数増加

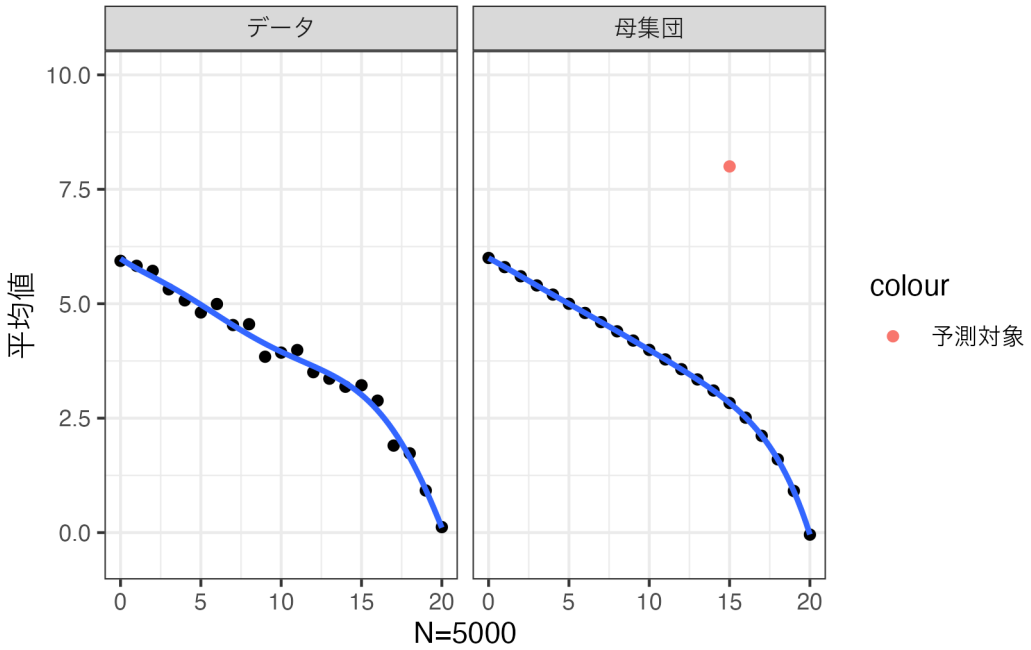

3.5 数値例: 単純なモデル + 多くの事例

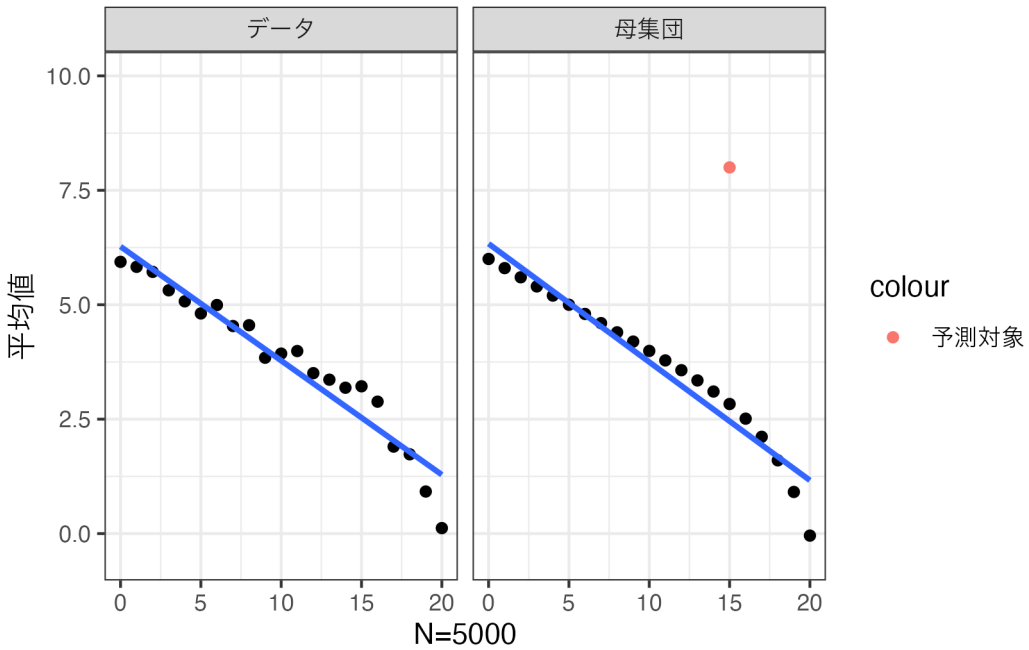

3.6 ポイント

- **削減不可能な誤差**: X が決まった時点で確定 (母集団の特徴)
- **定式化による誤差**: 推定するモデルを決めた時点で確定
- **推定誤差**: "傾向" は、推定するモデルと事例数に依存
- **定式化のトレードオフ**: 複雑すぎるモデルを推定すると、定式化による誤差は小さいが、推定誤差が大きい

3.7 OLS の整理

モデル	削減不可能	近似	Sampling
丸暗記	X 次第	0	極大
シンプルなモデル	X 次第	大	小
非常に複雑なモデル	X 次第	小	大

3.8 推奨

- 予測誤差の推定かモデル集計を行う
- 二乗項や交差項を投入した線形モデルを OLS で推定する
  - 係数の数が多くなる (例: 事例数の 2 割を超える) 場合、LASSO も試す
- 予告: Random Forest や Boosting などの回帰木系統の推定も行い、Stackig で集計する方法を推奨

4 予測誤差の推定

4.1 サンプル分割法

- 平均二乗予測誤差は、推定しないとわからない
- サンプル分割法: 代表的推定方法
- モデルを推定する前に、データをランダムに 2 分割する
  - **訓練データ**: モデルの推定を行うデータ
  - **テストデータ**: モデルの評価を行うデータ
    - Conformal interval を計算する場合は、1000 事例程度は必要[*1]

4.2 推定手順

1. 訓練データのみを用いて、予測モデルを推定
2. テストデータを用いて、データ上での平均二乗誤差/決定係数を計算

4.3 正当化

- 「母集団から新たに評価用のデータをランダム抽出」をサンプル分割で近似できる
  - ランダム分割で生成したテストデータ
    - = 同じ母集団から新たに抽出したデータ
- 「予測モデル推定に用いる、サンプルサイズが減少するが、現代のデータ環境では大きな問題ではない」

4.4 悪例: 丸暗記 + サンプル非分割

- 以下の 2 事例のデータから丸暗記法で予測モデルを推定

[*1] Conformal interval の計算に用いる場合は、calibration データとも呼ばれる

Y	X	予測値
10	1	10
5	2	5

- 平均二乗” 予測” 誤差 $= 0$...?
- 決定係数 $= 1$...?
- 予測ではなく、ただの現状確認/結果論

4.5 余談: インチキ自己啓発本の書き方

- “成功した” 筆者の経験を、“成功への法則” として紹介
  - “法則” が正しい根拠を、自身の成功体験に求める
  - 完璧に当たる成功への法則!!!...?
- 「丸暗記 + サンプル非分割」と同じ論法
- サンプル分割を行わない平均二乗誤差は、「単純なモデルを十分な事例数で推定する場合」のみ、予測性能の近似指標となる

5 Prediction interval

5.1 推定と推論

- ここまでは全ての推定 (Estimation) の話
  - 経済学においては、推論 (Inference) が事実上必須
- “推定” という単語は、“確定値” のように聞こえるが、
  - 他の和訳は、見当、見積もり、値踏み
    - 無限大の事例は存在しないので、一致性は正確性の根拠にならない
- 推論結果が、データと仮定から得られる「結論」

5.2 妥当な推論

- 妥当な推論 (valid inference):「前提が真であれば、結論は真である」が保証された推論 (ロジック)
- R 関数の比喩: バグがない関数
  -「入力 (前提) が正しければ、出力 (結論) は正しい」
  -「一見うまく機能している関数であっても、バグがあれば使いたくない」

5.3 予測区間

- 「データと予測目標が同じ母集団からランダム抽出されるならば」、「予測目標を” 概ね” 含む区間」
  - 演繹的妥当性「前提が真ならば、結論は” 概ね” 真」を持つ区間
- 予測区間: “予測対象の Y を一定確率 $(1-\alpha)$ で含む区間”
- さまざまな導出方法が提案されてきた
  - 本スライドでは Conformal interval[*2]を紹介

5.4 計算方法

1. **train データ**から、(任意の方法で) 予測モデルを推定
2. **test データ**[*3]から、事前に決めた α に対応する **calibration scores** (予測誤差の絶対値; $|Y-$予測値$|$) を計算
3. calibration scores の $\frac{(1+n)(1-\alpha)}{n}$ 分位点 (q) を計算
4. 予測区間: $[$予測値$-q$, 予測値$+q]$ を計算

5.5 例

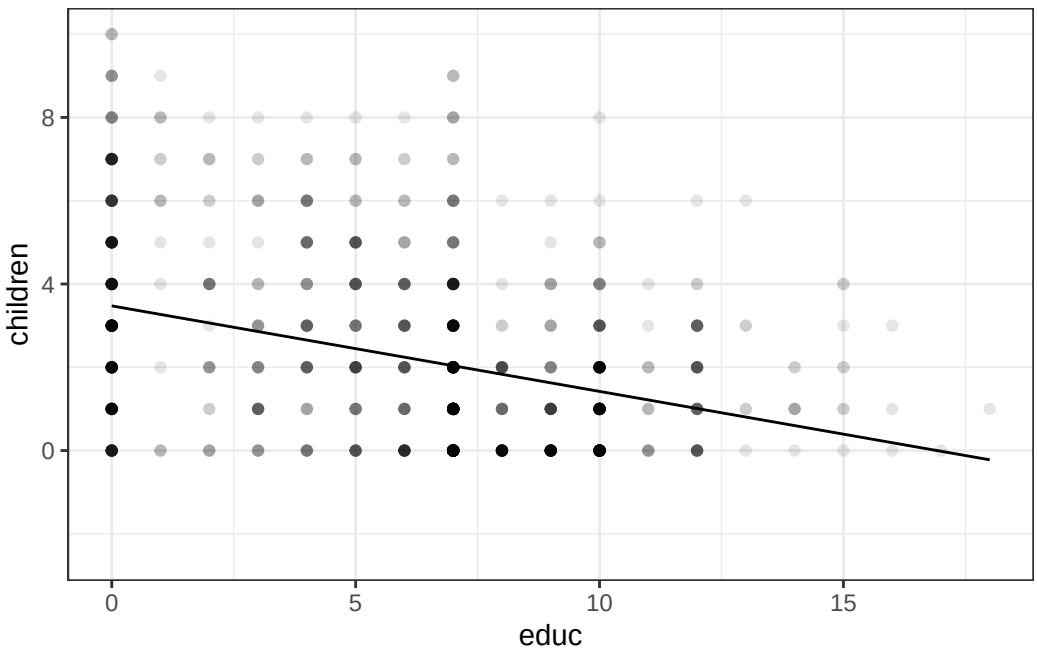

[*2] Angelopoulos and Bates (2021)
[*3] conformal inference の文脈では、calibration データと呼ばれる。

5.6 例

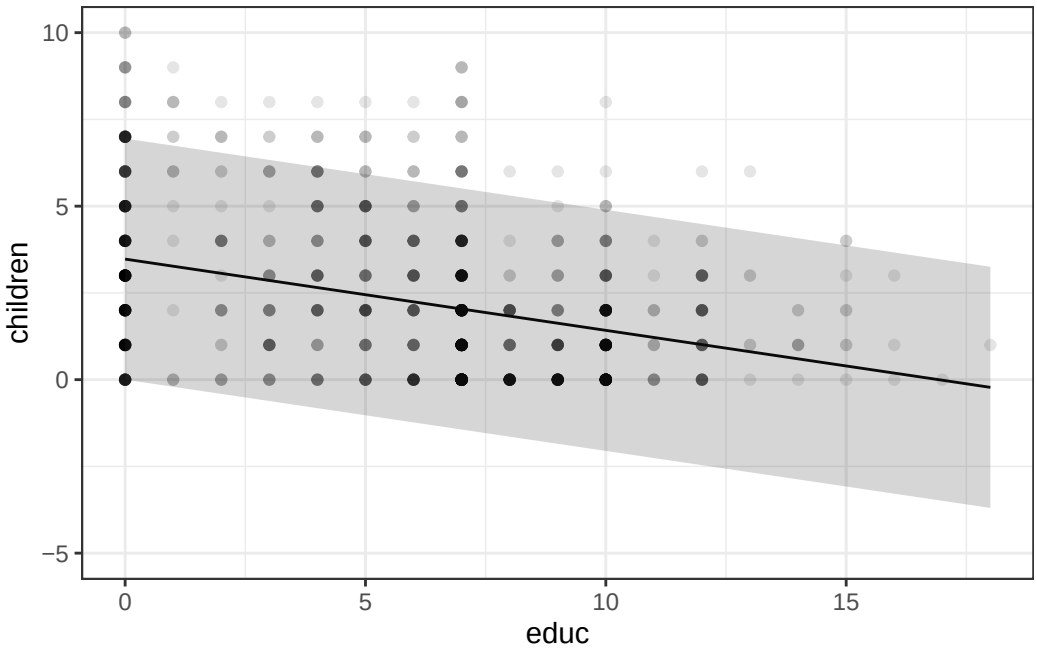

5.7 区間の性質

- **Calibration データで条件づけない場合:** “任意の事例数” について、予測対象を $1-\alpha$ で含む
  - 後で信頼区間、推定結果の分布とともに詳しく議論
- **Calibration データで条件づける場合:** 無限大の事例数があれば、予測対象を $1-\alpha$ で含む
  - Angelopoulos and Bates (2021)：Calibration (“Test”) データが 1000 事例程度あれば、$1-\alpha$ で” 概ね含む”

5.8 練習問題

- “任意の方法で” 推定したモデルについて、予測区間が計算できる
  - 「“川田がダーツを投げる” と 2 が出たので、子供の数は 2 と予測し続けるモデル」についても、$1-\alpha$ で予測対象を含む区間を計算できる
  - “子供の数 $=100$” でも計算できる
- なぜ?

5.9 例

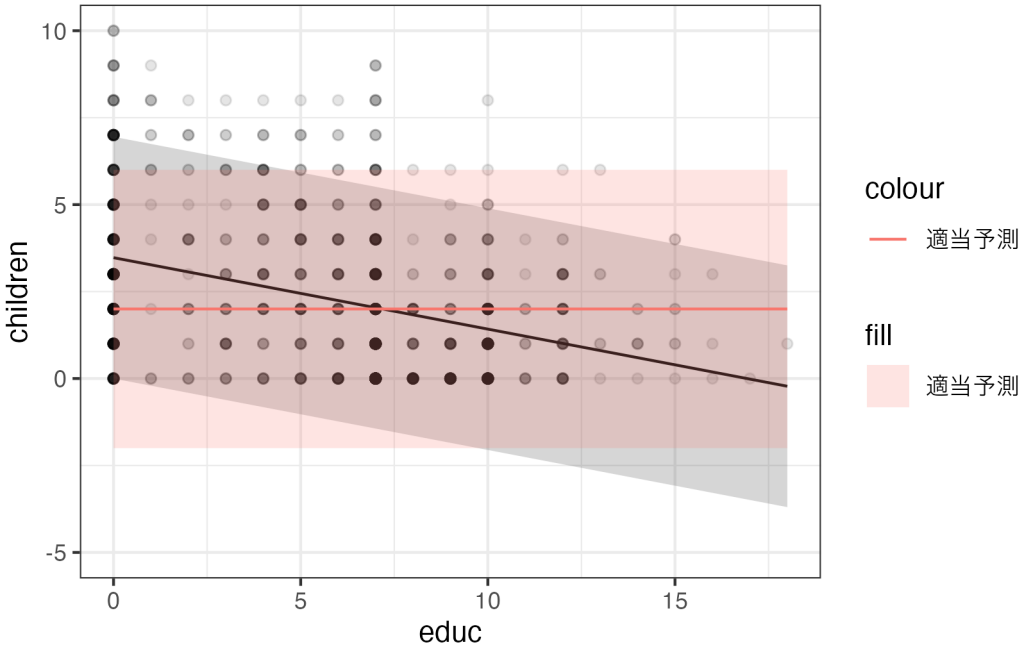

6 補論: Smoothing matrix による再解釈

6.1 予測における OLS の役割

- 丸暗記に比べて、OLS の結果はより" 安定的" な傾向がある
  - なぜ?
- 「モデルによる予測値の算出」と考えるとわかりにくい
- Y の加重平均による予測と再解釈すると、直感的

6.2 線形推定量

- 多くの予測モデル = 訓練データの事例についての Y の値の荷重和として表現できる[*4]

$$\underbrace{w_1}_{\text{第1事例への加重}} \times \underbrace{Y_1}_{\text{第1事例}} + w_2 \times Y_2 + \ldots$$

[*4] 線形推定量

6.3 例: 丸暗記方法

- $X = 1$ を予測

ID	Y	X	w
1	0	1	1
2	1	2	0
3	-1	-3	0

- 予測値

$$= \underbrace{1}_{\omega_1} \times \underbrace{0}_{Y_1} + 0 \times 1 + 0 \times -1 = 0$$

6.4 例: サブグループによる Smooting

ID	Y	X	w
1	0	1	0.5
2	1	2	0.5
3	-1	-3	0

- 予測値 $= X > 0$ の平均値

$$= \underbrace{0.5}_{\omega_1} \times \underbrace{0}_{Y_1} + 0.5 \times 1 + 0 \times -1 = 0.5$$

6.5 線形モデルの別解釈

- 線形モデル $\beta \times X$ を OLS で推定
  - 注意: Y/X 共に平均値が 0 なので、定数項は不要
- $X = x$ の予測値

$$\begin{aligned}\hat{\beta} \times x &= \frac{X_1Y_1 + X_2Y_2 + X_3Y_3}{X_1^2 + X_2^2 + X_3^3} \times x \\ &= \underbrace{\omega_1}_{=\frac{X_1 x}{X_1^2+X_2^2+X_3^3}} \times Y_1 + \underbrace{\omega_2}_{=\frac{X_2 x}{X_1^2+X_2^2+X_3^3}} \times Y_2 + \underbrace{\omega_3}_{=\frac{X_3 x}{X_1^2+X_2^2+X_3^3}} \times Y_3\end{aligned}$$

6.6 例: OLS

ID	Y	X	X=1 への w
1	0	1	0.07142857
2	1	2	0.1428571
3	-1	-3	-0.2142857

- OLS で推定した単回帰したモデルでの予測値
  - = 上記の w を利用した加重平均
  - 負の荷重も利用した smoothing

6.7 例: 過剰適合

ID	Y	X	X=1 への w
1	0	1	1
2	1	2	0
3	-1	-3	0

- $\beta_0 + \beta_1 \times X + \beta_2 \times X^2$ を OLS 推定したモデルで、$X = 1$ の予測
  - = 上記の w を利用した加重平均 $= Y_1$
    - 丸暗記方法と同じ予測!!!

6.8 再解釈

- LASSO も含めた多くの線形モデルの推定結果は、荷重を用いた事例ベースの予測として再解釈できる
  - 多くの事例の加重平均となるので、丸暗記よりはデータの偶然の偏りの影響が少ない傾向
- 注意点: マイナスの荷重も用いており、定式化次第では、非現実的な予測を生み出し得る
  - 外挿の暴走

7　補論: Distributional robustness

7.1　本来の問題構造

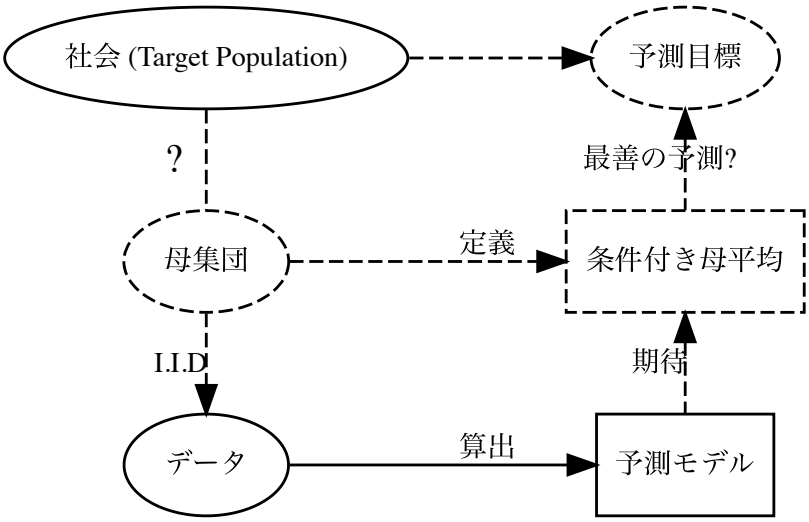

7.2 本来の問題構造

- 社会 = 母集団が期待できるならば、問題ない
- 多くの応用では、
  - データの母集団:「ある時点で収集されるので」、母集団は特定の時点に" 固定"
  - 社会: 流動的 (常に変化する)

7.3 具体例

- 予測モデルを推定してから" 時間が経過" すると、母集団と社会のずれが大きくなる (Conceptual drift)
- 予測モデルの社会実装自体が、社会を変化させ、母集団と社会のずれを生じさせる (Performative prediction (Hardt and Mendler-Dünner 2025))
- 対策: 予測性能の監視と再推定、分布の変化に対して頑強なモデルの推定 (Blanchet et al. 2025)

7.4 補論: 教養的入門書との乖離

- 社会 (Target Population, DGP) のような母集団の" 上位概念" を用いない統計学/機械学習の教科書も多い
- 例によっては、"不要" であることが一因?
  -「無限回コイントスを行った場合に表が出る割合」(母平均) を「限られたコイントスの結果」から推定する
  -「時間経過による性質変化」は想定せず、「無限回のコイントスという固定的な母集団」で事足りる

Reference

Angelopoulos, Anastasios N., and Stephen Bates. 2021. "A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification." *CoRR* abs/2107.07511. https://arxiv.org/abs/2107.07511.

Blanchet, Jose, Jiajin Li, Sirui Lin, and Xuhui Zhang. 2025. "Distributionally Robust Optimization and Robust Statistics." *Statistical Science* 40 (3): 351–77.

Einav, Liran, Amy Finkelstein, Sendhil Mullainathan, and Ziad Obermeyer. 2018. "Predictive Modeling of US Health Care Spending in Late Life." *Science* 360 (6396): 1462–65.

Hardt, Moritz, and Celestine Mendler-Dünner. 2025. "Performative Prediction: Past and Future." *Statistical Science* 40 (3): 417–36.