

記述モデル

経済学のための機械学習入門

川田恵介

2026-05-10

Table of contents

1	社会の把握: Get started	2
1.1	Get started	2
1.2	DML (Double LASSO)	3
1.3	よくある疑問	3
1.4	補論: “二つの文化”	4
2	モデルの多様な役割	4
2.1	モデルの活用目的	4
2.2	意思決定問題の例	4
2.3	把握のためのモデル	4
2.4	予測のためのモデル	4
2.5	意思決定者の目線	6
2.6	補論: 混乱の要因	7
3	信頼区間	7
3.1	論点	7
3.2	信頼区間の定義	7
3.3	事前と事後	7
3.4	信頼区間	8
3.5	経済学との類似点	8

3.6	落とし穴	8
3.7	類似例: 裁判	8
4	点推定値の分布	9
4.1	“統計的性質”の対象	9
4.2	対象	10
4.3	OLS の事前の性質	11
4.4	数値例	11
4.5	数値例: 設定	11
4.6	数値例	11
4.7	数値例: 点推定値の”ダンス”	12
4.8	β_A についての信頼区間	12
4.9	数値例: 信頼区間の”ダンス”	13
4.10	LASSO の問題点	13
4.11	数値例: LASSO の”ダンス”	14
4.12	錯覚を避けるコツ	14
5	補論	14
5.1	信頼区間の解釈	14
5.2	ベイズ法	15
	Reference	15

1 社会の把握: Get started

1.1 Get started

- 研究目標: 「社会 ($\simeq$ 事例の集合) における子供の数と教育年数の関係性を把握する」

```
set.seed(111)

library(tidyverse)

data("fertil2", package = "wooldridge")
```

```
estimatr::lm_robust(children ~ educ, fertil2)
```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower
(Intercept)	3.4955406	0.066368941	52.66832	0.000000e+00	3.3654238
educ	-0.2096504	0.008363588	-25.06704	1.165341e-129	-0.2260473

	CI Upper	DF
(Intercept)	3.6256575	4359
educ	-0.1932535	4359

- 「母集団のモデルは、マイナスの関係性を示唆する」

1.2 DML (Double LASSO)

```
model <- hdm::rlassoEffects(
  children ~ educ +
    (age + yearborn + spirit + protest + catholic)^2 +
    poly(age, 2) +
    poly(yearborn, 2),
  I = ~educ, # "Target"
  data = fertil2
)

confint(model)
```

	2.5 %	97.5 %
educ	-0.1027966	-0.07889253

- 「母集団のモデルは、(より小さな) マイナスの関係性を示唆する」

1.3 よくある疑問

- 典型的な DML では、「複雑なモデルを推定するツールである機械学習」を使って、一つのパラメタ (“単純な” 推定目標) を推定する
 - 複雑なモデルをそのまま用いれば良いのでは?
- 以下の二点を考える必要がある:
 - データ分析の最終的な” アウトプット ” は何か?
 - 統計的性質とは何か?

1.4 補論: “二つの文化”

- 機械学習の普及に伴い、(改めて?) 表面化した問題
- 二つの文化: 機械学習と統計学 (前のスライド) における伝統的な実践には大きなギャップがある (Breiman 2001)
 - 活発な議論を想起 (Shmueli (2010) ; Observational Studies の[特集号](#))

2 モデルの多様な役割

2.1 モデルの活用目的

- 一見同じモデルでも、活用目的によって、要求が異なる
 - 「意思決定者が、モデルをどのように活用するのか?」

2.2 意思決定問題の例

- 以下の社内会議において、“欲しい情報”は?
 - 「ある物件をいくらで下取るべきか?」
 - * 個別予想
 - 「どのような中期経営計画を立てるべきか?」
 - * 事業/市場/社会の状況

2.3 把握のためのモデル


- 経済学の伝統的用法: 「有効な **action** を”思いつき”、その有効性を**評価**する」ための、基礎情報の提供
- モデルの役割: 人間の認知能力に比べて、社会は複雑すぎるので
 - 要約モデルの特徴を、意思決定者が把握する
 - 人間が認識できる社会の模型 = 記述モデル
 - * 社会の**仕組み**の模型 = 記述的構造モデル

2.4 予測のためのモデル

- 前回までの内容: 個別予測やその性能指標の提供
- モデルの役割: 予測値の計算ツール

- － 意思決定者は、予測結果やその精度が把握できれば十分であり、モデルの詳細な特徴を”人間が”把握する必要はない
- － 予測のための”裏方”＝ 予測モデル

2.5 意思決定者の目線



2.6 補論: 混乱の要因

- かつては、同じ (単純な) モデルを記述と予測に用いてきた
- 正当化としては、
 - データが少なく、計算能力も限られているので、単純なモデルしか推定できない
 - “真実” (母平均) は意外に単純
- 現代経済学では、どちらも”説得的”ではない

3 信頼区間

3.1 論点

- 「単純な線形モデルを LASSO で推定すると、さらに単純なモデルが推定される」
 - 優れた記述モデル?
- 記述モデルの推定方法としては、問題点がある
 - 統計的推論の代表的なツールである、信頼区間の算出が難しい
 - * 推定結果が扱いづらい統計的性質を持つ

3.2 信頼区間の定義

- 事前に定めた方法で、データから算出される区間
 - 95% 信頼区間であれば「95% の確率で推定目標を含む区間」をデータから計算する方法
- 典型的な錯覚: 「計算した 95% 信頼区間 ($-0.103 \sim -0.079$) は、推定目標を 95% の確率で含む」は誤り
 - なぜ?
- Hint: 事前と事後の区別

3.3 事前と事後

- ある確率的事象が、実現する前が**事前**/後が**事後**
- 例: コイントスの結果について、「表が出ると**事前に主張**」:
 - 事前確率: 「50 % 正しい」かつ「50 % 間違い」
 - 事後確率: 「100 % 正しい」または「100 % 間違い」
 - * 表が出たのであれば、100% 正しい (確率の”消失”)

3.4 信頼区間

- 信頼区間における確率的事象は、「データの抽出」
- 理想的な 95% 信頼区間: 「(データから計算した) 区間が推定目標を含む」と主張すると:
 - 事前確率: 「95 % 正しい」 / 「5 % 間違い」
 - 事後確率: 「100 % 正しい」 / 「100 % 間違い」
- 仮定に基づき、間違いを犯す事前的確率をコントロールした主張を行う”ルール”

3.5 経済学との類似点

- 確率的事象を導入したモデルにおいて、事前と事後の区別は最重要論点
 - マクロ金融政策、契約理論、厚生経済学等
- ある火災保険契約の評価 = 火事 (確率事象) が起きる前の事前評価

	火災発生 (1%)	発生せず (99%)
加入	金銭損失 = 0	-20
非加入	-100	0

3.6 落とし穴

- コイントス: 事後 (コイントス後) において、宣言の当否は確認できる
 - 「裏が出た」のであれば、「表が出る」という宣言は 100% (事後確率) 誤り
- 信頼区間: 推定目標は、データに依存せずに決まる「不明だが確定した」値
 - 事後 (抽出したデータから計算した後) においても、宣言の当否が確認できず、事後確率も定義できない
 - * 「事後確率 = 事前的確率」という**錯覚**を生み出す一因
 - * 事後確率を定義したい場合、ベイズ法などを検討

3.7 類似例: 裁判


- ルールと証拠に基づいて、「量刑」を決める仕組み
 - 「実際に犯罪を犯した事後確率」を明らかにするわけではない
- 証拠の有無に関わらず「実際に犯罪を犯したかどうか」は、「不明だが確定した」事実
 - 「証拠不十分により、量刑を課さない」 $\neq$ 「犯罪を犯した事後確率が小さい」

4 点推定値の分布

4.1 “統計的性質”の対象

- 信頼区間の具体的な算出方法は、推定結果の統計的性質に基づく
- 代表的な統計的性質（一致性、漸近正規性、効率性 など）や本講義の対象は？
 - 母集団やパソコンに表示される推定値ではない
 - 推定結果を**計算する前**の「潜在的な無数の結果」についての性質

4.2 対象



4.3 OLS の事前的性質

- 推定目標 = Population OLS で計算されるパラメタ β
- 確率的事象であるデータから計算されるので、OLS の結果 $\hat{\beta}$ も確率的事象
- 「データがランダム抽出 + 技術的な仮定^{*1}」のもとで
 - $\hat{\beta}$ の期待値は β (不偏性; Unbiasedness)
 - 十分な事例数があれば、正規分布で近似できる (漸近正規性; Asymptotic normality)

4.4 数値例

- 推定目標: Y と $X = \text{カテゴリ変数 } (M, A, B)$ について、Population OLS の結果

$$E[Y | X] \simeq \beta_0 + \beta_A I_A + \beta_B I_B$$

- I_A, I_B : ダミー変数 (例: $X = A$ であれば $I_A = 1$ 、それ以外の場合は $I_A = 0$)

4.5 数値例: 設定

- 母平均: $E[Y | X] = 1 + \underbrace{.5}_{=\beta} \times I_A + 2 \times I_B$
 - I_A, I_B : ダミー変数 (例: $X = A$ であれば $I_A = 1$ 、それ以外の場合は $I_A = 0$)
- $\Pr[X = M] = .5, \Pr[X = A] = \Pr[X = B] = .25$
- $Y = E[Y | X] + \underbrace{\text{一様分布}}_{-5 \sim 5}$

4.6 数値例

- 「1000 事例のデータ」を 50 個 (データ ID1, データ ID2, ...) 発生させる


```
# A tibble: 5 x 2
```

データ ID 推定結果

	<int>	<dbl>
1	1	0.214
2	2	0.572
3	3	0.127
4	4	0.505
5	5	0.565

^{*1} 完全な多重共線性ではないなど

4.7 数値例: 点推定値の”ダンス”




4.8 β_A についての信頼区間

- 信頼区間の計算方法: データ上での OLS の結果 $\hat{\beta}_A$ に対して、

$$[\hat{\beta}_A - Q, \hat{\beta}_A + Q]$$

- Q = データから計算する”幅”
- 幅計算の根拠は、データ上での OLS が持つ、事前的な分布の性質


4.9 数値例: 信頼区間の”ダンス”



4.10 LASSO の問題点

- β の点推定値の事前分布が、
 - バイアスを持つ
 - 正規分布で近似できない

4.11 数値例: LASSO の” ダンス”



4.12 錯覚を避けるコツ

- 少なくとも本講義の範囲内では、確率は実在する存在ではなく、有益な分析概念 (フィクション) と見做す
 - 「いろんな可能性があるもの」の一部について、仮定に基づき付与できる値
 - * 付与できないものもある
 - * 本講義で登場する確率は、データを確認する前には定義されるが、R で計算した時点で消える

5 補論

5.1 信頼区間の解釈

- さまざまな解釈ができる^{*2}
- 個人的おすすめ: 仮定が正しいことを前提に
 - ある研究者が、「さまざまな母集団、推定目標、データに対して 95% 信頼区間を報告し続ける」
 - * 人生の中で、誤った宣言をしてしまう割合は、概ね 5% に抑えられる
 - * 研究成果の”品質管理”的な解釈

^{*2} Hanley (2026)

5.2 ベイズ法

- 事後確率を定義し算出できる、代表的方法
 - 仮定 (特定化された事前確率) を追加している
 - 詳しく学びたい人には、Gelman, Hill, and Vehtari (2021) がおすすめ
- ベイズにおいては、以下のような事後的確率についての主張ができる:
 - 「手元のデータから計算した**信用区間** (例: $-0.103 \sim -0.079$) は、95 % の確率で推定目標を含む」

Reference

- Breiman, Leo. 2001. “Statistical Modeling: The Two Cultures (with Comments and a Rejoinder by the Author).” *Statistical Science* 16 (3): 199–231.
- Gelman, Andrew, Jennifer Hill, and Aki Vehtari. 2021. *Regression and Other Stories*. Cambridge University Press.
- Hanley, James A. 2026. “Probabilistic Parameter Estimates That Require Less Small Print.” *The American Statistician*, 1–7.
- Shmueli, Galit. 2010. “To Explain or to Predict?” *Statistical Science*, 289–310.