

# 記述モデル

経済学のための機械学習入門

川田恵介

2026-05-09

## Table of contents

|     |                              |   |
|-----|------------------------------|---|
| 1   | <b>社会の把握: Get started</b>    | 2 |
| 1.1 | Get started . . . . .        | 2 |
| 1.2 | DML (Double LASSO) . . . . . | 3 |
| 1.3 | よくある疑問 . . . . .             | 3 |
| 1.4 | 補論: “二つの文化” . . . . .        | 4 |
| 2   | <b>モデルの多様な役割</b>             | 4 |
| 2.1 | モデルの活用目的 . . . . .           | 4 |
| 2.2 | 意思決定問題の例 . . . . .           | 4 |
| 2.3 | 把握のためのモデル . . . . .          | 4 |
| 2.4 | 予測のためのモデル . . . . .          | 4 |
| 2.5 | 意思決定者の目線 . . . . .           | 6 |
| 2.6 | 補論: 混乱の要因 . . . . .          | 7 |
| 3   | <b>信頼区間</b>                  | 7 |
| 3.1 | 論点 . . . . .                 | 7 |
| 3.2 | 信頼区間の定義 . . . . .            | 7 |
| 3.3 | 事前と事後 . . . . .              | 7 |
| 3.4 | 信頼区間 . . . . .               | 8 |
| 3.5 | 経済学との類似点 . . . . .           | 8 |

|      |                               |    |
|------|-------------------------------|----|
| 3.6  | 落とし穴 . . . . .                | 8  |
| 3.7  | 類似例: 裁判 . . . . .             | 8  |
| 4    | <b>点推定値の分布</b>                | 9  |
| 4.1  | “統計的性質” の対象 . . . . .         | 9  |
| 4.2  | 対象 . . . . .                  | 10 |
| 4.3  | OLS の事前的性質 . . . . .          | 11 |
| 4.4  | 数値例 . . . . .                 | 11 |
| 4.5  | 数値例: 設定 . . . . .             | 11 |
| 4.6  | 数値例 . . . . .                 | 11 |
| 4.7  | 数値例: 点推定値の” ダンス” . . . . .    | 12 |
| 4.8  | $\beta_A$ についての信頼区間 . . . . . | 12 |
| 4.9  | 数値例: 信頼区間の” ダンス” . . . . .    | 13 |
| 4.10 | LASSO の問題点 . . . . .          | 13 |
| 4.11 | 数値例: LASSO の” ダンス” . . . . .  | 14 |
| 4.12 | 錯覚を避けるコツ . . . . .            | 14 |
| 5    | <b>補論</b>                     | 14 |
| 5.1  | 信頼区間の解釈 . . . . .             | 14 |
| 5.2  | ベイズ法 . . . . .                | 15 |
|      | Reference . . . . .           | 15 |

## 1 社会の把握: Get started

### 1.1 Get started

- 研究目標: 「社会 ( $\simeq$  事例の集合) における子供の数と教育年数の関係性を把握する」

```
set.seed(111)

library(tidyverse)

data("fertil2", package = "wooldridge")
```

```
estimatr::lm_robust(children ~ educ, fertil2)
```

|             | Estimate   | Std. Error  | t value   | Pr(> t )      | CI Lower   |
|-------------|------------|-------------|-----------|---------------|------------|
| (Intercept) | 3.4955406  | 0.066368941 | 52.66832  | 0.000000e+00  | 3.3654238  |
| educ        | -0.2096504 | 0.008363588 | -25.06704 | 1.165341e-129 | -0.2260473 |

|             | CI Upper   | DF   |
|-------------|------------|------|
| (Intercept) | 3.6256575  | 4359 |
| educ        | -0.1932535 | 4359 |

- 「母集団のモデルは、マイナスの関係性を示唆する」

## 1.2 DML (Double LASSO)

```
model <- hdm::rlassoEffects(
  children ~ educ +
    (age + yearborn + spirit + protest + catholic)^2 +
    poly(age, 2) +
    poly(yearborn, 2),
  I = ~educ, # "Target"
  data = fertil2
)

confint(model)
```

|      | 2.5 %      | 97.5 %      |
|------|------------|-------------|
| educ | -0.1027966 | -0.07889253 |

- 「母集団のモデルは、(より小さな) マイナスの関係性を示唆する」

## 1.3 よくある疑問

- 典型的な DML では、「複雑なモデルを推定するツールである機械学習」を使って、一つのパラメタ (“単純な” 推定目標) を推定する
  - 複雑なモデルをそのまま用いれば良いのでは?
- 以下の二つの踏まえる必要がある
  - データ分析の最終的な” アウトプット ” は何か?
  - 統計的性質とは何か?

## 1.4 補論: “二つの文化”

- 機械学習の普及に伴い、(改めて?) 表面化した問題
- 二つの文化: 機械学習と統計学 (前のスライド) における伝統的な実践には大きなギャップがある (Breiman 2001)
  - 活発な議論を想起 (Shmueli (2010) ; Observational Studies の[特集号](#))

## 2 モデルの多様な役割

### 2.1 モデルの活用目的

- 「一見同じようなモデルでも、異なる動機で用いられる」ことに要注意
  - モデルの活用目的を意識するのがコツ
    - \* 「意思決定者が、モデルをどのように活用するのか?」

### 2.2 意思決定問題の例

- 以下の社内会議において、“欲しい情報”は？
  - 「ある物件をいくらで下取るべきか?」
    - \* 個別予想
  - 「どのような中期経営計画を立てるべきか?」
    - \* 事業/市場/社会の状況

### 2.3 把握のためのモデル


- 経済学の伝統的用法: 「有効な **action** を”思いつき”、その有効性を**評価**する」ための、基礎情報の提供
- モデルの役割: 人間の認知能力に比べて、社会は複雑すぎるので
  - 要約モデルの特徴を、意思決定者が把握する
  - 人間が認識できる社会の模型 = 記述モデル
    - \* 社会の**仕組み**の模型 = 記述的構造モデル

### 2.4 予測のためのモデル

- 前回までの内容: 個別予測やその性能指標の提供
- モデルの役割: 予測値の計算ツール

- － 意思決定者は、予測結果やその精度が把握できれば十分であり、モデルの詳細な特徴を”人間が”把握する必要はない
- － 予測のための”裏方”＝ 予測モデル

## 2.5 意思決定者の目線



## 2.6 補論: 混乱の要因

- かつては、同じ (単純な) モデルを記述と予測に用いてきた
- 正当化としては、
  - データが少なく、計算能力も限られているので、単純なモデルしか推定できない
  - “真実” (母平均) は意外に単純
- 現代経済学では、どちらも”説得的”ではない

## 3 信頼区間

### 3.1 論点

- 「単純な線形モデルを LASSO で推定すると、さらに単純なモデルが推定される」
  - 優れた記述モデル?
- 記述モデルの推定方法としては、問題点がある
  - 統計的推論の代表的なツールである、信頼区間の算出が難しい
    - \* 推定結果が扱いづらい統計的性質を持つ

### 3.2 信頼区間の定義

- 事前に定めた方法で、データから算出される区間
  - 95% 信頼区間であれば「95% の確率で推定目標を含む区間」をデータから計算する方法
- 典型的な錯覚: 「計算した 95% 信頼区間 ( $-0.103 \sim -0.079$ ) は、推定目標を 95% の確率で含む」は誤り
  - なぜ?
- Hint: 事前と事後の区別

### 3.3 事前と事後

- ある確率的事象が、実現する前が**事前**/後が**事後**
- 例: コイントスの結果について、「表が出ると**事前に主張**」:
  - 事前確率: 「50 % 正しい」かつ「50 % 間違い」
  - 事後確率: 「100 % 正しい」または「100 % 間違い」
    - \* 表が出たのであれば、100% 正しい (確率の”消失”)

### 3.4 信頼区間

- 信頼区間における確率的事象は、「データの抽出」
- 理想的な 95% 信頼区間: 「(データから計算した) 区間が推定目標を含む」と主張すると:
  - 事前確率: 「95 % 正しい」 / 「5 % 間違い」
  - 事後確率: 「100 % 正しい」 / 「100 % 間違い」
- 仮定に基づき、間違いを犯す事前的確率をコントロールした主張を行う”ルール”

### 3.5 経済学との類似点

- 確率的事象を導入したモデルにおいて、事前と事後の区別は最重要論点
  - マクロ金融政策、契約理論、厚生経済学等
- ある火災保険契約の評価 = 火事 (確率事象) が起きる前の事前評価

|     | 火災発生 (1%) | 発生せず (99%) |
|-----|-----------|------------|
| 加入  | 金銭損失 = 0  | -20        |
| 非加入 | -100      | 0          |

### 3.6 落とし穴

- コイントス: 事後 (コイントス後) において、宣言の当否は確認できる
  - 「裏が出た」のであれば、「表が出る」という宣言は 100% (事後確率) 誤り
- 信頼区間: 推定目標は、データに依存せずに決まる「不明だが確定した」値
  - 事後 (抽出したデータから計算した後) においても、宣言の当否が確認できず、事後確率も定義できない
    - \* 「事後確率 = 事前的確率」という**錯覚**を生み出す一因
    - \* 事後確率を定義したい場合、ベイズ法などを検討

### 3.7 類似例: 裁判

- ルールと証拠に基づいて、「量刑」を決める仕組み
  - 「実際に犯罪を犯した事後確率」を明らかにするわけではない
- 証拠の有無に関わらず「実際に犯罪を犯したかどうか」は、「不明だが確定した」事実
  - 「証拠不十分により、量刑を課さない」 $\neq$ 「犯罪を犯した事後確率が小さい」




## 4 点推定値の分布

### 4.1 “統計的性質”の対象

- 信頼区間の具体的な算出方法は、推定結果の統計的性質に基づく
- 代表的な統計的性質（一致性、漸近正規性、効率性 など）や本講義の対象は？
  - 母集団やパソコンに表示される推定値ではない
  - 推定結果を計算する前の「潜在的な無数の結果」についての性質

## 4.2 対象



### 4.3 OLS の事前的性質

- 推定目標 = Population OLS で計算されるパラメタ  $\beta$
- 確率的事象であるデータから計算されるので、OLS の結果  $\hat{\beta}$  も確率的事象
- 「データがランダム抽出 + 技術的な仮定<sup>\*1</sup>」のもとで
  - $\hat{\beta}$  の期待値は  $\beta$  (不偏性; Unbiasedness)
  - 十分な事例数があれば、正規分布で近似できる (漸近正規性; Asymptotic normality)

### 4.4 数値例

- 推定目標:  $Y$  と  $X = \text{カテゴリ変数 } (M, A, B)$  について、Population OLS の結果

$$E[Y | X] \simeq \beta_0 + \beta_A I_A + \beta_B I_B$$

- $I_A, I_B$  : ダミー変数 (例:  $X = A$  であれば  $I_A = 1$ 、それ以外の場合は  $I_A = 0$ )

### 4.5 数値例: 設定

- 母平均:  $E[Y | X] = 1 + \underbrace{.5}_{=\beta} \times I_A + 2 \times I_B$ 
  - $I_A, I_B$  : ダミー変数 (例:  $X = A$  であれば  $I_A = 1$ 、それ以外の場合は  $I_A = 0$ )
- $\Pr[X = M] = .5, \Pr[X = A] = \Pr[X = B] = .25$
- $Y = E[Y | X] + \underbrace{\text{一様分布}}_{-5 \sim 5}$

### 4.6 数値例

- 「1000 事例のデータ」を 50 個 (データ ID1, データ ID2, ...) 発生させる

```
# A tibble: 5 x 2
```


```
データ ID 推定結果
```

|   | <int> | <dbl> |
|---|-------|-------|
| 1 | 1     | 0.214 |
| 2 | 2     | 0.572 |
| 3 | 3     | 0.127 |
| 4 | 4     | 0.505 |
| 5 | 5     | 0.565 |

---

<sup>\*1</sup> 完全な多重共線性ではないなど

#### 4.7 数値例: 点推定値の”ダンス”




#### 4.8 $\beta_A$ についての信頼区間

- 標信頼区間の計算方法: データ上での OLS の結果  $\hat{\beta}_A$  に対して、

$$[\hat{\beta}_A - Q, \hat{\beta}_A + Q]$$

- $Q$  = データから計算する”幅”
- 幅計算の根拠は、データ上での OLS が持つ、事前的な分布の性質


#### 4.9 数値例: 信頼区間の”ダンス”



#### 4.10 LASSO の問題点

- $\beta$  の点推定値の事前分布が、
  - バイアスを持つ
  - 正規分布で近似できない

#### 4.11 数値例: LASSO の”ダンス”



#### 4.12 錯覚を避けるコツ

- 少なくとも本講義の範囲内では、確率は実在する存在ではなく、有益な分析概念 (フィクション) と見做す
  - 「いろんな可能性があるもの」の一部について、仮定に基づき付与できる値
    - \* 付与できないものもある
    - \* 本講義で登場する確率は、データを確認する前には定義されるが、R で計算した時点で消える

### 5 補論

#### 5.1 信頼区間の解釈

- さまざまな解釈ができる: 仮定が正しいことを前提に
  1. 大量の研究者が、「同じ母集団と推定目標に対して、独立して抽出したデータを用いて 95% 信頼区間を計算し、推定目標を含む」と宣言する
    - 全チームのうち、概ね 5% は誤った宣言をしてしまう

2. ある研究者が、「さまざまな母集団、推定目標、データに対して 95% 信頼区間を報告し続ける」

- 人生の中で、概ね 5% は誤った宣言をしてしまう

## 5.2 ベイズ法

- 事後確率を定義し算出できる、代表的方法
  - 仮定 (特定化された事前確率) を追加している
- ベイズにおいては、以下のような事後的確率についての主張ができる:
  - 「手元のデータから計算した**信用区間** (例:  $-0.103 \sim -0.079$ ) は、95 % の確率で推定目標を含む」

## Reference

- Breiman, Leo. 2001. “Statistical Modeling: The Two Cultures (with Comments and a Rejoinder by the Author).” *Statistical Science* 16 (3): 199–231.
- Shmueli, Galit. 2010. “To Explain or to Predict?” *Statistical Science*, 289–310.