

調整後の比較: OLS と 2 重選択

経済学のための機械学習入門

川田恵介

2026-05-10

Table of contents

1	調整後の比較: Get started	3
1.1	Get started: 単純比較	3
1.2	Get started: 背景の差	4
1.3	Get started: OLS による調整	4
1.4	Get started: 2 重選択	5
1.5	Get started: 2 重選択による調整	5
2	調整後の比較	6
2.1	推定目標の定義	6
2.2	Stratified estimation	6
3	効果の同質性に基づく推定	7
3.1	部分線型モデル	7
3.2	推定目標の定式化	7
3.3	OLS による推定	7
3.4	例	7
3.5	OLS の問題点	8

4	準備: D と X の相関	8
4.1	D と X の相関	8
4.2	数値例: Mac 格差	8
4.3	数値例: 推定するモデル	8
4.4	数値例: 相関構造	8
4.5	500 事例のデータを 50 発生	9
4.6	直感: 無相関	10
4.7	直感: 無相関	10
4.8	直感: 無相関	11
4.9	直感: 逆相関	11
4.10	直感: 逆相関	12
4.11	直感: 逆相関	12
4.12	直感	13
4.13	まとめ	13
5	2 重選択	13
5.1	定義	13
5.2	Post selection	13
5.3	非推奨: Single selection	14
5.4	推奨: 2 重選択	14
5.5	数値例	14
5.6	理由	15
5.7	Single selection の問題点	15
5.8	Mac 格差における直感	15
5.9	2 重選択の利点	15
5.10	2 重選択の性質	15
5.11	数値例	16

6	補論	16
6.1	母平均	16
6.2	データ主導のモデル選択 + 推論	16
6.3	報告の際の注意点	17
6.4	私見	17
6.5	Stock (2010) (一部抜粋)	17
	Reference	17

1 調整後の比較: Get started

1.1 Get started: 単純比較

- 研究目標: 「社会 ($\simeq$ 事例の集合) における子供の数と初等教育の関係性を把握する」

```
set.seed(111)

library(tidyverse)

data("fertil2", package = "wooldridge")


fertil2$D <- if_else(fertil2$educ >= 7, 1, 0)

estimatr::lm_robust(
  children ~ D,
  fertil2
)
```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper
(Intercept)	3.251290	0.05610069	57.95454	0.00000e+00	3.141304	3.361276
D	-1.770068	0.06501879	-27.22395	7.38425e-151	-1.897538	-1.642598
	DF					
(Intercept)	4359					
D	4359					

1.2 Get started: 背景の差

```
cobalt::love.plot(  
  D ~ children + age + yearborn,  
  data = fertil2  
)
```



- 近年の世代の方が教育年数が長い
 - 同じ世代で比べたら?

1.3 Get started: OLS による調整

- 推定目標: 年齢や生まれ年に関する差を解消 (調整) した後の平均子供数の学歴間格差

```
model <- estimatr::lm_robust(  
  children ~ D +  
    age:yearborn +  
    poly(age, 2) +  
    poly(yearborn, 2),  
  fertil2
```

```
)
```

```
confint(model)[2, ]
```

```
      2.5 %      97.5 %  
D -0.6876787 -0.5049571
```

1.4 Get started: 2重選択

```
X <- model.matrix(  
  ~ D +  
    age:yearborn +  
    poly(age, 2) +  
    poly(yearborn, 2),  
  data = fertil2  
)
```

```
X <- X[, -1]
```

```
model <- hdm::rlassoEffects(  
  x = X,  
  y = fertil2$children,  
  index = 1,  
  method = "double selection"  
)
```

```
confint(model)
```

```
      2.5 %      97.5 %  
D -0.6880078 -0.5052875
```

1.5 Get started: 2重選択による調整

```
model$selection.matrix
```

D

```

D                NA
poly(age, 2)1     TRUE
poly(age, 2)2     FALSE
poly(yearborn, 2)1 TRUE
poly(yearborn, 2)2 FALSE
age:yearborn      TRUE

```

2 調整後の比較

2.1 推定目標の定義

- X の値が全く同じ集団内で、 Y の分布を D 間で比較する
- 本スライドでは、「 D は2値変数、平均値の比較」に焦点を絞る;

$$\text{推定目標} = E[Y \mid D = 1, X] - E[Y \mid D = 0, X]$$

2.2 Stratified estimation

- 理想的方法は、すべての x について、OLS を行う

```

estimatr::lm_robust(
  children ~ D,
  fertil2,
  subset = age == 42 &
    yearborn == 45
)

```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
(Intercept)	5.0	1.527525	3.273268	0.04666188	0.138733	9.861267	3
D	-3.5	1.607275	-2.177599	0.11761376	-8.615067	1.615067	3

- 問題点: サンプルサイズが5しかない

3 効果の同質性に基づく推定

3.1 部分線型モデル

- 母平均は部分線型モデルを用いて、定式化できる

$$E[Y | D, X] = \underbrace{\tau(X)}_{E[Y|D=1,X] - E[Y|D=0,X]} \times D + \underbrace{f(X)}_{E[Y|D=0,X]}$$

- $\tau(X)$: 関心となる部分
- $f(X)$: nuisance (厄介/局外) term
 - 母平均と整合的なモデルを作るために必要

3.2 推定目標の定式化

- 部分線型モデルの利点: 推定目標を明示的に定式化できる
- 同質なモデル: 母集団において、すべての X について、 $\tau \simeq \tau(X)$ を想定
 - 特徴把握の出発点
- 注意: 差の異質性を前提としても、解釈可能 (後述)

3.3 OLS による推定

- 以下をデータ上で OLS 回帰する

$$E[Y | D, X] \simeq \tau \times D + \underbrace{\beta_0 + \beta_1 X_1 + \dots}_{f(X)}$$

- $E[Y | D, X]$ に近づけるために、高次項や交差項などを加えて、 $f(X)$ を複雑に定式化する必要がある

3.4 例

```
estimatr::lm_robust(  
  children ~ D +  
    age:yearborn +  
    poly(age, 2) +  
    poly(yearborn, 2),  
  fertil2  
)
```

3.5 OLS の問題点

- X の数が増えると、推定モデルが非常に複雑になる
 - OLS ではうまく推定できなくなる
 - 信頼区間の計算も難しくなる (正規分布に十分に収束しない)
 - * CausalML chapter 4. 参照

4 準備: D と X の相関

4.1 D と X の相関

- 母平均の「正しくシンプルなモデル」を推定できない場合、 D と X の相関関係に注意が必要
- D と X 相関が強い場合、モデルの定式化は D のパラメタ (Population OLS の結果; 推定目標) やその推定結果に大きな影響を与える

4.2 数値例: Mac 格差

- 条件付き母平均:

$$E[Y \mid Mac, Win] = 0.8 \times Mac + Win$$

- Y : Excel スキル
 - Mac: Mac を 2 年以上利用した経験があれば 1、それ以外は 0
 - Win: Win を 2 年以上利用した経験があれば 1、それ以外は 0
- 個別の $Y =$ 母平均 + 一様分布 ($-5 \sim 5$)

4.3 数値例: 推定するモデル

- 以下の二つのモデルを比較する;
 - $Long = \beta_0 + \beta_{Mac} \times Mac + \beta_{Win} \times Win$
 - $E[Y \mid Mac, Win]$ を極力近似する
 - $Short = \beta_0 + \beta_{Mac} \times Mac$
 - $E[Y \mid Mac]$ に当てはまる

4.4 数値例: 相関構造


- 非現実的な想定

無相関	Mac=1	Mac=0
Win=1	.25	.25
Win=0	.25	.25


- より現実的 (?) な想定

逆相関	Mac=1	Mac=0
Win=1	.05	.45
Win=0	.45	.05


4.5 500 事例のデータを 50 発生




4.6 直感: 無相関




4.7 直感: 無相関




4.8 直感: 無相関




4.9 直感: 逆相関



4.10 直感: 逆相関



4.11 直感: 逆相関



4.12 直感

- Win の利用経験が同じであれば、Mac の利用経験と Excel スキルは正の相関
- Mac の有無のみで単純比較すると、「Mac の経験がない人は、Win の経験を持つ割合が高い」という相関構造の影響も含めた比較を行う
 - 「Mac 未経験者 (実は大半が win 経験者) の方が、Excel スキルが高い」という、“()” を無視すると、直感に反する推定結果が示されがち

4.13 まとめ

- D と X の相関が激しいと、モデルの定式化 (Long/Short) で、点推定値や信頼区間の分布が決定的に変化する
- 注意: 信頼区間は「事実上の推定目標」が対象
- 相関がなければ

$$\begin{aligned} \text{Shortにおける}\beta_D &= \underbrace{E[Y \mid D = 1] - E[Y \mid D = 0]}_{\text{事実上の推定目標}} \\ &\stackrel{\text{相関があれば}\neq}{=} \underbrace{E[Y \mid D = 1, X] - E[Y \mid D = 0, X]}_{\text{本来の推定目標}} \end{aligned}$$

5 2重選択

5.1 定義

- Double Machine Learning の一種
 - 「OLS のシンプルな拡張」として理解できる、DML の優れた出発点 (Angrist and Frandsen 2022; Chernozhukov, Hansen, and Spindler 2015)
- 共通アイディア: 機械学習による「下準備を行い」、OLS や平均値などで推定目標を推定する

5.2 Post selection

- アイディア: LASSO による変数選択のみを活用する
- 1. LASSO によって、 X の中から”重要な変数”のみを選ぶ
- 2. 重要な変数のみ線形モデルに導入して、OLS で推定する
- 不偏性や中心極限定理は回復する?

5.3 非推奨: Single selection

1. X から Y を予測するモデルを推定し、“重要な変数” のみを選ぶ


- Y の予測において、特に重要そうな X が選択される
- D と X の相関構造の情報が有効活用されないため、非推奨

5.4 推奨: 2重選択

1. X から Y または D を予測するモデルを推定し、“重要な変数” のみを選ぶ

- D と X の相関構造の情報を明示的に活用
- 「重要な変数は X の一部であり、事例数に比べて十分少ない」という仮定のもとで
 - 「変数はデータから選択された」という事実を”無視し”、通常の OLS と同様の手順で信頼区間を近似計算できる

5.5 数値例



5.6 理由

- 重要な点: データ抽出によって生じる、推定結果の事前分布が焦点
- データの影響を受ける、すべてを反映する必要がある:
 - あるモデルの推定結果
 - **モデルに含む変数**
 - * OLS: 「データを見る前 (事前) にモデルを決める」ので固定
 - * LASSO での変数選択: 「データによって決める」ので**確率的**

5.7 Single selection の問題点

- 「モデルに含む変数」がデータに依存するので、推定結果の複雑な事前分布が生じる
 - 特に「 Y との相関はそこそこだが、 D との相関が強い変数」を誤って脱落させてしまうリスクが、無視できないほど高い
- 注意点: 機械学習による変数選択は、「絶対に正しい」、と錯覚しないことが重要
 - データ次第であり、確率的に正しい

5.8 Mac 格差における直感

- Win と Mac の相関が強い場合、Win はモデルに加えるべき変数
- $Y \sim Win$ を LASSO で推定すると
 - Win は重要な予測変数ではなく、脱落しやすい!!!
 - * 「Win の経験はあるが、Mac は無し」VS 「Mac の経験はあるが、Win は無し」の比較であり、

5.9 2重選択の利点

- ダブルチェック (Y の予測にも、 D の予測にも役に立たない場合のみ除外する) を行う、
 - 変数選択の影響を、“十分な事例数があれば、無視できるくらい小さくする”、ことができる
 - * あたかも「データを見る前 (事前) にモデルを決めた OLS」のように、推論できる


5.10 2重選択の性質

- 十分な事例数があり、「Population OLS における D のパラメタに大きな影響を与える変数は、 X の中の一部」(Approximate Sparsity; 近似的に疎)^{*1}、が仮定できれば

^{*1} + 完全な多重共線性がないなどの技術的条件

- $\hat{\beta}$ の期待値は β (漸近不偏性; Asymptotic Unbiasedness)
 - * 通常の OLS とは異なり、事例数が少なければ、無視できないバイアスが生じ得る
- 正規分布で近似できる (漸近正規性; Asymptotic normality)

5.11 数値例



6 補論

6.1 母平均

- $E[Y | D, X] = 0.8 \times D + X$ について:

$$E[Y | X] = 0.8 \times E[D | X] + X$$

- X についての差は

$$E[Y | 1] - E[Y | 0] = 1$$

\$\$

- $0.8 \times \{E[D | X=1] - E[D | X=0]\}$ \$\$

6.2 データ主導のモデル選択 + 推論

- 「データから事後的に定式化した記述モデル」の推定や推論は、未解決な課題

- Kuchibhotla, Kolassa, and Kuffner (2022)
- DML: X に関する部分 (Nuisance) についてののみ、データ主導の定式化を行い、その影響を小さくするような工夫を施すことで
 - D に関するパラメタへの推論が可能
 - 「記述モデル全体」についての推論を保証しているわけではないことに注意

6.3 報告の際の注意点

- 「調整後の比較」において、 D と関係ない係数は、「関心の対象外」
 - 多くの因果推論や格差研究も、推定目標は「調整後の比較」なので、同様
- X に関するものも含めた「すべての係数」についての、解釈を要求する”読者”が存在することに注意 (Westreich and Greenland 2013)
 - 推奨: 「 D のパラメタが関心である」ことを、徹底的に強調

6.4 私見

- かつての教科書: しばしば「推定するモデルは、母平均を簡潔に正しく表現」が暗黙の前提
 - 目標: すべてのパラメタについて統計的推論を行うことで、「母平均の真の式」を明らかにする
- 本講義の対象: セミパラメトリック推定 + 機械学習
 - 誤定式化の可能性を明示的に考慮する代わりに、特定のパラメタについて推論
 - * 「研究目標と関連づけられるパラメタ」が推定目標となる因果推論/格差研究と相性が良い

6.5 Stock (2010) (一部抜粋)

- In the 1980s, the standard undergraduate curriculum addressed estimation and inference in models in which all regressors were treated symmetrically
- The classroom today focuses more on the estimation of specific objects, mainly specific causal effects, and less on the estimation of “models.”
- I supervised an undergraduate senior thesis with the goal of estimating the effect of steroids on home runs
 - 20 years ago, the goal might have been to develop a model of home runs.
- 注: 多くの研究目標で、経済モデルに基づく推定は依然不可欠 (Shapiro (2026))

Reference

Angrist, Joshua D, and Brigham Frandsen. 2022. “Machine Labor.” *Journal of Labor Economics* 40 (S1): S97–140.

- Chernozhukov, Victor, Christian Hansen, and Martin Spindler. 2015. “Valid Post-Selection and Post-Regularization Inference: An Elementary, General Approach.” *Annu. Rev. Econ.* 7 (1): 649–88.
- Kuchibhotla, Arun K, John E Kolassa, and Todd A Kuffner. 2022. “Post-Selection Inference.” *Annual Review of Statistics and Its Application* 9 (1): 505–27.
- Shapiro, Jesse M. 2026. *Introduction to Quantitative Economics*. MIT Press.
- Stock, James H. 2010. “The Other Transformation in Econometric Practice: Robust Tools for Inference.” *Journal of Economic Perspectives* 24 (2): 83–94.
- Westreich, Daniel, and Sander Greenland. 2013. “The Table 2 Fallacy: Presenting and Interpreting Confounder and Modifier Coefficients.” *American Journal of Epidemiology* 177 (4): 292–98.