

前半のまとめ

経済学のための機械学習入門

川田恵介

2026-05-17


Table of contents

1	逆向きに復習	3
1.1	研究の流れ	3
1.2	研究目標	4
1.3	実例: Dube et al. (2020)	4
1.4	実例: Dube et al. (2020)	4
1.5	実例: Dube et al. (2020)	4
1.6	推定方法	4
1.7	二重選択	5
1.8	数値例	5
1.9	数値例: D の点推定値	6
1.10	注意点	6
1.11	数値例: Z の点推定値	7
1.12	二重選択の問題点	7
2	後半戦の内容	7
2.1	後期の主目標	7
2.2	実例	8
2.3	実例	8
2.4	実例	9

2.5	アイデア: 個別 VS 集団	10
2.6	アイデア: 機械学習の利点/欠点	10
2.7	DML の例: 残差回帰	11
3	補論: 因果推論への接続	11
3.1	研究目標	11
3.2	因果推論	11
3.3	例	11
3.4	Observable variation	12
3.5	介入の因果効果	12
3.6	現実/仮想世界	12
3.7	識別の”大雑把な”仮定	12
3.8	不変的な構造	13
3.9	不変的な構造の含意	13
3.10	RCT	13
3.11	機械学習の活用例	13
3.12	一般的な推定手順	13
3.13	発展的トピックス	14
3.14	Reference	14

1 逆向きに復習

1.1 研究の流れ



1.2 研究目標

- 前半は、以下を紹介

観察できる変数	
個別の事例	予測
事例の集団	調整後の比較

- LASSO = 予測、二重選択 = 調整後の比較

1.3 実例: Dube et al. (2020)

- 研究目標: 労働市場における**需要独占** (経済学的概念) の測定
 - 経済学理論に基づき、間接的に測定
 - * 市場での競争圧力が高い (独占力が行使できない) のであれば
 - ・ 提示賃金の低下は、仕事の充足率を大きく低下させる

1.4 実例: Dube et al. (2020)

- 市場での競争圧力を測定するには、**同じような仕事内容**について、提示賃金と充足率の関係性を推定する必要がある
- 仕事内容を調整しないと以下のような結果になりうる:
 - 賃金が安い (けど楽な仕事) のに簡単に埋まる
 - 賃金が高い (けど難しい/キツイ仕事) のになかなか埋まらない

1.5 実例: Dube et al. (2020)

- 推定目標: 仕事の内容 X が共通な求人における、仕事の充足率と提示賃金の関係性
- 推定上の課題: 仕事の内容には、大量の変数によって定義される
 - 例: 職務内容のテキスト情報から抽出したキーワード

1.6 推定方法

- $E[Y \mid D, X]$ を推定する必要がある

- 以下で近似:

$$E[Y \mid D, X] \underset{\text{定式化誤差の可能性}}{\cong} \beta_D \times D + \underbrace{f(X)}_{\text{Nuisance}}$$

- 定式化誤差を減らすためには、 $f(X)$ を複雑に定式化する必要がある
 - X の数が多いと、OLS での推定が難しくなる


1.7 二重選択

1. $f(X)$ を複雑に定式化し、重要な項のみを選択する
 - Y または D の**どちらの予測**にも役に立たない変数は除外する
2. OLS で推定する
 - 今後の議論との共通の戦略: 機械学習で下準備し、モーメント法 (OLS や平均値) で推定

1.8 数値例

- $E[Y \mid D, X, Z] = .8 \times D + X + Z$
 - D と X, Z は負の相関
 - X, Z は正の相関
- OLS、(D のパラメタ) についての 2 重選択/Single selection を比較


1.9 数値例: D の点推定値



1.10 注意点

- 二重選択は、線形モデルを推定/推論する方法ではない
 - モデルの特定のパラメタを推定/推論する方法
- X, Z のパラメタは、“関心ではない”

1.11 数値例: Z の点推定値



1.12 二重選択の問題点

- 有力な方法だが、柔軟性に限界がある
 - 明示的な変数選択を伴うアルゴリズムが必要
 - より複雑な推定目標へ適用しにくい

2 後半戦の内容

2.1 後期の主目標

- 以下のモデルを多様な機械学習の手法 (含む Random Forest, Boosting 等) を活用して推定

$$E[Y \mid D, X] = \underbrace{\tau(X)}_{X \text{ について何らかの関数}} \times D + f(X)$$

- 例: $D = \text{year}$, $X = \text{tenure, size, district, reform}$
 - $\tau(X)$: 物件の特徴 X に応じて、どのくらい値上がりしているのか?

2.2 実例

```
set.seed(111)

library(tidyverse)


data <- nanoparquet::read_parquet("Public/data.parquet")

X <- model.matrix(
  ~ 0 + tenure + distance + size + district + reform,
  data)

model <- grf::causal_forest( # Causal Forest
  Y = data$price,
  W = data$year,
  X = X)
```

2.3 実例

```
hist(model$predictions)
```

2.4 実例

```
grf::best_linear_projection(
  model,
  scale(X)
)
```

Best linear projection of the conditional average treatment effect.
 Confidence intervals are cluster- and heteroskedasticity-robust (HC3):

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	9.0863039	0.7272675	12.4938	< 2.2e-16 ***
tenure	-2.7691155	0.7980166	-3.4700	0.0005236 ***
distance	-1.3470617	0.7809472	-1.7249	0.0845879 .
size	7.1391520	2.8401024	2.5137	0.0119694 *
district 世田谷	0.7362798	0.9359042	0.7867	0.4314814
district 中央	2.3418071	0.7627321	3.0703	0.0021466 **
district 中野	0.5186572	0.6151791	0.8431	0.3992014
district 北	0.1836010	0.5662265	0.3243	0.7457556
district 千代田	2.5057941	1.8020469	1.3905	0.1644129

district 台東	1.5574964	0.6223141	2.5027	0.0123457	*
district 品川	1.9397480	0.8457125	2.2936	0.0218412	*
district 大田	-0.4505218	0.7397946	-0.6090	0.5425558	
district 文京	-0.0100308	0.7453348	-0.0135	0.9892627	
district 新宿	2.0777221	0.8815098	2.3570	0.0184502	*
district 杉並	0.2191090	0.6685358	0.3277	0.7431145	
district 板橋	-0.0031279	0.7193369	-0.0043	0.9965307	
district 江戸川	-0.4654193	0.6489558	-0.7172	0.4732857	
district 江東	1.9779790	0.9753587	2.0280	0.0426028	*
district 渋谷	1.4991331	1.6211019	0.9248	0.3551214	
district 港	4.6746058	1.6860758	2.7725	0.0055777	**
district 目黒	1.2044681	0.9966464	1.2085	0.2268874	
district 練馬	0.0889311	0.6983522	0.1273	0.8986716	
district 荒川	-0.4641351	0.5846437	-0.7939	0.4272938	
district 葛飾	-0.5093008	0.6261575	-0.8134	0.4160306	
district 豊島	1.7599177	0.7083256	2.4846	0.0129921	*
district 足立	-0.5412729	0.6976333	-0.7759	0.4378516	
reform	0.7017964	0.7253858	0.9675	0.3333372	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

2.5 アイディア: 個別 VS 集団

- 個別予測は非常に難しいが、母平均を推定するツールとしてならば有効では? (Varian 2014; Brunson-Smith, Feller, and Nakamura 2023)

$$\begin{aligned}
 \underbrace{Y - \text{予測値}}_{\text{大きい傾向}} &= \underbrace{Y - E[Y | X]}_{\text{削減不可能な誤差; 大きい傾向}} \\
 + \underbrace{E[Y | X] - \text{予測値}}_{\text{削減可能な誤差; 把握において重要}}
 \end{aligned}$$

2.6 アイディア: 機械学習の利点/欠点

- OLS で母平均を推定するためには、研究者が適切にモデルを定式化し、二つの誤差のバランスを取る必要がある

$$\begin{aligned}
 E[Y | X] - \text{予測値} &= \underbrace{E[Y | X] - \text{Population OLS}}_{\text{定式化誤差}} \\
 + \underbrace{\text{Population OLS} - \text{予測値}}_{\text{推定誤差}}
 \end{aligned}$$

- LASSO を含む機械学習は、ある程度データ手動でバランスを取ることができる
 – ただし統計的推論は難しい

2.7 DML の例: 残差回帰

1. $E[Y | X], E[D | X]$ を機械学習で、**交差推定**
2. 以下を OLS で推定:

$$Y - \underbrace{\hat{E}[Y | X]}_{\text{Step1の推定結果}} \simeq \beta_D \times (D - \underbrace{\hat{E}[D | X]}_{\text{Step1の推定結果}})$$

- 「 X の影響を” 除去する ” という下準備を、LASSO や RandomForest などの機械学習で行う」

3 補論: 因果推論への接続

3.1 研究目標

- 太字に目標について、ここまでの内容で**推定**は可能

	観察できる変数	観察できない概念
個別の事例	予測	個別因果効果の予測
事例の集団	平均値、線形要約モデル	平均効果/構造推定

3.2 因果推論

- 二重選択法を含む DML の主要な応用先 (Chernozhukov et al. 2018)
 - 他には格差研究など
- カテゴリーエラーに注意
 - 狭義の因果推論: 因果に関する研究目標と推定目標を接続 (識別) する議論
 - DML: 推定目標をデータから推定する方法

3.3 例

- ある学部で、「統計学」の受講を前提に、「機械学習」が受講できるとする
 - Y = 大学院へ進学すれば 1、それ以外は 0
 - D = 機械学習を受講していれば 1、それ以外は 0
 - X = 統計学を受講していれば 1、それ以外は 0

3.4 Observable variation

- 以下の3種類の値が存在するとすると
 - $E[Y \mid D = 1, X = 1]$
 - $E[Y \mid D = 0, X = 1]$
 - $E[Y \mid D = 0, X = 0]$
- 比較/予測分析は可能
 - 狭義の機械学習/統計学の手法の対象

3.5 介入の因果効果

- 「全学生に機械学習の受講を義務付けた」世界と現実世界の違いは?
- Hypothetical free variation (Haavelmo 1944)
 - 現実には存在しない”違い”
 - * 例においては、「統計学を受講せずに機械学習を受講する」は想像できるが、現実には存在しない
 - 計量経済学黎明期の議論を知りたい人は、Aldrich (1989) 推奨

3.6 現実/仮想世界^{*1}

- 実現世界と(介入した)仮想世界(分布を*で表す)を想定し、以下を比較したい;
 - 現実世界の母集団: Y の分布 $f(Y)$
 - * 狭義の機械学習/統計学の対象
 - 仮想世界の母集団: Y の分布 $f^*(Y)$
- Natural Effect (Rudolph et al. 2022)

$$f^*(Y = 1) - f(Y = 1)$$

3.7 識別の”大雑把な”仮定

- 識別の仮定: 現実世界と仮想世界の間関係性は?
 - 最も単純な識別は以下を要求
$$f(Y \mid D = 1) = f^*(Y)$$
 - * 現実世界における機械学習受講者の平均値と仮想世界の平均値が等しい
 - どうやって正当化する?

^{*1} Mlodozeniec, Krueger, and Turner (2025)

3.8 不変的な構造

- 仮定: どちらの世界でも、 Y は以下の”構造式”で決定

$$Y = D \times \underbrace{Y_1}_{\text{観察できない}} + (1 - D) \times \underbrace{Y_0}_{\text{観察できない}}$$

- Y_1/Y_0 : 不変的な個人レベルの値
 - 潜在結果モデル (Wang, Richardson, and Robins 2025) では、SUTVA の仮定と呼ばれる

3.9 不変的な構造の含意

- 仮想世界の分布を、現実世界における Y_1 の分布に置き換えられる;

$$f^*(Y) \underset{D=1\text{なので}}{\equiv} f^*(Y_1) \underset{\text{不変的な構造}}{\equiv} f(Y_1)$$

- Y_1 は観察できないので、推定できない

3.10 RCT

- 現実世界において、 D の値が完全ランダムに決まっているならば、

$$\begin{aligned} f(Y_1) &\underset{\text{Random}}{\equiv} f(Y_1 | D = 1) \\ &\underset{\text{不変的な構造}}{\equiv} f(Y | D = 1) \end{aligned}$$

- 因果効果を推定問題を、 $f(Y | D = 1) - f(Y)$ を推定する問題に置き換えられる

3.11 機械学習の活用例

- 「構造式 (SUTVA)」と「 X 内で D がランダムに決まる」ならば

$$\text{因果効果} = f(Y | D = 1, X) - f(Y | X)$$

- X に大量の変数が含まれていたとしても、DML で推定できる

3.12 一般的な推定手順

- **研究目標の定義:** 仮想的な分布や概念も用いて、知りたい値を定式化する
- **識別:** 識別のための仮定を用いて、観察可能な変数についての母分布のみで、推定目標を定義する

- **推定:** 推定のための仮定 (ランダム抽出など) に用いて、データから推定目標を推定
- 経済理論を用いた構造推定もよく似た分析工程となる
 - 構造推定: Shapiro (2026)

3.13 発展的トピックス

- 潜在結果だけでなく、構造方程式モデルや do-演算子 (DAG) を用いた議論も可能 (Wang, Richardson, and Robins 2025)
- 講義レポジトリのリンク、Cinelli et al. (2025)

3.14 Reference

- Aldrich, John. 1989. “Autonomy.” *Oxford Economic Papers* 41 (1): 15–34.
- Bruns-Smith, David, Avi Feller, and Emi Nakamura. 2023. “Using Supervised Learning to Estimate Inequality in the Size and Persistence of Income Shocks.” In *Proceedings of the 2023 ACM Conference on Fairness, Accountability, and Transparency*, 1747–56.
- Chernonozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. 2018. “Double/Debiased Machine Learning for Treatment and Structural Parameters.” *The Econometrics Journal* 21 (1): C1–68.
- Cinelli, Carlos, Avi Feller, Guido Imbens, Edward Kennedy, Sara Magliacane, and Jose Zubizarreta. 2025. “Challenges in Statistics: A Dozen Challenges in Causality and Causal Inference.” *arXiv Preprint arXiv:2508.17099*.
- Dube, Arindrajit, Jeff Jacobs, Suresh Naidu, and Siddharth Suri. 2020. “Monopsony in Online Labor Markets.” *American Economic Review: Insights* 2 (1): 33–46.
- Haavelmo, Trygve. 1944. “The Probability Approach in Econometrics.” *Econometrica*, iii–115.
- Mlodozieniec, Bruno Kacper, David Krueger, and Richard E Turner. 2025. “Position: Probabilistic Modelling Is Sufficient for Causal Inference.” In *Forty-Second International Conference on Machine Learning Position Paper Track*.
- Rudolph, Jacqueline E, Abigail Cartus, Lisa M Bodnar, Enrique F Schisterman, and Ashley I Naimi. 2022. “The Role of the Natural Course in Causal Analysis.” *American Journal of Epidemiology* 191 (2): 341–48.
- Shapiro, Jesse M. 2026. *Introduction to Quantitative Economics*. MIT Press.
- Varian, Hal R. 2014. “Big Data: New Tricks for Econometrics.” *Journal of Economic Perspectives* 28 (2): 3–28.
- Wang, Linbo, Thomas Richardson, and James Robins. 2025. “Causal Inference: A Tale of Three Frameworks.” *arXiv Preprint arXiv:2511.21516*.