

回帰木系統のアルゴリズム

経済学のための機械学習入門

川田恵介

2026-05-25

Table of contents

1	Get started	3
1.1	データ分割	3
1.2	モデル推定	3
1.3	予測性能	3
1.4	訓練データへの適合度	4
1.5	現状	4
1.6	鍵となるアイデア	5
2	回帰木モデル	5
2.1	動機	5
2.2	数値例	5
2.3	数値例: 母平均	6
2.4	数値例: データ	6
2.5	母平均推定: 2つのチャレンジ	7
2.6	数値例: 線形モデル	7
2.7	数値例	8
2.8	回帰木法: 2回分割	8
2.9	数値例: 2回分割	9
2.10	数値例: 2回分割	9
2.11	回帰木法: 一般化	10

3	深い回帰木による内挿	10
3.1	回帰木法: 複数回分割	10
3.2	数値例: 最大限分割	11
3.3	数値例: 最大限分割	11
3.4	深い木の課題	12
3.5	スムージングの方法	12
3.6	モデルの集計方法	12
4	X のランダム抽出	12
4.1	アプローチ	12
4.2	数値例	13
4.3	数値例	13
4.4	機能	14
4.5	比喩: Intersectionality	14
5	事例のランダム抽出	14
5.1	アプローチ	14
5.2	数値例	15
5.3	数値例	15
5.4	性質	16
5.5	比喩: 現代的「ハズレ値」処理	16
6	補論: ranger の挙動	16
6.1	アルゴリズム	16
6.2	カテゴリ変数の処理	16
6.3	連続変数の欠損値の処理	16
7	補論: ブートストラップ	17
7.1	ブートストラップ	17
7.2	ブートストラップ: シンプルな例	17
	Reference	17

1 Get started

1.1 データ分割

```
set.seed(100)

library(tidyverse)

data("fertil2", package = "wooldridge")

split <- rsample::initial_split(fertil2)

train <- rsample::training(split)

test <- rsample::testing(split)
```

1.2 モデル推定

```
ols <- lm(
  children ~
    (mnthborn + yearborn + age + educ + urban + spirit + protest + catholic + evermarr)^2 +
    I(mnthborn^2) + I(yearborn^2) + I(age^2) + I(educ^2),
  train)

ranger <- ranger::ranger(
  children ~
    mnthborn + yearborn + age + educ + urban + spirit + protest + catholic + evermarr,
  train) # Random Forest
```

1.3 予測性能

```
pred_ols <- predict(ols, test)
pred_rf <- predict(ranger, test)$predictions
```

```
1 - mean((test$children - pred_ols)^2)/var(test$children)
```

```
[1] 0.6248272
```

```
1 - mean((test$children - pred_rf)^2)/var(test$children)
```

```
[1] 0.6112929
```

- ほぼ同等の性能

1.4 訓練データへの適合度

```
pred_ols <- predict(ols,train)
pred_rf <- predict(ranger,train)$predictions
```

```
1 - mean((train$children - pred_ols)^2)/var(train$children)
```

```
[1] 0.6006768
```

```
1 - mean((train$children - pred_rf)^2)/var(train$children)
```

```
[1] 0.8189155
```

- Random Forest は、訓練データへの適合度が高い

1.5 現状

- “there seem to remain substantial gaps in our theoretical understanding of the performance of tree-based algorithms and neural networks.” (CausalML. Chapter 8.)
 - Trust but verify
- 本講義では、Scornet and Hooker (2026) の 2.7 章の” 良性の過剰適合 (Benign overfitting) “に基づく議論を紹介
 - 訓練データへの適合度が高い (しばしば完全に適合する) にも関わらず、予測性能が高い傾向があることに注目

1.6 鍵となるアイデア

- “かつて”のイメージ: 訓練データに存在する X の組み合わせ (地点) について、母平均を推定
- 本スライド: X の数が多く、訓練データに**存在しない** X の地点についての推定精度が重要
 - 「1958 年 7 月生まれ 30 才、教育年数 5 年、都市部居住、アミニズム、結婚経験あり」はテストデータにしか存在しない
 - * テストデータの 1056 事例の内、182 事例しか同じ地点が訓練データに存在しない

2 回帰木モデル


2.1 動機

- 社会的変数について、“万能アルゴリズム”は、(講師の知る限り) 存在しない
- 複数の予測モデルを集計 (Stacking) することが実践的
 - 線形モデルとは大きく異なる推定方法も必要
 - * 回帰木とその発展的推定方法が有力 (Grinsztajn, Oyallon, and Varoquaux 2022; Somvanshi et al. 2026)


2.2 数値例

- $X = \text{Mac}$ の利用経験が全くない (1) ~ 十分ある (4)
- $Z = \text{Win}$ の利用経験が全くない (1) ~ 十分ある (4)
- 基本的に、 $E[Y | X, Z] = X + Z$
 - ただし $X = Z = 1$ については、 $E[Y | X, Z] = -18$ (大きな非線形性)
 - $Y = E[Y | X, Z] +$ 一様分布 $(-.5 \sim .5)$

2.3 数値例: 母平均



2.4 数値例: データ



2.5 母平均推定: 2 つのチャレンジ

- 訓練データに存在する地点における推定
- 存在しない地点における推定
 - 内挿 (Interpolation)
 - * X の数が増える/連続変数が含まれる場合、爆発的/“無限”に増大

2.6 数値例: 線形モデル

```
lm(Y ~ X + Z,  
   train)
```

Call:


```
lm(formula = Y ~ X + Z, data = train)
```

Coefficients:

(Intercept)	X	Z
-26.039	5.060	5.326

- 問題点: 極端な非線形性を捉えるのが難しく、“ハズレ値”にモデル全体が左右される


2.7 数値例




2.8 回帰木法: 2 回分割

1. Y, X を指定する
2. データによって X についてサブグループを定義する
 - すべての X との区切り位置について、訓練データへの二乗誤差を最も小さくする区切り方を選ぶ
3. 2 をもう一度繰り返す (Greedy algorithm)
4. Y のサブグループ平均を計算する

2.9 数值例: 2 回分割



2.10 数值例: 2 回分割



2.11 回帰木法: 一般化


1. Y, X を指定する
2. データによって X についてサブグループを定義する
 - すべての X との区切り位置について、訓練データへの二乗誤差を最も小さくする区切り方を選ぶ
3. 停止条件 (サブサンプルサイズなど) に到達するまで、上記を繰り返す
4. Y のサブグループ平均を計算する

3 深い回帰木による内挿


3.1 回帰木法: 複数回分割

- 停止条件を緩くし、分割できる限り分割を繰り返させる
- 先の数値例では、サブサンプルが 1 事例のみになるまで、分割が進む
 - 訓練データに完全に適合する
 - 訓練データに存在しない地点については、内挿 (interpolation) が行われる
 - * データ主導で定義された”最も近い”訓練事例の値が、推定値になる

3.2 数值例: 最大限分割



3.3 数值例: 最大限分割



3.4 深い木の課題

- 一般に推定誤差が大きすぎる
 - すべての地点について、極めて少ない事例数 (多くの場合、1 事例) によって、推定値が決まる
 - 「より多くの訓練事例を用いた推定値」 (“スムーjing”) が必要

3.5 スムーjingの方法

- 剪定 (Pruning): 深い木を単純化する (LASSO に近いアイデア)
- モデル平均化 (Averaging): 大量のモデルを推定し、その平均値を最終予測とする
 - Aggregation/Ensemble/Stacking

3.6 モデルの集計方法


- どうやって大量のモデルを生み出すか?
 - X のランダム抽出
 - 事例のランダム抽出
 - 事例と X のランダム抽出 `ranger` や `grf` などが実装する Random Forest

4 X のランダム抽出


4.1 アプローチ

- 木の分割を行う際に、元々の X から一部 (デフォルトでは、 $\sqrt{X}$ の数) をランダム抽出し、そこから変数と分割位置を選ぶ
 - $\{\text{age}, \text{educ}, \text{yearborn}\}$ から、最初の分割は $\{\text{age}, \text{yearborn}\}$ 、次は $\{\text{yearborn}, \text{educ}\}$ から分割点を選ぶ
- 上記を繰り返して、大量の予測モデルを生成し、平均値を最終予測とする
 - 良性の過剰適合を目指す

4.2 数值例



4.3 数值例



4.4 機能

- 木の構造は、訓練データに存在しない地点の予測に大きな影響を与える
 - X のランダム抽出によって、異なる訓練事例が、訓練データに存在しない地点の推定に活用される
 - * 集計することで、複数の訓練事例の” 平均値” を最終予測とし、ハズレ値の影響を緩和する
- 多くの応用で、訓練データに存在する地点の予測も変化する
 - ランダムに選ばれた変数次第で、分割が停止するため

4.5 比喩: Intersectionality





- 格差研究の重要論点の一つ (Kaufman 2025)
 - 複数の属性 (性別、親の SES、人種等) の組み合わせによって、格差は大きく異なる可能性
 - “Primany” な属性に注目しすぎること、大きな格差を見過ごす恐れがある
- “データ主導で” モデルを組んだとしても、リスクは消えない
 - データ上に存在しない組み合わせが要注意

5 事例のランダム抽出


5.1 アプローチ

- 訓練データから、ランダムに再抽出した一部のデータについて、回帰木を推定する

5.2 数值例



5.3 数值例



5.4 性質

- 木の構造を変化させる + ハズレ値の影響を緩和する
- 個人差が大きい (条件付き平均値のばらつきに比べて、 X 内での個人差が大きい) 場合に有効

5.5 比喩: 現代的「ハズレ値」処理

- 事例再抽出による「ハズレ値」処理
 - 伝統的な方法: 人間が目視で除去する
 - * 事例数や X の数が多いと難しい/研究不正の原因となりうる
 - ・ 非推奨
 - ランダム抽出: 並列処理も容易であり、スケーラビリティも高い

6 補論: ranger の挙動

6.1 アルゴリズム

1. ブートストラップにより、データを複製 (可能な限り多く、`ranger` の default は 500)
 2. 各複製データについて、Regression Tree を推定
- 分割時に使用できる変数はランダムに選ぶ

6.2 カテゴリ変数の処理

- 初期設定では、各カテゴリのレベルごとに Y の平均値を計算し、順位付ける
 - 順位を連続変数として扱って、木を計算
 - 欠損カテゴリーも、一つのレベルとして扱う

6.3 連続変数の欠損値の処理

- 欠損値を最大、最小のどちらかに移動させる
 - 二乗誤差を小さくする基準に基づく

7 補論: ブートストラップ

7.1 ブートストラップ

- 代表的なデータの複製方法
 - 元データから、復元抽出 (被りありの抽選) により事例を抽出し、データを複製する
- 経済学においては、統計的推論 (信頼区間計算) によく用いられてきたが、予測性能の改善にも活用できる

7.2 ブートストラップ: シンプルな例

- 訓練データ = $[5, 6, 100]$
- 復元抽出により、同じ数 (3) の事例をランダムに選ぶ
 - 複製データ 1 = $[6, 6, 100]$ = の平均値 37.3
 - 複製データ 2 = $[6, 6, 5]$ = の平均値 5.7
- 最終予測 = 21.5
- ハズレ値 (“100”) を反映しない予測も活用される

Reference

- Grinsztajn, Léo, Edouard Oyallon, and Gaël Varoquaux. 2022. “Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data?” *Advances in Neural Information Processing Systems* 35: 507–20.
- Kaufman, Jay S. 2025. “Statistical Aspects of Racial and Ethnic Health Disparities.” *Annual Review of Statistics and Its Application* 13.
- Scornet, Erwan, and Giles Hooker. 2026. “Theory of Random Forests.” *Annual Review of Statistics and Its Application* 13 (1): 99–121.
- Somvanshi, Shriyank, Subasish Das, Syed Javed, Gian Antariksa, and Ahmed Hossain. 2026. “A Survey on Tabular Data: From Tree-Based Methods to Tabular Deep Learning.” *ACM Computing Surveys*.