

モデル集計: 発展

経済学のための機械学習入門

川田恵介

2026-06-07

Table of contents

1	Get started	2
1.1	データ分割	2
1.2	モデル推定	3
1.3	予測	4
2	モデル集計	4
2.1	最終予測モデル	4
2.2	誤った手順	4
2.3	悪例	5
2.4	悪例	5
2.5	手順: 2 分割法	6
2.6	2 分割	6
2.7	2 分割	6
2.8	確認: ランダム再抽出の役割	7
2.9	問題点	7
3	交差推定	7
3.1	交差推定; Cross estimation	7
3.2	推定方法	8
3.3	数値例: 3 分割	8

3.4	数値例: Step 1	8
3.5	数値例: Step 2	9
3.6	数値例: Step 3	9
3.7	利点	9
3.8	Super learner の実装	10
3.9	漸近性質	10
4	発展: 汎用 LLM の活用	10
4.1	非定型変数の活用	10
4.2	汎用 LLM	10
4.3	Engl and Aronow (2025)	11
4.4	注意点	11
4.5	Local LLM の活用	11
4.6	意義	11
	Reference	11

1 Get started

1.1 データ分割

```

set.seed(100)

library(tidyverse)
library(SuperLearner) # 簡便なモデル集計

data("fertil2", package = "wooldridge")

split <- rsample::initial_split(fertil2)

Y <- rsample::training(split)$children

X <- select(
  rsample::training(split),
  yearborn,

```

```

    age,
    educ)

Y_test <- rsample::testing(split)$children

X_test <- select(
  rsample::testing(split),
  yearborn,
  age,
  educ)

```

1.2 モデル推定

```

model <- SuperLearner(
  Y = Y,
  X = X,
  SL.library = c(
    "SL.lm", # OLS
    "SL.glmnet", # LASSO (glmnet を事前にインストール)
    "SL.ranger"), # Random Forest
  cvControl = list(V = 2) # 2分割
)

model

```

Call:

```

SuperLearner(Y = Y, X = X, SL.library = c("SL.lm", "SL.glmnet", "SL.ranger"),
  cvControl = list(V = 2))

```

	Risk	Coef
SL.lm_All	2.193136	0.7133252
SL.glmnet_All	2.193250	0.0000000
SL.ranger_All	2.309436	0.2866748

1.3 予測

```
pred <- predict(  
  model,  
  X_test  
)  
  
1 - mean((Y_test - pred$pred)^2)/  
  var(Y_test) # Super Learner
```

```
[1] 0.5798784
```

```
1 - mean((Y_test - pred$library.predict[,1])^2)/  
  var(Y_test) # OLS
```

```
[1] 0.5676434
```

2 モデル集計

2.1 最終予測モデル

- さまざまな推定方法が生む出す予測の集計値^{*1}

$$\beta_1 \times OLS \text{の予測} + \beta_2 \times RandomForest \text{の予測} + \dots$$

- β は、何らかの方法で推定する
 - Random Forest 型のモデル集計は単純平均 ($\beta_1 = \beta_2 = \dots$)

2.2 誤った手順

- 全訓練データを用いて、
 1. OLS や RandomForest など適用し、個別予測モデルを推定
 2. 個別モデルの予測値を計算し、 X とみなして、 Y を予測する線形モデルを推定し、 β を確定
- 不適切な β が推定される

^{*1} Stacking, モデルアンサンブルなどとも呼ばれる

2.3 悪例

```
data <- select(fertil2, children, age, yearborn, mnthborn, educ)

ols <- lm(children ~ age + yearborn + mnthborn + educ, data)
ranger <- ranger::ranger(children ~ age + mnthborn + yearborn + educ, data)

data$pred_ols <- predict(ols, data)
data$pred_ranger <- predict(ranger, data)$predictions

head(data)
```

	children	age	yearborn	mnthborn	educ	pred_ols	pred_ranger
1	0	24	64	5	12	1.120051	0.6253113
2	3	32	56	1	13	2.518802	2.3858097
3	1	30	58	7	5	2.748398	3.3460771
4	2	42	45	11	4	5.062303	3.9436476
5	2	43	45	5	11	4.531996	2.7343250
6	1	36	52	8	7	3.597459	3.4323562

2.4 悪例

```
lm(children ~ pred_ols + pred_ranger, data)
```

Call:

```
lm(formula = children ~ pred_ols + pred_ranger, data = data)
```

Coefficients:

(Intercept)	pred_ols	pred_ranger
-0.00389	-0.49098	1.49210

- Random Forest の実際の予測力が、高いわけではない

2.5 手順: 2 分割法

- 訓練データをさらに 2 分割し
 1. 片方のデータで、OLS や RandomForest など適用し、個別予測モデルを推定
 2. もう一方のデータで、 Y を個別モデルの予測値に回帰し、 β を確定
- 事例数が大きければ、問題ない

2.6 2 分割

```
split <- rsample::initial_split(data)
train <- rsample::training(split)
test <- rsample::testing(split)

ols <- lm(children ~ age + yearborn + mnthborn + educ ,train)
ranger <- ranger::ranger(children ~ age + mnthborn + yearborn + educ,train)

test$pred_ols <- predict(ols,test)
test$pred_ranger <- predict(ranger,test)$predictions

head(test)
```

	children	age	yearborn	mnthborn	educ	pred_ols	pred_ranger
1	0	24	64	5	12	1.148944	1.243237
2	3	32	56	1	13	2.536999	2.260919
3	1	36	52	8	7	3.553905	4.034955
4	4	37	51	7	16	2.998676	1.918549
5	0	26	62	6	7	1.885423	2.175497
6	2	47	41	8	5	5.609934	4.702413

2.7 2 分割

```
lm(children ~ pred_ols + pred_ranger,
    test)
```

Call:

```
lm(formula = children ~ pred_ols + pred_ranger, data = test)
```

Coefficients:

(Intercept)	pred_ols	pred_ranger
-0.1732	0.7334	0.3540

2.8 確認: ランダム再抽出の役割

- 「データからランダム分割し、予測モデルの推定に用いるデータとは、独立したデータを生成する」は、非常に重要な手法
- データ分割が必要な”下流タスク”
 - 予測モデルの性能評価
 - 予測区間 (Conformal interval) の計算
 - モデル集計 (このスライド)
 - パラメタ推定 (次のスライド)

2.9 問題点

- データ分割は、個々のデータの事例数を減少させる
- 複雑な応用では、データの分割数が増える
 - 「モデル集計し、性能をテストする」ためには、データの 3 分割 (テストと 2 分割した訓練データ) が必要
- 事例数が十分にあれば大きな問題ではないが、現実的なデータでは応用上の課題となる

3 交差推定

3.1 交差推定; Cross estimation

- Train/Test への分割は、予測モデルや β の推定に、データの一部しか利用できない
 - 事例数が限られている場合、“もったいない”
- 交差推定を用いれば、全事例が活用できる
 - モデルの性能評価 (交差検証; Cross-validation) や LASSO 等における λ の選択にも利用される
- Causal ML 3.B 参照

3.2 推定方法

1. データをサブデータ $(1, \dots, G)$ にランダム分割
2. 第 1 サブデータ以外で予測モデルを推定し、第 1 サブデータを予測
3. 第 2 サブデータ以外で予測モデルを推定し、第 2 サブデータを予測
4. 以上を全てのデータについて繰り返す
5. 予測対象 Y に対して、各予測値で回帰して β を推定

3.3 数値例: 3 分割

```
# A tibble: 9 x 3
  StationDistance Price Group
      <int>      <dbl> <fct>
1           9  6.05    3
2           4  3.94    2
3           7 31.0     3
4           1  8.64    1
5           2 -5.99    3
6           7 -4.48    1
7           2 -0.895   1
8           3  0.00785  2
9           1 -3.12    2
```

3.4 数値例: Step 1

```
# A tibble: 9 x 5
  StationDistance Price Group OLS RandomForest
      <int>      <dbl> <fct> <dbl>      <dbl>
1           9  6.05    3    NA        NA
2           4  3.94    2    NA        NA
3           7 31.0     3    NA        NA
4           1  8.64    1   -4.12     -1.89
5           2 -5.99    3    NA        NA
6           7 -4.48    1   12.9      16.7
7           2 -0.895   1   -1.29     -1.91
8           3  0.00785  2    NA        NA
9           1 -3.12    2    NA        NA
```


- Group 2,3 を Training データとして活用

3.5 数値例: Step 2

```
# A tibble: 9 x 5
  StationDistance Price Group   OLS RandomForest
      <int>      <dbl> <fct>   <dbl>         <dbl>
1           9  6.05    3      NA           NA
2           4  3.94    2      4.86        -0.189
3           7 31.0     3      NA           NA
4           1  8.64    1     -4.12        -1.89
5           2 -5.99    3      NA           NA
6           7 -4.48    1     12.9         16.7
7           2 -0.895   1     -1.29        -1.91
8           3  0.00785  2       3.55        -0.189
9           1 -3.12    2       0.938         1.91
```

- Group 1,3 を Training データとして活用

3.6 数値例: Step 3

```
# A tibble: 9 x 5
  StationDistance Price Group   OLS RandomForest
      <int>      <dbl> <fct>   <dbl>         <dbl>
1           9  6.05    3     -4.88        -1.84
2           4  3.94    2       4.86        -0.189
3           7 31.0     3     -3.03        -1.84
4           1  8.64    1     -4.12        -1.89
5           2 -5.99    3       1.61         0.945
6           7 -4.48    1     12.9         16.7
7           2 -0.895   1     -1.29        -1.91
8           3  0.00785  2       3.55        -0.189
9           1 -3.12    2       0.938         1.91
```

3.7 利点

- 全データに、「ある事例への予測値を、その事例を使わずに推定した予測モデルから算出できる」
- 全データを用いて、下流タスクを実行できる

3.8 Super learner の実装^{*2}

1. 全訓練データを用いて、個別の予測モデルを推定
2. β の推定
 - 交差推定を用いて、全訓練事例に、個別予測値を計算
 - 全訓練データを用いて、 Y を個別予測値で回帰
 - β は非負、総和は 1 になるように推定
3. 1 の予測モデルを 2 の β で集計

3.9 漸近性質

- 事例数が十分あれば、Super learner は、個別の予測モデル内の”最善のモデル”と比べて、同等以上の予測性能を持つ

4 発展: 汎用 LLM の活用

4.1 非定型変数の活用

- 画像、音、動画なども重要な X となりうる (Bajari et al. 2025)
 - 中古マンションの外観や眺望の写真など
- Deep learning の活用が有力な選択肢 (CausalML Chap 8/ISL Chap 10)
 - 課題: 中規模以下のデータで、“1 から” Deep learning のモデルを高い精度で推定するのは難しい
 - Foundation models の活用などが有力候補 (Vafa, Athey, and Blei 2025)

4.2 汎用 LLM

- 近年の大きな変化として、膨大なデータから推定された汎用 LLM (Gemini, ChatGPT 等) が利用可能になっている
 - 「データの外の世界の情報を要約したモデル」と見做せる
- 「 X (写真等も含む) から価格を予測して」というお願いもできる
 - 関心のある母集団について、予測精度の保証はできない
 - * 利用しているデータや具体的な推定手法が公開されていない

^{*2} Phillips et al. (2023)

4.3 Engh and Aronow (2025)

- 「LLM の予測価格」を X として用いれば良いのでは?
 - 以下を LASSO 推定

$$E[Y \mid X, \underset{\text{LLMの予測}}{\hat{Y}}] \simeq \beta_1 \times \hat{Y} + \beta \times X$$

- 小規模データ (300 事例程度) において、特に有効
- モデル集計の応用として解釈できる

4.4 注意点

- LLM の学習に、「分析に用いているデータが利用されていないこと」が必要
 - 自身で収集した、非公開、収集したばかり等のデータであれば、比較的安心して使える
- クラウド上の LLM は、“勝手にアップデートされる”
 - 分析の再現可能性がない

4.5 Local LLM の活用

- 現状、(透明性/再現可能性が求められる) 学術研究への応用案としては、
 - 自身の PC にインストールした、open-source LLM
 - 「LLM が推定された時点 (Knowledge Cutoff)」後に収集されたデータ
- 時間がある時に、Local LLM 環境の構築にチャレンジしてみても良いのでは？

4.6 意義

- 伝統的なデータ分析: データの情報 + データの外側についての”限定的な”情報 (仮定)
- 今後の可能性: LLM を通じて、データの外側についての膨大な情報を持ち込み、下流タスクに活用
 - 「LLM が”Black box”」に対応できる活用法が重要
 - * 今回の内容 (DML) は有力候補

Reference

Bajari, Patrick, Zhihao Cen, Victor Chernozhukov, Manoj Manukonda, Suhas Vijaykumar, Jin Wang, Ramon Huerta, et al. 2025. “Hedonic Prices and Quality Adjusted Price Indices Powered by AI.” *Journal of Econometrics* 251: 106052.

- Engh, Chris, and PM Aronow. 2025. “Using LLMs to Directly Guess Conditional Expectations Can Improve Efficiency in Causal Estimation.” *arXiv Preprint arXiv:2510.09684*.
- Phillips, Rachael V, Mark J Van Der Laan, Hana Lee, and Susan Gruber. 2023. “Practical Considerations for Specifying a Super Learner.” *International Journal of Epidemiology* 52 (4): 1276–85.
- Vafa, Keyon, Susan Athey, and David M Blei. 2025. “Estimating Wage Disparities Using Foundation Models.” *Proceedings of the National Academy of Sciences* 122 (22): e2427298122.