

モデル集計: 発展

経済学のための機械学習入門

川田恵介

2026-06-07

Table of contents

1	Get started	2
1.1	データ分割	2
1.2	モデル推定	3
1.3	予測	4
2	モデル集計	4
2.1	最終予測モデル	4
2.2	誤った手順	4
2.3	悪例	5
2.4	悪例	5
2.5	手順: 2 分割法	6
2.6	2 分割	6
2.7	2 分割	6
2.8	確認: ランダム再抽出の役割	7
2.9	問題点	7
3	交差推定	7
3.1	交差推定; Cross estimation	7
3.2	推定方法	8
3.3	数値例: 3 分割	8

3.4	数値例: Step 1	8
3.5	数値例: Step 2	9
3.6	数値例: Step 3	9
3.7	利点	9
3.8	Super learner の実装	10
4	発展: 汎用 LLM の活用	10
4.1	非定型変数の活用	10
4.2	汎用 LLM	10
4.3	Engh and Aronow (2025)	10
4.4	注意点	11
4.5	Local LLM の活用	11
4.6	意義	11
	Reference	11

1 Get started

1.1 データ分割

```

set.seed(100)

library(tidyverse)
library(SuperLearner) # 簡便なモデル集計

data("fertil2", package = "wooldridge")

split <- rsample::initial_split(fertil2)

Y <- rsample::training(split)$children

X <- select(
  rsample::training(split),
  yearborn,
  age,

```

```

educ)

Y_test <- rsample::testing(split)$children

X_test <- select(
  rsample::testing(split),
  yearborn,
  age,
  educ)

```

1.2 モデル推定

```

model <- SuperLearner(
  Y = Y,
  X = X,
  SL.library = c(
    "SL.lm", # OLS
    "SL.glmnet", # LASSO (glmnet を事前にインストール)
    "SL.ranger"), # Random Forest
  cvControl = list(V = 2) # 2 分割
)

model

```

Call:

```

SuperLearner(Y = Y, X = X, SL.library = c("SL.lm", "SL.glmnet", "SL.ranger"),
  cvControl = list(V = 2))

```

	Risk	Coef
SL.lm_All	2.193136	0.7133252
SL.glmnet_All	2.193250	0.0000000
SL.ranger_All	2.309436	0.2866748

1.3 予測

```
pred <- predict(  
  model,  
  X_test  
)  
  
1 - mean((Y_test - pred$pred)^2)/  
  var(Y_test) # Super Learner
```

```
[1] 0.5798784
```

```
1 - mean((Y_test - pred$library.predict[,1])^2)/  
  var(Y_test) # OLS
```

```
[1] 0.5676434
```

2 モデル集計

2.1 最終予測モデル

- さまざまな推定方法が生む出す予測の集計値^{*1}

$$\beta_1 \times OLS \text{の予測} + \beta_2 \times RandomForest \text{の予測} + \dots$$

- β は、何らかの方法で推定する
 - Random Forest 型のモデル集計は単純平均 ($\beta_1 = \beta_2 = \dots$)

2.2 誤った手順

- 全訓練データを用いて、
 1. OLS や RandomForest など適用し、個別予測モデルを推定
 2. 個別モデルの予測値を計算し、 X とみなして、 Y を予測する線形モデルを推定し、 β を確定
- 不適切な β が推定される

^{*1} Stacking, モデルアンサンブルなどとも呼ばれる

2.3 悪例

```
data <- select(fertil2, children, age, yearborn, mnthborn, educ)

ols <- lm(children ~ age + yearborn + mnthborn + educ, data)
ranger <- ranger::ranger(children ~ age + mnthborn + yearborn + educ, data)

data$pred_ols <- predict(ols, data)
data$pred_ranger <- predict(ranger, data)$predictions

head(data)
```

	children	age	yearborn	mnthborn	educ	pred_ols	pred_ranger
1	0	24	64	5	12	1.120051	0.6253113
2	3	32	56	1	13	2.518802	2.3858097
3	1	30	58	7	5	2.748398	3.3460771
4	2	42	45	11	4	5.062303	3.9436476
5	2	43	45	5	11	4.531996	2.7343250
6	1	36	52	8	7	3.597459	3.4323562

2.4 悪例

```
lm(children ~ pred_ols + pred_ranger, data)
```

Call:

```
lm(formula = children ~ pred_ols + pred_ranger, data = data)
```

Coefficients:

(Intercept)	pred_ols	pred_ranger
-0.00389	-0.49098	1.49210

- Random Forest の実際の予測力が、高いわけではない

2.5 手順: 2 分割法

- 訓練データをさらに 2 分割し
 1. 片方のデータで、OLS や RandomForest など適用し、個別予測モデルを推定
 2. もう一方のデータで、 Y を個別モデルの予測値に回帰し、 β を確定
- 事例数が大きければ、問題ない

2.6 2 分割

```
split <- rsample::initial_split(data)
train <- rsample::training(split)
test <- rsample::testing(split)

ols <- lm(children ~ age + yearborn + mnthborn + educ ,train)
ranger <- ranger::ranger(children ~ age + mnthborn + yearborn + educ,train)

test$pred_ols <- predict(ols,test)
test$pred_ranger <- predict(ranger,test)$predictions

head(test)
```

	children	age	yearborn	mnthborn	educ	pred_ols	pred_ranger
1	0	24	64	5	12	1.148944	1.243237
2	3	32	56	1	13	2.536999	2.260919
3	1	36	52	8	7	3.553905	4.034955
4	4	37	51	7	16	2.998676	1.918549
5	0	26	62	6	7	1.885423	2.175497
6	2	47	41	8	5	5.609934	4.702413

2.7 2 分割

```
lm(children ~ pred_ols + pred_ranger,
    test)
```

Call:

```
lm(formula = children ~ pred_ols + pred_ranger, data = test)
```

Coefficients:

(Intercept)	pred_ols	pred_ranger
-0.1732	0.7334	0.3540

2.8 確認: ランダム再抽出の役割

- 「データからランダム分割し、予測モデルの推定に用いるデータとは、独立したデータを生成する」は、非常に重要な手法
- データ分割が必要な”下流タスク”
 - 予測モデルの性能評価
 - 予測区間 (Conformal interval) の計算
 - モデル集計 (このスライド)
 - パラメタ推定 (次のスライド)

2.9 問題点

- データ分割は、個々のデータの事例数を減少させる
- 複雑な応用では、データの分割数が増える
 - 「モデル集計し、性能をテストする」ためには、データの 3 分割 (テストと 2 分割した訓練データ) が必要
- 事例数が十分にあれば大きな問題ではないが、現実的なデータでは応用上の課題となる

3 交差推定

3.1 交差推定; Cross estimation

- Train/Test への分割は、予測モデルや β の推定に、データの一部しか利用できない
 - 事例数が限られている場合、“もったいない”
- 交差推定を用いれば、全事例が活用できる
 - モデルの性能評価 (交差検証; Cross-validation) や LASSO 等における λ の選択にも利用される
- Causal ML 3.B 参照

3.2 推定方法

1. データをサブデータ $(1, \dots, G)$ にランダム分割
2. 第 1 サブデータ以外で予測モデルを推定し、第 1 サブデータを予測
3. 第 2 サブデータ以外で予測モデルを推定し、第 2 サブデータを予測
4. 以上を全てのデータについて繰り返す
5. 予測対象 Y に対して、各予測値で回帰して β を推定

3.3 数値例: 3 分割

```
# A tibble: 9 x 3
  StationDistance Price Group
      <int>      <dbl> <fct>
1           9  6.05    3
2           4  3.94    2
3           7 31.0     3
4           1  8.64    1
5           2 -5.99    3
6           7 -4.48    1
7           2 -0.895   1
8           3  0.00785  2
9           1 -3.12    2
```

3.4 数値例: Step 1

```
# A tibble: 9 x 5
  StationDistance Price Group OLS RandomForest
      <int>      <dbl> <fct> <dbl>      <dbl>
1           9  6.05    3    NA        NA
2           4  3.94    2    NA        NA
3           7 31.0     3    NA        NA
4           1  8.64    1   -4.12     -1.89
5           2 -5.99    3    NA        NA
6           7 -4.48    1   12.9      16.7
7           2 -0.895   1   -1.29     -1.91
8           3  0.00785  2    NA        NA
9           1 -3.12    2    NA        NA
```


- Group 2,3 を Training データとして活用

3.5 数値例: Step 2

```
# A tibble: 9 x 5
  StationDistance Price Group   OLS RandomForest
      <int>      <dbl> <fct>   <dbl>         <dbl>
1           9  6.05    3      NA           NA
2           4  3.94    2      4.86        -0.189
3           7 31.0     3      NA           NA
4           1  8.64    1     -4.12        -1.89
5           2 -5.99    3      NA           NA
6           7 -4.48    1     12.9         16.7
7           2 -0.895   1     -1.29        -1.91
8           3  0.00785  2       3.55        -0.189
9           1 -3.12    2       0.938         1.91
```

- Group 1,3 を Training データとして活用

3.6 数値例: Step 3

```
# A tibble: 9 x 5
  StationDistance Price Group   OLS RandomForest
      <int>      <dbl> <fct>   <dbl>         <dbl>
1           9  6.05    3     -4.88        -1.84
2           4  3.94    2       4.86        -0.189
3           7 31.0     3     -3.03        -1.84
4           1  8.64    1     -4.12        -1.89
5           2 -5.99    3       1.61         0.945
6           7 -4.48    1     12.9         16.7
7           2 -0.895   1     -1.29        -1.91
8           3  0.00785  2       3.55        -0.189
9           1 -3.12    2       0.938         1.91
```

3.7 利点

- 全データに、「ある事例への予測値を、その事例を使わずに推定した予測モデルから算出できる」
- 全データを用いて、下流タスクを実行できる

3.8 Super learner の実装^{*2}

1. 全訓練データを用いて、個別の予測モデルを推定
2. β の推定
 - 交差推定を用いて、全訓練事例に、個別予測値を計算
 - 全訓練データを用いて、 Y を個別予測値で回帰
 - β は非負、総和は 1 になるように推定
3. 1 の予測モデルを 2 の β で集計

4 発展: 汎用 LLM の活用

4.1 非定型変数の活用

- 画像、音、動画なども重要な X となりうる (Bajari et al. 2025)
 - 中古マンションの外観や眺望の写真など
- Deep learning の活用が有力な選択肢 (CausalML Chap 8/ISL Chap 10)
 - 課題: 中規模以下のデータで、“1 から” Deep learning のモデルを高い精度で推定するのは難しい
 - Foundation models の活用などが有力候補 (Vafa, Athey, and Blei 2025)

4.2 汎用 LLM

- 近年の大きな変化として、膨大なデータから推定された汎用 LLM (Gemini, ChatGPT 等) が利用可能になっている
 - 「データの外の世界の情報を要約したモデル」と見做せる
- 「 X (写真等も含む) から価格を予測して」というお願いもできる
 - 関心のある母集団について、予測精度の保証はできない
 - * 利用しているデータや具体的な推定手法が公開されていない

4.3 Engh and Aronow (2025)

- 「LLM の予測価格」を X として用いれば良いのでは?
 - 以下を LASSO 推定

$$E[Y \mid X, \hat{Y}_{LLMの予測}] \simeq \beta_1 \times \hat{Y} + \beta \times X$$

^{*2} Phillips et al. (2023)

- 小規模データ (300 事例程度) において、特に有効
- モデル集計の応用として解釈できる

4.4 注意点

- LLM の学習に、「分析に用いているデータが利用されていないこと」が必要
 - 自身で収集した、非公開、収集したばかり等のデータであれば、比較的安心して使える
- クラウド上の LLM は、“勝手にアップデートされる”
 - 分析の再現可能性がない

4.5 Local LLM の活用

- 現状、(透明性/再現可能性が求められる) 学術研究への応用案としては、
 - 自身の PC にインストールした、open-source LLM
 - 「LLM が推定された時点 (Knowledge Cutoff)」後に収集されたデータ
- 時間がある時に、Local LLM 環境の構築にチャレンジしてみても良いのでは？

4.6 意義

- 伝統的なデータ分析: データの情報 + データの外側についての”限定的な”情報 (仮定)
- 今後の可能性: LLM を通じて、データの外側についての膨大な情報を持ち込み、下流タスクに活用
 - 「LLM が”Black box”」に対応できる活用法が重要
 - * 今回の内容 (DML) は有力候補

Reference

- Bajari, Patrick, Zhihao Cen, Victor Chernozhukov, Manoj Manukonda, Suhas Vijaykumar, Jin Wang, Ramon Huerta, et al. 2025. “Hedonic Prices and Quality Adjusted Price Indices Powered by AI.” *Journal of Econometrics* 251: 106052.
- Engh, Chris, and PM Aronow. 2025. “Using LLMs to Directly Guess Conditional Expectations Can Improve Efficiency in Causal Estimation.” *arXiv Preprint arXiv:2510.09684*.
- Phillips, Rachael V, Mark J Van Der Laan, Hana Lee, and Susan Gruber. 2023. “Practical Considerations for Specifying a Super Learner.” *International Journal of Epidemiology* 52 (4): 1276–85.
- Vafa, Keyon, Susan Athey, and David M Blei. 2025. “Estimating Wage Disparities Using Foundation Models.” *Proceedings of the National Academy of Sciences* 122 (22): e2427298122.