

DML: 残差回帰

経済学のための機械学習入門

川田恵介

2026-06-14

Table of contents

1	Get started: 残差回帰	2
1.1	予定	2
1.2	推定目標	3
1.3	部分線型モデル	3
1.4	OLS による推定	3
1.5	残差回帰	3
1.6	実装: 変数の定義	4
1.7	モデル推定	4
1.8	モデル推定	5
2	残差回帰: 推定目標	5
2.1	統計モデルの書き換え	5
2.2	統計モデルの書き換え	5
2.3	推定目標	5
3	残差回帰: 一致性	6
3.1	復習: OLS の一致性	6
3.2	復習: OLS	6
3.3	復習: 一致性	6
3.4	残差回帰の例: 2 分割法	6

3.5	残差回帰の例: 予測	7
3.6	残差回帰の例: 推定	7
3.7	残差回帰の例: 推定	7
3.8	残差回帰	8
3.9	仮定: 予測モデルの一致性	8
3.10	残差回帰: Oracle 推定量	8
3.11	残差回帰: 一致性	8
3.12	まとめ	8
3.13	数値例	9
3.14	数値例	9
3.15	数値例: 予測モデル	9
3.16	数値例: 残差回帰 VS OLS	10
3.17	数値例: 残差回帰の分解	10
3.18	まとめ	11
4	残差回帰: 漸近分布の推定	11
4.1	漸近分布の推定	11
4.2	復習: OLS	11
4.3	復習: OLS	11
4.4	残差回帰	11
4.5	残差回帰	12
4.6	正式な命題	12
	Reference	12

1 Get started: 残差回帰

1.1 予定

- 予測 (OLS/LASSO) -> パラメタ推定 (二重選択) -> 予測 (Random Forest/モデル平均) と議論
- 本日から、パラメタ推定に関するより柔軟なアプローチを紹介
 - Staggered design/DID/IV/RD/Mediation/Value added model 等への応用が可能
 - 汎用 LLM も活用可能 (Engel and Aronow 2025)

- 本日は部分線形モデルについての残差回帰の性質を紹介
 - 次回、一般化 (Neyman の直行条件を満たすモーメント条件 + 交差推定)

1.2 推定目標

- 本スライドでは、 D は 0 または 1
- $\tau = E[Y | 1, X] - E[Y | 0, X]$
 - X が同じ集団内での差
 - 同質性を仮定
- τ について、妥当な信頼区間の計算を目指す

1.3 部分線型モデル^{*1}

- 以下のモデルを推定

$$E[Y | D, X] = \underbrace{E[Y | D, X] - E[Y | 0, X]}_{\simeq \tau \times D} + E[Y | 0, X]$$

1.4 OLS による推定

- 以下のモデルを、OLS で推定

$$E[Y | D, X] \simeq \beta_D \times D + f(X)$$

- $\beta_D = \tau$ を達成するためには
 - $f(X)$ を複雑に定式化する必要がある
 - * 限られた事例数の元では推定誤差が大きくなる

1.5 残差回帰

- Double/Debiased Machine Learning の一手法

1. 予測: $E[Y | X], E[D | X]$ を、「高性能な機械学習の何らかの手法」で交差推定
2. 誤差の計算:

$$\hat{\Delta}_Y = Y - \underbrace{\hat{E}[Y | X]}_{\text{推定値}}, \hat{\Delta}_D = D - \underbrace{\hat{E}[D | X]}_{\text{推定値}}$$

3. 推定: $E[\hat{\Delta}_Y | \hat{\Delta}_D] \simeq \tau \times \hat{\Delta}_D$ を OLS 推定

^{*1} Robinson (1988)

1.6 実装: 変数の定義

```
set.seed(100)

library(tidyverse)

data("fertil2", package = "wooldridge")

Y <- fertil2$children

D <- if_else(fertil2$educ >= 7, 1, 0)

X <- select(
  fertil2,
  yearborn,
  mnthborn,
  age,
  spirit,
  protest,
  catholic
)
```

1.7 モデル推定

```
model <- ddml::ddml_plm(
  y = Y,
  D = D,
  X = data.matrix(X),
  learners = list(
    list(fun = ddml::ols),
    list(fun = ddml::mdl_ranger)
  ),
  shortstack = TRUE,
  silent = TRUE,
  sample_folds = 2 # 分割数 (10 程度が推奨)
)
```

1.8 モデル推定

```
summary(model) # DML
```

PLM estimation results:

, , nnls

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0184	0.0223	-0.823	4.10e-01
D_r	-0.5550	0.0476	-11.658	2.08e-31

2 残差回帰: 推定目標

2.1 統計モデルの書き換え

- 部分線形モデル;

$$E[Y | D, X] = \tau \times D + f(X)$$

- 事例レベルでの表現

$$Y = \tau \times D + f(X) + \underset{E[u|D,X]=0}{u}$$

– D, X についての条件付き平均値は、同じモデルになる

2.2 統計モデルの書き換え

- X についての条件付き平均値

$$E[Y | X] = \tau \times E[D | X] + f(X)$$

- 両辺を引くと

$$\underset{=Y-E[Y|X]}{\Delta_Y} = \tau \times \underset{=D-E[D|X]}{\Delta_D} + u$$

2.3 推定目標

- τ は、母集団上で、 Δ_Y を Δ_D を OLS 推定することで算出できる

$$\tau = \frac{E[\Delta_Y \times \Delta_D]}{E[\Delta_D \times \Delta_D]}$$

3 残差回帰: 一致性

3.1 復習: OLS の一致性

- 「無限大の事例数 + ランダム抽出^{*2}」で計算した OLS の係数は、母集団上での OLS で計算したパラメータと一致する
 - 「事例数が増えると、母集団上での結果” 付近 ” の推定値を得やすくなる」

3.2 復習: OLS

- モデル $\delta_{Y_i} \sim \beta_D \times D$
 - 事実上の推定目標 = 母集団上で OLS により計算した β_D
- データ上での OLS

$$\hat{\beta}_D = \frac{\mathbb{E}_N[\delta_{Y_i} \times D_i]}{\mathbb{E}_N[D_i \times D_i]}$$

- $\mathbb{E}_N[Y]$ = 事例数 N のデータ上での平均値

3.3 復習: 一致性

- 事例数が無限大になると、データ上の平均値は母平均に収束するので、

$$\hat{\beta}_D = \frac{\mathbb{E}_N[\delta_{Y_i} \times D_i]}{\mathbb{E}_N[D_i \times D_i]} \rightarrow \frac{E[\delta_Y \times D]}{E[D \times D]} = \beta_D$$

- 書き換えると、 $(\beta_D - \hat{\beta}_D) \rightarrow 0$
- もし $\beta_D = \tau$ ならば

$$(\beta_D - \tau) \rightarrow 0$$

3.4 残差回帰の例: 2 分割法

```
split <- rsample::initial_split(fertil2, prop = 1/2)
data_pred <- rsample::training(split) # 予測用
data_est <- rsample::testing(split) # 推定用
```

^{*2} + 完全な多重共線性が無い

3.5 残差回帰の例: 予測

```
library(SuperLearner)

model_Y <- SuperLearner(
  Y = data_pred$children,
  X = select(data_pred,age,yearborn),
  SL.library = c("SL.lm","SL.ranger"),
  cvControl = list(V = 2)
)

model_D <- SuperLearner(
  Y = data_pred$educ,
  X = select(data_pred,age,yearborn),
  SL.library = c("SL.lm","SL.ranger"),
  cvControl = list(V = 2)
)
```

3.6 残差回帰の例: 推定

```
delta_Y <- data_est$children -
  predict(model_Y,data_est)$pred #  $E[Y|X]$  の推定値

delta_D <- data_est$educ -
  predict(model_D,data_est)$pred #  $E[D|X]$  の推定値
```

3.7 残差回帰の例: 推定

```
estimatr::lm_robust(delta_Y ~ 0 + delta_D)
```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper
delta_D	-0.091417	0.008842082	-10.33885	1.712676e-24	-0.1087568	-0.07407721
	DF					
delta_D	2180					

- 「データに依存する要素」は、
 - 変換ルール ($\hat{\Delta}_Y = Y - \hat{E}[Y | X]$ など) が予測用データ (data_pred) に依存する
 - 平均値 ($\mathbb{E}_N[\hat{\Delta}_{Y_i} \times \hat{\Delta}_{D_i}]$ など) が推定用データ (data_est) に依存する

3.8 残差回帰

- 推定用データ (data_est) 上での残差回帰:

$$\hat{\beta}_D = \frac{\mathbb{E}_N[\hat{\Delta}_{Y_i} \times \hat{\Delta}_{D_i}]}{\mathbb{E}_N[\hat{\Delta}_{D_i} \times \hat{\Delta}_{D_i}]}$$

3.9 仮定: 予測モデルの一致性

- 追加の仮定が必要
 - 予測モデルの一致性: 無限大の事例数を持つ予測用データで推定すれば $\hat{E}[Y | X] \rightarrow E[Y | X]$
 - * $\hat{\Delta}_Y = Y - \hat{E}[Y | X] \rightarrow Y - E[Y | X] = \Delta_Y$
 - * Δ_D についても同様
- 多様な予測アルゴリズムを組み込んだモデル平均法を用いる、などが必要

3.10 残差回帰: Oracle 推定量

- 無限大の事例数を持つ予測用データで推定すれば

$$\hat{\beta}_D = \frac{\mathbb{E}_N[\hat{\Delta}_{Y_i} \times \hat{\Delta}_{D_i}]}{\mathbb{E}_N[\hat{\Delta}_{D_i} \times \hat{\Delta}_{D_i}]} \rightarrow \frac{\mathbb{E}_N[\Delta_{Y_i} \times \Delta_{D_i}]}{\mathbb{E}_N[\Delta_{D_i} \times \Delta_{D_i}]} = \hat{\beta}_D^{Oracle}$$

- $\hat{\beta}_D^{Oracle}$: 「理想的な予測モデル (母平均) を用いた」限られた事例数の推定用データから算出される**仮想的な推定値**

3.11 残差回帰: 一致性

- 無限大の事例数を持つ推定用データから算出する Oracle 推定量は、

$$\hat{\beta}_D^{Oracle} = \frac{\mathbb{E}_N[\Delta_{Y_i} \times \Delta_{D_i}]}{\mathbb{E}_N[\Delta_{D_i} \times \Delta_{D_i}]} \rightarrow \frac{E[\Delta_{Y_i} \times \Delta_{D_i}]}{E[\Delta_{D_i} \times \Delta_{D_i}]} = \beta_D$$

3.12 まとめ

- 2段階の収束をイメージすることが重要

- 予測モデルの条件付き母平均への収束 + 平均値の母平均への収束

$$\hat{\tau} \xrightarrow{\text{無限事例の予測用データ}} \hat{\tau}^{Oracle} \xrightarrow{\text{無限事例の推定用データ}} \tau$$


3.13 数値例

- $E[Y | D, X] = D - 1$ if $X \geq 0.5$
 - $E[Y | D, X] = D$ if $X < 0.5$
- $f(D = 1 | X) = 0.95$ if $X \geq 0.5$
 - $f(D = 1 | X) = 0.05$ if $X < 0.5$
- $Y = E[Y | D, X] + \text{一様分布}(-2, 2)$


3.14 数値例

- 「500/5000 事例のデータ抽出して、推定する」を 100 回繰り返す
 - OLS (誤定式): $Y \simeq \beta_D D + \beta_0 + \beta_1 X + \dots + \beta_6 X^6$
 - OLS (正しい定式): $Y \simeq \beta_D D + \beta_0 + \beta_1 \times \underbrace{I_{X \geq 0.5}}_{X \geq 0.5 \text{であれば} 1, \text{それ以外は} 0}$
 - 残差回帰: $E[Y | X], E[D | X]$ は、回帰木で推定


3.15 数値例: 予測モデル



3.16 数値例: 残差回帰 VS OLS



3.17 数値例: 残差回帰の分解



3.18 まとめ

- 「予測モデルの一致性」が成り立つのであれば、事例数が増加すると、 $\tau - \hat{\tau}$ は 0 に収束する
 - 予測モデルの推定誤差に起因する誤差 ($\hat{\tau}^{Oracle} - \hat{\tau}$) は、平均値の推定誤差に起因する誤差 ($\tau - \hat{\tau}^{Oracle}$) よりも”より早く”0 に収束する
 - 残差回帰が Neyman の直行条件を満たすため (次回)

4 残差回帰: 漸近分布の推定

4.1 漸近分布の推定

- 事例数がある程度大きくなると、推定値は推定目標に近づくだけでなく、“規則性は生じ”、推定可能な場合がある
 - 信頼区間計算に活用可能
 - * 漸近正規性、中心極限定理、頑強な標準誤差、ブートストラップ、DML...

4.2 復習: OLS

- 事例数が十分大きくなると、
- OLS: $\beta_D - \hat{\beta}_D$ は平均 0 の正規分布で近似できる^{*3}
 - $\beta_D = \tau$ ならば、 $\tau - \hat{\beta}_D$ も平均 0 の正規分布で近似できる
 - 分散もサンドウィッチ推定できる

4.3 復習: OLS

- 変数を「データに依存しないルールで変換しても」成り立つ
 - 例: $\delta_{Y_i} = Y_i/100\text{万円}$

4.4 残差回帰

- 事例数が十分に大きくなると

$$\tau - \hat{\tau} = \underbrace{\tau - \hat{\tau}^{Oracle}}_{\text{平均0の正規分布}} + \underbrace{\tau^{Oracle} - \hat{\tau}}_{\rightarrow 0}$$

- ポイント

^{*3} 中心極限定理

- 予測モデルの推定誤差に起因する差は、早い速度で 0 に収束する

4.5 残差回帰

- $\hat{\tau}^{Oracle}$ は、 $\Delta_Y \sim \Delta_D$ の OLS 推定結果
 - Δ_Y, Δ_D は、母平均を用いた変換
 - * 母平均は「データに依存しない」
 - * 通常の OLS と同じ確率的性質をもつ
- 要点: 母平均は、変数の変換ルールと見做せる
 - $\delta_{Y_i} = Y_i/100$ 万円: 既知かつ**確定**
 - $\Delta_Y = Y - E[Y | X]$: 未知だが**確定**

4.6 正式な命題^{*4}

- 主要な仮定: $(E[Y | X] - \hat{E}[Y | X])^2$ の平均値が、 $1/\text{事例数}^{1/4}$ 以上の速度で 0 に収束する
- 性質: $N^{1/2} \times (\tau - \hat{\tau})$ は、平均 0 の正規分布に収束し、分散をサンドウィッチ推定できる
 - 補助性質: $N^{1/2} \times (\tau - \hat{\tau})$ は、 $N^{1/2} \times (\tau - \hat{\tau}^{Oracle})$ に収束する

Reference

- Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. 2018. “Double/Debiased Machine Learning for Treatment and Structural Parameters.” *The Econometrics Journal* 21 (1): C1–68.
- Engh, Chris, and PM Aronow. 2025. “Using LLMs to Directly Guess Conditional Expectations Can Improve Efficiency in Causal Estimation.” *arXiv Preprint arXiv:2510.09684*.
- Robinson, Peter M. 1988. “Root-n-Consistent Semiparametric Regression.” *Econometrica*, 931–54.

^{*4} Chernozhukov et al. (2018)