

DML: 残差回帰

経済学のための機械学習入門

川田恵介

2026-06-15

Table of contents

1	Get started: 残差回帰	3
1.1	予定	3
1.2	推定目標	3
1.3	部分線型モデル	3
1.4	OLS による推定	3
1.5	残差回帰	4
1.6	実装: 変数の定義	4
1.7	モデル推定	4
1.8	モデル推定	5
2	残差回帰: 推定目標	5
2.1	統計モデルの書き換え	5
2.2	統計モデルの書き換え	6
2.3	推定目標	6
3	残差回帰: 一致性	6
3.1	復習: OLS の一致性	6
3.2	復習: OLS の一致性	6
3.3	残差回帰の例: 2 分割法	6
3.4	残差回帰の例: 予測	7

3.5	残差回帰の例: 推定	7
3.6	残差回帰の例: 推定	7
3.7	残差回帰: 2種類の置き換え	8
3.8	仮定: 予測モデルの一致性	8
3.9	残差回帰: Oracle 推定量	8
3.10	まとめ	8
3.11	数値例	9
3.12	数値例	9
3.13	数値例: 残差回帰 VS OLS	9
3.14	収束の速度	10
3.15	収束速度: 推定値	10
3.16	数値例: 予測モデル	10
3.17	数値例: 予測モデル	11
3.18	収束速度: 予測モデル	11
3.19	収束速度: 予測モデル	12
3.20	収束速度: 分解	12
3.21	数値例: 残差回帰の分解	13
3.22	まとめ	13
4	残差回帰: 漸近分布の推定	13
4.1	漸近分布の推定	13
4.2	復習: OLS	14
4.3	復習: OLS	14
4.4	残差回帰	14
4.5	残差回帰	14
4.6	正式な命題	15
5	予告	15
5.1	一般化	15
5.2	課題	15

5.3	解決策	15
5.4	補論: 経済学の比喻	15
	Reference	16

1 Get started: 残差回帰

1.1 予定

- 予測 (OLS/LASSO) -> パラメタ推定 (二重選択) -> 予測 (Random Forest/モデル平均) と議論
- 本日から、パラメタ推定に関するより柔軟なアプローチを紹介
 - Staggered design/DID/IV/RD/Mediation/Value added model 等への応用が可能
 - 汎用 LLM も活用可能 (Engl and Aronow 2025)
- 本日は部分線形モデルについての残差回帰の大標本性質を紹介
 - 次回、一般化 (Neyman の直行条件を満たすモーメント条件 + 交差推定)

1.2 推定目標

- 本スライドでは、 D は 0 または 1
- 条件付き平均差 (τ) = $E[Y | 1, X] - E[Y | 0, X]$
 - X が同じ集団内での差 (因果効果/格差)
 - 同質性を仮定
- τ について、妥当な信頼区間の計算を目指す

1.3 部分線型モデル^{*1}

- 以下のモデルを推定

$$E[Y | D, X] = \underbrace{E[Y | D, X] - E[Y | 0, X]}_{\simeq \tau \times D} + E[Y | 0, X]$$

1.4 OLS による推定

- 以下のモデルを、OLS で推定

$$E[Y | D, X] \simeq \beta_D \times D + f(X)$$

- $\beta_D = \tau$ を達成するためには
 - $f(X)$ を複雑に定式化する必要がある
 - * 限られた事例数の元では推定誤差が大きくなる

^{*1} Robinson (1988)

1.5 残差回帰

- Double/Debiased Machine Learning の一手法

1. 予測: $E[Y | X], E[D | X]$ を、「高性能な機械学習の何らかの手法」で交差推定
2. 誤差の計算:

$$\hat{\Delta}_Y = Y - \underbrace{\hat{E}[Y | X]}_{\text{推定値}}, \hat{\Delta}_D = D - \underbrace{\hat{E}[D | X]}_{\text{推定値}}$$

3. 推定: $E[\hat{\Delta}_Y | \hat{\Delta}_D] \simeq \tau \times \hat{\Delta}_D$ を OLS 推定

1.6 実装: 変数の定義

```
set.seed(100)

library(tidyverse)

data("fertil2", package = "wooldridge")

Y <- fertil2$children

D <- if_else(fertil2$educ >= 7, 1, 0)

X <- select(
  fertil2,
  yearborn,
  mnthborn,
  age,
  spirit,
  protest,
  catholic
)
```

1.7 モデル推定

```

model <- ddml::ddml_plm(
  y = Y,
  D = D,
  X = data.matrix(X),
  learners = list(
    list(fun = ddml::ols),
    list(fun = ddml::mdl_ranger)
  ),
  shortstack = TRUE,
  silent = TRUE,
  sample_folds = 2 # 分割数 (10 程度が推奨)
)

```

1.8 モデル推定

```
summary(model) # DML
```

PLM estimation results:

, , nnls

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0184	0.0223	-0.823	4.10e-01
D_r	-0.5550	0.0476	-11.658	2.08e-31

2 残差回帰: 推定目標

2.1 統計モデルの書き換え

- 部分線形モデル;

$$E[Y \mid D, X] = \tau \times D + f(X)$$

- 事例レベルでの表現

$$Y = \tau \times D + f(X) + \underset{E[u \mid D, X] = 0}{u}$$

– D, X についての条件付き平均値は、同じモデルになる

2.2 統計モデルの書き換え

- X についての条件付き平均値

$$E[Y | X] = \tau \times E[D | X] + f(X)$$

- 両辺を引くと

$$\begin{aligned} \Delta_Y &= \tau \times \Delta_D + u \\ = Y - E[Y|X] &= \tau \times (D - E[D|X]) + u \end{aligned}$$

2.3 推定目標

- $\tau: \Delta_Y \simeq \tau \Delta_D$ を、OLS で母集団に当てはめた結果

3 残差回帰: 一致性

3.1 復習: OLS の一致性

- OLS の事実上の推定目標: 線形モデル

$$E[Y | D] \simeq \beta_D \times D + \underbrace{f(X)}_{\text{何らかの定式化}}$$

を母集団に当てはめた結果 β_D

- OLS 推定: 同じモデルをデータに当てはめた結果 $\hat{\beta}_D$
 - 推定誤差: 当てはめるモデルに応じて、 $\hat{\beta}_D$ の値が異なる

3.2 復習: OLS の一致性

- 「無限大の事例数 + ランダム抽出^{*2}」ならば、 $\hat{\beta}_D \rightarrow \beta_D$
 - 「大きな事例数のもとでは、母集団上でのパラメタ”付近”の推定値を得やすくなる」
- $f(X)$ を十分に複雑化したモデルを推定すると、 $\beta_D \rightarrow \tau$
 - 「複雑なモデルを大きな事例数で推定すると、条件付き母平均差”付近”の推定値を得やすくなる」

3.3 残差回帰の例: 2 分割法

^{*2} + 完全な多重共線性が無い

```
split <- rsample::initial_split(fertil2, prop = 1/2)
data_pred <- rsample::training(split) # 予測用
data_est <- rsample::testing(split) # 推定用
```

3.4 残差回帰の例: 予測

```
library(SuperLearner)

model_Y <- SuperLearner(
  Y = data_pred$children,
  X = select(data_pred, age, yearborn),
  SL.library = c("SL.lm", "SL.ranger"),
  cvControl = list(V = 2)
)

model_D <- SuperLearner(
  Y = data_pred$educ,
  X = select(data_pred, age, yearborn),
  SL.library = c("SL.lm", "SL.ranger"),
  cvControl = list(V = 2)
)
```

3.5 残差回帰の例: 推定

```
delta_Y <- data_est$children -
  predict(model_Y, data_est)$pred #  $E[Y|X]$  の推定値

delta_D <- data_est$educ -
  predict(model_D, data_est)$pred #  $E[D|X]$  の推定値
```

3.6 残差回帰の例: 推定

```
estimatr::lm_robust(delta_Y ~ 0 + delta_D)
```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper
delta_D	-0.091417	0.008842082	-10.33885	1.712676e-24	-0.1087568	-0.07407721
DF						
delta_D	2180					

3.7 残差回帰: 2種類の置き換え

- 理想: $\Delta_Y \simeq \tau \times \Delta_D$ を母集団で OLS
- 現実: $\hat{\Delta}_Y \simeq \tau \times \hat{\Delta}_D$ を推定用データ ($\neq$ 母集団) で OLS
 - $\hat{\Delta}_Y = Y - \hat{E}[Y | X]$ などには、予測データから推定した予測モデル ($\neq$ 母平均) を用いる

3.8 仮定: 予測モデルの一致性

- 追加の仮定が必要
 - 予測モデルの一致性: 無限大の事例数を持つ予測用データで推定すれば $\hat{E}[Y | X] \rightarrow E[Y | X]$
 - * $\hat{\Delta}_Y = Y - \hat{E}[Y | X] \rightarrow Y - E[Y | X] = \Delta_Y$
 - * Δ_D についても同様
- 多様な予測アルゴリズムを組み込んだモデル平均法の使用を推奨

3.9 残差回帰: Oracle 推定量

- 推定用データで $\Delta_Y \simeq \tau \times \Delta_D$ を OLS 推定した結果得られる推定値 $\hat{\tau}^{Oracle}$
 - 「推定された予測モデルではなく、母平均そのものが利用できる」と想定
- 推定用データが「ランダム抽出 + 無限大の事例数を持つ」ならば、 $\hat{\tau}^{Oracle} \rightarrow \tau$

3.10 まとめ

- 2段階の収束をイメージすることが重要
- 予測モデルの条件付き母平均への収束 + 平均値の母平均への収束

$$\hat{\tau} \xrightarrow{\text{無限事例の予測用データ}} \hat{\tau}^{Oracle} \xrightarrow{\text{無限事例の推定用データ}} \tau$$


3.11 数値例

- $E[Y | D, X] = D - 1$ if $X \geq 0.5$
 – $E[Y | D, X] = D$ if $X < 0.5$
- $f(D = 1 | X) = 0.95$ if $X \geq 0.5$
 – $f(D = 1 | X) = 0.05$ if $X < 0.5$
- $Y = E[Y | D, X] + \text{一様分布}(-2, 2)$

3.12 数値例

- 「500/5000 事例のデータ抽出して、推定する」を 100 回繰り返す
 - OLS (誤定式): $Y \simeq \beta_D D + \beta_0 + \beta_1 X + \dots + \beta_6 X^6$
 - OLS (正しい定式): $Y \simeq \beta_D D + \beta_0 + \beta_1 \times \underbrace{I_{X \geq 0.5}}_{X \geq 0.5 \text{であれば} 1, \text{それ以外は} 0}$
 - 残差回帰: $E[Y | X], E[D | X]$ は、回帰木で推定

3.13 数値例: 残差回帰 VS OLS



3.14 収束の速度

- ある確率変数 X_n が 0 に収束する (確率が消失する)
- どのくらいのスピードで収束する
 - “簡単な計算式” と比較する
 - * よく使われるのは $n^{-\alpha} = 1/n^\alpha$ (α は何らかの値)
- $\frac{X_n}{1/n^\alpha} = N^\alpha X_n$ の確率分布が n を無限大にした時に、確率分布が発散も消失もしないのであれば、「 X_n は $n^{-\alpha}$ 以上のスピードで収束する」


3.15 収束速度: 推定値

- OLS (誤定式化) の推定値は τ には収束しない
 - β_D に収束する
- OLS (正しい定式化) の推定値は、 τ に収束する
 - 収束速度は、変数の数がそれほど多くないのであれば、事例数 $^{-1/2}$
- 残差回帰の推定値は、後述する条件のもとで、OLS(正しい定式化) と同じ速度で τ に収束する

3.16 数値例: 予測モデル

- $E[Y | X]$ を、「500/5000 事例のランダム抽出 + 推定」を 4 回繰り返す
 - OLS (誤定式化): $\beta_0 + \beta_1 X$
 - OLS (正しい定式化): $\beta_0 + \beta_1 \underbrace{I_{X \geq 0.5}}_{X \geq 0.5 \text{ ならば } 1, \text{ それ以外は } 0}$
 - 回帰木: 最大 4 分割


3.17 数値例: 予測モデル



3.18 収束速度: 予測モデル

- 条件付き母平均に対する平均二乗平方根誤差: $\sqrt{E[(E[Y | X] - \text{予測値})^2]}$
 - X について平均を取る
- OLS (誤定式化): 平均二乗平方根誤は 0 には収束しない
- OLS (正しい定式化): 0 に収束し、変数の数がそれほど多くないのであれば、収束速度は 事例数 $^{-1/2}$
- 回帰木: 0 に収束するが、OLS (正しい定式化) よりも収束速度が遅い
 - 機械学習の手法一般の特徴
 * 一つの妥協的目標は 事例数 $^{-1/4}$


3.19 収束速度: 予測モデル



3.20 収束速度: 分解

- $\tau - \hat{\tau}^{Oracle}$: OLS の推定誤差に起因する
 - 0 に収束し、収束速度は 事例数 $^{-1/2}$
- $\hat{\tau}^{Oracle} - \hat{\tau}$: 予測モデルの推定誤差に起因する
 - 予測モデルの収束速度が 事例数 $^{-1/4}$ よりも早いのであれば、OLS の推定誤差よりも早い速度で 0 に収束

3.21 数値例: 残差回帰の分解



3.22 まとめ

- 「予測モデルの一致性」が成り立つのであれば、事例数が増加すると、 $\tau - \hat{\tau}$ は0に収束する
 - 予測モデルの推定誤差に起因する誤差 ($\hat{\tau}^{Oracle} - \hat{\tau}$) は、平均値の推定誤差に起因する誤差 ($\tau - \hat{\tau}^{Oracle}$) よりも早い速度で、0に収束することが期待できる
 - (機械学習で推定した) 予測モデルそのものの収束速度は遅いにも関わらず!!!
 - 残差回帰が Neyman の直行条件を満たすため (次回)

4 残差回帰: 漸近分布の推定

4.1 漸近分布の推定

- 事例数がある程度大きくなると、推定値は推定目標に近づくだけでなく、確率分布に推定可能な”規則性”が生じる
 - 信頼区間計算に活用可能
 - 関連ワード: 漸近正規性、中心極限定理、サンドウィッチ推定、ブートストラップ、DML...

4.2 復習: OLS

- 事例数が十分大きくなると、
- OLS: $\sqrt{N}(\beta_D - \hat{\beta}_D)$ は平均 0 の正規分布で近似できる*3
 - $\beta_D = \tau$ ならば、 $\sqrt{N}(\beta_D - \hat{\beta}_D)$ も平均 0、分散 σ^2 の正規分布で近似できる
 - * $\beta_D - \hat{\beta}_D$ は $N(0, \sigma^2/N)$ で近似できる
 - 分散もブートストラップ/サンドウィッチ推定できる

4.3 復習: OLS

- 変数を「データに依存しないルールで変換」しても成り立つ
 - 例: $Y = \text{price} = \text{取引価格}/100 \text{ 万円}$

4.4 残差回帰

- 事例数が十分に大きくなると

$$\sqrt{N}(\tau - \hat{\tau}) = \underbrace{\sqrt{N}(\tau - \hat{\tau}^{Oracle})}_{\rightarrow \text{平均0の正規分布}} + \underbrace{\sqrt{N}(\tau^{Oracle} - \hat{\tau})}_{\rightarrow 0}$$

- ポイント
 - 予測モデルの推定誤差に起因する差は、早い速度で 0 に収束する

4.5 残差回帰

- $\hat{\tau}^{Oracle}$ は、 $\Delta_Y \sim \Delta_D$ の OLS 推定結果
 - Δ_Y, Δ_D は、母平均を用いた変換
 - * 母平均は「データに依存しない」
 - * 通常の OLS と同じ確率的性質をもつ
- 要点: 母平均は、変数の変換ルールと見做せる
 - $\delta_{Y_i} = Y_i/100 \text{ 万円}$: 既知かつ**確定**
 - $\Delta_Y = Y - E[Y | X]$: 未知だが**確定**

*3 中心極限定理

4.6 正式な命題^{*4}

- 主要な仮定: $\sqrt{E[(E[Y | X] - \hat{E}[Y | X])^2]}$ および $\sqrt{E[E[D | X] - \hat{E}[D | X])^2]}$ が、 $1/\text{事例数}^{1/4}$ 以上の速度で 0 に収束する
 - “高性能な” 機械学習アルゴリズムを使用する
- 性質: $N^{1/2} \times (\tau - \hat{\tau})$ は、平均 0 の正規分布に収束し、分散もブートストラップ/サンドウィッチ推定できる
 - 補助性質: $N^{1/2} \times (\tau - \hat{\tau})$ は、 $N^{1/2} \times (\tau - \hat{\tau}^{Oracle})$ に収束する

5 予告

5.1 一般化

- DML: 「機械学習による予測モデルを組み込んだ、平均値や OLS (モーメント) 推定」法
 - 理想の予測モデル (母平均) を組み込んだ、Oracle 推定値 $\hat{\tau}^{OLS}$ を定義できる

5.2 課題

- 推定誤差の分解:

$$\tau - \hat{\tau} = \underbrace{\tau - \hat{\tau}^{Oracle}}_{\text{モーメント推定に起因}} + \underbrace{\hat{\tau}^{Oracle} - \hat{\tau}}_{\text{予測モデル推定に起因}}$$

- 「予測モデル推定に起因」する誤差は扱いづらい
 - 機械学習の推定量は、収束が遅い、バイアス、中心極限定理が破綻

5.3 解決策

- 残差回帰のような Neyman の直行条件を満たすモーメント条件では、「交差推定された予測モデルの誤差に起因」する誤差は早い速度で 0 に収束
 - 十分な事例数があれば、“存在しない” ように扱うことができる
- “微分可能” なモーメント条件であれば、直行条件を満たすように書き換えられる

5.4 補論: 経済学の比喩

- DML の直感: 「機械学習の由来する複雑な推定誤差が、推定目標 τ の推定に与える影響を軽減する」

^{*4} Chernozhukov et al. (2018)

- 防災学/マクロ経済学: 災害や” 景気変動ショック” の影響が、増幅され、社会の重要な要素 (家計など) へ” 深刻に波及する” ことを食い止めたい
 - 根本となる災害や景気変動ショックそのものを、発生させないことを目指しているわけではない
 - * $\simeq$ 推定誤差が生じない機械学習の開発を目指すわけではない

Reference

- Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. 2018. “Double/Debiased Machine Learning for Treatment and Structural Parameters.” *The Econometrics Journal* 21 (1): C1–68.
- Engl, Chris, and PM Aronow. 2025. “Using LLMs to Directly Guess Conditional Expectations Can Improve Efficiency in Causal Estimation.” *arXiv Preprint arXiv:2510.09684*.
- Robinson, Peter M. 1988. “Root-n-Consistent Semiparametric Regression.” *Econometrica*, 931–54.