

DML: 一般化

経済学のための機械学習入門

川田恵介

2026-06-22

Table of contents

1	Get started: BLP	2
1.1	推定目標	2
1.2	データ	3
1.3	モデル推定	3
1.4	モデル推定	4
2	VS naive plug-in	4
2.1	2段階推定	4
2.2	2段階推定	5
2.3	例: 部分線型モデル	5
2.4	Naive plug-in	5
2.5	例	5
2.6	例	6
2.7	ポイント	6
2.8	数値例	6
2.9	数値例	6
2.10	分布	7
2.11	Naive plug-in の分解	7
2.12	推定量	8

2.13	オラクル推定量	9
2.14	分布: $\tau - \hat{\tau}^{Oracle}$	10
2.15	分布: $\hat{\tau}^{Oracle} - \hat{\tau}$	10
2.16	ポイント	11
3	Neyman の直交条件	11
3.1	概要	11
3.2	notation	11
3.3	推定量: Naive plug-in	11
3.4	推定量: 残差回帰	11
3.5	推定量	12
3.6	推定量	12
3.7	推定量	12
3.8	推定量	12
3.9	ポイント	12
3.10	ポイント	13
3.11	一般の手順	13
3.12	Neyman の直交条件の導出	13
4	応用: τ の BLP	13
4.1	推定目標	13
4.2	Neyman の直交条件を満たす定式化	13
4.3	推定方法	14
4.4	中心化の意味	14
	Reference	14

1 Get started: BLP

1.1 推定目標

- τ が X により変化することを許容; 推定目標は $\tau_0, \dots$

$$E[Y \mid D, X] = \underbrace{(\tau_0 + \tau_1 \times Z_1 + \dots)}_{\simeq \tau(X)} \times D + f(X)$$

1.2 データ

```
library(tidyverse)

data("fertil2", package = "wooldridge")

Y <- fertil2$children

D <- if_else(fertil2$educ >= 7, 1, 0)

X <- select(
  fertil2,
  yearborn,
  mnthborn,
  age,
  spirit,
  protest,
  catholic
)
```

1.3 モデル推定

```
model <- ddml::ddml_plm(
  y = Y,
  D = D,
  X = data.matrix(X),
  learners = list(
    list(fun = ddml::ols),
    list(fun = ddml::mdl_ranger)
  ),
  shortstack = TRUE,
  silent = TRUE,
  sample_folds = 2 # 分割数 (10 程度が推奨)
)
```

1.4 モデル推定

```
fertil2$res_Y <- model$ols_fit$model$y_r

fertil2$res_D <- model$ols_fit$model$D_r

estimatr::lm_robust(
  res_Y ~ res_D +
    res_D:scale(age) + res_D:scale(spirit) + res_D:scale(protest) + res_D:scale(catholic),
  fertil2)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.01570262	0.02225715	-0.7055091	4.805312e-01
res_D	-0.56693490	0.04781086	-11.8578694	6.045730e-32
res_D:scale(age)	-0.34295691	0.06216097	-5.5172390	3.643408e-08
res_D:scale(spirit)	0.08039359	0.05402389	1.4881117	1.367938e-01
res_D:scale(protest)	-0.02635157	0.06104537	-0.4316720	6.660012e-01
res_D:scale(catholic)	-0.03804466	0.05569552	-0.6830830	4.945907e-01

	CI Lower	CI Upper	DF
(Intercept)	-0.05933797	0.02793272	4355
res_D	-0.66066851	-0.47320129	4355
res_D:scale(age)	-0.46482404	-0.22108979	4355
res_D:scale(spirit)	-0.02552074	0.18630791	4355
res_D:scale(protest)	-0.14603156	0.09332841	4355
res_D:scale(catholic)	-0.14723621	0.07114689	4355

2 VS naive plug-in

2.1 2段階推定

- DML: 「機械学習により推定した予測モデルを、パラメタ推定という下流タスクに活用する」 2段階推定
 1. 機械学習による予測モデルの推定
 2. 予測モデルの予測値を組み込んだ平均値や OLS によるパラメタ推定

2.2 2段階推定

- 機械学習による予測モデルが一致性^{*1}を満たすのであれば
 - パラメタの推定値も一致性を満たす「2段階目の推定」は複数存在する
 - 良い「2段階目」を選ぶ必要がある

2.3 例: 部分線型モデル

- 以下の τ_D を推定;

$$E[Y \mid D, X] = \tau_D \times D + \underbrace{f(X)}_{E[Y \mid D=0, X]}$$

- 残差回帰は、一致性を満たす推定方法の例
 - 他には Naive plug-in

2.4 Naive plug-in

- $E[Y \mid D, X]$ を機械学習の手法で推定
- 各事例について、 $\hat{E}[Y \mid D = 1, X] - \hat{E}[Y \mid D = 0, X]$ を計算する
- 2 のデータ上の平均値を計算する

- 非推奨
 - 残差回帰のように信頼区間計算ができない

2.5 例

```
library(SuperLearner)

model_naive <- SuperLearner(
  Y = Y,
  X = mutate(X,D),
  SL.library = c("SL.lm","SL.ranger")
)

pred_Y1 <- predict(model_naive,mutate(X,D=1))$pred
```

^{*1} 無限大の事例数 + ランダム抽出データであれば、 $\hat{E}[Y \mid X] \rightarrow E[Y \mid X]$

```
pred_Y0 <- predict(model_naive,mutate(X,D=0))$pred
```

```
mean(pred_Y1) - mean(pred_Y0)
```

```
[1] -0.5342415
```

2.6 例

	yearborn	mnthborn	age	spirit	protest	catholic	pred_Y1	pred_Y0
1	64	5	24	0	0	0	1.160106	1.930725
2	56	1	32	0	0	0	2.985040	3.296628
3	58	7	30	1	0	0	2.500337	3.169215
4	45	11	42	0	0	0	3.460372	4.646008
5	45	5	43	0	1	0	3.802810	5.055833
6	52	8	36	0	0	0	3.418240	4.157306

2.7 ポイント

- パラメタの推論においては、以下の推定が重要
 - 事後的な点推定値
 - 推定誤差の事前分布
 - * 忘れられがちなので注意
- 機械学習を活用した Naive plug-in は、「推定誤差の事前分布」の推定が難しい

2.8 数値例


- 前回と同じ設定
- $E[Y \mid D, X] = D - 1$ if $X \geq 0.5$
 - $E[Y \mid D, X] = D$ if $X < 0.5$
- $f(D = 1 \mid X) = 0.95$ if $X \geq 0.5$
 - $f(D = 1 \mid X) = 0.05$ if $X < 0.5$
- $Y = E[Y \mid D, X] + \text{一様分布}(-2, 2)$

2.9 数値例

- 「500/2000 事例のデータ抽出して、推定する」を 100 回繰り返す

- Naive plug-in
- 残差回帰
- 予測モデル推定には回帰木を活用

2.10 分布




2.11 Naive plug-in の分解


- 残差回帰と同様に、Oracle 推定量を定義できる
- Oracle 推定量: $\hat{\tau}^{Oracle} = E[Y \mid D = 1, X] - E[Y \mid D = 0, X]$
- 推定誤差: $\tau - \hat{\tau}$

$$= \underbrace{\tau - \hat{\tau}^{Oracle}}_{\text{平均値の推定誤差に起因}} + \underbrace{\hat{\tau}^{Oracle} - \hat{\tau}}_{\text{機械学習による予測誤差に起因}}$$
- τ は一定なので、 $\tau - \hat{\tau}^{Oracle} = 0$


2.12 推定量




2.13 オラクル推定量



2.14 分布: $\tau - \hat{\tau}^{Oracle}$



2.15 分布: $\hat{\tau}^{Oracle} - \hat{\tau}$



2.16 ポイント

- Naive plug-in については、機械学習由来の推定誤差が残る
 - 推定しにくい (漸近正規性が成り立たない/収束が遅い等)
- 残差回帰については、機械学習由来の推定誤差は迅速に収束し、推定しやすい平均値や OLS に由来する誤差が残る

3 Neyman の直交条件

3.1 概要

- 「機械学習による予測モデルが一致性」を満たし、推定目標の定義式が「Neyman の直交条件を満たす」のであれば、機械学習の推定誤差の影響 $\hat{\tau}^{Oracle} - \hat{\tau}$ が 0 に収束する速度が上昇する
- 残差回帰は満たすが、Naive plug-in は満たさない

3.2 notation

- 予測モデルの推定誤差の影響を考えるために、母平均と予測モデルの乖離 $\hat{U}[Y | X]$ を定義する;

$$\hat{E}[Y | X] = E[Y | X] + \underbrace{\hat{U}[Y | X]}_{\hat{E}[Y|X] - E[Y|X]}$$

3.3 推定量: Naive plug-in

- $\hat{E}[Y | D = 1, X] - \hat{E}[Y | D = 0, X]$ の平均値
 $= E[Y | D = 1, X] + \hat{U}[Y | D = 1, X] - \hat{E}[Y | D = 0, X]$ の平均値
- $\hat{U}[Y | D = 1, x] = 0.5$ ならば、 $0.5 \times x$ の割合 だけズレる

3.4 推定量: 残差回帰

- $Y - \hat{E}[Y | X]$ を $D - \hat{E}[D | X]$ で回帰すると;

$$\begin{aligned} & \frac{(Y - \hat{E}[Y | X]) \times (D - \hat{E}[D | X]) \text{の平均}}{(D - \hat{E}[D | X])^2 \text{の平均}} \\ &= \frac{(Y - E[Y | X] - \hat{U}[Y | X])(D - \hat{E}[D | X]) \text{の平均}}{(D - \hat{E}[D | X])^2 \text{の平均}} \end{aligned}$$

3.5 推定量

- $\hat{U}[Y | X]$ に起因する誤差 =
$$\frac{\hat{U}[Y | X] \times (D - \hat{E}[D | X]) \text{の平均}}{(D - \hat{E}[D | X])^2 \text{の平均}}$$

3.6 推定量

- $\hat{U}[Y | 0.4] = 0.5$ ならば、ズレ幅 =
$$0.5 \times D - \hat{E}[D | 0.4] \text{の「X=0.4」における平均}$$
$$\times \frac{X = 0.4 \text{の割合}}{(D - \hat{E}[D | 0.4])^2 \text{の平均}}$$

3.7 推定量

- $\hat{U}[Y | 0.4] = 0.5$ ならば、ズレ幅 =
$$0.5 \times \underbrace{D \text{の「X=0.4」における平均} - \hat{E}[D | 0.4]}_{\substack{\rightarrow E[D|X=0.4] \rightarrow E[D|X=0.4] \\ \text{予測用/推定用データが増えれば、0に収束}}}$$
$$\times \frac{X = 0.4 \text{の割合}}{(D - \hat{E}[D | 0.4])^2 \text{の平均}}$$

3.8 推定量

- $\hat{U}[Y | 0.4] = 0.5$ ならば、ズレ幅 =
$$0.5 \times \underbrace{D \text{の「X=0.4」における平均} - \hat{E}[D | 0.4]}_{\substack{\text{予測用/推定用データが十分に大きければ、}<1 \\ <0.5}}$$
$$\times \frac{X = 0.4 \text{の割合}}{(D - \hat{E}[D | X])^2 \text{の平均}}$$

3.9 ポイント

- Neyman の直交条件を満たすのであれば、機械学習に起因する誤差が「0 に収束する項」との掛け算の形で現れる
 - 0 に向けて収束する項の掛け算は、一般に、個々よりも速い速度で収束する

3.10 ポイント

- 機械学習の予測モデルを交差推定することで、掛け算の項の収束速度をさらに早くできる
 - Neyman の直交条件を満たすのであれば、機械学習による予測が $N^{-1/4}$ 以上の速度で収束するのであれば、 $\hat{\tau}^{Oracle} - \hat{\tau}$ は $N^{-1/2}$ 以上の速度で 0 に収束する
 - 事例数が十分に大きければ、推定しにくい機械学習による推定誤差を”無視できる”

3.11 一般的手順

- 推定目標を母分布のモーメント条件として定義する
- Neyman の直交条件を満たすようにモーメント条件を書き直す
- 機械学習を用いて、nuisance 関数を推定する
- 予測モデルをモーメント条件に代入し、モーメント推定 (OLS や平均値の推定) を行う

3.12 Neyman の直交条件の導出

- nuisance 関数について微分可能な推定対象について、Neyman の直交条件を満たす定式化を解析的に導出できる
 - Fisher and Kennedy (2021) , Hines et al. (2022), Ichimura and Newey (2022) , Renson et al. (2025)
- データから「自動的に推定する方法」も提案されている (Williams, Hines, and Rudolph 2025)

4 応用: τ の BLP

4.1 推定目標

- τ が X により変化することを許容; 推定目標は $\tau_0, \dots$

$$E[Y \mid D, X] = \underbrace{(\tau_0 + \tau_1 \times Z_1 + \dots)}_{\simeq \tau(X)} \times D + f(X)$$

- Z は X の一部

4.2 Neyman の直交条件を満たす定式化

- 残差回帰を応用できる

$$Y - E[Y \mid X] \simeq (\tau_0 + \tau_1 \times Z_1 + \dots) \times (D - E[D \mid X])$$

4.3 推定方法

0. Z を中心化: $\mathbf{z} - \text{mean}(\mathbf{z})$ (必須ではないが、推奨)
1. $\hat{E}[Y | X]$ と $\hat{E}[D | X]$ を機械学習で交差推定
2. $Y - \hat{E}[Y | X]$ を、 $D - \hat{E}[D | X]$ と Z との交差項 $Z \times (D - \hat{E}[D | X])$ で回帰

4.4 中心化の意味

- $\tau \simeq (\tau_0 + \tau_1 \times Z_1 + \dots)$ は、予測モデルではなく「差の異質性」を捉える記述モデル
 - 各パラメタを「人間が把握したい」
- Z を中心化しないと、 $\tau_0 =$ すべての Z が”0”であった時の近似値
 - 一般に解釈不能
- Z を中心化すると、 $\tau_0 =$ すべての Z が平均値であった時の近似値
 - 解釈がより容易

Reference

- Fisher, Aaron, and Edward H Kennedy. 2021. “Visually Communicating and Teaching Intuition for Influence Functions.” *The American Statistician* 75 (2): 162–72.
- Hines, Oliver, Oliver Dukes, Karla Diaz-Ordaz, and Stijn Vansteelandt. 2022. “Demystifying Statistical Learning Based on Efficient Influence Functions.” *The American Statistician* 76 (3): 292–304.
- Ichimura, Hidehiko, and Whitney K Newey. 2022. “The Influence Function of Semiparametric Estimators.” *Quantitative Economics* 13 (1): 29–61.
- Renson, Audrey, Lina Montoya, Dana E Goin, Iván Díaz, and Rachael K Ross. 2025. “Pulling Back the Curtain: The Road from Statistical Estimand to Machine-Learning-Based Estimator for Epidemiologists (No Wizard Required).” *American Journal of Epidemiology* 194 (12): 3566–71.
- Williams, Nicholas T, Oliver J Hines, and Kara E Rudolph. 2025. “Riesz Representers for the Rest of Us.” *arXiv Preprint arXiv:2507.19413*.