

R-learner

経済学のための機械学習入門

川田恵介

2026-06-29

Table of contents

1	Get started: Causal Forest	2
1.1	実例: Causal Forest	2
1.2	実例: $E[Y \mid D = 1, X] - E[Y \mid D = 0, X]$	3
1.3	Causal Forest	4
2	準備: 定義 VS 仮定	4
2.1	整理	4
2.2	定義と仮定の区別	5
2.3	定義と仮定の区別	5
2.4	推定目標の定義	5
2.5	母分布への仮定	5
2.6	練習問題	5
2.7	練習問題: 回帰木	6
3	セミパラメトリック推定	6
3.1	定義	6
3.2	例: 母平均の推定	6
3.3	代用による推定	7
3.4	OLS	7
3.5	セミパラメトリック推定の利点	7

3.6	悪例	7
4	Neyman 直行条件	8
4.1	残差回帰の推定目標	8
4.2	置き換えによる推定	8
4.3	Neyman の直行条件	8
4.4	単純な例	8
4.5	単純な例	8
4.6	Neyman 直行性を満たさない例	9
4.7	注意	9
5	R-learner	9
5.1	機械学習	9
5.2	R-learner の推定目標	9
5.3	R-learner の推定目標	10
5.4	推定方法	10
5.5	機械学習の活用	10
5.6	次回	10
6	補論: renv	10
6.1	動機	10
6.2	初期状態	11
6.3	独立化	12
6.4	renv 環境	13
6.5	手順	13
	Reference	14

1 Get started: Causal Forest

1.1 実例: Causal Forest

```

set.seed(100)

library(tidyverse)

data("fertil2", package = "wooldridge")

Y <- fertil2$children

D <- if_else(fertil2$educ >= 7, 1, 0)

X <- select(
  fertil2,
  yearborn,
  mnthborn,
  age,
  spirit,
  protest,
  catholic
)

model <- grf::causal_forest(
  Y = Y,
  X = X,
  W = D)


```

1.2 実例: $E[Y \mid D = 1, X] - E[Y \mid D = 0, X]$

```

hist(model$predictions)

```



1.3 Causal Forest

- DML のシンプルな拡張である R-learner の一種
 - M 推定 (Empirical risk minimization) の考え方に慣れる必要がある
 - OLS や DML などのパラメタ推定や機械学習による予測モデルの推定を統合的に理解できる枠組み
- Point: 推定目標の**定義の仕方**に、複数の形式がある

2 準備: 定義 VS 仮定

2.1 整理

- 統計的手法は、以下のように整理できる

推定方法	母分布への仮定	推定目標
ノンパラ ^{*1}	ノンパラ	ノンパラ
セミパラ ^{*2}	ノンパラ	パラメトリック
パラメトリック ^{*3}	パラメトリック	パラメトリック

^{*1} カーネル回帰、Random Forest、**Causal Forest**

^{*2} **DML**

^{*3} 伝統的な最尤法/ベイズ

推定方法	母分布への仮定	推定目標
------	---------	------

2.2 定義と仮定の区別

- 母分布への仮定: もし母分布が観察できたとすると、真偽判定ができる
 - 仮定 $E[Y | X] = \beta_0 + \beta_1 \times X$ (Y の平均値と X は一直線) は、真偽判定可能
 - * 日常的な例: 日本社会を理解するには、香川県を理解すれば十分だ

2.3 定義と仮定の区別

- 推定目標の定義: 「関心となる母分布の特徴」の宣言であり、真偽の判定が不可能
 - 「 $E[Y | X]$ を $\beta_0 + \beta_1 \times X$ に落とし込んで、 Y と X の関係性を把握したい」が嘘とは?
 - * 日常的な例: 日本社会の中でも、特に香川県に関心がある ^{*4}

2.4 推定目標の定義

- 推定目標 = 一般に母分布の特徴
 - パラメトリック: 母分布から計算される有限個のパラメタ
 - * 母平均など (把握に有効)
 - ノンパラ: 母分布から計算される一般形の関数
 - * $E[Y | X]$ など (予測に有効)

2.5 母分布への仮定

- 推定の根拠
 - パラメトリック: 母分布を有限個のパラメタからなる関数で表現できる
 - * $f(Y | X) = N(\beta_0 + \beta_1 \times X, \sigma^2)$ ^{*5}
 - ノンパラ: 母分布の性質についての仮定
 - * 連続性など

2.6 練習問題


- 「母集団において計算した OLS や平均値の点推定値を、データ上の OLS や平均値とする」は何推定?

^{*4} 有用性や重要性など、母分布以外の視座からの評価は可能であり、推定目標の重要性をしっかりと議論することが重要

^{*5} 古典的線形モデル

2.7 練習問題: 回帰木

- X が連続変数の場合、回帰木の推定目標はパラメトリック?



3 セミパラメトリック推定

3.1 定義

- 母分布についてのパラメトリックな仮定を設定せずに、母分布から定義される推定目標 (Parameter of interest)^[パラメタ = 母分布の汎関数] を推定する (Kennedy 2024)
 - Z 推定 (モーメント推定の一般化) や M 推定など、密接な関係性のある複数の定式化がある
 - * 推定目標の定義の仕方が異なる

3.2 例: 母平均の推定

- 推定目標 = Y の母平均 β_0
- 複数の”表現”がある
 - $\beta = E[Y]$
 - $0 = E[Y - \beta_0]$ (Z 推定)

- $\min_{\beta_0} E[(\beta_0 - Y)^2]$ (M 推定^{*6})
- 注意 $E[Y] = (Y) \times (Y \text{ の母分布})$ の総和^{*7}

3.3 代用による推定^{*8}

- 母分布をデータ上の分布に置き換えて推定
- $0 = E[Y - \beta_0]$ を、データ上の平均値に置き換える^{*9}
- $\min_{\beta_0} E[(\beta_0 - Y)^2]$ と同じ最適化問題を、データ上で行う^{*10}

3.4 OLS

- $E[Y | D] \simeq \beta \times D$ の推定目標とする; 厳密には
 - $\min_{\beta} E[(\beta \times D - Y)^2]$
 - 一階条件から、 $0 = E[D \times (\beta \times D - Y)]$
- 代用による推定: データ上の分布に置き換える
 - 骨子「母集団上での問題を、データ上で解く」は同じ

3.5 セミパラメトリック推定の利点

- 推定目標の定義と仮定を、明確に分離できる
- 「明確に定義した目標を、極力少ない仮定で推定する」という研究戦略と相性が良い

3.6 悪例

- 「 $E[Y | X] = \beta_0 + \beta_1 \times X_1 + \dots$ を仮定し、推定し、結果を事後解釈する」
 - 「真実は人間が理解できる程度に単純」でない限り、無理がある
- 本講義では非推奨
 - そもそも何を知りたいの?
 - 仮定を満たすためには、複雑なモデルを推定する必要があり、結果が解釈しにくい
 - 結果について、因果的/経済学的/規範的解釈の根拠は?

^{*6} Zero-estimation, Maximum/Minimum estimation

^{*7} $E[Y] = \int Y \times f(Y) dY$

^{*8} 一般に plug-in 原理、アナログ原理と呼ばれる。

^{*9} $\hat{f}(Y)$ をデータ上の分布とすると、 $0 = \sum (Y - \beta_0) \times \hat{f}(Y)$ を解く

^{*10} $\sum (Y - \beta_0) \times \hat{f}(Y)$ を最小化する β を探す

4 Neyman 直行条件

4.1 残差回帰の推定目標

- $\min_{\tau} L = E[(Y - E[Y | X] - \tau \times (D - E[D | X]))^2]$
- 一階条件は、

$$0 = \frac{\partial L}{\partial \tau}$$

- 一階条件を満たすように τ を決める

4.2 置き換えによる推定

- L をデータ上で最小化することは不可能
 - $E[Y | X], E[D | X]$ も置き換える必要がある
 - * 機械学習の予測値で代用
 - ・ 予測値と母平均の乖離も、本来は考慮する必要がある

4.3 Neyman の直行条件

- $\frac{\partial L}{\partial \tau}$ を $E[Y | X]$ や $E[D | X]$ で関数微分した値が 0
 - 予測値と母平均が微細に乖離しても、 τ を決める一階条件は影響を受けない
- 含意: 事例数が大きく、 L に類似する関数を最小化している状況では、予測値の推定誤差は無視して良い

4.4 単純な例

- 推定目標:

$$\min_{\tau} L = E[(Y - \underbrace{\bar{Y}}_{E[Y]; \text{nuisance}} - \tau \times (D - \underbrace{\bar{D}}_{E[D]; \text{nuisance}}))^2]$$

- 一階条件:

$$0 = \frac{\partial L}{\partial \tau} = E[(D - \bar{D}) \times (Y - \bar{Y} - \tau \times (D - \bar{D}))]$$

4.5 単純な例

- 交差微分:

$$\frac{\partial^2 L}{\partial \tau \partial \bar{Y}} = -E[(D - \bar{D})] = 0$$

- Neyman 直行性を満たす ($\bar{D}$ についても同様)

4.6 Neyman 直行性を満たさない例

- 推定目標:

$$\min_{\tau} L = E[(Y - \bar{Y} - \tau \times D)^2]$$

- $\partial^2 L / \partial \tau \partial \bar{Y} = -E[D] \neq 0$

4.7 注意

- 単純な平均値については、データの平均値で置き換えることで簡単に推定できる
 - 収束速度が速いので、Neyman 直行性は重要ではない
 - * 単純な例は単なる例
 - 機械学習のような収束速度が遅い推定結果で置き換えたい場合に、Neyman 直行性は重要

5 R-learner

5.1 機械学習

- 推定目標の別解釈: $\min_{\tau(X)} L = E[(Y - \tau(X))^2]$
 - $\tau(X)$ をパラメトリックに定式化 ($\tau(X) \simeq \beta_0 + \beta_1 X_1 + \dots$) するのであれば、データ上で同じ最適化問題を解けば良い
 - $\tau(X)$ を非常に複雑/ノンパラに定式化するのであれば、過剰適合し、データ上での解と母集団での解は大きく乖離する
 - * LASSO/Random Forest 等の機械学習の活用

5.2 R-learner の推定目標

- $\min_{\tau(X)} L = E[(Y - E[Y | X] - \tau(X) \times (D - E[D | X]))^2]$ ^{*11}
 - 前回: $\tau(X)$ をパラメトリックに定式化 ($\tau(X) \simeq \beta_0 + \beta_1 X_1 + \dots$)
 - 本日: パラメトリックに定式化しない

^{*11} Nie and Wager (2021)

5.3 R-learner の推定目標

- 関数微分を用いて、Neyman 直行性を満たすことが確認できる

$$\begin{aligned} 0 &= \frac{\partial^2 L}{\partial \tau(X) \partial E[Y | X]} \\ &= \frac{\partial^2 L}{\partial \tau(X) \partial E[D | X]} \end{aligned}$$

5.4 推定方法

- $E[Y | X], E[D | X]$ を交差推定した予測値で置き換え
- $\tau(X)$ がパラメトリックに定式化 (事例数に比べて、十分に少ないパラメタによって定式化) するのであれば、以下を $\tau(X)$ について最適化

$$\begin{aligned} &(Y - \hat{E}[Y | X] - \tau(X) \times (D - \hat{E}[D | X]))^2 \\ &\text{のデータ上の平均} \end{aligned}$$

5.5 機械学習の活用

- $\tau(X)$ をパラメトリックに定式化しないのであれば、過剰適合が発生する
 - $\tau(X)$ についての、母集団上とデータ上での最適化が大きく乖離する
 - 過剰適合への対応は機械学習の得意分野!!!
 - Causal Forest は Random Forest を用いて $\tau(X)$ を推定

5.6 次回

- $\tau(X)$ のノンパラメトリック推定における Neyman 直行性の役割は?
- 他の推定手法は?
- どのように活用できる?


6 補論: renv

6.1 動機

- 「分析の再現性」は重要な課題


- 全米経済学会の policy
- LLM による自動チェック (Kohler et al. 2026; Kubota et al. 2026)
- 再現を不可能にする要因の一つは、R や package のバージョン違い
 - 同じコードとデータを、異なるバージョンで計算した場合、結果が異なる場合がある
- とりあえず [renv](#) の利用を推奨

6.2 初期状態




- 問題点: どれかの分析で package のバージョンを更新すると、全てのプロジェクトが影響を受ける

6.3 独立化



- 問題点: パッケージを重複してインストール必要があり、いろいろ無駄

6.4 renv 環境



6.5 手順

1. `renv::init()` でセットアップ

- いろんな設定や起動を自動化してくれる

2. 必要に応じて、`renv::install()` で新しいパッケージをインストール
3. 分析がひと段落したら `renv::snapshot()` で、作業環境 (バージョン) を lockfile として保存
4. 再現者にコードと lockfile を共有

Reference

- Kennedy, Edward H. 2024. “Semiparametric Doubly Robust Targeted Double Machine Learning: A Review.” *Handbook of Statistical Methods for Precision Medicine*, 207–36.
- Kohler, Benjamin, David Zollikofer, Johanna Einsiedler, Alexander Hoyle, and Elliott Ash. 2026. “Read the Paper, Write the Code: Agentic Reproduction of Social-Science Results.” *arXiv Preprint arXiv:2604.21965*.
- Kubota, So, Hiromu Yakura, Sho Yamada, Yuki Nakamura, Tobias Werner, and Samuel Coavoux. 2026. “LLM-Assisted Replication as Scientific Infrastructure.” *Open Science Framework*.
- Nie, Xinkun, and Stefan Wager. 2021. “Quasi-Oracle Estimation of Heterogeneous Treatment Effects.” *Biometrika* 108 (2): 299–319.