

異質性分析への活用

川田恵介

Table of contents

1	Get started	2
1.1	データ	2
1.2	Causal forest	3
1.3	予測値による Group 分け	3
1.4	GATE	3
1.5	CLAN	4
2	$\tau(X)$ の応用	5
2.1	下流タスク	5
2.2	異質性分析における $\tau(X)$ の問題点	5
2.3	$\tau(X)$ の特徴把握	5
2.4	GATE の推定	5
2.5	例	5
2.6	例	7
2.7	注: Causal Forest の特性	7
2.8	BLP との比較	7
2.9	比喩	7
2.10	比喩: BLP	8
2.11	比喩: GATE	8
2.12	個人的な経験	8

3	補論: $\tau(X)$ の他の推定方法	9
3.1	ここまでの整理	9
3.2	2 値変数 $D = \{0, 1\}$ のケース	9
3.3	平均差	9
3.4	平均差	9
3.5	例	10
3.6	ATE の推定方法: AIPW	10
3.7	ATE の推定方法	10
3.8	BLP	10
3.9	他のウェイト	11
3.10	推定目標の選択	11
3.11	推定目標の選択	11
3.12	注意	11
4	補論: $\tau(X)$ のノンパラ推定のバリエーション	12
4.1	一般的な手順	12
4.2	R-learner	12
4.3	目的関数の設定	12
4.4	T learners	12
4.5	Neyman 直行性の役割	13
4.6	Neyman 直行性の役割	13
4.7	モデル集計	13
	Reference	13

1 Get started

1.1 データ

```
set.seed(100)

library(tidyverse)
```

```

data("fertil2", package = "wooldridge")

Y <- fertil2$children

D <- if_else(fertil2$educ >= 7,1,0)

X <- select(
  fertil2,
  yearborn,
  mnthborn,
  age,
  spirit,
  protest,
  catholic
)

```

1.2 Causal forest

```

model <- grf::causal_forest(
  Y = Y,
  X = X,
  W = D
)

```

1.3 予測値による Group 分け

```

X$prediction <- as.numeric(model$predictions) # Leave-One-Out が実行され、事実上の交差推定となる

X$group <- ntile(X$prediction,n=2) # グループ分け

```

1.4 GATE

Characteristic	1 N = 2,181 ¹	2 N = 2,180 ¹
yearborn	55 (49, 60)	68 (65, 70)
mnthborn	7 (4, 9)	6 (3, 9)
age	33 (28, 38)	20 (18, 23)
spirit	853 (39%)	988 (45%)
protest	536 (25%)	457 (21%)
catholic	241 (11%)	206 (9.4%)
prediction	-0.77 (-1.02, -0.60)	-0.20 (-0.28, -0.14)

¹Median (Q1, Q3); n (%)

```
grf::average_treatment_effect(
  model,
  subset = X$group == 1
)
```

```
estimate    std.err
-0.8134330  0.0881838
```

```
grf::average_treatment_effect(
  model,
  subset = X$group == 2
)
```

```
estimate    std.err
-0.2585864  0.0490236
```

1.5 CLAN

```
gtsummary::tbl_summary(
  X,
  by = group
)
```

2 $\tau(X)$ の応用

2.1 下流タスク

- R-learners などで推定された $\hat{\tau}(X)$ は非常に複雑な関数であり、人間による把握は難しい
 - どう使う？

1. 個人効果の予測 (次回、因果効果の復習ともに紹介)
2. 異質性分析への活用 (本日)

2.2 異質性分析における $\tau(X)$ の問題点

- そのままでは把握できない
- 信頼区間等の統計的推論が難しい
 - Causal forest は例外的に可能 (Sparsity の仮定が必要)

2.3 $\tau(X)$ の特徴把握

- BLP (slide10): $\tau(X) \simeq \beta_0 + \beta_1 Z_1 + \dots$ と近似し、その特徴を推定/推論
- GATE (本日): 推定値 $\hat{\tau}(X)$ に基づいて、サブグループ分析を行う
 - Chernozhukov et al. (2025) , Athey and Wager (2019) に基づく議論を紹介

2.4 GATE の推定

1. データを 2 分割 (main/auxiliary)
2. auxiliary のみを用いて、 $\tau(X)$ の予測モデルを推定 (Causal forest など)
3. main に適用し、推定値 $\hat{\tau}(X)$ を算出
4. $\hat{\tau}(X)$ を用いて”ソート”し、等分 (5 分割など)
5. サブグループ内で平均差を推定

2.5 例

```
data("fertil2", package = "wooldridge")
```

```

split <- rsample::initial_split(fertil2,prop = 499/500)

Y <- rsample::training(split)$children

D <- if_else(rsample::training(split)$educ >= 7,1,0)

X <- select(
  rsample::training(split),
  yearborn,
  mnthborn,
  age,
  spirit,
  protest,
  catholic
)

Y_test <- rsample::testing(split)$children

D_test <- if_else(rsample::testing(split)$educ >= 7,1,0)

X_test <- select(
  rsample::testing(split),
  yearborn,
  mnthborn,
  age,
  spirit,
  protest,
  catholic
)

model <- grf::causal_forest(
  Y = Y,
  X = X,
  W = D
)

```

2.6 例

```
X_test$pred_tau <- predict(model,X_test)$predictions  
  
arrange(X_test,pred_tau)
```

	yearborn	mnthborn	age	spirit	protest	catholic	pred_tau
1	55	9	33	0	0	0	-1.25994947
2	52	2	36	0	0	0	-0.62371596
3	57	5	31	0	0	1	-0.62104760
4	48	7	40	1	0	0	-0.60442125
5	42	5	46	1	0	0	-0.50070800
6	60	12	27	1	0	0	-0.30842993
7	65	1	23	1	0	0	-0.16174142
8	73	3	15	0	0	1	-0.12495066
9	72	8	16	1	0	0	-0.06292938

2.7 注: Causal Forest の特性

- Causal (Random) Forest は、サブサンプリングによって、モデル平均を行う
 - ある事例について、その事例を使っていない回帰木のみを平均し、予測値を計算することが可能
 - Leave-one-out

2.8 BLP との比較

- BLP: 個々の X と $\tau(X)$ を線形”記述”モデル化する
- GATE: X の複雑なモデルの出力でサブグループ化する
 - 各サブグループについて、平均差や記述統計量を計算することで、差が大きい/小さいグループの特徴を捉えられる

2.9 比喻

- $\tau(X)$ ではなく、 Y の把握であれば、伝統的な論点
- `child` と X の関係性を把握するために
 - BLP: $child \simeq \beta_0 + \beta_1 X_1 + \dots$ を推定

- GATE: *child* = 0, 1, 2 などサブグループを作り、サブグループごとに *X* の記述統計を確認
 - * *child* の予測値でのサブグループ分けも可能

2.10 比喩: BLP

```
estimatr::lm_robust(children ~ age + educ, fertil2)
```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower
(Intercept)	-1.99674983	0.094675271	-21.09051	4.230638e-94	-2.1823615
age	0.17483062	0.003430657	50.96127	0.000000e+00	0.1681048
educ	-0.08993971	0.006137119	-14.65504	1.661116e-47	-0.1019716

	CI Upper	DF
(Intercept)	-1.81113816	4358
age	0.18155645	4358
educ	-0.07790783	4358

2.11 比喩: GATE

```
fertil2 |>
  select(children,age,educ) |>
  mutate(
    children = if_else(
      children >= 4,
      4,
      children
    )
  ) |>
  gtsummary::tbl_summary(
    by = children
  )
```

2.12 個人的な経験

- BLP よりも、GATE の方が、誤解なく伝えやすい
 - 多重共線性や高次の交差項の捨象など、線形記述モデルの繊細さに由来する誤解が生まれにくい

Characteristic	0 N = 1,132 ^I	1 N = 907 ^I	2 N = 696 ^I	3 N = 528 ^I	4 N = 1,098 ^I
age	18 (16, 21)	22 (20, 26)	26 (24, 30)	30 (26, 34)	36 (32, 41)
educ	7 (6, 9)	7 (6, 10)	7 (4, 10)	6 (0, 7)	3 (0, 6)

^IMedian (Q1, Q3)

- 右辺が左辺を”決定する”と誤読する読者が一定する存在する
- GATE も区切り方の決め方など、恣意性は混入しうることに注意

3 補論: $\tau(X)$ の他の推定方法

3.1 ここまでの整理

- 推定目標: 以下の母集団における最適化問題の解として定義される $\tau(X)$

$$\min E[(Y - E[Y | X] - \tau(X) \times (D - E[D | X]))^2]$$

- $\tau(X)$ の定式化 (推定目標の定義) が異なる
 - $\tau(X) \simeq$ パラメトリックな関数 ($\beta_0, \beta_0 + \beta_1 X_1 + \dots$),
 - $\tau(X) \simeq$ ノンパラな関数

3.2 2値変数 $D = \{0, 1\}$ のケース

- $\tau(X) = E[Y | D = 1, X] - E[Y | D = 0, X]$
 - 有力な代替的な方法がある
 - * 推定目標が異なる場合が多い点に注意

3.3 平均差

- 推定目標: $\tau(X)$ の母平均

$$\tau = \int \tau(X) \times \underbrace{\omega(X)}_{\text{ウェイト}} dX$$

3.4 平均差

- **ATE^{*1}**: $\omega(X) = X$ の母分布 $f(X)$

^{*1} Average “Treatment” Effect

- 残差回帰: $\omega(X) = \text{Overlap weight}$

$$\frac{E[D|X] \times (1 - E[D|X]) \times f(X)}{\int E[D|X] \times (1 - E[D|X]) \times f(X) dX}$$

3.5 例

X	$\tau(X)$	$f(X)$	$E[D X]$
A	20	0.5	0.1
B	30	0.5	0.5

- ATE の推定目標 $= 0.5 \times 20 + 0.5 \times 30 = 25$
- 残差回帰の推定目標 $\simeq 0.26 \times 20 + 0.74 \times 30 = 27.4$
 - D のばらつきが大きい (オーバーラップしている) グループを重視

3.6 ATE の推定方法: AIPW^{*2}

- Neyman 直行性を満たす推定目標^{*3}: 以下の母平均

$$\begin{aligned} \phi(Y, D, X) &= E[Y | D = 1, X] - E[Y | D = 0, X] \\ &\quad + \frac{D(Y - E[Y | D = 1, X])}{f(D = 1 | X)} \\ &\quad - \frac{(1 - D)(Y - E[Y | D = 0, X])}{f(D = 0 | X)} \end{aligned}$$

3.7 ATE の推定方法

1. $E[Y | D, X], f(D | X)$ を機械学習で交差推定
2. ϕ の定義式に代入し、データ上で平均値を計算
3. 信頼区間を導出

- Neyman 直行性を満たすので、十分な事例数があれば、機械学習の推定誤差を無視して計算できる

3.8 BLP

- $\tau(X) \simeq \beta_0 + \beta_1 Z_1 + \dots$ を AIPW で推定できる

^{*2} Augmented Inverse Probability Weighting

^{*3} IPW などにも有名だが、Neyman 直行性を満たさない

- 母集団上で以下が成り立つ

$$E[\tau(X) | Z] = E[\phi | Z] \simeq \beta_0 + \beta_1 Z_1 + \dots$$

- 2. 以降を、OLS で行えば OK

3.9 他のウェイト

- $ATT = \int \tau(X) \times f(X | D = 1) dX$
- $ATC = \int \tau(X) \times f(X | D = 0) dX$
- それぞれ Average Treatment Effect on Treated/Controls

3.10 推定目標の選択

- 残差回帰と AIPW は、実装が簡単であり、Neyman 直行性を満たす
 - 解釈や最終的な推定精度には大きな違いが発生しうる
- AIPW の方が、ウェイトの解釈が直感的
 - $f(D = 1 | X)$ が 0 や 1 となる集団が存在する場合、AIPW は”母集団でも”算出できない(定義式の分母が 0 になってしまう)*4
 - 0 や 1 に近い集団が存在する場合、推定はできるが、推定精度が大きく悪化する

3.11 推定目標の選択

- $f(D = 1 | X)$ が 0 または 1 に近いの**どちらかのみ**の存在が問題であれば、ATT や ATC が有力
- **どちらも**存在する場合、残差回帰が(妥協的に)有力
 - ウェイトの解釈が難しくなることに注意

3.12 注意

- Neyman 直行性は、機械学習の推定誤差を漸近的に無視できることを保証する
- 2 段階目の推定 (ϕ の母平均をデータ上の平均で置き換えて推定する) の精度は、 ϕ の分散に依存する
 - $f(D = 1 | X)$ が 0 や 1 に近い場合、 ϕ の分散が無限大に大きくなる
 - 機械学習の推定誤差が無視できたとしても、最終的な推定誤差が大きくなる

*4 overlap の仮定が満たされていない

4 補論: $\tau(X)$ のノンパラ推定のバリエーション

4.1 一般的な手順

1. $E[Y | X]$ などの nuisance を機械学習で推定
 2. nuisance を埋め込んだ何らかの最適化問題の解として、 $\tau(X)$ を推定
- どのような目的関数 (R/X/DR/S learners 等) を最適化するか?
 - どのように (causal forest/LASSO 等) 最適化するか?

4.2 R-learner

- 目的関数についての定義: 以下を最小化する

$$\min E[(Y - \hat{E}[Y | X]) - \tau(X) \times (D - \hat{E}[D | X])^2]$$

- 最適化の方法として、Random Forest (Causal Forest) 以外も有力な選択肢

4.3 目的関数の設定

- D が 0/1 変数であれば、R-learner 以外の目的関数が存在
 - T/X/DR learners^{*5}

4.4 T learners

- T-learner: $\tau(X) = E[Y | D = 1, X] - E[Y | D = 0, X]$ なので
1. $E[Y | D = 1, X], E[Y | D = 0, X]$ を機械学習などで推定
 2. $\hat{\tau}(X) = \hat{E}[Y | D = 1, X] - \hat{E}[Y | D = 0, X]$
- X の一部 Z で予測したいのであれば、以下を解を近似できる問題をデータ上で解く

$$\min E[(\hat{E}[Y | D = 1, X] - \hat{E}[Y | D = 0, X] - \tau(Z))^2]$$

^{*5} CausalML 15 章参照

4.5 Neyman 直行性の役割

- R-learner における Neyman 直行性の恩恵
- 事例数が十分に大きくなると、以下の最適化問題の解が一致する

$$\min E[(Y - E[Y | X]) - \tau(X) \times (D - E[D | X])^2]$$

$$\min E[(Y - \hat{E}[Y | X]) - \tau(X) \times (D - \hat{E}[D | X])^2]$$

- 本当の母平均を用いた場合と、同じような予測モデルが推定できる

4.6 Neyman 直行性の役割

- T は、Neyman 直行性を満たさない
 - $\tau(X), E[Y | D, X]$ による交差微分が 0 にならない
- パラメタの推定 (DML) ほど、大きな問題ではない
 - $\tau(X)$ のノンパラメトリックな推定では信頼区間計算が Oracle 推定でも難しいため
- 母集団の性質によっては、T-learner の方が推定精度は高くなり得る

4.7 モデル集計

- $\tau(X)$ の推定については、大量のバリエーションが存在:
 - $\tau(X)$ の定義式 (R/X/T/S/DR learners...) × 機械学習のアルゴリズム (OLS/LASSO/Random Forest...)
- $\tau(X)$ の大量の推定結果を集計することが有力
 - Q-aggregation (Lan and Syrgkanis 2024)

Reference

- Athey, Susan, and Stefan Wager. 2019. “Estimating Treatment Effects with Causal Forests: An Application.” *Observational Studies* 5 (2): 37–51.
- Chernozhukov, Victor, Mert Demirer, Esther Duflo, and Iván Fernández-Val. 2025. “Fisher–Schultz Lecture: Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments, with an Application to Immunization in India.” *Econometrica* 93 (4): 1121–64.
- Lan, Hui, and Vasilis Syrgkanis. 2024. “Causal q-Aggregation for Cate Model Selection.” In *International Conference on Artificial Intelligence and Statistics*, 4366–74. PMLR.