

AIPW 推定

Semiparametric 推定への応用

川田恵介

Table of contents

AIPW	2
Get Start: AIPW	2
Summary	2
frequency weight への動機づけ	3
結果: $N = 10000$	3
なぜグループ間で差が異なるのか?	3
可能性 1	4
可能性 2	4
可能性 3	4
整理	5
Estimation	5
Plugin	5
IPW	5
AIPW	6
AIPW の性質	6
Overlap 問題	6
Overlap の仮定: Identification	7
Overlap の重要性: Estimation	7
Oracle 推定への影響	7
数値例	8
まとめ	8
注意: Overlap 問題の普遍性	8
注意: Overlap 問題の普遍性	8
対応	9
Research question の修正	9

Moving goal posts	9
Variance weight	9
Propensity score weight	9
グループサイズの不均衡への対応	10
ATET	10
まとめ	10
Reference	11

AIPW

- Partialling out は、variance weight を用いた estimand を推定
 - しばしば解釈が困難
- D がカテゴリカル (density が推定可能) であれば、frequency weight を使った estimand も推定可能
 - 有力な代替案: AIPW (Robins and Rotnitzky 1995)

Get Start: AIPW

1. $E[Y|D = d, X] = g_{Y(d)}(X), E[D|X] = g_D(X)$ を教師付き学習などを用いて推定
2. S_i^{AIPW} の母平均を推定、ただし

$$S_i^{AIPW} = g_{Y(1)}(X_i) - g_{Y(0)}(X_i) + \frac{D_i(Y_i - g_{Y(1)}(X_i))}{g_D(X_i)} - \frac{(1 - D_i)(Y_i - g_{Y(0)}(X_i))}{1 - g_D(X_i)}$$

Summary

- AIPW と Partialling out では、Estimand が異なることに注意


$$\tau = \int \omega_P(x) \times \tau_P(x) dx$$

- AIPW: $\omega_P(x) = f_P(x)$ (frequency weight)
- Partialling out: $\omega_P(x) = f_P(x) \times \text{var}_P(D_i|x)$ (variance weight)

frequency weight への動機づけ

- しばしば決定的に異なる: 例えば、Sub group 分析
- $\int E_P[Y|D=1, X] - E_P[Y|D=0, X, Z] \times \omega_P(X) dX$ を、 $Z = \{0, 1\}$ ごとに比較したい
 - Y : 賃金、 D : 高卒/大卒、 X : 東京出身 = 1 / その他 = 0、 Z : 1984 年生まれ = 1 / 1960 年生まれ = 0
 - 1984 年と 1960 年で、出身地をコントロールした上での、大卒・高卒間賃金格差を比較したい

結果: $N = 10000$



- $Z = 1$ (1984 年生まれ) の方が学歴間賃金格差が小さい

なぜグループ間で差が異なるのか?

- 可能性 1: X が同じであったとしても、 $Z = 1$ の方が平均差が小さい (学歴間賃金格差が減った)
- 可能性 2: 差が小さい X の割合が多い (賃金格差が大きい地域で人口が減った)
- 可能性 3: 差が大きい X について、 D の分散が大きい (?)
 - Variance weight を使って集計しているため

可能性 1

```
# A tibble: 4 x 5
  `Tau(X,Z)`      Z      X `f(X,Z)` `E[D|X,Z]`
    <dbl> <dbl> <dbl>    <dbl>    <dbl>
1         5      1      1     0.25     0.5
2         5      1      0     0.25     0.5
3        10      0      1     0.25     0.5
4        10      0      0     0.25     0.5
```

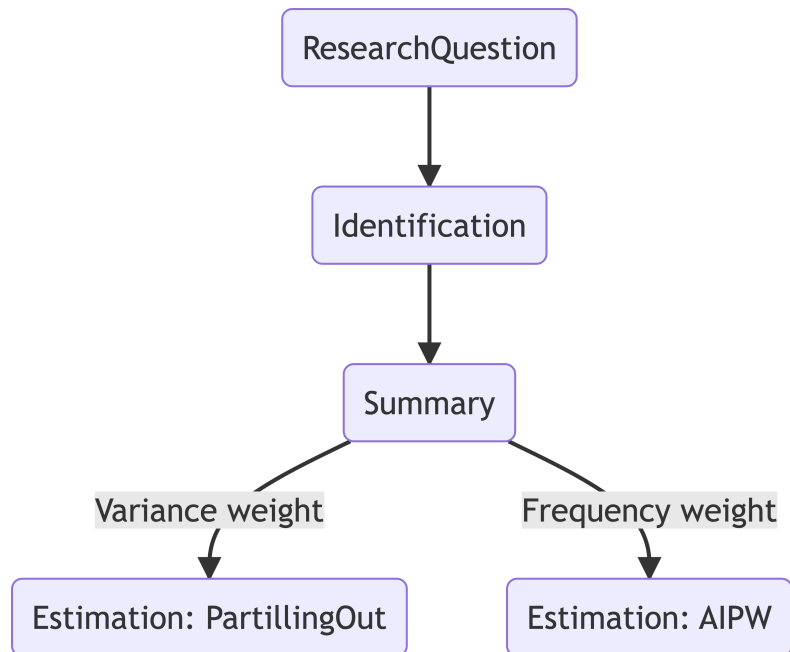
可能性 2

```
# A tibble: 4 x 5
  `Tau(X,Z)`      Z      X `f(X,Z)` `E[D|X,Z]`
    <dbl> <dbl> <dbl>    <dbl>    <dbl>
1        10      1      1     0.15     0.5
2         5      1      0     0.35     0.5
3        10      0      1     0.25     0.5
4         5      0      0     0.25     0.5
```

可能性 3

```
# A tibble: 4 x 5
  `Tau(X,Z)`      Z      X `f(X,Z)` `E[D|X,Z]`
    <dbl> <dbl> <dbl>    <dbl>    <dbl>
1        10      1      1     0.25     0.9
2         5      1      0     0.25     0.5
3        10      0      1     0.25     0.5
4         5      0      0     0.25     0.5
```

整理



Estimation

- frequency weight を用いた平均差推定について、いくつか (無数?) の方法が考えられる
- (本講義における) 非推奨: (Naive) Plugin, Inverse **P**ropensity **W**eight (IPW)
- 推定: **A**ugmented Inverse **P**robability **W**eighted (AIPW)

Plugin

1. $E[Y|D = d, X] = g_{Y(d)}(X)$ を教師付き学習などを用いて推定
2. S_i^{Plugin} の母平均を推定、ただし

$$S_i^{Plugin} = g_{Y(1)}(X_i) - g_{Y(0)}(X_i)$$

- $g_{Y(d)}$ の推定誤差に敏感: 一般に \sqrt{N} CAN estimator にならない

IPW

1. $E[D|X] = g_D(X)$ を教師付き学習などを用いて推定

2. S_i^{IPW} の母平均を推定、ただし

$$S_i^{IPW} = \frac{D_i Y_i}{g_D(X_i)} - \frac{(1 - D_i) Y_i}{1 - g_D(X_i)}$$

- g_D の推定誤差に敏感: 一般に \sqrt{N} CAN estimator にならない

AIPW

1. $E[Y|D = d, X] = g_{Y(d)}(X), E[D|X] = g_D(X)$ を教師付き学習などを用いて推定
2. S_i^{AIPW} の母平均を推定、ただし

$$S_i^{AIPW} = S_i^{Plugin}$$

$$+ \frac{D_i(Y_i - g_{Y(1)}(X_i))}{g_D(X_i)} - \frac{(1 - D_i)(Y_i - g_{Y(0)}(X_i))}{1 - g_D(X_i)}$$

AIPW の性質

- Partialling out と本質的に同じ性質
 - $g_{Y(d)}, g_D$ が少なくとも $n^{-1/4}$ よりも早い速度で $E_P[Y|D, X], E_P[D|X]$ に収束するのであれば、推定値は \sqrt{N} CAN estimator になる
 - 注意: 一致推定量であることは大前提
- 理由も同じ
 - Oracle 推定量に \sqrt{N} 以上の速度で収束する
 - 推定誤差同士の掛け算になるため

Overlap 問題

- 因果推論/比較研究における重要な **Identification の仮定**
 - Sumamry/Estimation においても厳重な注意が必要
- 注意が払われていない応用研究も散見される

Overlap の仮定: Identification

- すべての x について、 $1 > E_P[D|X = x] > 0$
 - 満たされないと、原理的に比較できない (母集団において存在しない) グループが存在
 - Well-specified model であれば、外挿によって”可能”になる (後述)

Overlap の重要性: Estimation


- $1 > E_P[D|X = x] > 0$ が成り立っていたとしても、 $E_P[D|X = x] \simeq 0$ または 1 であれば識別できても、推定困難
- AIPW の推定量も、漸近的に Oracle 推定量と同じ挙動をする
 - Oracle 推定量の性質が悪いと、実際の統計量も性質が悪くなる

Oracle 推定への影響

$$S_i^{AIPW} = g_{Y(1)}^P(X_i) - g_{Y(0)}^P(X_i) + \underbrace{\frac{D_i(Y_i - g_{Y(1)}^P(X_i))}{g_D^P(X_i)} - \frac{(1 - D_i)(Y_i - g_{Y(1)}^P(X_i))}{1 - g_D^P(X_i)}}_{\text{"不安定"}}$$

- g^P : 母平均
- g_D^P が 0 に近いグループがいれば、実質的にそのグループの実現値が推定値を決める
 - S_i^{AIPW} の母分散が爆発

数値例



まとめ

- $E_P[D_i|X=x]$ が 0 ないし 1 になるグループがあれば、“識別できない”
- ゼロに近いグループがいれば、**推定困難**
 - frequency weight を用いた summary は、“実装困難”

注意: Overlap 問題の普遍性

- かつての実証研究ではしばしば、Overlap 問題に大きな関心が払われなかった
 - 計算上は、推定誤差の爆発が起きない (ただし解釈困難な) 方法で推定してきた
 - 教科書はしばしば well specified model を前提としてきた

注意: Overlap 問題の普遍性

- Partialling out であれば、Overlap に問題があっても、推定値の”信頼区間”は爆発しない
 - Overlap の問題を抱えているサブグループを”無視している”だけ

- 直感的な解釈からの乖離拡大
- 理想的な実験データであれば、Overlap 問題は生じない
- Well-specified model があれば、外挿によって解決できる
 - “東京とそれ以外で賃金格差が変わらない” のを知っているの、overlap の問題が生じないサブグループで推定すれば良い

対応

Research question の修正

- 原理的に比較できないサブグループ $E[D|X] = 0, 1$ は、分析対象から外す
 - 直接比較を行う” 実証研究” としては不適切
 - 他のアプローチ (理論?) で頑張る

Moving goal posts

- 識別可能かつ推定可能な Estimand に目標変更する
 - Summary を変える
- 有名なものとして
 - Propensity score weight
 - Trimming
 - Variance weight (既習)

Variance weight

- Variance weight であれば、推定困難なサブグループへの Weight が自動的に下がる
- Overlap が微妙でも、推定値は” 安定的” だが、
 - Overlap の度合いは、Estimand の解釈に決定的に重要
 - Variance が少ないグループは、勝手に無視されている

Propensity score weight

- $\omega_P(X) = E_P[D|X] \times f_P(X)$ ないし $= (1 - E_P[D|X]) \times f_P(X)$

- $D = 1$ (あるいは $D = 0$) の比率が大きいサブグループを重点評価
 - Variance よりは解釈しやすい？
- ある種の Overlap 問題を解消する

グループサイズの不均衡への対応

- しばしば 特定の $D = d$ の人数が極めて少ない場合がある
 - 金銭的制約等により、東大生の 5% のみを強制的に留学させる実験
 - $E_P[D|X] \sim 0$ が発生しがち
- $E_P[D|X]$ を Weight として使用すれば、そのようなグループは無視される

ATET

- 因果推論の文脈で、Propensity score weight は、Average treatment effect in treated (ないし controlled) と呼ばれる
 - 解釈も比較的容易
 - 識別の家庭のもとで、介入を受けたグループ ($D = 1$) 内での平均効果
 - * ないし、受けなかったグループ内での平均効果

まとめ

- AIPW はカテゴリカルな D についての、“Default standard”
 - [DoubleML vignett](#)
 - ただし overlap は深刻な問題
- 他にも選択肢
 - overlap weight (Crump et al. 2006)
 - TMLE (Van Der Laan and Rubin 2006)
 - “soft intervention” (Kennedy 2019)
- 推定の容易さ VS 解釈
 - 盛んに研究されている

Reference

- Crump, Richard K, V Joseph Hotz, Guido Imbens, and Oscar Mitnik. 2006. “Moving the Goalposts: Addressing Limited Overlap in the Estimation of Average Treatment Effects by Changing the Estimand.” National Bureau of Economic Research Cambridge, Mass., USA.
- Kennedy, Edward H. 2019. “Nonparametric Causal Effects Based on Incremental Propensity Score Interventions.” *Journal of the American Statistical Association* 114 (526): 645–56.
- Robins, James M., and Andrea Rotnitzky. 1995. “Semiparametric Efficiency in Multivariate Regression Models with Missing Data.” *Journal of the American Statistical Association* 90 (429): 122129. <https://doi.org/10.1080/01621459.1995.10476494>.
- Van Der Laan, Mark J, and Daniel Rubin. 2006. “Targeted Maximum Likelihood Learning.” *The International Journal of Biostatistics* 2 (1).