

# 平均差の NonParametric 推定

異質性分析

川田恵介

## Table of contents

Nonparametric 推定	2
条件付き平均差の近似モデル	2
応用: 個人因果効果の予測	2
因果効果の予測	2
分解	2
分解: BLP	3
分解: ここからの手法	3
S/D Learner (Künzel et al. 2019)	3
数値例	4
数値例: バランス ( $a = 0.5$ )	4
数値例: アンバランス ( $a = 0.1$ )	5
Regulization bias	5
R-learner (Nie and Wager 2021)	5
R-learner (Nie and Wager 2021)	6
Causal Forest	6
DR-learner (Kennedy 2020)	6
数値例: バランス ( $a = 0.5$ )	7
数値例: アンバランス ( $a = 0.1$ )	7
推定誤差	8
補論: 予測性能	8
まとめ	8
Reference	8

## Nonparametric 推定

### 条件付き平均差の近似モデル

- Estimand:

$$\tau_P(X) = E_P[Y|D = 1, X] - E_P[Y|D = 0, X]$$

—

$$\tau_P(X) \sim g_\tau(X)$$

を推定

- 近似性質は”大目にみる”

### 応用: 個人因果効果の予測

- 潜在結果の枠組み (Imbens 2022) を用いると、個人因果効果を定義できる
  - $D = 0$  の世界線における結果  $Y_i(0)$  と  $D = 1$  の結果  $Y_i(1)$  の差  $\tau_i = Y_i(1) - Y_i(0)$
- 異なる世界線は原理的に観察不可能なので、 $\tau_i$  を推定することは”不可能”
  - 因果推論の根本問題

### 因果効果の予測

- 因果効果の予測であれば、通常の枠組みに収められる
- 

$$E_P[(\tau_i - g_\tau(X_i))^2]$$

を最小にする関数  $g_\tau$  を推定する

- 理想の予測モデル:

$$g_\tau(X_i) = E_P[\tau_i|X_i]$$

### 分解

$$\tau_i - g_\tau(X_i)$$

$$= \underbrace{\tau_i - E_P[\tau|X]}_{IrreducibleError}$$

$$+ \underbrace{E_P[\tau|X] - g_{\tau,\infty}(X)}_{ApproximationError}$$

$$+ \underbrace{g_{\tau,\infty}(X) - g_\tau(X)}_{EstimationError}$$

分解: BLP

$$\tau_i - g_\tau(X_i)$$

$$= \underbrace{\tau_i - E_P[\tau|X]}_{IrreducibleError}$$

$$+ \underbrace{E_P[\tau|X] - g_{\tau,\infty}(X)}_{ApproximationError \neq 0}$$

$$+ \underbrace{g_{\tau,\infty}(X) - g_\tau(X)}_{EstimationError \sim \mathbb{N}}$$

分解: ここからの手法

$$\tau_i - g_\tau(X_i)$$

$$= \underbrace{\tau_i - E_P[\tau|X]}_{IrreducibleError}$$

$$+ \underbrace{E_P[\tau|X] - g_{\tau,\infty}(X)}_{ApproximationError \rightarrow 0}$$

$$+ \underbrace{g_{\tau,\infty}(X) - g_\tau(X)}_{EstimationError \sim ?}$$

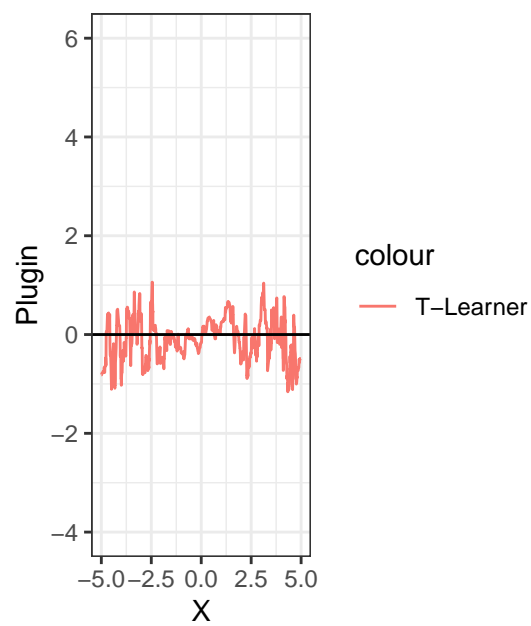

S/D Learner (Künzel et al. 2019)

1. S-Learner:  $E[Y|D, X] \sim g_Y(D, X)$  を教師付き学習で推定, D-Learner:  $E[Y|1, X] \sim g_{Y(1)}(X), E[Y|0, X] \sim g_{Y(0)}(X)$
2. S-Learner:  $g_\tau(X) = g_Y(1, X) - g_Y(0, X)$ , D-Learner:  $g_\tau(X) = g_{Y(1)}(X) - g_{Y(0)}(X)$

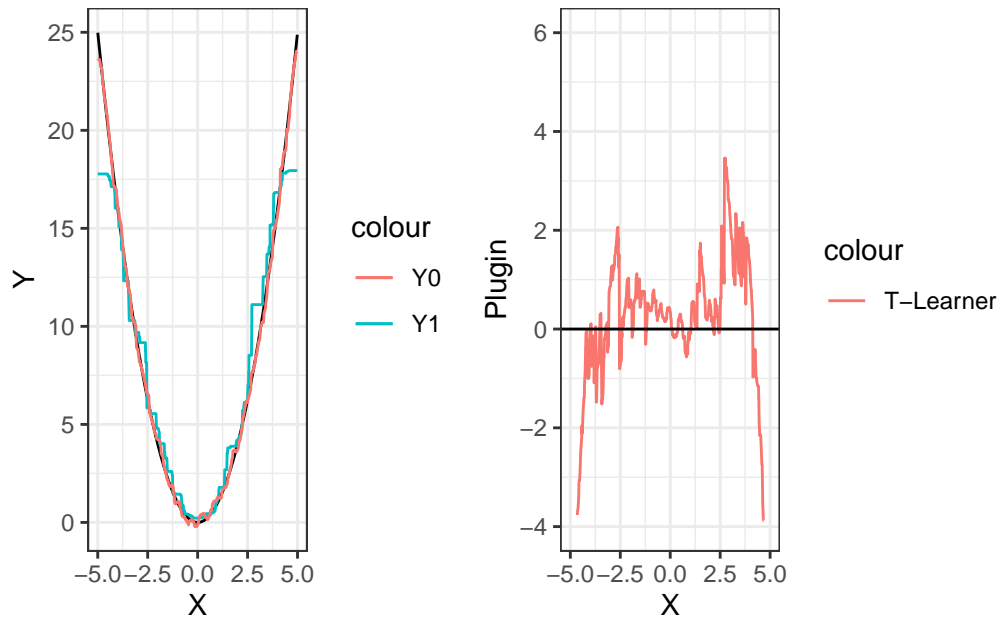
## 数値例

- $E[Y|D = 1, X] = E[Y|D = 0, X] = X^2$ 
  - 差なし
- $\Pr[D = 1] = a$
- サンプルサイズは 1000

### 数値例: バランス ( $a = 0.5$ )



数値例: アンバランス ( $a = 0.1$ )



## Regulization bias

- 教師付き学習は、“適切に単純化する”はずだが、過剰に複雑化させている
  - $D$  の分布が偏っているケースにおいて、非常に深刻
- 問題点: 最適化問題の設定ミス
  - $\min E_P[(\tau_i - g_\tau)^2]$  ではなく、 $\min E_P[(Y_i - g_\tau)^2 | D_i = d]$  を目指して単純化が行われる
  - $a = 0.1$  のケースでは、 $g_{Y(1)}(X)$  に対して入念な単純化が行われてしまう

## R-learner (Nie and Wager 2021)

- Partialling Out の一般化: Robinson Learner

$$\tau_P(X) \in \arg \min E_P[(Y - E_P[Y|X] - \tau_P(X) \times [D - E_P[D|X]])^2]$$

- PartialingOut した  $Y$  と  $D$  について、母集団における誤差を最小化するように  $\tau_P(X)$  を定義
  - 最も母集団に適合する  $\tau_P(X)$  関数を推定

## R-learner (Nie and Wager 2021)

1.  $g_Y(X) \sim E_P[Y|X], g_D(X) \sim E_P[D|X]$  を交差推定
  2.  $E_P[(Y - g_Y(X) - \tau(X) \times [D - f_D(X)])^2]$  を近似的に最小化するよう  $\tau$  を推定
- 2段階目にも、教師付き学習も活用可能
    - 前回は OLS

## Causal Forest

- 2段階目を RandomForest で実装

- 

$$E[(Y - g_Y(X) - \tau(X) \times [D - f_D(X)])^2]$$

- 

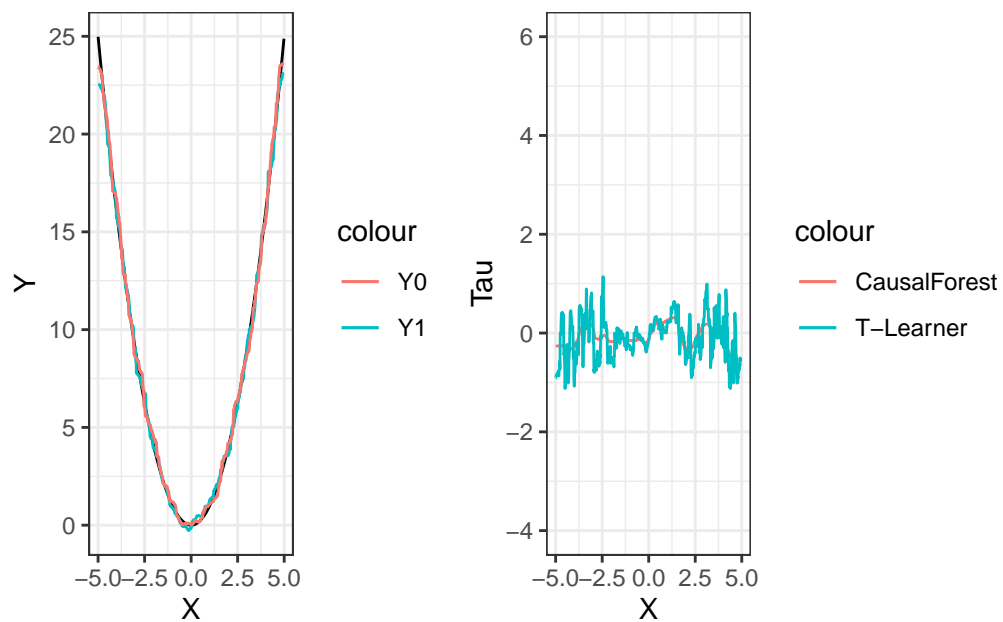
$$= E\left[\underbrace{(D - f_D(X))^2}_{Weight} \times \left(\underbrace{\frac{Y - g_Y(X)}{D - g_D(X)}}_{Outcome} - \tau(X)\right)^2\right]$$

- 様々な工夫: Athey, Tibshirani, and Wager (2019), Wager and Athey (2018)


## DR-learner (Kennedy 2020)

- AIPW の一般化
1.  $g_{Y(d)}(X) \sim E_P[Y|d, X], g_D(X) \sim E_P[D|X]$  を交差推定
  2.  $E_P[m_{AIPW}|X] \sim \tau(X)$  を推定
- 2段階目にも、教師付き学習も活用可能
    - 前回は平均

数値例: バランス ( $a = 0.5$ )



数値例: アンバランス ( $a = 0.1$ )



## 推定誤差

- 教師付き学習と同様に、一般に推定誤差 (母平均との乖離リスク) を推定することは困難
- HonestTree (Athey and Imbens 2016) をベースにした Random Forest は例外的に可能
  - ただし  $X$  の数は少ない必要がある
  - (川田の経験上)、信頼区間がかなり大きくなる
- (後日) 平均差の予測モデルを Nuisance 関数として活用

## 補論: 予測性能

- 予測モデル性能をどのように評価
- 

$$E_P[(\underbrace{\tau_i}_{\text{観察不可能}} - g_\tau(X_i))^2]$$

は推定可能?

- 標準的な予測問題では、 $\tau_i = Y_i$  なので、サンプル分割を行えば OK
- 色々な提案
  - Rank Average Treatment Effect (Yadlowsky et al. 2021) は grf に実装済み

## まとめ

- 非常に Hot(だった?) 研究課題であり、多くのアイデアが提案
- ここでは PartiallingOut, AIPW の拡張である R/DR Learner を紹介
  - Morzywolek, Decruyenaere, and Vansteelandt (2023) で統合的に理解できる枠組みを提案

## Reference

- Athey, Susan, and Guido Imbens. 2016. “Recursive Partitioning for Heterogeneous Causal Effects.” *Proceedings of the National Academy of Sciences* 113 (27): 7353–60.
- Athey, Susan, Julie Tibshirani, and Stefan Wager. 2019. “Generalized Random Forest.” *The Annals of Statistics* 47 (2): 1148–78.
- Imbens, Guido W. 2022. “Causality in Econometrics: Choice Vs Chance.” *Econometrica* 90 (6): 2541–66.
- Kennedy, Edward H. 2020. “Towards Optimal Doubly Robust Estimation of Heterogeneous Causal Effects.” *arXiv Preprint arXiv:2004.14497*.



- Künzel, Sören R, Jasjeet S Sekhon, Peter J Bickel, and Bin Yu. 2019. “Metalearners for Estimating Heterogeneous Treatment Effects Using Machine Learning.” *Proceedings of the National Academy of Sciences* 116 (10): 4156–65.
- Morzywolek, Pawel, Johan Decruyenaere, and Stijn Vansteelandt. 2023. “On a General Class of Orthogonal Learners for the Estimation of Heterogeneous Treatment Effects.” *arXiv Preprint arXiv:2303.12687*.
- Nie, Xinkun, and Stefan Wager. 2021. “Quasi-Oracle Estimation of Heterogeneous Treatment Effects.” *Biometrika* 108 (2): 299–319.
- Wager, Stefan, and Susan Athey. 2018. “Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests.” *Journal of the American Statistical Association* 113 (523): 1228–42.
- Yadlowsky, Steve, Scott D. Fleming, Nigam Haresh Shah, Emma Brunskill, and Stefan Wager. 2021. “Evaluating Treatment Prioritization Rules via Rank-Weighted Average Treatment Effects.” In.