

SemiParametric 推定

異質性分析

川田恵介

Table of contents

Semiparametric 推定への応用	1
「異質性を調べよ」	1
ここまでの手法	2
Treatment effect risk	2
Get Start	2
性質	3
実例	3
実例	4
Neyman の直行条件	4
Estimand の一般的定義	4
Estimand の一般的定義	4
仮定の区分	4
Parametric Assumption の有無	5
練習問題	5
モーメント法: 単純なケース	5
モーメント法: 複雑なケース	5
Neyman's orthogonality condition	5
まとめ	6
Reference	6

Semiparametric 推定への応用

「異質性を調べよ」

- 具体的には？
 - $\tau_P(X)$ に特に大きな影響を与える X を知りたい

* BLP の活用

– $\tau_P(X)$ がどの程度異なるのか知りたい

* ?

ここまでの手法

- 条件付き平均差 $\tau^P(X)$ を
 - BLP で近似: 定式化依存し、ApproximationError が大きい可能性
 - NonParametric に近似: 信頼区間計算に不安, Too much な推定かも

Treatment effect risk

- Kallus (2022) により提案

•

$$E_P[\tau_P(X) | \tau_P(X) \leq Q_P(q)]$$

–

$$Q_P(q) =$$

qth quantile of $\tau_P(X)$

– $\tau_P(X)$ のモデル $g_\tau(X)$ を Nuisance として活用する

- CHERNOZHUKOV et al. (2022) と類似したアイデア
 - Estimand が完全に母集団上で定義できており、解釈がより明確

Get Start

1. データを 3 分割 (交差推定可能)
2. $g_y(D, X), g_D(X)$ を (教師付き学習などで) 推定
3. $m^{AIPW} \sim g_\tau(X)$ を (教師付き学習などで) 推定
4. $E[m_i^{Risk}]$ を推定

•

$$m_a^{Risk} = Q_P(q)$$


•

$$+ \frac{I(g_\tau(X) \leq Q_P(q))}{a} [m^{AIPW} - Q_P(q)]$$


性質

- **Neyman の直行条件**を満たすので、 g が $n^{-1/4}$ 以上の速度で収束するのであれば、 g の推定誤差は漸近分布を計算する際に無視できる
- 信頼区間が形成可能

実例



実例



Neyman の直行条件

Estimand の一般的定義

- 研究課題 -> 識別 -> 要約から、Estimand θ を定義する分布 *Distribution* の関数 T を定義

-

$$T(\text{Distribution}) = \theta$$

- 例: $\theta = \text{平均}$

-

$$T(\text{Distribution}) = \int Y \times f(Y) \times dY$$

Estimand の一般的定義

- ポイント: $T = \text{データ/母集団分布、どちらについても定義できる”記述統計量”}$

仮定の区分

- 推定には、Distribution/Estimand 双方について、“仮定”(定式化) が必要

- Parametric Assumption (有限個のパラメタで記述できるとするかどうか) の有無で区分できる
 - ポイント: Distribution/Estimand への仮定をしっかり区別

Parametric Assumption の有無

Estimand/Distribution	有	無
有	教科書的な構造推定	セミパラメトリック
無	古典的な予測研究?	教師付き学習による予測研究

練習問題

- 母平均をサンプル平均で推定
- OLS

モーメント法: 単純なケース

- セミパラメトリック推定の代表的な方法
- 母集団上で Estimand を定義する式を設定
-

$$E_P[m(\theta_P, Y, D, X)] = 0$$

- 設定可能であることは**仮定**
- 例: 母平均 $m = Y - \theta$

モーメント法: 複雑なケース

-
- $E_P[m(\theta_P, Y, D, X, g)] = 0$
- g Nuisance 関数
 - $E_P[Y|X], E_P[D|X], E_P[\tau|X]$ の Nonparametric な推定値

Neyman's orthogonality condition

-
- $$\partial E_P[m(\theta, Y, D, X, g)] / \partial g|_{g=E_P} = 0$$

- E_P : “真” の関数
- 注: 関数微分
- g が真の値から微妙にずれていたとしても、 m は影響をほとんど受けない
 - m^{Risk} は満たす
- 漸近性質が、 $E[m(\theta, Y, D, X, E_P)]$ と等しくなる

まとめ

- Neyman の直行条件を満たすように設定することは、幅広い Estimand について可能
 - 緩い条件のもとで、Nuisance 関数の推定誤差を”無視”できる
- 応用例は幅広い
 - 操作変数方 (Chernozhukov, Hansen, and Spindler 2015)、差の差の推定 (Chang 2020) や、Mediation 分析 (Farbmacher et al. 2022; Díaz et al. 2021), Sensitivity 分析 (Chernozhukov et al. 2022)

Reference

- Chang, Neng-Chieh. 2020. “Double/Debiased Machine Learning for Difference-in-Differences Models.” *The Econometrics Journal*.
- Chernozhukov, Victor, Carlos Cinelli, Whitney Newey, Amit Sharma, and Vasilis Syrgkanis. 2022. “Long Story Short: Omitted Variable Bias in Causal Machine Learning.” National Bureau of Economic Research.
- CHERNOZHUKOV, VICTOR, MERT DEMIRER, ESTHER DUFLO, and IVAN FERNANDEZ-VAL. 2022. “Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments, with an Application to Immunization in India.”
- Chernozhukov, Victor, Christian Hansen, and Martin Spindler. 2015. “Valid Post-Selection and Post-Regularization Inference: An Elementary, General Approach.” *Annu. Rev. Econ.* 7 (1): 649–88.
- Díaz, Iván, Nima S Hejazi, Kara E Rudolph, and Mark J van Der Laan. 2021. “Nonparametric Efficient Causal Mediation with Intermediate Confounders.” *Biometrika* 108 (3): 627–41.
- Farbmacher, Helmut, Martin Huber, Lukáš Laffers, Henrika Langen, and Martin Spindler. 2022. “Causal Mediation Analysis with Double Machine Learning.” *The Econometrics Journal* 25 (2): 277–300.
- Kallus, Nathan. 2022. “Treatment Effect Risk: Bounds and Inference.” *2022 ACM Conference on Fairness, Accountability, and Transparency (Minor Revision in Management Science)*.